

SNN在线与本地学习算法未来方向思考内容

摘要

脉冲神经网络（Spiking Neural Network, SNN）凭借其事件驱动、稀疏脉冲通信和生物可解释性，被认为是实现低功耗边缘智能的重要候选模型。然而，传统的训练算法，尤其是基于时间的反向传播（BPTT），因需展开整个时间计算图并存储所有时刻的状态，内存和计算开销随时间步数线性增长，难以在资源受限设备上实现在线学习。为突破这一瓶颈，历史上的研究者们提出了多种在线学习算法，包括我们在这里提及的OTTT、NDOT、S-TLLR和TESS，分别从时序依赖近似、动态核重参数化、STDP启发式资格迹以及本地学习信号生成等角度，实现了与时间步数无关的常数存储复杂度，并在不同程度上降低了计算复杂度。

然而，这些算法仍面临若干根本性挑战：在线梯度究竟丢失了哪些信息、如何补偿梯度误差、如何设计更优的资格迹与学习信号、如何在生物合理性与高性能间取得平衡、如何在存储与计算复杂度间达到最优解、如何有效应对长期时间依赖、如何与神经形态硬件协同设计、以及如何无缝融合持续学习能力。我们的研究方向主要是：首先系统梳理这四种算法的核心思想、数学形式与复杂度特性，然后从多个维度提炼关键研究问题，结合已有算法的技术特点，提出详细的推进方案，旨在为SNN在线学习的后续研究提供系统性的路线图与理论指导。

文章汇总

RTRL: A learning algorithm for continually running fully recurrent neural networks [1];

E-prop: A solution to the learning dilemma for recurrent networks of spiking neurons [2];

OTTT: Online Training Through Time for Spiking Neural Networks [3];

NDOT: NDOT: Neuronal Dynamics-based Online Training for Spiking Neural Networks [4];

S-TLLR: S-TLLR: STDP-inspired Temporal Local Learning Rule for Spiking Neural Networks [5];

TESS: TESS: A Scalable Temporally and Spatially Local Learning Rule for Spiking Neural Networks [6]

I. 引言

A. SNN在线学习的背景与意义

脉冲神经网络（Spiking Neural Networks, SNNs）被誉为第三代神经网络，其神经元通过离散脉冲（spikes）进行通信，在神经形态硬件上具有极高的能效。然而，SNN的监督训练长期受困于脉冲发放函数不可微的问题。基于代理梯度的BPTT（Backpropagation Through Time）虽然通过时间展开实现了有效的梯度传播，但其存储和计算成本均与时间步数 T 成正比：

$$\text{Mem}_{\text{BPTT}} = O(TLn), \quad \text{MAC}_{\text{BPTT}} = O(TLn^2),$$

其中 L 为层数， n 为每层神经元数。这种对 T 的线性依赖使得BPTT无法满足在线学习和边缘部署的需求。

为突破这一瓶颈，近年的研究聚焦于设计“时间本地”或“时空本地”的学习规则。这些算法的核心目标可以概括为：在不保存完整时间历史的情况下，尽可能准确地近似BPTT的时空梯度，并使权重更新更加适合实时学习和硬件实现。

B. 四种代表性在线学习算法概述

a) (1) *OTTT (Online Training Through Time)* : OTTT的核心思想是丢弃BPTT时间连乘中的重置路径, 即令:

$$\frac{\partial u[i+1]}{\partial s[i]} \frac{\partial s[i]}{\partial u[i]} \approx 0,$$

仅保留泄漏路径 λ 。其梯度公式简化为:

$$\nabla_{\mathbf{w}^l} L = \sum_{t=1}^T \mathbf{g}_{\mathbf{u}^{l+1}}[t] \left(\sum_{\tau \leq t} \lambda^{t-\tau} \mathbf{s}^l[\tau] \right)^\top,$$

其中踪迹 $\hat{\mathbf{a}}^l[t] = \sum_{\tau \leq t} \lambda^{t-\tau} \mathbf{s}^l[\tau]$ 可通过递推 $\hat{\mathbf{a}}^l[t] = \lambda \hat{\mathbf{a}}^l[t-1] + \mathbf{s}^l[t]$ 前向计算。存储复杂度 $O(Ln)$, 时间复杂度 $O(Ln^2)$ 。

b) (2) *NDOT (Neuronal Dynamics-based Online Training)* : NDOT认为OTTT中固定的 λ 无法精确刻画神经元动态, 因此从连续LIF微分方程推导出动态时序核:

$$\mathbf{e}^l[t] = \frac{\mathbf{u}^l[t] - V_{th} \mathbf{s}^l[t]}{\mathbf{u}^l[t-1] - V_{th} \mathbf{s}^l[t-1]},$$

并用 $\mathbf{e}$ 替代固定 λ 构造前向递推:

$$\hat{\mathbf{a}}^l[t] = \mathbf{e}^l[t-1] \odot \hat{\mathbf{a}}^l[t-1] + \mathbf{s}^l[t].$$

存储复杂度仍为 $O(Ln)$ (额外存储分母项), 时间复杂度仍为 $O(Ln^2)$ 。

c) (3) *S-TLLR (STDP-inspired Temporal Local Learning Rule)* : S-TLLR受STDP启发, 定义广义资格迹:

$$e_{ij}[t] = \alpha_{pre} \Psi(u_i[t]) \sum_{t'=0}^t \lambda_{pre}^{t-t'} x_j[t'] + \alpha_{post} x_j[t] \sum_{t'=0}^{t-1} \lambda_{post}^{t-t'} \Psi(u_i[t']),$$

主要部分为因果项和非因果项的求和。通过引入踪迹变量 $\text{tr}(x_j)$ 和 $\text{tr}(\Psi(u_i))$, 可前向计算。学习信号 δ_i 由BP或DFA生成, 因此S-TLLR仅时间本地, 空间上仍依赖全局误差传播。存储复杂度 $O(Ln)$, 时间复杂度 $O(Ln^2)$ 。

d) (4) *TESS (Temporally and Spatially Local Learning Rule)* : TESS在S-TLLR的基础上, 将抽象踪迹 tr 实例化为显式张量 $\mathbf{q}$ (前突触踪迹) 和 $\mathbf{h}$ (后突触踪迹), 并引入本地学习信号生成 (LSG):

$$\mathbf{v}_m^{(l)}[t] = \mathbf{B}^{(l)\top} (f(\mathbf{B}^{(l)} \mathbf{o}^{(l)}[t]) - \mathbf{y}^*),$$

其中 $\mathbf{B}^{(l)}$ 为固定随机矩阵 (维度 $C \times n$, C 为类别数)。该信号完全在本层生成, 无需跨层传播。存储复杂度仍为 $O(Ln)$, 但时间复杂度降至 $O(LCn)$, 因为LSG将空间误差传播从 $O(n^2)$ 降为 $O(Cn)$ 。

II. 关键问题一：在线梯度究竟丢失了哪些信息？

A. 问题背景

目前几乎所有在线学习算法都会宣称自身是在对BPTT进行某种近似，然而绝大多数工作仅仅关注如何构造新的梯度表达式，却很少回答一个更加本质的问题：在线学习究竟丢失了哪些信息？

BPTT能够获得完整梯度，是因为它能够保存整个时间序列上的神经元状态，并利用未来时刻产生的误差信号对历史状态进行统一修正。因此，一个完整的梯度实际上包含了多个不同来源的信息：未来误差（Future Error）、未来状态依赖（Future State Dependency）、时间信用分配（Temporal Credit Assignment）、跨层误差传播（Spatial Dependency）以及网络整体优化目标（Global Objective）等多个组成部分。

B. 信息丢失的来源分析

在BPTT中，第 l 层第 t 时刻的梯度可以严格写为以下形式：

$$\frac{\partial L}{\partial \mathbf{W}^l} = \sum_{t=1}^T \frac{\partial L}{\partial \mathbf{s}^{l+1}[t]} \frac{\partial \mathbf{s}^{l+1}[t]}{\partial \mathbf{u}^{l+1}[t]} \left(\frac{\partial \mathbf{u}^{l+1}[t]}{\partial \mathbf{W}^l} + \sum_{\tau < t} \prod_{i=t-1}^{\tau} \left(\frac{\partial \mathbf{u}^{l+1}[i+1]}{\partial \mathbf{u}^{l+1}[i]} + \frac{\partial \mathbf{u}^{l+1}[i+1]}{\partial \mathbf{s}^{l+1}[i]} \frac{\partial \mathbf{s}^{l+1}[i]}{\partial \mathbf{u}^{l+1}[i]} \right) \frac{\partial \mathbf{u}^{l+1}[\tau]}{\partial \mathbf{W}^l} \right) \quad (1)$$

该公式揭示了完整梯度所包含的多个关键信息来源：

- 1) **当前时刻直接贡献**： $\frac{\partial \mathbf{u}^{l+1}[t]}{\partial \mathbf{W}^l}$ ，表示当前输入对权重的直接影响，即当前时刻的输入脉冲。
- 2) **时间依赖链**： $\prod_{i=t-1}^{\tau}$ (绿色 + 青色 × 红色)，其中绿色项表示膜电位的泄漏传播，青色项表示脉冲对膜电位的重置影响，红色项表示脉冲发放对膜电位的导数（需用代理梯度）。
- 3) **历史起点信息**： $\frac{\partial \mathbf{u}^{l+1}[\tau]}{\partial \mathbf{W}^l}$ ，表示历史时刻 τ 的膜电位对权重的直接偏导，即历史时刻的输入脉冲。
- 4) **未来误差**： $\frac{\partial L}{\partial \mathbf{s}^{l+1}[t]}$ ，表示来自输出层或高层反向传播的误差信号，它包含了整个未来序列的信息。

大多数在线学习算法都会主动舍弃其中的一部分信息。例如，OTTT通过忽略重置路径（青色×红色），因此丢失了重置耦合信息；E-prop利用Eligibility Trace替代完整时间展开，因此舍弃了完整未来误差传播；NDOT则进一步利用神经元动力学模型近似未来梯度；而TESS则通过时间窗口截断减少历史依赖。

C. 信息分解框架与推进方案

建议建立一个统一的信息分析框架（Information Decomposition Framework），将真实梯度拆分为多个组成部分，并分析不同算法究竟保留了哪些信息、舍弃了哪些信息。可以按照以下方式分解：

$$g_{\text{BPTT}} = g_{\text{current}} + g_{\text{leak}} + g_{\text{reset}} + g_{\text{future}}$$

其中：

- $g_{\text{current}} = \frac{\partial u[t]}{\partial W}$: 当前时刻直接贡献
- $g_{\text{leak}} = \sum_{\tau < t} \lambda^{t-\tau} \frac{\partial u[\tau]}{\partial W}$: 泄漏传播贡献
- $g_{\text{reset}} = \sum_{\tau < t} \prod(-\lambda V_{th} \sigma') \frac{\partial u[\tau]}{\partial W}$: 重置耦合贡献
- $g_{\text{future}} = \frac{\partial L}{\partial s[t']}$: 未来误差贡献

进一步地，可以构建一种Information Loss Taxonomy，对现有所有在线学习算法按照信息损失类型进行统一分类：

算法	保留当前信息	保留泄漏	保留重置	保留未来误差
BPTT	✓	✓	✓	✓
OTTT	✓	✓	×	✓
NDOT	✓	动态替代	动态替代	✓
S-TLLR	✓	tr	tr	✓ (BP/DFA)
TESS	✓	q	h	本地LSG

该方向的核心研究问题包括：

- 1) 不同类型的信息丢失分别对最终性能造成怎样的影响？
- 2) 在给定资源约束下，哪些信息是“必须保留”的，哪些是可以舍弃的？
- 3) 能否设计一种“信息重要性度量”，动态决定在资源紧张时应优先保留哪些信息？

III. 关键问题二：如何补偿在线梯度与真实梯度之间的误差？

A. 统一误差建模

几乎所有在线学习方法最终都可以写成如下统一形式：

$$g_{\text{online}} = g_{\text{true}} + \epsilon,$$

其中 g_{true} 表示BPTT产生的真实梯度，而 ϵ 表示由于在线近似所带来的梯度误差。不同算法产生误差的来源并不相同。具体而言：

- OTTT中的误差主要来源于Detach带来的梯度截断，即丢失了重置路径信息。
- E-prop中的误差主要来源于Learning Signal对真实误差信号的替代。
- NDOT中的误差来源于神经元动力学模型的近似，即用 $e[t]$ 替代 $\epsilon[t]$ 。
- S-TLLR中的误差来源于资格迹对真实时间依赖的近似以及学习信号的近似。
- TESS中的误差来源于时间截断和空间本地信号替代全局误差。

在NDOT中，时间依赖项从BPTT的离散 $\epsilon[t]$ 被替换为连续动力学导出的 $e[t]$ ，两者之间的误差为：

$$\Delta^l[t] = \epsilon^l[t] - e^l[t],$$

其中 $\epsilon^l[t] = \lambda - \lambda V_{th} \sigma'(u[t])$ ，而 $e^l[t] = \frac{u[t] - V_{th} s[t]}{u[t-1] - V_{th} s[t-1]}$ 。

B. 梯度误差的统计特性分析

可以分析梯度误差的统计特性。假设真实梯度服从分布 $g_{\text{true}} \sim \mathcal{N}(\mu_g, \Sigma_g)$ ，在线梯度误差 ϵ 可能表现出以下特性：

$$\mathbb{E}[\epsilon] = \mu_\epsilon, \quad \text{Cov}(\epsilon) = \Sigma_\epsilon, \quad \mathbb{E}[\|g_{\text{online}} - g_{\text{true}}\|^2] = \text{Tr}(\Sigma_\epsilon) + \|\mu_\epsilon\|^2.$$

理想情况下，我们希望 $\mathbb{E}[\epsilon] = 0$ 且 $\|\epsilon\|$ 尽可能小。

C. 推进方案

为了系统评估梯度误差补偿效果，建议构建验证体系：

- 1) **梯度级评估**：在小规模网络上，计算在线梯度与BPTT真实梯度的余弦相似度、相对误差和方向偏差，直接量化梯度质量。
- 2) **训练级评估**：在中等规模任务上，比较不同补偿方法对收敛速度、最终精度和训练稳定性的影响。
- 3) **推广级评估**：在多种不同类型的数据集上验证补偿方法的通用性和鲁棒性，分析补偿策略是否对特定任务过拟合。

该方向不仅具有较强的理论价值，也有望突破当前在线学习精度普遍低于BPTT的瓶颈。

IV. 关键问题三：如何设计同时具备“生物合理性”与“高性能”的本地学习规则？

A. 问题背景

生物神经系统依赖局部突触可塑性（如STDP、资格迹）进行学习，无需全局误差反向传播。然而，纯生物启发的方法在复杂任务上性能远不及梯度方法。当前在线学习算法在“生物合理性”与“任务性能”之间存在明显断层。

S-TLLR中非因果项系数 α_{post} 的最优取值（-1、0、+1）在不同任务上表现迥异：

数据集	$\alpha_{\text{post}} = 0$	$\alpha_{\text{post}} = +1$	$\alpha_{\text{post}} = -1$
DVS Gesture	94.61%	94.01%	95.07%
DVS CIFAR10	72.93%	73.42%	73.93%
SHD	77.09%	78.23%	74.69%

- 空间主导任务（DVS CIFAR10、DVS Gesture）： $\alpha_{\text{post}} = -1$ 最优（因果性占主导）。
- 时间主导任务（SHD）： $\alpha_{\text{post}} = +1$ 最优（同步性占主导）。

B. 核心研究问题

- 1) 能否建立统一框架，将OTTT/NDOT与S-TLLR/TESS纳入同一数学形式？
- 2) α_{post} 的最优取值是否与任务的时间结构（事件密度、脉冲稀疏度）存在确定性关联？
- 3) 能否优化 **B** 矩阵以提升TESS的性能，同时保持本地性？
- 4) 代理梯度 σ' 能否被设计为更具生物合理性的形式？

C. 推进方案

a) 统一框架构建:

b) $\mathbf{B}$ 矩阵的优化:

- 使用无监督预训练（如PCA）提取主成分作为 $\mathbf{B}$ 初始值。
- 使用准正交确定性序列（如Hadamard矩阵）替代随机矩阵。
- 设计可学习的低秩矩阵 $\mathbf{B} = \mathbf{UV}^\top$ 。

c) 更具生物合理性的代理梯度设计: 传统代理梯度 $\sigma'(x)$ 可被设计为类STDP的时间依赖形式:

$$\sigma'(u[t], u[t-1], s[t-1]) = f(u[t] - V_{th}, \Delta t, s[t-1]),$$

使得代理梯度不仅依赖当前膜电位, 还依赖脉冲发放历史。这将使学习规则更接近真实的生物突触可塑性。

V. 关键问题四: ELIGIBILITY TRACE是否存在新的定义方式?

A. 传统定义的局限

目前, 大多数Eligibility Trace都采用统一形式:

$$e_t = \frac{\partial s_t}{\partial W},$$

即利用神经元状态对权重的偏导数描述历史影响。这种定义方式存在三个主要局限:

- 1) **存储与计算代价:** 每个突触需要独立的 e_{ij} , 导致 $O(n^2)$ 的存储和计算成本（虽然通过踪迹分解可降至 $O(n)$, 但表达能力受限）。
- 2) **单一时间尺度:** 传统资格迹仅支持单一的指数衰减时间尺度, 难以捕捉多尺度时序依赖。
- 3) **局限于神经元级表示:** 资格迹仅追踪单个神经元的脉冲历史, 无法捕获更抽象的时序模式（如神经群体同步、时空脉冲模式）。

B. 推进方案

a) (1) 多尺度踪迹设计: 设计多个不同衰减率的踪迹 $(\lambda_1, \lambda_2, \dots, \lambda_K)$, 分别对应短、中、长时间尺度:

$$\hat{a}^{(k)}[t] = \lambda_k \hat{a}^{(k)}[t-1] + s[t], \quad k = 1, \dots, K$$

最终资格迹为多尺度踪迹的加权组合:

$$\hat{a}[t] = \sum_{k=1}^K w_k \hat{a}^{(k)}[t], \quad w_k \text{ 可通过学习获得.}$$

b) (2) 层级化资格迹:

- **神经元级:** 传统 e_{ij} , 追踪单个突触历史。
- **层级别:** $\mathbf{E}^l[t] = \sum_{\tau \leq t} \lambda^{t-\tau} \mathbf{s}^l[\tau] \otimes \mathbf{s}^{l-1}[\tau]$, 追踪层间活动模式。
- **网络级:** $\mathbf{E}^{\text{net}}[t] = \sum_{\tau \leq t} \lambda^{t-\tau} \mathbf{s}^{\text{all}}[\tau]$, 追踪整体网络状态。

c) (3) 注意力式踪迹: 借鉴Transformer, 用可学习的查询-键-值机制动态选择历史关键时刻:

$$\text{Attention}(t, \tau) = \text{softmax} \left(\frac{\mathbf{q}(t)^\top \mathbf{k}(\tau)}{\sqrt{d}} \right),$$

$$\hat{a}[t] = \sum_{\tau \leq t} \text{Attention}(t, \tau) \cdot s[\tau].$$

d) (4) 基于信息理论的踪迹设计: 从信息论角度设计最优踪迹, 最大化历史信息保留同时最小化存储代价:

$$\text{maximize } I(\hat{a}[t]; \{s[\tau]\}_{\tau \leq t}), \quad \text{s.t. } \dim(\hat{a}) \leq K.$$

VI. 关键问题五: LEARNING SIGNAL应该如何设计?

A. 问题背景

E-prop提出之后, Learning Signal逐渐成为在线学习研究的重要组成部分。目前, 大多数Learning Signal主要来源于:

- 全局误差 (Global Error)—— 来自输出层的反向传播
- 局部分类器 (Local Classifier)—— 每层独立分类
- 随机投影 (Random Projection)—— DFA/DRTP风格
- 教师信号 (Teacher Signal)—— 蒸馏/知识迁移
- Synthetic Gradient—— 用网络预测梯度

然而, 目前尚不存在一种统一的方法能够说明什么样的Learning Signal才是最优的。理想的Learning Signal应当同时满足:

- 1) 信息丰富, 能够有效引导权重更新
- 2) 通信开销低, 适合硬件实现
- 3) 能够在线生成, 不依赖未来信息
- 4) 训练稳定性好, 收敛快
- 5) 适合神经形态硬件实现

B. 推进方案

a) (1) 动态误差调制: 引入注意力机制动态调节误差信号:

$$\delta_i^{(l)}[t] = \alpha_i^{(l)}[t] \cdot \frac{\partial L}{\partial y_i^{(l)}[t]},$$

其中 $\alpha_i^{(l)}[t]$ 可由该神经元当前活动或置信度决定。

b) (2) 预测性学习信号: 利用预测网络生成未来误差估计:

$$\delta_{\text{pred}}[t] = \mathcal{P}(u[t], s[t], \theta_{\text{pred}}),$$

使权重更新不仅考虑当前误差, 还考虑未来可能的修正方向。

c) (3) 自监督学习信号: 利用自监督学习构建局部训练目标, 使每层获得独立的监督信号, 无需全局标签信息。

d) (4) 教师-学生蒸馏信号: 使用教师-学生网络框架产生更稳定的局部监督信息, 教师网络可以是预训练的BPTT模型或EMA模型。

VII. 关键问题六: STBP 能否与空间本地化结合?

A. 问题背景

STBP (Spatio-Temporal Backpropagation) 是目前训练深度SNN最成功的方法之一, 它同时沿时间域 (BPTT) 和空间域 (层间BP) 传播误差。然而, STBP的两个维度都依赖全局信息: 时间域需要保存全部历史状态, 空间域需要逐层反向传播误差。OTTT、NDOT等算法已经解决了时间域的本地化问题 (通过踪迹机制), 但空间域仍然依赖全局误差信号。因此, 一个自然的问题是: 能否在保留STBP时间建模能力的同时, 实现空间域的本地化?

目前, S-TLLR和TESS已经在这一方向上进行了初步探索, 但尚未与STBP形成系统的融合框架。核心挑战在于: 空间本地化 (如LSG、DFA、本地损失) 引入的梯度近似误差, 是否会破坏STBP在时间维度上的精确信用分配?

B. 推进方案

a) (1) LSG-STBP: 用本地学习信号替代空间误差传播: 将TESS的LSG机制嵌入STBP框架, 用本地生成的学习信号 $\mathbf{v}_m^{(l)}[t]$ 替代全局反传的 $\delta^{(l)}[t]$ 。时间维度仍保持STBP的展开方式, 空间维度实现本地化。关键研究问题包括: LSG与真实BP梯度的误差上界是什么? 这种近似在深层网络中是否仍然有效?

b) (2) DFA-STBP: 直接反馈对齐与时间展开的结合: 用DFA的固定随机投影替代STBP中的逐层误差反传, 使每一层直接从输出层接收误差信号。该方法已在S-TLLR中作为备选方案出现, 但尚未与完整的时间展开框架系统结合。需要研究DFA引入的梯度噪声对时间信用分配的影响。

c) (3) 本地损失-STBP: 逐层独立训练目标: 为每一层引入本地损失函数 $L^{(l)}[t] = \ell(\mathbf{h}^{(l)}[t], \mathbf{y})$, 使每层根据自身输出计算误差信号, 完全消除空间依赖。该方法在概念上最为“本地”, 但需要解决本地分类器的设计、层间梯度不匹配以及深层网络中本地损失的有效性下降等问题。

d) (4) 分层混合架构: 根据网络深度采用不同的本地化策略: 浅层使用完全本地学习 (TESS风格), 深层保留部分全局误差传播 (STBP风格), 中间层采用DFA作为折中。这种架构需要在精度和效率之间寻找最优的“本地化曲线”。

e) (5) 理论分析: 时间-空间耦合的解耦条件: STBP中时间域和空间域的误差传播通过 $\frac{\partial L}{\partial \mathbf{s}^{l+1}[t]}$ 耦合。当空间域被本地化后, 时间域的信用分配是否会受到影响? 需要从理论上分析这种耦合的可解耦条件, 明确在什么情况下时间域可以独立于空间域进行精确计算。

f) (6) 硬件部署验证: 在FPGA或神经形态芯片上实现上述混合方案, 量化通信开销、存储占用和计算延迟的实际收益。关键指标包括: 层间通信带宽减少比例、片上存储节省、以及每时间步的延迟降低。

VIII. 推进方向1: DOT 的数学本质与在线学习中的信息损失问题 (草稿)

A. 本部分内容概览

- NDOT 与 BPTT 的本质区别: NDOT 是否真的“避免”了代理梯度?

- **NDOT** 未成主流的原因：数学约束、数值不稳定性与适用范围的限制
- 在线学习中的信息损失：如何定义、度量与可视化梯度信息的保留与丢失
- 基于单层网络的研究方案：从最简单结构入手，建立理论分析框架

B. *NDOT* 与 *BPTT* 的本质区别

1) *BPTT* 中代理梯度的精确位置：在标准 *BPTT* 中，代理梯度（Surrogate Gradient, SG）出现在两个不同的位置：

- 1) 空间维度（误差传播入口）： $\frac{\partial \mathbf{s}^{l+1}[t]}{\partial \mathbf{u}^{l+1}[t]}$ ，这是误差从脉冲域进入膜电位域的必经通道。
- 2) 时间维度（时间连乘内部）： $\frac{\partial \mathbf{s}^{l+1}[i]}{\partial \mathbf{u}^{l+1}[i]}$ ，出现在历史回溯的连乘中，控制重置路径对时间传播的贡献。

BPTT 的完整梯度公式为 [3]：

$$\frac{\partial L}{\partial \mathbf{W}^l} = \sum_{t=1}^T \frac{\partial L}{\partial \mathbf{s}^{l+1}[t]} \frac{\partial \mathbf{s}^{l+1}[t]}{\partial \mathbf{u}^{l+1}[t]} \left(\frac{\partial \mathbf{u}^{l+1}[t]}{\partial \mathbf{W}^l} + \sum_{\tau < t} \prod_{i=t-1}^{\tau} \left(\lambda \mathbf{I} + (-\lambda V_{th} \mathbf{I}) \cdot \frac{\partial \mathbf{s}^{l+1}[i]}{\partial \mathbf{u}^{l+1}[i]} \right) \frac{\partial \mathbf{u}^{l+1}[\tau]}{\partial \mathbf{W}^l} \right),$$

其中红色标记的项就是代理梯度。

2) *NDOT* 的核心创新：时间维度的“去代理梯度化”：*NDOT* [4] 的核心观察是：时间连乘中的代理梯度 $\sigma'(\cdot)$ 是人为构造的近似值，缺乏坚实的数学基础。因此，*NDOT* 尝试在时间维度上用物理可计算量替代它。

NDOT 从连续 LIF 微分方程出发：

$$\frac{du(t)}{dt} = -u(t) + I(t),$$

利用隐函数关系定义连续时序敏感度：

$$e(t) \triangleq \frac{\partial u(t+1)}{\partial u(t)} = \frac{u'(t+1)}{u'(t)} = \frac{u(t+1) - I(t+1)}{u(t) - I(t)}.$$

离散化并代入 LIF 迭代方程 $u[t+1] = \lambda(u[t] - V_{th}s[t]) + I[t+1]$ ，得到：

$$\mathbf{e}^l[t] = \frac{\mathbf{u}^l[t] - V_{th}\mathbf{s}^l[t]}{\mathbf{u}^l[t-1] - V_{th}\mathbf{s}^l[t-1]}.$$

这个 $e[t]$ 完全由前向状态决定，不包含任何代理梯度。

NDOT 的时序传播核变为：

$$\mathbf{P}_{k,t}^l \triangleq \prod_{i=k}^{t-1} \mathbf{e}^l[i] = \frac{\mathbf{u}^l[t-1] - V_{th}\mathbf{s}^l[t-1]}{\mathbf{u}^l[k-1] - V_{th}\mathbf{s}^l[k-1]},$$

通过望远镜化简（Telescoping），连乘化简为首尾比值，既保持了前向可计算性，又在时间维度上摆脱了对代理梯度的依赖。

3) *NDOT* 是否真正“避免”了代理梯度? : 严谨结论: *NDOT* 没有完全避免代理梯度, 它只是把代理梯度从“时间维度”移到了“空间维度”。

算法	空间维度 (入口)	时间维度 (连乘内部)
BPTT	需要 SG	需要 SG
OTTT	需要 SG	丢弃 (置零)
NDOT	仍然需要 SG	用 $e[t]$ 替代
S-TLLR	需要 SG	用 STDP 踪迹替代
TESS	需要 SG	用 $\mathbf{q}, \mathbf{h}$ 替代

NDOT 公式中的空间梯度仍然为:

$$\mathbf{g}_{\mathbf{u}^l}[t] = \left(\frac{\partial L[t]}{\partial \mathbf{s}^N[t]} \prod_{i=N-1}^{l+1} \frac{\partial \mathbf{s}^{i+1}[t]}{\partial \mathbf{s}^i[t]} \cdot \frac{\partial \mathbf{s}^{l+1}[t]}{\partial \mathbf{u}^{l+1}[t]} \right)^\top,$$

其中红色项依然是代理梯度。

因此, *NDOT* 的准确表述应该是: “**NDOT** 仅在时间维度避免了代理梯度, 但空间维度仍然依赖代理梯度”。

C. *NDOT* 未成主流的原因: 数学约束与隐藏损失

1) 原因一: 严格的收敛性条件 (适用范围窄): *NDOT* 的理论保证依赖于加权发放率的收敛性 [4]。其定理 2 要求:

$$\|\mathbf{J}_{f_\theta} |_{\mathbf{a}[T]}\| \leq \eta < \frac{\sigma_{\min}^2}{\sigma_{\max}^2},$$

即网络的动力学映射必须是收缩的 (contractive)。这一条件在以下场景中难以满足:

- 1) 短时间步 (T 很小): 发放率尚未收敛, $e[t]$ 无法有效近似 $\epsilon[t]$ 。
- 2) 深度网络 (层数 L 较大): 深层中膜电位分布不稳定, 平衡态假设被打破。
- 3) 高动态输入: 快速变化的事件流中, 膜电位频繁重置, $e[t]$ 的动态比值剧烈振荡。

2) 原因二: 严重的数值不稳定性: *NDOT* 在原文附录 A.2 中专门提出了“数值稳定性增强策略”, 这本身就是其不稳定性存在的证据。计算 $e[t]$ 时:

$$e^l[t] = \frac{u^l[t] - V_{th}s^l[t]}{u^l[t-1] - V_{th}s^l[t-1]}.$$

当神经元处于静息状态 (膜电位接近 0) 或刚完成重置后, 分子和分母都可能接近 0, 导致除法结果爆炸:

$$\lim_{u[t-1] \rightarrow V_{th}s[t-1]} e^l[t] = \infty.$$

相比之下, OTTT 使用固定常数 $\lambda \in (0, 1)$, 不存在任何数值风险。

3) 原因三：隐藏的计算与存储开销：虽然 NDOT 和 OTTT 的理论复杂度均为 $O(Ln)$ ，但实际常数项不同：

算法	每层存储内容	每步计算内容
OTTT	1 个踪迹 $\hat{a}[t]$	标量乘法
NDOT	$\hat{a}[t] + \text{分母信息 } u[t] - V_{th}s[t]$	逐元素除法

NDOT 的实际存储量约为 OTTT 的 2 倍，且除法在硬件（FPGA/ASIC）上的实现成本远高于乘法。

4) 原因四：缺乏理论误差上界：定义 NDOT 与 BPTT 在时序依赖上的偏差：

$$\Delta^l[t] = \epsilon^l[t] - e^l[t] = (\lambda - \lambda V_{th} \sigma'(u^l[t])) - \frac{u^l[t] - V_{th}s^l[t]}{u^l[t-1] - V_{th}s^l[t-1]}.$$

NDOT 论文从未给出 $\Delta^l[t]$ 的解析上界。在什么条件下 $\Delta^l[t] \approx 0$ ？在什么条件下 $\|\Delta^l[t]\|$ 会急剧增大？目前没有理论回答。缺乏这一误差上界，使得工业界和学术界难以放心用 NDOT 替代成熟的 OTTT。

D. 在线学习中的信息损失：定义、度量与研究框架

1) 核心问题：

- 在线化的过程中，我们到底损失了什么信息？
- 如何定义和量化“信息是否损失”？
- 各种在线学习算法各保留了多少信息、又损失了多少信息？

2) 定义：梯度信息谱：BPTT 的完整梯度可以分解为一个二维信息矩阵 $C_{\tau,t}$ ，其中 τ 是历史时刻， t 是当前时刻，每个元素代表“来自历史时刻 τ 的输入脉冲对当前时刻 t 的梯度贡献”。

对于单层网络，BPTT 的完整梯度可以显式写成：

$$g_{\text{BPTT}} = \sum_{t=1}^T \sum_{\tau=1}^t \mathbf{g}[t] \cdot \left(\prod_{i=\tau}^{t-1} D_i \right) \cdot \mathbf{s}[\tau],$$

其中 $D_i = \lambda - \lambda V_{th} \sigma'(u[i])$ 。

定义分量矩阵：

$$C_{\tau,t} \triangleq \mathbf{g}[t] \cdot \left(\prod_{i=\tau}^{t-1} D_i \right) \cdot \mathbf{s}[\tau].$$

归一化为能量分布：

$$M_{\tau,t} \triangleq \frac{\|C_{\tau,t}\|_F}{\sum_{\tau',t'} \|C_{\tau',t'}\|_F}.$$

热力图 $M_{\tau,t}$ 直观显示了完整梯度中“哪些时间跨度的贡献最重要”。

3) 各算法的信息保留模式：— 算法 — 保留的分量 — 丢弃的分量 — — : — — : — — : — — —
 BPTT — 全部 $C_{\tau,t}$ — 无 — — OTTT — $\lambda^{t-\tau} \cdot \mathbf{s}[\tau]$ — 包含 σ' 的重置路径 — — NDOT — $\prod e[i] \cdot \mathbf{s}[\tau]$ — 完整的 $\epsilon[i]$ 被 $e[i]$ 替代 — — S-TLLR — 因果项 + 非因果项 — 精确的 BPTT 时间结构 — —
 TESS — $\mathbf{q} + \mathbf{h}$ （本地信息） — 跨层误差传播信息 —

定义算法 A 的信息保留率为：

$$\text{InfoRetention}(A) \triangleq \sum_{\tau,t} M_{\tau,t} \cdot \mathbb{I}[\text{算法 } A \text{ 能近似分量}(\tau,t)].$$

4) 基于单层网络的研究方案（具体抓手）：为了清晰理解这些概念，建议从最简单的结构开始研究：

Step 1: 选择基准模型

- 单层全连接 SNN，输入维度 d ，输出维度 n （建议 $d = 10, n = 10$ ）。
- 时间步 T 可在 2-20 之间变化。
- 使用静态输入（可重复的随机脉冲序列），便于精确计算 BPTT 梯度。

Step 2: 精确计算 BPTT 梯度 使用标准 BPTT（含代理梯度）计算 $g_{\text{BPTT}} \in \mathbb{R}^{n \times d}$ ，同时记录所有中间状态 $(u[t], s[t], g[t])$ ，离线构建完整的 $M_{\tau,t}$ 矩阵。

Step 3: 计算各在线算法的近似梯度 分别用 OTTT、NDOT、S-TLLR、TESS 计算梯度 g_A ，也记录其内部状态（踪迹值、动态核值等）。

Step 4: 量化分析

- 余弦相似度: $\text{Sim}_A = \frac{\langle g_A, g_{\text{BPTT}} \rangle}{\|g_A\| \cdot \|g_{\text{BPTT}}\|}$
- 相对误差: $\text{Err}_A = \frac{\|g_A - g_{\text{BPTT}}\|}{\|g_{\text{BPTT}}\|}$
- 信息保留率: 对每个算法，计算其保留的矩阵分量占比

Step 5: 关键变量扫描

- 变化 T (2, 4, 6, 10, 20)，观察长时依赖下的信息衰减
- 变化输入动态性（静态帧 vs 高速事件流），观察不同场景下的最优算法
- 变化代理梯度类型（sigmoid vs 矩形），观察对信息保留的影响

5) 预期产出与学术贡献:

- 1) 量化选择指南: 给出“在何种条件下应使用哪种在线算法”的系统性建议。
- 2) 理论下界猜想: 在线算法的时间复杂度若降至 $O(1)$ ，其梯度信息保真度会以 $O(1/\sqrt{T})$ 速率衰减。
- 3) 算法改进灵感: 基于“信息保留率”分析，设计一个混合算法——当分母危险时回退到 OTTT，否则使用 NDOT，兼顾精度与稳定性。

E. 总结

NDOT 未成主流的根本原因包括：严格的收敛性条件、数值不稳定、隐含的存储和计算成本、以及缺乏理论误差上界。在线学习中的信息损失可通过“梯度信息谱” $M_{\tau,t}$ 来度量和可视化。建议从单层网络入手，系统量化 OTTT、NDOT、S-TLLR、TESS 的信息保留率，为后续研究建立理论基础。

参考文献

- [1] R. J. Williams and D. Zipser, “A learning algorithm for continually running fully recurrent neural networks,” *Neural computation*, vol. 1, no. 2, pp. 270–280, 1989.
- [2] G. Bellec, F. Scherr, A. Subramoney, E. Hajek, D. Salaj, R. Legenstein, and W. Maass, “A solution to the learning dilemma for recurrent networks of spiking neurons,” *Nature Communications*, vol. 11, no. 1, p. 3625, Jul. 2020. [Online]. Available: <https://doi.org/10.1038/s41467-020-17236-y>

- [3] M. Xiao, Q. Meng, Z. Zhang, D. He, and Z. Lin, "Online Training Through Time for Spiking Neural Networks," in *Advances in Neural Information Processing Systems*, S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, and A. Oh, Eds., vol. 35. Curran Associates, Inc., 2022, pp. 20 717–20 730. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2022/file/82846e19e6d42ebfd4ace4361def29ae-Paper-Conference.pdf
- [4] H. Jiang, G. D. Masi, H. Xiong, and B. Gu, "NDOT: Neuronal Dynamics-based Online Training for Spiking Neural..." [Online]. Available: <https://openreview.net/forum?id=eIF0QoBSFV>
- [5] M. P. E. Apolinario and K. Roy, "S-TLLR: STDP-inspired Temporal Local Learning Rule for Spiking Neural Networks," Oct. 2024, arXiv:2306.15220 [cs]. [Online]. Available: <http://arxiv.org/abs/2306.15220>
- [6] M. P. E. Apolinario, K. Roy, and C. Frenkel, "TESS: A Scalable Temporally and Spatially Local Learning Rule for Spiking Neural Networks," in *2025 International Joint Conference on Neural Networks (IJCNN)*, Jun. 2025, pp. 1–9, iSSN: 2161-4407. [Online]. Available: <https://ieeexplore.ieee.org/abstract/document/111227652>