

SNN 信用分配：从原公式到在线/局部化近似

摘要

本方案以六篇与 SNN 在线/局部信用分配密切相关的核心论文为理论主线，从每篇的原公式出发，逐步推导它们各自的梯度计算方式。

研究基准：从 BPTT 与 RTRL 两类精确信用分配基准出发（reverse-mode / forward-mode），分析在线/局部算法在 **temporal representation**、**eligibility** 与 **learning signal** 上进行了何种重组或近似。

总研究问题：What information is lost by temporal/spatial localization, and how do the losses interact?

三条研究路径：

- **时间近似：**BPTT $\rightarrow$ OTTT $\rightarrow$ NDOT，研究 temporal dependency $e^l[t]$ 如何被 λI 或 $\text{diag}(e^l[t])$ 替代；
- **精确到局部：**RTRL $\rightarrow$ e-prop，研究 RTRL 的 full forward sensitivity 与 e-prop 的 local eligibility + learning-signal factorization 之间的关系；
- **生物局部化：**STDP $\rightarrow$ S-TLLR $\rightarrow$ TESS，研究预突触-突触后时序信息如何逐步引入 task credit 与空间局部性。

核心研究问题：这些在线/局部化操作到底保留了什么 credit information，丢失了什么 credit information，以及这些差异什么时候真正影响学习。

文章汇总

RTRL: A learning algorithm for continually running fully recurrent neural networks [1];

E-prop: A solution to the learning dilemma for recurrent networks of spiking neurons [2];

OTTT: Online Training Through Time for Spiking Neural Networks [3];

NDOT: NDOT: Neuronal Dynamics-based Online Training for Spiking Neural Networks [4];

S-TLLR: S-TLLR: STDP-inspired Temporal Local Learning Rule for Spiking Neural Networks [5];

TESS: TESS: A Scalable Temporally and Spatially Local Learning Rule for Spiking Neural Networks [6].

I. 研究背景与核心问题

A. SNN 训练的根本困难

SNN 用二进制脉冲 $s_j^t \in \{0, 1\}$ 传递信息：神经元只有在膜电位达到阈值时才发放一个脉冲，脉冲本身是二值的、不可微的。这带来两个层面的信用分配困难：

- 1) **时间信用分配：**一个输出时刻的损失，可能由多个时间步之前的输入决定；要把这个损失归因到具体某个时刻的突触权重上，需要追踪“过去 $\rightarrow$ 现在”的因果链；
- 2) **空间信用分配：**损失发生在输出层，但要归因到每个隐藏层的权重上；需要把误差从输出层反向传播到各隐藏层。

BPTT 是求解这两个问题的标准方法。它的核心思想是：把 SNN 沿时间展开成一个很深的 feedforward 计算图，然后在这个展开图上调用反向传播。代价是需要保存所有时间步的 forward

states (每个时刻的膜电位 $u^l[t]$ 、脉冲 $s^l[t]$ 等), 内存 $O(TLn)$, 且必须等整个序列前向完成后才能开始反向, 这排除了在线学习。

关于”精确”的约定: BPTT 与 RTRL 对一个可微 recurrent computational graph 分别给出 reverse-mode 和 forward-mode exact gradient。但 SNN 的脉冲发放 $s = H(u - V_{th})$ 几乎处处导数为零, 不是可微函数; 实际训练中所有方法都用 surrogate Ψ'_{SG} 替代 $\partial s / \partial u$ 。因此本文所用的 reference 是 **BPTT-with-SG / RTRL under the same surrogate rule**, 其”精确”仅指相对于选定 surrogate backward rule 的精确计算, 不代表连续动力学的真实导数。下文所有 g_{BPTT} 均指 **BPTT-with-SG reference estimator**, 不称为”exact gradient”。

B. 已有工作

时间近似主线: OTTT [3] 注意到在 BPTT 的 temporal chain 里, spike-mediated path 通常极稀疏 (因为 H 几乎处处导数为零), 于是丢弃该路径, 把时序依赖退化为固定指数衰减 $\lambda^{t-\tau}$; NDOT [4] 进一步从连续 LIF 微分方程推导动态比率 $e^l[t]$, 替代固定 λ 。

精确到局部主线: RTRL [1] 用 forward-mode 计算参数敏感度 P_t , 是完全 forward-in-time 的精确梯度方法, 但内存 $O(n^3)$; e-prop [2] 重新组织 chain rule, 把梯度分解为”局部 eligibility $\times$ learning signal”, 大幅降低内存。

生物局部化主线: STDP 用 pre/post 时序定义突触可塑性; S-TLLR [5] 引入 STDP 形式的因果与非因果资格迹, 再用 learning signal 调制; TESS [6] 通过本地学习信号生成实现时空全局部。

关于”联合局部化”的现状: 时空联合局部学习本身已经被研究过——TESS [6] 已把 temporal eligibility 与 layer-local spatial signal 结合; Traces Propagation 等工作也处理时空联合的 forward-only learning。因此本研究不以”首次实现时空联合”作为 novelty。

本研究的问题不是”能否联合”, 而是”联合局部化时各自损失了什么、损失如何耦合”:

- 时间局部化 (例如 OTTT 的固定 λ 、NDOT 的 $\text{diag}(e^l)$) 在 temporal dependency 上引入了何种结构性误差?
- 空间局部化 (例如 Mostafa-style local classifier) 在目标替换上引入了何种结构性误差?
- 当两种局部化同时施加时, 误差是简单叠加还是产生 interaction?

参考文献

- [1] R. J. Williams and D. Zipser, “A learning algorithm for continually running fully recurrent neural networks,” *Neural computation*, vol. 1, no. 2, pp. 270–280, 1989.
- [2] G. Bellec, F. Scherr, A. Subramoney, E. Hajek, D. Salaj, R. Legenstein, and W. Maass, “A solution to the learning dilemma for recurrent networks of spiking neurons,” *Nature Communications*, vol. 11, no. 1, p. 3625, Jul. 2020. [Online]. Available: <https://doi.org/10.1038/s41467-020-17236-y>
- [3] M. Xiao, Q. Meng, Z. Zhang, D. He, and Z. Lin, “Online Training Through Time for Spiking Neural Networks,” in *Advances in Neural Information Processing Systems*, S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, and A. Oh, Eds., vol. 35. Curran Associates, Inc., 2022, pp. 20 717–20 730. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2022/file/82846e19e6d42ebfd4ace4361def29ae-Paper-Conference.pdf
- [4] H. Jiang, G. D. Masi, H. Xiong, and B. Gu, “NDOT: Neuronal Dynamics-based Online Training for Spiking Neural...” [Online]. Available: <https://openreview.net/forum?id=elF0QoBSFV>
- [5] M. P. E. Apolinario and K. Roy, “S-TLLR: STDP-inspired Temporal Local Learning Rule for Spiking Neural Networks,” Oct. 2024, arXiv:2306.15220 [cs]. [Online]. Available: <http://arxiv.org/abs/2306.15220>

- [6] M. P. E. Apolinario, K. Roy, and C. Frenkel, "TESS: A Scalable Temporally and Spatially Local Learning Rule for Spiking Neural Networks," in *2025 International Joint Conference on Neural Networks (IJCNN)*, Jun. 2025, pp. 1–9, iSSN: 2161-4407. [Online]. Available: <https://ieeexplore.ieee.org/abstract/document/11227652>