

SNN 本地学习的逐层信息保留与损失定位

摘要

本地学习算法（OTTT、NDOT、S-TLLR、TESS）通过时间局部化与空间局部化降低训练开销，但它们各自优化局部目标，没有像 BPTT 那样统一的全局梯度信号。因此在现有评估中，只能看到最终准确率，无法判断信息在哪一层损失、损失了多少。本方案提出在层与层之间引入中间量，逐层量化本地学习的信息保留程度与训练效果。具体包括三个研究方向：逐层探针、逐层表示相似度、逐层梯度对齐。三者分别从“最终效用、学习结果、学习过程”三个层面定位信息损失，共同回答“信息在哪一层损失、损失多少、为什么损失”。

文章汇总

RTRL: A learning algorithm for continually running fully recurrent neural networks [1];

E-prop: A solution to the learning dilemma for recurrent networks of spiking neurons [2];

OTTT: Online Training Through Time for Spiking Neural Networks [3];

NDOT: NDOT: Neuronal Dynamics-based Online Training for Spiking Neural Networks [4];

S-TLLR: S-TLLR: STDP-inspired Temporal Local Learning Rule for Spiking Neural Networks [5];

TESS: TESS: A Scalable Temporally and Spatially Local Learning Rule for Spiking Neural Networks [6].

I. 研究背景与核心问题

A. 本地学习缺少全局梯度

本地学习算法是降低 SNN 训练开销的主要途径。OTTT [3] 丢弃 spike-mediated 路径、用固定衰减 λ 近似时间依赖；NDOT [4] 用神经元动力学系数 $e^l[t]$ 替代固定 λ ；S-TLLR [5] 用 STDP 风格的因果/非因果资格迹做时间信用分配；TESS [6] 进一步用本地生成的学习信号替代跨层误差反传，实现时空全局部。它们的共同点是：每层（或每个突触）只依据局部可得的信息优化一个局部目标，网络内部不存在一个像 BPTT 那样贯穿全网的统一梯度。

BPTT 的梯度有明确的全局结构：误差从输出层出发，沿空间（层到层）和时间（ t 到 $t-1$ ）两个方向逐层、逐时刻地传播，最终落到每个权重上。因此对 BPTT 而言，“信息在哪一层损失”至少在梯度层面是可定义的——可以逐层检查反向传播到该层的误差信号大小。而本地学习切断了这一全局链条：每层各自优化局部目标，层与层之间没有统一的误差信号可追踪，于是“信息在哪一层损失、损失多少”这一问题在现有评估框架下没有答案。

B. 核心研究问题

目前的评估方式停留在“看最终准确率”：给每个本地学习算法在某个任务上报告一个准确率，谁高谁好。但这无法回答三个关键问题：

- 1) 信息在哪一层损失：本地学习相对 BPTT 的性能差距，究竟来自浅层还是深层？
- 2) 损失了多少：每一层各自保留了多少任务信息、丢弃了多少？
- 3) 为什么损失：损失来自时间近似的结构性误差、空间目标替换，还是两者耦合？

核心研究问题：在层与层之间引入中间量，逐层量化本地学习的信息保留程度与训练效果，从而定位“信息在哪一层损失、损失多少”及其来源。

II. 三个研究方向

三个方向分别从不同层面切入同一个核心问题，构成从“因”到“果”的链条：梯度对齐度量学习过程本身是否偏离，表示相似度度量学习结果是否被扭曲，逐层探针度量最终任务信息是否保留。下面逐一说明每个方向要回答什么问题、为什么需要、如何定义指标，以及与另外两个方向的关系。

A. 方向一：逐层探针

要回答的问题：第 l 层的表示本身携带了多少关于任务标签 y 的信息？即“任务信息在到达第 l 层时还保留多少”。

为什么需要：这是三个方向里最直接的“信息损失”度量。如果第 l 层的表示已经能够以高精度解码出任务标签，说明信息在到达该层时尚未丢失；如果解码精度很低，说明信息在该层之前（或该层内部）已经丢失。逐层扫描即可定位损失发生的位置。

探针的挂法：在每一层输出之后挂一个独立的、小的解码器（探针），只以该层的表示作为输入去预测任务标签。主网络的权重在挂探针时保持冻结，探针只在冻结的表示之上训练。具体地，第 l 层在 T 个时间步的脉冲序列 $s^l[1], \dots, s^l[T]$ 先聚合为一个向量表示 z^l ，例如取时间平均（firing rate）

$$z^l = \frac{1}{T} \sum_{t=1}^T s^l[t] \in \mathbb{R}^{n^l}. \quad (1)$$

探针取线性分类器

$$f_{\text{probe}}^l(z^l) = \text{softmax}(P^l z^l + c^l), \quad P^l \in \mathbb{R}^{C \times n^l}, \quad c^l \in \mathbb{R}^C, \quad (2)$$

其中 C 是类别数。探针参数 P^l, c^l 通过最小化交叉熵（或其他任务损失）在训练集上拟合，训练时不回传梯度到主网络。

探针准确率的计算：在验证集上，用训练好的探针对每个样本 n 做预测 $\hat{y}_n = \arg \max_c f_{\text{probe}}^l(z_n^l)$ ，探针准确率定义为

$$\text{Acc}_{\text{probe}}^l = \frac{1}{N} \sum_{n=1}^N \mathbb{I}[\hat{y}_n = y_n]. \quad (3)$$

归一化信息保留率：为了跨层比较，把准确率归一化到“从随机猜测到输出层”的区间，定义

$$\rho^l = \frac{\text{Acc}_{\text{probe}}^l - \text{Acc}_{\text{chance}}}{\text{Acc}_{\text{probe}}^L - \text{Acc}_{\text{chance}}}, \quad (4)$$

其中 $\text{Acc}_{\text{chance}} = 1/C$ 是随机猜测水平， $\text{Acc}_{\text{probe}}^L$ 是输出层（第 L 层）探针的准确率，作为“该任务可达到的信息上限”。

如何用曲线判断信息在层间的分布：画出 ρ^l 对层索引 l 的曲线。 ρ^l 越接近 1，说明该层表示保留的任务信息越接近上限；曲线中下降最快的区间，就是信息损失最集中的层。将本地学习算法与 BPTT 的两条 ρ^l 曲线画在同一张图上：两者差距最大的层，就是该本地学习算法相对 BPTT 信息损失最大的层。

与另外两个方向的关系：探针回答“信息还在不在”，属于“最终效用”层面，但它只看结果、不解释原因——它无法说明“为什么这一层丢了信息”。要回答“为什么”，需要表示相似度（看表示结构是否被扭曲）和梯度对齐（看优化方向是否偏离）来补充。

B. 方向二：逐层表示相似度

要回答的问题：本地学习训练出的第 l 层表示，与 BPTT 训练出的第 l 层表示，在几何结构上有多像？

为什么需要：探针只能说明“信息是否还在”，但不能说明“表示本身是否被扭曲”。两个不同的表示可能保留同样的任务信息（探针准确率相同），但几何结构完全不同——例如两者相差一个复杂的非线性变换。这种结构差异虽然不降低当前任务的解码精度，却会影响泛化、迁移和与后续层的配合。因此需要直接比较表示本身，而不只是比较它们能解码出什么。

表示相似度指标的定义：对第 l 层，收集 N 个样本的表示，分别排成矩阵：本地学习给出 $Z_{\text{local}}^l \in \mathbb{R}^{N \times n^l}$ ，BPTT 给出 $Z_{\text{BPTT}}^l \in \mathbb{R}^{N \times n^l}$ ，其中第 n 行是第 n 个样本的表示 z_n^l 。比较两个表示，本质上是比较它们各自定义的“样本间几何结构”。用 Gram 矩阵刻画这一结构： $K_{\text{local}}^l = Z_{\text{local}}^l (Z_{\text{local}}^l)^\top$ 的第 (i, j) 元是样本 i 与样本 j 表示的内积，度量两样本在该表示下的相似程度； K_{BPTT}^l 同理。为了让比较不受表示均值（全局平移）的影响，先对 Gram 矩阵做中心化：记 $H = I - \frac{1}{N} \mathbf{1}\mathbf{1}^\top$ （ $\mathbf{1}$ 为全 1 向量， I 为单位阵），定义

$$\tilde{K}_{\text{local}}^l = H K_{\text{local}}^l H, \quad \tilde{K}_{\text{BPTT}}^l = H K_{\text{BPTT}}^l H. \quad (5)$$

然后定义第 l 层的表示相似度为两个中心化 Gram 矩阵的（归一化）内积：

$$\text{sim}^l = \frac{\langle \tilde{K}_{\text{local}}^l, \tilde{K}_{\text{BPTT}}^l \rangle_F}{\|\tilde{K}_{\text{local}}^l\|_F \|\tilde{K}_{\text{BPTT}}^l\|_F} = \frac{\text{tr}(\tilde{K}_{\text{local}}^l \tilde{K}_{\text{BPTT}}^l)}{\|\tilde{K}_{\text{local}}^l\|_F \|\tilde{K}_{\text{BPTT}}^l\|_F}, \quad (6)$$

其中 $\langle A, B \rangle_F = \text{tr}(A^\top B)$ 是 Frobenius 内积， $\|\cdot\|_F$ 是 Frobenius 范数。

取值范围与含义： sim^l 本质上是两个矩阵（视为高维向量）之间夹角的余弦，取值范围为 $[-1, 1]$ ，实际中通常落在 $[0, 1]$ 。 $\text{sim}^l = 1$ 表示两种表示的“样本间几何结构”完全一致（只可能相差一个保持该结构的正交变换）； sim^l 越低，表示本地学习的表示相对 BPTT 偏离越大。用 Gram 矩阵而非原始表示的原因在于：它只关心“样本之间的关系结构”，对表示自身的旋转、以及（经过归一化后）缩放不敏感，从而把比较聚焦在“结构是否被扭曲”上。

逐层曲线的读法：画出 sim^l 对 l 的曲线。浅层通常相似度较高（输入编码尚未被明显改变），越往深层差异可能越大。相似度快速下降的层，就是本地学习相对 BPTT 表示被“扭曲”最严重的层。

与另外两个方向的关系：表示相似度回答“表示结构变没变”，属于“学习结果”层面，是探针（最终效用）与梯度对齐（学习过程）之间的中间环节。它比探针更能定位“在哪一层几何结构开

始偏离”，但相似度下降并不必然等于任务信息丢失——有时只是换了一个等价表示。因此需要与探针交叉验证：相似度低且探针准确率也低，才是真正”有害”的信息损失。

C. 方向三：逐层梯度对齐

要回答的问题：本地学习在第 l 层产生的梯度（或等效更新方向）与 BPTT 在第 l 层的梯度，方向是否一致？

为什么需要：探针和表示相似度都是”事后”看结果，梯度对齐看的是”学习过程”本身。即使某层当前表示与 BPTT 相似，如果本地学习的梯度方向错误，那么在后续训练中该层会逐渐偏离。梯度对齐直接度量”本地学习是否正朝着 BPTT 会走的方向优化”，因此是三个方向里最接近”原因”的度量。

梯度对齐的定义：把第 l 层的权重 $W^{l \leftarrow l-1}$ 展平为一个向量，本地学习给出的梯度记为 $g_{\text{local}}^l \in \mathbb{R}^d$ ，BPTT 给出的梯度记为 $g_{\text{BPTT}}^l \in \mathbb{R}^d$ 。二者的方向一致性用余弦相似度度量：

$$\cos^l = \frac{\langle g_{\text{local}}^l, g_{\text{BPTT}}^l \rangle}{\|g_{\text{local}}^l\| \|g_{\text{BPTT}}^l\|} \in [-1, 1]. \quad (7)$$

$\cos^l = 1$ 表示方向完全一致， $= 0$ 表示正交， < 0 表示方向相反。

平行/垂直分量分解：为了把”方向一致”进一步拆成”有效的平行部分”与”有害的垂直部分”，把 g_{local}^l 沿 g_{BPTT}^l 方向做正交分解：

$$g_{\parallel}^l = \frac{\langle g_{\text{local}}^l, g_{\text{BPTT}}^l \rangle}{\|g_{\text{BPTT}}^l\|^2} g_{\text{BPTT}}^l, \quad g_{\perp}^l = g_{\text{local}}^l - g_{\parallel}^l. \quad (8)$$

$g_{\parallel}^l$ 是本地梯度中真正沿着 BPTT 方向、能推动正确优化的分量； $g_{\perp}^l$ 是垂直于 BPTT 方向、与正确优化无关（甚至有害）的分量。相应地定义两个标量：

$$c_{\parallel}^l = \frac{\langle g_{\text{local}}^l, g_{\text{BPTT}}^l \rangle}{\|g_{\text{BPTT}}^l\|^2}, \quad R_{\perp}^l = \frac{\|g_{\perp}^l\|}{\|g_{\text{BPTT}}^l\|}. \quad (9)$$

$c_{\parallel}^l$ 是”本地梯度中有效的平行部分占 BPTT 梯度的比例”， $R_{\perp}^l$ 是”垂直偏差相对 BPTT 梯度的大小”。

逐层曲线的读法：画出 $\cos^l$ （或 $c_{\parallel}^l$ 、 $R_{\perp}^l$ ）对 l 的曲线。 $\cos^l$ 低、或 $R_{\perp}^l$ 高的层，就是本地近似在该层引入的梯度误差最大的层，也就是最可能”带偏”该层优化的位置。

与另外两个方向的关系：梯度对齐回答”优化方向对不对”，属于”学习过程”层面，是三者的”因”。梯度方向错了会导致表示偏离（方向二），进而导致任务信息丢失（方向一）。三者构成”梯度（过程）→ 表示（结果）→ 任务信息（效用）”的因果链，共同回答核心问题。

D. 三个方向的关系与整体定位

三个方向构成一条从因到果的链条，共同回答”信息在哪一层损失、损失多少、为什么损失”：

- 1) **梯度对齐**（学习过程）：定位”哪一层的优化方向被本地近似带偏”；
- 2) **表示相似度**（学习结果）：定位”哪一层的表示结构被本地学习扭曲”；
- 3) **逐层探针**（最终效用）：定位”哪一层的任务信息真正丢失”。

定位流程是：先用探针找到信息在哪一层损失（结果层），再用表示相似度确认表示在哪一层被扭曲（结构层），最后用梯度对齐解释为什么在这一层损失（原因层）。三者互补——探针只看结果、梯度只看过程，表示相似度居中承上启下——单独使用任何一个都不足以完整回答核心问题。

参考文献

- [1] R. J. Williams and D. Zipser, “A learning algorithm for continually running fully recurrent neural networks,” *Neural computation*, vol. 1, no. 2, pp. 270–280, 1989.
- [2] G. Bellec, F. Scherr, A. Subramoney, E. Hajek, D. Salaj, R. Legenstein, and W. Maass, “A solution to the learning dilemma for recurrent networks of spiking neurons,” *Nature Communications*, vol. 11, no. 1, p. 3625, Jul. 2020. [Online]. Available: <https://doi.org/10.1038/s41467-020-17236-y>
- [3] M. Xiao, Q. Meng, Z. Zhang, D. He, and Z. Lin, “Online Training Through Time for Spiking Neural Networks,” in *Advances in Neural Information Processing Systems*, S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, and A. Oh, Eds., vol. 35. Curran Associates, Inc., 2022, pp. 20 717–20 730. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2022/file/82846e19e6d42ebfd4ace4361def29ae-Paper-Conference.pdf
- [4] H. Jiang, G. D. Masi, H. Xiong, and B. Gu, “NDOT: Neuronal Dynamics-based Online Training for Spiking Neural...” [Online]. Available: <https://openreview.net/forum?id=elF0QoBSFV>
- [5] M. P. E. Apolinario and K. Roy, “S-TLLR: STDP-inspired Temporal Local Learning Rule for Spiking Neural Networks,” Oct. 2024, arXiv:2306.15220 [cs]. [Online]. Available: <http://arxiv.org/abs/2306.15220>
- [6] M. P. E. Apolinario, K. Roy, and C. Frenkel, “TESS: A Scalable Temporally and Spatially Local Learning Rule for Spiking Neural Networks,” in *2025 International Joint Conference on Neural Networks (IJCNN)*, Jun. 2025, pp. 1–9, iSSN: 2161-4407. [Online]. Available: <https://ieeexplore.ieee.org/abstract/document/111227652>