

课程笔记 SNN训练算法汇总综述

Tao

摘要

课程笔记 SNN训练算法汇总综述，涵盖了从传统的 BPTT/STBP 到最新的在线学习方法（OTTT、NDOT）以及局部学习规则（S-TLLR、TESS）。重点分析了每种方法的核心思想、数学推导、优缺点以及适用场景。通过对比不同算法在时间依赖性处理、梯度计算复杂度和生物可解释性方面的差异，全面总结了 SNN 训练领域的研究进展和未来方向。

PPT *Week4_SNNTraining.pptx*

文章汇总

RTRL: A learning algorithm for continually running fully recurrent neural networks [1];

E-prop: A solution to the learning dilemma for recurrent networks of spiking neurons [2];

OTTT: Online Training Through Time for Spiking Neural Networks [3];

NDOT: NDOT: Neuronal Dynamics-based Online Training for Spiking Neural Networks [4];

S-TLLR: S-TLLR: STDP-inspired Temporal Local Learning Rule for Spiking Neural Networks [5];

TESS: TESS: A Scalable Temporally and Spatially Local Learning Rule for Spiking Neural Networks [6]

I. RTRL: 实时循环学习算法

本部分内容概览

- 网络模型与符号约定
- 误差定义与目标函数
- 核心思想：追踪每个权重对每个输出的影响
- 递推公式的详细推导
- 权重更新规则与在线版本
- 教师强制（Teacher Forcing）变体
- 计算复杂度分析

PPT 内容:

- **网络模型**： n 个单元（神经元）， m 个外部输入。
 - $\mathbf{y}(t)$: n 维网络输出向量（时刻 t ）
 - $\mathbf{x}(t)$: m 维外部输入向量
 - $\mathbf{z}(t) = [\mathbf{x}(t); \mathbf{y}(t)]$: 扩展状态
 - U : 网络单元索引集合； I : 输入索引集合

• 动力学:

$$s_k(t) = \sum_{l \in U \cup I} w_{kl} z_l(t), \quad k \in U \quad (1)$$

$$y_k(t+1) = f_k(s_k(t)) \quad (2)$$

- 误差: 目标 $d_k(t)$, 误差 $e_k(t) = d_k(t) - y_k(t)$ 若 $k \in T(t)$, 否则 0。
- 目标: 最小化 $J_{\text{total}} = \sum_t J(t)$, $J(t) = \frac{1}{2} \sum_k e_k^2(t)$ 。
- 核心量: $p_{ij}^k(t) \triangleq \frac{\partial y_k(t)}{\partial w_{ij}}$ 。
- 递推:

$$p_{ij}^k(t+1) = f'_k(s_k(t)) \left[\sum_{l \in U} w_{kl} p_{ij}^l(t) + \delta_{ik} z_j(t) \right] \quad (3)$$

初始条件 $p_{ij}^k(t_0) = 0$ 。

- 权重更新: $\Delta w_{ij}(t) = \alpha \sum_{k \in U} e_k(t) p_{ij}^k(t)$ (在线版本)。
- 教师强制: 用目标值替代实际输出, 递推中排除被强制单元。
- 复杂度: $O(n^3 + mn^2)$ 存储, $O(n^4)$ 计算每步。

讲稿 (详细推导):

a) 1. 网络模型与符号: 我们考虑一个完全循环的神经网络, 共有 n 个单元 (神经元) 和 m 个外部输入线。在离散时间 t , 网络输出向量记为 $\mathbf{y}(t) \in \mathbb{R}^n$, 外部输入向量记为 $\mathbf{x}(t) \in \mathbb{R}^m$ 。将两者拼接得到扩展向量 $\mathbf{z}(t) = [\mathbf{x}(t); \mathbf{y}(t)] \in \mathbb{R}^{m+n}$ 。我们定义 U 为单元索引集合 ($|U| = n$), I 为输入索引集合 ($|I| = m$)。为了统一处理, 给每个输入也分配一个索引, 使得 $z_k(t)$ 当 $k \in I$ 时取 $x_k(t)$, 当 $k \in U$ 时取 $y_k(t)$ 。

网络中的每个单元 k 在时刻 t 接收到净输入 $s_k(t)$, 其计算方式为所有扩展输入 $z_l(t)$ 乘上对应权重 w_{kl} 之和:

$$s_k(t) = \sum_{l \in U \cup I} w_{kl} z_l(t).$$

然后单元的输出由非线性激活函数 f_k 作用, 在下一时刻产生:

$$y_k(t+1) = f_k(s_k(t)).$$

这里 f_k 通常取 sigmoid 或 tanh 函数。注意, 外部输入 $x(t)$ 并不会立刻影响输出, 而是延迟一个时间步。

整个网络的状态由所有单元的膜电位 (或激活值) 和输入共同决定, 权重矩阵 $\mathbf{W}$ 是一个 $n \times (m+n)$ 的矩阵, 包含了所有单元间和输入到单元的连接。为了引入偏置, 我们可以在输入中包含一个始终为 1 的常数输入。

b) 2. 误差与目标函数: 在监督学习场景中, 某些单元在特定时刻被指定为目标值。令 $T(t)$ 为在时刻 t 有目标值的单元集合, 目标值为 $d_k(t)$ 。定义误差 $e_k(t)$:

$$e_k(t) = \begin{cases} d_k(t) - y_k(t), & k \in T(t) \\ 0, & \text{否则.} \end{cases}$$

瞬时误差 $J(t) = \frac{1}{2} \sum_{k \in U} e_k^2(t)$, 总误差 $J_{\text{total}} = \sum_{t=t_0+1}^{t_1} J(t)$ 。我们的目标是通过梯度下降调整权重 $\mathbf{W}$, 使 J_{total} 最小。

c) 3. 核心思想：跟踪敏感度 p_{ij}^k ：RTRL 的关键创新是定义 $p_{ij}^k(t) \triangleq \frac{\partial y_k(t)}{\partial w_{ij}}$ ，即时刻 t 单元 k 的输出对权重 w_{ij} 的偏导数。这个量告诉我们：如果微调权重 w_{ij} ，会对单元 k 的输出产生多大影响。因为网络是循环的， $y_k(t)$ 不仅直接依赖 w_{ij} （如果 $k = i$ ），还通过之前时刻的输出间接影响当前。因此 $p_{ij}^k(t)$ 需要递归计算。

初始时刻 t_0 ，我们假设网络初始状态不依赖于权重，因此 $p_{ij}^k(t_0) = 0$ 。

d) 4. 递推公式的详细推导：为了得到 $p_{ij}^k(t+1)$ ，我们对 $y_k(t+1) = f_k(s_k(t))$ 关于 w_{ij} 求导：

$$p_{ij}^k(t+1) = f'_k(s_k(t)) \cdot \frac{\partial s_k(t)}{\partial w_{ij}}.$$

现在关键是求 $\frac{\partial s_k(t)}{\partial w_{ij}}$ 。由于 $s_k(t) = \sum_{l \in U} w_{kl} y_l(t) + \sum_{l \in I} w_{kl} x_l(t)$ ，其中 $y_l(t)$ 本身也依赖于所有权重（包括 w_{ij} ），因此我们应使用全导数（虽然符号上仍写偏导）。具体地：

$$\frac{\partial s_k(t)}{\partial w_{ij}} = \sum_{l \in U} w_{kl} \frac{\partial y_l(t)}{\partial w_{ij}} + \sum_{l \in U} \frac{\partial w_{kl}}{\partial w_{ij}} y_l(t) + \sum_{l \in I} \frac{\partial w_{kl}}{\partial w_{ij}} x_l(t).$$

其中 $\frac{\partial y_l(t)}{\partial w_{ij}} = p_{ij}^l(t)$ 。只有当 $k = i$ 且 $l = j$ 时才为 1，否则为 0（注意 j 可以是单元或输入索引）。但这里的 l 在 U 中，而 j 可能属于 $U \cup I$ ，因此我们需要区分。更精确地，直接对 $s_k(t)$ 的表达式求导：

$$s_k(t) = \sum_{l \in U \cup I} w_{kl} z_l(t),$$

则

$$\frac{\partial s_k(t)}{\partial w_{ij}} = \sum_{l \in U \cup I} \frac{\partial w_{kl}}{\partial w_{ij}} z_l(t) + \sum_{l \in U \cup I} w_{kl} \frac{\partial z_l(t)}{\partial w_{ij}}.$$

$\frac{\partial w_{kl}}{\partial w_{ij}}$ 只有在 $k = i$ 且 $l = j$ 时为 1，否则为 0。而 $\frac{\partial z_l(t)}{\partial w_{ij}}$ 当 $l \in U$ 时为 $p_{ij}^l(t)$ ，当 $l \in I$ 时为 0（因为输入与权重无关）。因此：

$$\frac{\partial s_k(t)}{\partial w_{ij}} = \delta_{ik} z_j(t) + \sum_{l \in U} w_{kl} p_{ij}^l(t).$$

其中 δ_{ik} 是克罗内克函数。所以：

$$p_{ij}^k(t+1) = f'_k(s_k(t)) \left[\sum_{l \in U} w_{kl} p_{ij}^l(t) + \delta_{ik} z_j(t) \right].$$

这就是 RTRL 的核心递推方程。这里 j 可以属于 U 或 I ， i 属于 U （因为权重只有从单元或输入到单元的）。

e) 5. 权重更新与在线学习：有了 $p_{ij}^k(t)$ ，我们可以计算梯度：

$$-\frac{\partial J(t)}{\partial w_{ij}} = \sum_{k \in U} e_k(t) p_{ij}^k(t).$$

因此离线版本累积所有时刻的梯度：

$$\Delta w_{ij} = -\alpha \sum_t \frac{\partial J(t)}{\partial w_{ij}} = \alpha \sum_t \sum_k e_k(t) p_{ij}^k(t).$$

在线版本则在每个时刻立即更新：

$$\Delta w_{ij}(t) = \alpha \sum_k e_k(t) p_{ij}^k(t), \quad w_{ij} := w_{ij} + \Delta w_{ij}(t).$$

这使得训练无需定义明确的训练区间，网络可以持续运行并学习。

f) 6. 教师强制变体: 教师强制是一种常用技巧: 当存在目标值时, 我们将单元的输出替换为目标值, 用于计算后续的净输入。这样修改 $z_k(t)$ 的定义: 若 $k \in T(t)$, 则 $z_k(t) = d_k(t)$ (而非 $y_k(t)$)。这种改变会影响 $\frac{\partial s_k(t)}{\partial w_{ij}}$, 因为教师值不依赖于权重, 所以在求和时, 被强制单元的 p_{ij}^l 项被剔除。于是递推变为:

$$p_{ij}^k(t+1) = f'_k(s_k(t)) \left[\sum_{l \in U \setminus T(t)} w_{kl} p_{ij}^l(t) + \delta_{ik} z_j(t) \right].$$

这相当于在计算 p_{ij}^k 时把被教师强制单元的导数视为零。

g) 7. 计算复杂度: 对于全连接网络, 我们需要存储 p_{ij}^k 对每个权重 w_{ij} (共 $n(m+n)$ 个) 和每个单元 k (n 个) 的组合, 即 $n \times n \times (m+n) = n^3 + mn^2$ 个变量。每时间步更新每个 p 需要 $O(n)$ 次操作 (求和), 因此总复杂度 $O(n^4)$ (考虑 m 较小)。这使得 RTRL 在大规模网络中不实用, 但它是第一个在线梯度方法。

II. E-PROP: 资格传播

本部分内容概览

- 脉冲神经网络的一般模型与符号
- 核心数学定理: 梯度分解为学习信号与资格迹的乘积
- 资格迹的定义与递推
- 定理的严格证明 (从 BPTT 到 E-prop 的重新因子化)
- LIF 与 ALIF 神经元的具体资格迹推导
- 学习信号的不同变体 (对称、随机、自适应)
- 奖励基 E-prop (强化学习)

PPT 内容:

- 通用模型: 可观状态 z_j^t (脉冲 0/1), 隐藏状态 $\mathbf{h}_j^t$ (膜电位、适应变量等)。

$$\mathbf{h}_j^t = M(\mathbf{h}_j^{t-1}, z_j^{t-1}, \mathbf{x}^t, \mathbf{W}_j) \quad (4)$$

$$z_j^t = f(\mathbf{h}_j^t) \quad (5)$$

- 核心目标: 计算损失 E 对突触权重 W_{ji} 的梯度 $\frac{dE}{dW_{ji}}$ 。
- 关键定理 (式 (1)(3)):

$$\frac{dE}{dW_{ji}} = \sum_t L_j^t e_{ji}^t \quad (6)$$

其中 $L_j^t = \frac{dE}{dz_j^t}$ (学习信号), $e_{ji}^t = \left[\frac{dz_j^t}{dW_{ji}} \right]_{\text{local}}$ (资格迹)。

- 资格迹定义:

$$e_{ji}^t = \frac{\partial z_j^t}{\partial \mathbf{h}_j^t} \cdot \epsilon_{ji}^t \quad (7)$$

$$\epsilon_{ji}^t = \sum_{t' \leq t} \left(\frac{\partial \mathbf{h}_j^t}{\partial \mathbf{h}_j^{t-1}} \cdots \frac{\partial \mathbf{h}_j^{t'+1}}{\partial \mathbf{h}_j^{t'}} \right) \cdot \frac{\partial \mathbf{h}_j^{t'}}{\partial W_{ji}} \quad (8)$$

递推: $\epsilon_{ji}^t = \frac{\partial \mathbf{h}_j^t}{\partial \mathbf{h}_j^{t-1}} \cdot \epsilon_{ji}^{t-1} + \frac{\partial \mathbf{h}_j^t}{\partial W_{ji}}$

- **定理证明要点:** 从 BPTT 经典因子化出发, 递归展开 $\frac{dE}{d\mathbf{h}_j^{t'}}$, 交换求和顺序, 得到 L_j^t 与 e_{ji}^t 的乘积形式。

- **LIF 神经元的资格迹:**

$$e_{ji}^t = \psi_j^t \bar{z}_i^{t-1}, \quad \bar{z}_i^{t-1} = \sum_{\tau} \alpha^{t-1-\tau} z_i^{\tau} \quad (9)$$

- **ALIF 神经元 (适应):** 存在额外慢变量 a_j^t , 资格迹包含慢分量。

$$e_{ji}^t = \psi_j^t (\bar{z}_i^{t-1} - \beta \epsilon_{ji,a}^t) \quad (10)$$

其中 $\epsilon_{ji,a}^{t+1} = \psi_j^t \bar{z}_i^{t-1} + (\rho - \psi_j^t \beta) \epsilon_{ji,a}^t$

- **学习信号变体:**

- 对称: $L_j^t = \sum_k W_{kj}^{out} (y_k^t - y_k^{*,t})$
- 随机: $L_j^t = \sum_k B_{jk} (y_k^t - y_k^{*,t})$ (固定随机)
- 自适应: 随机加可塑性

- **奖励基 E-prop:** 用于强化学习, $\Delta W_{ji} = -\eta \sum_t \delta^t \mathcal{F}_{\gamma}(L_j^t e_{ji}^t)$, δ^t 为奖励预测误差。

讲稿 (详细推导):

a) 1. 脉冲网络的通用模型: **E-prop** 面向脉冲循环神经网络 (RSNN)。我们考虑一般形式: 每个神经元 j 具有隐藏状态向量 $\mathbf{h}_j^t$ (可能包含膜电位、适应变量等) 和可观输出 $z_j^t \in \{0, 1\}$ (脉冲)。网络动力学由两个函数定义:

$$\mathbf{h}_j^t = M(\mathbf{h}_j^{t-1}, z_j^{t-1}, \mathbf{x}^t, \mathbf{W}_j), \quad z_j^t = f(\mathbf{h}_j^t).$$

其中 M 是状态更新函数 (例如 LIF 膜电位更新), f 是脉冲生成函数 (通常为 Heaviside 阶跃函数)。权重 W_{ji} 是从神经元 i 到 j 的突触权重。

b) 2. 梯度分解定理: E-prop 的核心数学结果是, 损失函数 E (取决于所有脉冲) 对权重 W_{ji} 的梯度可以表示为:

$$\frac{dE}{dW_{ji}} = \sum_t L_j^t e_{ji}^t,$$

其中 $L_j^t = \frac{dE}{dz_j^t}$ 称为 “学习信号”, e_{ji}^t 称为 “资格迹”。资格迹定义为局部可计算的量:

$$e_{ji}^t \triangleq \left[\frac{dz_j^t}{dW_{ji}} \right]_{\text{local}}.$$

这个局部导数不是近似, 它收集了所有可以通过前向计算 (仅依赖神经元 j 和 i 的历史) 获得的梯度信息。具体展开为:

$$e_{ji}^t = \frac{\partial z_j^t}{\partial \mathbf{h}_j^t} \cdot \epsilon_{ji}^t,$$

其中 ϵ_{ji}^t 是 “资格向量”, 定义为:

$$\epsilon_{ji}^t = \sum_{t' \leq t} \left(\frac{\partial \mathbf{h}_j^t}{\partial \mathbf{h}_j^{t-1}} \cdots \frac{\partial \mathbf{h}_j^{t'+1}}{\partial \mathbf{h}_j^{t'}} \right) \cdot \frac{\partial \mathbf{h}_j^{t'}}{\partial W_{ji}}.$$

资格向量满足简单的递归方程：

$$\epsilon_{ji}^t = \frac{\partial \mathbf{h}_j^t}{\partial \mathbf{h}_j^{t-1}} \cdot \epsilon_{ji}^{t-1} + \frac{\partial \mathbf{h}_j^t}{\partial W_{ji}},$$

初始 $\epsilon_{ji}^0 = 0$ 。这个递归完全在前向过程中计算，无需存储历史。

c) 3. 定理的严格证明：我们从 BPTT 的经典因子化开始。将 RNN 按时间展开成前馈网络，每个时间步 t' 对应一层，权重共享。对于前馈网络，损失对权重的梯度为：

$$\frac{dE}{dW_{ji}} = \sum_{t'} \frac{dE}{d\mathbf{h}_j^{t'}} \cdot \frac{\partial \mathbf{h}_j^{t'}}{\partial W_{ji}}.$$

这是因为每个时间步的权重副本相同，求和。注意 $\frac{dE}{d\mathbf{h}_j^{t'}}$ 是总导数，考虑了后续时刻的影响。

现在递归展开 $\frac{dE}{d\mathbf{h}_j^{t'}}$ 。在计算图节点 $\mathbf{h}_j^{t'}$ ，它连接到 $z_j^{t'}$ 和 $\mathbf{h}_j^{t'+1}$ ，因此：

$$\frac{dE}{d\mathbf{h}_j^{t'}} = \frac{dE}{dz_j^{t'}} \frac{\partial z_j^{t'}}{\partial \mathbf{h}_j^{t'}} + \frac{dE}{d\mathbf{h}_j^{t'+1}} \frac{\partial \mathbf{h}_j^{t'+1}}{\partial \mathbf{h}_j^{t'}}.$$

定义 $L_j^{t'} = \frac{dE}{dz_j^{t'}}$ ，并继续展开 $\frac{dE}{d\mathbf{h}_j^{t'+1}}$ ，直到最后时间 T （边界为零），得到：

$$\frac{dE}{d\mathbf{h}_j^{t'}} = \sum_{t \geq t'} L_j^t \frac{\partial z_j^t}{\partial \mathbf{h}_j^t} \left(\frac{\partial \mathbf{h}_j^t}{\partial \mathbf{h}_j^{t-1}} \cdots \frac{\partial \mathbf{h}_j^{t'+1}}{\partial \mathbf{h}_j^{t'}} \right).$$

将此代入经典因子化：

$$\frac{dE}{dW_{ji}} = \sum_{t'} \sum_{t \geq t'} L_j^t \frac{\partial z_j^t}{\partial \mathbf{h}_j^t} \left(\prod_{\tau=t'+1}^t \frac{\partial \mathbf{h}_j^\tau}{\partial \mathbf{h}_j^{\tau-1}} \right) \frac{\partial \mathbf{h}_j^{t'}}{\partial W_{ji}}.$$

交换求和顺序（先 t 后 t' ）：

$$\frac{dE}{dW_{ji}} = \sum_t L_j^t \frac{\partial z_j^t}{\partial \mathbf{h}_j^t} \left[\sum_{t' \leq t} \left(\prod_{\tau=t'+1}^t \frac{\partial \mathbf{h}_j^\tau}{\partial \mathbf{h}_j^{\tau-1}} \right) \frac{\partial \mathbf{h}_j^{t'}}{\partial W_{ji}} \right].$$

方括号中的项正是 ϵ_{ji}^t 的定义，因此得到 $\frac{dE}{dW_{ji}} = \sum_t L_j^t \epsilon_{ji}^t$ 。这完成了证明。

d) 4. LIF 神经元资格迹：对于 LIF 神经元，隐藏状态仅为膜电位 v_j^t ，隐藏状态更新为：

$$v_j^{t+1} = \alpha v_j^t + \sum_i W_{ji} z_i^t - z_j^t v_{th}.$$

忽略重置项对导数的贡献（或按公式处理），我们有 $\frac{\partial v_j^{t+1}}{\partial v_j^t} = \alpha$ ， $\frac{\partial v_j^t}{\partial W_{ji}} = z_i^{t-1}$ （近似）。资格向量变为：

$$\epsilon_{ji}^t = \sum_{t' \leq t} \alpha^{t-t'} z_i^{t'-1} = \bar{z}_i^{t-1},$$

即前突触脉冲的低通滤波。脉冲导数 $\frac{\partial z_j^t}{\partial v_j^t}$ 用伪梯度 ψ_j^t 代替，故 $e_{ji}^t = \psi_j^t \bar{z}_i^{t-1}$ 。

e) 5. ALIF 神经元资格迹：ALIF 神经元有适应变量 a_j^t ，阈值 $A_j^t = v_{th} + \beta a_j^t$ ，适应动态 $a_j^{t+1} = \rho a_j^t + z_j^t$ 。隐藏状态为二维。资格向量有两个分量，其中适应分量满足：

$$\epsilon_{ji,a}^{t+1} = \psi_j^t \bar{z}_i^{t-1} + (\rho - \psi_j^t \beta) \epsilon_{ji,a}^t.$$

因为 $\frac{\partial z_j^t}{\partial \mathbf{h}_j^t} = [\psi_j^t, -\beta \psi_j^t]$ ，最终资格迹为：

$$e_{ji}^t = \psi_j^t (\bar{z}_i^{t-1} - \beta \epsilon_{ji,a}^t).$$

这引入了慢分量，使梯度信息能跨越长时延传播。

f) 6. 学习信号变体: 理想学习信号 $L_j^t = \frac{dE}{dz_j^t}$ 需要反向传播。E-prop 使用近似:

- 对称: $L_j^t = \sum_k W_{kj}^{out}(y_k^t - y_k^{*,t})$, 其中 W_{kj}^{out} 是输出权重, y_k^t 是输出神经元的滤波活性。这要求权重对称。
- 随机: $L_j^t = \sum_k B_{jk}(y_k^t - y_k^{*,t})$, B_{jk} 固定随机, 类似反馈对齐。
- 自适应: 在随机基础上, B_{jk} 通过局部可塑性逐渐演化, 模仿对称情况。

g) 7. 奖励基 E-prop: 对于强化学习, 网络输出策略和价值估计。使用奖励预测误差 $\delta^t = r^t + \gamma V^{t+1} - V^t$ 。权重更新为:

$$\Delta W_{ji} = -\eta \sum_t \delta^t \mathcal{F}_\gamma(L_j^t \bar{e}_{ji}^t),$$

其中 $\mathcal{F}_\gamma$ 是折扣因子低通滤波, $\bar{e}_{ji}^t$ 是资格迹的平滑版本。这使 E-prop 适用于深度强化学习任务。

III. RTRL 与 E-PROP 的联系与对比

本部分内容概览

- 数学结构的对比
- 复杂度的对比
- 生物合理性的对比
- 对脉冲神经元的适应性
- 总结与演化关系

PPT 内容:

- 数学结构:
 - RTRL: $\Delta w_{ij}(t) = \alpha \sum_k e_k(t) p_{ij}^k(t)$, p_{ij}^k 为三阶张量。
 - E-prop: $\Delta W_{ji} = -\eta \sum_t L_j^t \bar{e}_{ji}^t$, 分解为学习信号和资格迹。
 - E-prop 可视为 RTRL 的因子化: $p_{ij}^k(t)$ 被分解为 L_j^t 和 $\bar{e}_{ji}^t$ 的乘积 (求和)。
- 复杂度:
 - RTRL: 存储 $O(n^3)$, 计算 $O(n^4)$ (全连接)。
 - E-prop: 存储 $O(S)$ (突触数), 计算 $O(S)$ 。
- 生物合理性:
 - RTRL: 非局部 (需要全局误差和权重矩阵), 不生物。
 - E-prop: 局部资格迹 + 全局学习信号 (类比多巴胺), 更生物合理。
- 适应性:
 - RTRL: 主要针对连续值单元, 不直接适用于脉冲神经元。
 - E-prop: 专为脉冲神经元设计, 包含适应神经元的慢变量。
- 总结: E-prop 是 RTRL 在脉冲网络中的高效、局部、生物合理的演化版本。

讲稿:

a) 1. 数学结构的对比: RTRL 的核心是 $p_{ij}^k(t) = \frac{\partial y_k(t)}{\partial w_{ij}}$, 它是一个三阶张量, 需要追踪每个权重对每个神经元输出的影响。权重更新需要累加所有输出单元的误差 $e_k(t)$ 与相应 p_{ij}^k 的乘积。而 E-prop 通过分解将这种影响分成两部分: 学习信号 L_j^t (仅依赖于神经元 j 的全局影响) 和资格迹 e_{ji}^t (仅依赖突触前后的局部活动)。这样, 原本的 p_{ij}^k 被替换为 $L_j^t \cdot e_{ji}^t$ 在时间上的求和, 大大简化了存储和计算。

b) 2. 复杂度的对比: RTRL 需要存储 n^3 量级的变量 (全连接), 计算每步 $O(n^4)$, 无法扩展。E-prop 只需存储每个突触的资格迹 ($O(S)$, S 为突触数), 计算也仅与突触数线性相关, 这是最优的, 因为模拟网络本身就需要 $O(S)$ 时间。

c) 3. 生物合理性: RTRL 的更新需要每个突触访问所有单元的误差和权重矩阵, 这在大脑中无法实现。E-prop 的资格迹仅依赖于前突触和后突触的局部活动 (如脉冲频率和膜电位), 而学习信号可以是全局的 (如多巴胺释放), 这在生物学上有对应。因此 E-prop 更符合神经可塑性的约束。

d) 4. 对脉冲神经元的适应性: RTRL 最初设计用于连续激活函数, 而脉冲神经元的离散性需要额外的处理 (如伪导数)。E-prop 从头针对脉冲设计, 并且自然地包含了 ALIF 神经元的慢适应变量, 使其能够解决长时间信用分配问题。BPTT 也能处理脉冲网络, 但 RTRL 直接用于脉冲网络会面临更大的计算和导数问题。

e) 5. 总结: E-prop 可以视为 RTRL 在脉冲网络中的高效、局部化、生物合理的演化版本。它继承了 RTRL 的在线学习能力, 但通过重新因子化梯度大幅降低了复杂度, 并适配了脉冲神经元的特性。两者共同为循环网络的在线学习提供了理论基础, 其中 E-prop 更加实用和生物可信。

参考文献

- [1] R. J. Williams and D. Zipser, "A learning algorithm for continually running fully recurrent neural networks," *Neural computation*, vol. 1, no. 2, pp. 270–280, 1989.
- [2] G. Bellec, F. Scherr, A. Subramoney, E. Hajek, D. Salaj, R. Legenstein, and W. Maass, "A solution to the learning dilemma for recurrent networks of spiking neurons," *Nature Communications*, vol. 11, no. 1, p. 3625, Jul. 2020. [Online]. Available: <https://doi.org/10.1038/s41467-020-17236-y>
- [3] M. Xiao, Q. Meng, Z. Zhang, D. He, and Z. Lin, "Online Training Through Time for Spiking Neural Networks," in *Advances in Neural Information Processing Systems*, S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, and A. Oh, Eds., vol. 35. Curran Associates, Inc., 2022, pp. 20717–20730. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2022/file/82846e19e6d42ebfd4ace4361def29ae-Paper-Conference.pdf
- [4] H. Jiang, G. D. Masi, H. Xiong, and B. Gu, "NDOT: Neuronal Dynamics-based Online Training for Spiking Neural..." [Online]. Available: <https://openreview.net/forum?id=elF0QoBSFV>
- [5] M. P. E. Apolinario and K. Roy, "S-TLLR: STDP-inspired Temporal Local Learning Rule for Spiking Neural Networks," Oct. 2024, arXiv:2306.15220 [cs]. [Online]. Available: <http://arxiv.org/abs/2306.15220>
- [6] M. P. E. Apolinario, K. Roy, and C. Frenkel, "TESS: A Scalable Temporally and Spatially Local Learning Rule for Spiking Neural Networks," in *2025 International Joint Conference on Neural Networks (IJCNN)*, Jun. 2025, pp. 1–9, ISSN: 2161-4407. [Online]. Available: <https://ieeexplore.ieee.org/abstract/document/11227652>