

SNN在线与本地学习算法研究汇总

Tao

摘要

SNN在线与本地学习算法研究汇总

文章汇总

RTRL: A learning algorithm for continually running fully recurrent neural networks [1];

E-prop: A solution to the learning dilemma for recurrent networks of spiking neurons [2];

OTTT: Online Training Through Time for Spiking Neural Networks [3];

NDOT: NDOT: Neuronal Dynamics-based Online Training for Spiking Neural Networks [4];

S-TLLR: S-TLLR: STDP-inspired Temporal Local Learning Rule for Spiking Neural Networks [5];

TESS: TESS: A Scalable Temporally and Spatially Local Learning Rule for Spiking Neural Networks [6]

I. INTRODUCTION: 研究背景与问题引入

- 1. SNN 与 ANN 的基本差异
- 2. SNN 训练的核心困难：脉冲的不可求导性质
- 3. 时间依赖性与 credit assignment 问题
- 4. 传统 BPTT/STBP 的基本思想与使用的局限性
- 5. 在线学习与本地学习的研究动机

A. SNN 与 ANN 的基本差异

ANN 使用连续值激活函数：

$$y = f(Wx)$$

SNN 使用事件驱动 spike：

$$s_t = H(u_t - \theta)$$

在 ANN 中，神经元输出通常是一个连续函数，例如 ReLU 或 sigmoid，输出只依赖当前输入。但在 SNN 中，神经元的输出是 spike，即一个离散的0-1事件，由膜电位是否超过阈值决定。

更关键的是，SNN 是一个带状态的动态系统，神经元的膜电位会随时间累积并衰减，因此当前时刻的输出不仅依赖当前输入，还依赖历史输入序列。

这一点使得 SNN 更接近生物神经系统，但也使得训练变得更加复杂。

B. SNN 训练的核心困难（不可导性）

Spike generation function:

$$s_t = H(u_t - \theta)$$

Heaviside function:

$$H(x) = \begin{cases} 1 & x > 0 \\ 0 & x \leq 0 \end{cases}$$

SNN 训练的核心数学障碍。

SNN 的 spike 是由 Heaviside step function 产生的，它是一个离散函数。

这个函数的导数在绝大多数位置都是零，在阈值点又是不可导的，因此无法直接用于梯度下降。

而深度学习的核心优化方法是 gradient descent 梯度下降，因此这构成了 SNN 训练的第一大障碍。

也就是说，我们无法像 ANN 一样直接对 loss function 进行反向传播。

C. 时间依赖性与 credit assignment 问题

- SNN neuron state:

$$u_t = f(u_{t-1}, s_{t-1}, x_t)$$

- 当前输出依赖：
 - 当前输入 x_t
 - 历史膜电位 u_{t-1}
 - 历史 spike s_{t-1}
- 问题：credit assignment over time
- 核心困难：
 - 哪个时间步导致当前 loss?
 - 如何将误差分配到过去?

SNN 的第二个核心困难：时间依赖性。

在 SNN 中，神经元是一个递归动态系统，它的状态由上一时刻的状态决定。

因此当前的输出不仅由当前输入决定，还受到过去所有时间步的影响。

这导致一个关键问题：当我们计算当前 loss 时，无法直接判断是哪一个时间步的输入或状态导致了这个误差。

这就是 temporal credit assignment problem，也就是时间维度上的误差分配问题。

这个问题是后续所有方法（BPTT、RTRL、E-prop 等）的核心出发点。

D. BPTT / STBP 的基本思想与局限

- 基本思想：
 - 将 SNN 沿时间展开
 - 转换为 deep feedforward graph
- STBP:
 - surrogate gradient 解决 spike 不可导问题
 - 结合 BPTT 进行训练
- 优点：
 - 可以直接使用 gradient descent
 - 训练效果较好
- 局限：
 - 需要存储完整时间序列
 - 非在线更新
 - 不适合硬件实现

这一页介绍目前最标准的解决方案：**BPTT** 和 **STBP**。

BPTT 的核心思想是把 SNN 在时间维度展开成一个深度神经网络，然后使用链式法则进行反向传播。

但由于 spike 不可导的问题，需要引入 **STBP**，也就是 surrogate gradient 方法，用一个平滑函数近似 spike 的导数，从而使梯度可以传播。

这种方法的优点是训练效果好，并且可以直接使用现有的深度学习优化框架。

但它的核心问题是必须存储整个时间序列的状态，因此内存消耗随时间增长，并且无法进行实时在线更新。

E. 研究动机：在线学习与本地学习

- BPTT / STBP 的问题：
 - memory cost scales with time
 - not suitable for streaming input
 - not biologically plausible
- 目标1: Online learning
 - update weights at each timestep
 - no need to store full history
- 目标2: Local learning
 - weight update uses only local information
 - no global backpropagation required
- 本报告主线：

BPTT/STBP → Online Learning → Local Learning

这一页总结整个 **Introduction** 的研究动机。

虽然 BPTT 和 STBP 可以有效训练 SNN，但它们存在明显的局限性，包括内存消耗随时间增长、无法进行在线更新，以及与生物神经系统机制不一致。

因此研究主要发展出两个方向。

第一个方向是 online learning，也就是在每个时间步直接更新参数，而不依赖完整历史。

第二个方向是 local learning，也就是权重更新只依赖突触局部可获得的信息，而不需要全局误差信号传播。

本报告的后序内容将围绕这一条演化路径展开，从 BPTT 和 STBP 出发，逐步介绍在线学习方法以及局部学习规则。

II. 脉冲神经网络反向传播算法：BPTT

III. 脉冲神经网络反向传播算法：BPTT

- SNN时空计算图定义 (layer-time coupled graph)
- 膜电位动力学 (state evolution)
- 脉冲生成函数与不可导性
- BPTT完整链式梯度结构 (OTTT一致形式)
- eligibility dependence across time
- surrogate gradient (SG)处理
- STBP的严格定义 (BPTT + SG)
- BPTT计算复杂度与问题

A. 1. SNN时空计算图 (OTTT一致建模)

在OTTT中，SNN被建模为：

$$\{u_i^l[t], s_i^l[t]\}, \quad l = 1, \dots, L, \quad t = 1, \dots, T \quad (1)$$

其中：

- l : 网络层索引
- t : 时间步索引
- $u_i^l[t]$: 膜电位状态
- $s_i^l[t]$: 脉冲输出

—

B. 2. 膜电位动力学 (OTTT标准形式)

OTTT中使用标准离散LIF更新：

$$u_i^l[t] = \lambda u_i^l[t-1] + \sum_j W_{ij}^l s_j^{l-1}[t] - v_{th} s_i^l[t-1] \quad (2)$$

—

C. 3. 脉冲生成函数（不可导核心）

$$s_i^l[t] = H(u_i^l[t] - v_{th}) \quad (3)$$

其中：

$$H(x) = \begin{cases} 1 & x > 0 \\ 0 & x \leq 0 \end{cases} \quad (4)$$

—

D. 4. loss定义（OTTT instantaneous loss）

OTTT采用逐时间步loss：

$$L = \sum_{t=1}^T L[t], \quad L[t] = \mathcal{L}(s^L[t], y) \quad (5)$$

—

E. 5. BPTT核心思想（严格OTTT版本）

BPTT的核心不是简单RNN展开，而是：

同时传播：时间依赖 + 层间依赖 + **spike**非线性依赖

—

F. 6. BPTT完整梯度公式（OTTT核心Eq.）

对权重 W^l ：

$$\frac{\partial L}{\partial W^l} = \sum_{t=1}^T \frac{\partial L}{\partial s^l[t]} \frac{\partial s^l[t]}{\partial u^l[t]} \frac{\partial u^l[t]}{\partial W^l} \quad (6)$$

—

G. 7. 时间依赖展开（关键考核点）

OTTT强调：

$$\frac{\partial u^l[t]}{\partial W^l} = \sum_{\tau=1}^t \frac{\partial u^l[t]}{\partial u^l[\tau]} \frac{\partial u^l[\tau]}{\partial W^l} \quad (7)$$

—

含义解释（导师重点问）：

- τ ：过去时间对当前状态的影响
- $\frac{\partial u[t]}{\partial u[\tau]}$ ：temporal dependency kernel
- 该项导致必须存储全时间轨迹

—

H. 8. 层间传播结构 (*spatial BPTT*)

$$\frac{\partial u^{l+1}[t]}{\partial u^l[t]} = W^l \cdot \sigma'(u^l[t]) \quad (8)$$

因此完整梯度路径是：

time unfolding + layer unfolding + nonlinear spike path

—

I. 9. *surrogate gradient* (OTTT一致写法)

由于：

$$\frac{\partial s^l[t]}{\partial u^l[t]} = 0 \quad (\text{a.e.}) \quad (9)$$

替换为：

$$\frac{\partial s^l[t]}{\partial u^l[t]} \approx \sigma'(u^l[t] - v_{th}) \quad (10)$$

—

J. 10. *STBP*的严格定义 (非常重要)

在严格意义上：

$$\text{STBP} = \text{BPTT} + \text{Surrogate Gradient} \quad (11)$$

但注意：

- STBP不是OTTT中的核心术语
- OT TT统一使用 BPTT + SG 表达
- STBP属于工程/综述性命名

—

K. 11. *BPTT*的核心问题 (OTTT动机)

- 需要存储全部 $\{u[t], s[t]\}_{t=1}^T$
- memory complexity: $\mathcal{O}(T)$
- 不能在线更新 (non-streaming)
- temporal dependency fully coupled

—

L. 12. 总结（导师问答版）

- BPTT = time + layer + nonlinear spike unfolding
- gradient depends on full history $\tau \leq t$
- surrogate gradient only fixes differentiability
- OTTT builds on this full BPTT formulation

IV. RTRL 与 E-PROP: 从 BPTT 到在线学习

V. OTTT 与 NDOT: 针对 SNN 的在线训练方法

VI. S-TLLR 与 TESS: 时间本地化与空间本地化学习

参考文献

- [1] R. J. Williams and D. Zipser, "A learning algorithm for continually running fully recurrent neural networks," *Neural computation*, vol. 1, no. 2, pp. 270–280, 1989.
- [2] G. Bellec, F. Scherr, A. Subramoney, E. Hajek, D. Salaj, R. Legenstein, and W. Maass, "A solution to the learning dilemma for recurrent networks of spiking neurons," *Nature Communications*, vol. 11, no. 1, p. 3625, Jul. 2020. [Online]. Available: <https://doi.org/10.1038/s41467-020-17236-y>
- [3] M. Xiao, Q. Meng, Z. Zhang, D. He, and Z. Lin, "Online Training Through Time for Spiking Neural Networks," in *Advances in Neural Information Processing Systems*, S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, and A. Oh, Eds., vol. 35. Curran Associates, Inc., 2022, pp. 20 717–20 730. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2022/file/82846e19e6d42ebfd4ace4361def29ae-Paper-Conference.pdf
- [4] H. Jiang, G. D. Masi, H. Xiong, and B. Gu, "NDOT: Neuronal Dynamics-based Online Training for Spiking Neural..." [Online]. Available: <https://openreview.net/forum?id=elF0QoBSFV>
- [5] M. P. E. Apolinario and K. Roy, "S-TLLR: STDP-inspired Temporal Local Learning Rule for Spiking Neural Networks," Oct. 2024, arXiv:2306.15220 [cs]. [Online]. Available: <http://arxiv.org/abs/2306.15220>
- [6] M. P. E. Apolinario, K. Roy, and C. Frenkel, "TESS: A Scalable Temporally and Spatially Local Learning Rule for Spiking Neural Networks," in *2025 International Joint Conference on Neural Networks (IJCNN)*, Jun. 2025, pp. 1–9, iSSN: 2161-4407. [Online]. Available: <https://ieeexplore.ieee.org/abstract/document/11227652>