

SNN在线与本地学习算法研究汇总

Tao

摘要

SNN在线与本地学习算法研究汇总

文章汇总

RTRL: A learning algorithm for continually running fully recurrent neural networks [1];

E-prop: A solution to the learning dilemma for recurrent networks of spiking neurons [2];

OTTT: Online Training Through Time for Spiking Neural Networks [3];

NDOT: NDOT: Neuronal Dynamics-based Online Training for Spiking Neural Networks [4];

S-TLLR: S-TLLR: STDP-inspired Temporal Local Learning Rule for Spiking Neural Networks [5];

TESS: TESS: A Scalable Temporally and Spatially Local Learning Rule for Spiking Neural Networks [6]

I. INTRODUCTION: 研究背景与问题引入

- 1. SNN 与 ANN 的基本差异
- 2. SNN 训练的核心困难：脉冲的不可求导性质
- 3. 时间依赖性与 credit assignment 问题
- 4. 传统 BPTT/STBP 的基本思想与使用的局限性
- 5. 在线学习与本地学习的研究动机

A. SNN 与 ANN 的基本差异

ANN 使用连续值激活函数：

$$y = f(Wx)$$

SNN 使用事件驱动 spike：

$$s_t = H(u_t - \theta)$$

在 ANN 中，神经元输出通常是一个连续函数，例如 ReLU 或 sigmoid，输出只依赖当前输入。但在 SNN 中，神经元的输出是 spike，即一个离散的0-1事件，由膜电位是否超过阈值决定。

更关键的是，SNN 是一个带状态的动态系统，神经元的膜电位会随时间累积并衰减，因此当前时刻的输出不仅依赖当前输入，还依赖历史输入序列。

这一点使得 SNN 更接近生物神经系统，但也使得训练变得更加复杂。

B. SNN 训练的核心困难（不可导性）

Spike generation function:

$$s_t = H(u_t - \theta)$$

Heaviside function:

$$H(x) = \begin{cases} 1 & x > 0 \\ 0 & x \leq 0 \end{cases}$$

SNN 训练的核心数学障碍。

SNN 的 spike 是由 Heaviside step function 产生的，它是一个离散函数。

这个函数的导数在绝大多数位置都是零，在阈值点又是不可导的，因此无法直接用于梯度下降。

而深度学习的核心优化方法是 gradient descent 梯度下降，因此这构成了 SNN 训练的第一大障碍。

也就是说，我们无法像 ANN 一样直接对 loss function 进行反向传播。

C. 时间依赖性与 credit assignment 问题

- SNN neuron state:

$$u_t = f(u_{t-1}, s_{t-1}, x_t)$$

- 当前输出依赖：
 - 当前输入 x_t
 - 历史膜电位 u_{t-1}
 - 历史 spike s_{t-1}
- 问题：credit assignment over time
- 核心困难：
 - 哪个时间步导致当前 loss?
 - 如何将误差分配到过去?

SNN 的第二个核心困难：时间依赖性。

在 SNN 中，神经元是一个递归动态系统，它的状态由上一时刻的状态决定。

因此当前的输出不仅由当前输入决定，还受到过去所有时间步的影响。

这导致一个关键问题：当我们计算当前 loss 时，无法直接判断是哪一个时间步的输入或状态导致了这个误差。

这就是 temporal credit assignment problem，也就是时间维度上的误差分配问题。

这个问题是后续所有方法（BPTT、RTRL、E-prop 等）的核心出发点。

D. BPTT / STBP 的基本思想与局限

- 基本思想：
 - 将 SNN 沿时间展开
 - 转换为 deep feedforward graph
- STBP:
 - surrogate gradient 解决 spike 不可导问题
 - 结合 BPTT 进行训练
- 优点：
 - 可以直接使用 gradient descent
 - 训练效果较好
- 局限：
 - 需要存储完整时间序列
 - 非在线更新
 - 不适合硬件实现

这一页介绍目前最标准的解决方案：**BPTT** 和 **STBP**。

BPTT 的核心思想是把 SNN 在时间维度展开成一个深度神经网络，然后使用链式法则进行反向传播。

但由于 spike 不可导的问题，需要引入 STBP，也就是 surrogate gradient 方法，用一个平滑函数近似 spike 的导数，从而使梯度可以传播。

这种方法的优点是训练效果好，并且可以直接使用现有的深度学习优化框架。

但它的核心问题是必须存储整个时间序列的状态，因此内存消耗随时间增长，并且无法进行实时在线更新。

E. 研究动机：在线学习与本地学习

- BPTT / STBP 的问题：
 - memory cost scales with time
 - not suitable for streaming input
 - not biologically plausible
- 目标1: Online learning
 - update weights at each timestep
 - no need to store full history
- 目标2: Local learning
 - weight update uses only local information
 - no global backpropagation required
- 本报告主线：

BPTT/STBP → Online Learning → Local Learning

这一页总结整个 **Introduction** 的研究动机。

虽然 BPTT 和 STBP 可以有效训练 SNN，但它们存在明显的局限性，包括内存消耗随时间增长、无法进行在线更新，以及与生物神经系统机制不一致。

因此研究主要发展出两个方向。

第一个方向是 online learning，也就是在每个时间步直接更新参数，而不依赖完整历史。

第二个方向是 local learning，也就是权重更新只依赖突触局部可获得的信息，而不需要全局误差信号传播。

本报告的后序内容将围绕这一条演化路径展开，从 BPTT 和 STBP 出发，逐步介绍在线学习方法以及局部学习规则。

II. 脉冲神经网络反向传播算法：BPTT

$$\frac{\partial L}{\partial \mathbf{W}^l} = \sum_{t=1}^T \frac{\partial L}{\partial \mathbf{s}^{l+1}[t]} \frac{\partial \mathbf{s}^{l+1}[t]}{\partial \mathbf{u}^{l+1}[t]} \left(\frac{\partial \mathbf{u}^{l+1}[t]}{\partial \mathbf{W}^l} + \sum_{\tau < t} \prod_{i=\tau-1}^{\tau} \left(\frac{\partial \mathbf{u}^{l+1}[i+1]}{\partial \mathbf{u}^{l+1}[i]} + \frac{\partial \mathbf{u}^{l+1}[i+1]}{\partial \mathbf{s}^{l+1}[i]} \frac{\partial \mathbf{s}^{l+1}[i]}{\partial \mathbf{u}^{l+1}[i]} \right) \frac{\partial \mathbf{u}^{l+1}[\tau]}{\partial \mathbf{W}^l} \right), \quad (1)$$

[3];

$$\frac{\partial \mathbf{u}^{l+1}[i+1]}{\partial \mathbf{u}^{l+1}[i]} + \frac{\partial \mathbf{u}^{l+1}[i+1]}{\partial \mathbf{s}^{l+1}[i]} \frac{\partial \mathbf{s}^{l+1}[i]}{\partial \mathbf{u}^{l+1}[i]} \quad (2)$$

$$\frac{d\mathbf{u}^{l+1}[i+1]}{d\mathbf{u}^{l+1}[i]} = \frac{\partial \mathbf{u}^{l+1}[i+1]}{\partial \mathbf{u}^{l+1}[i]} + \frac{\partial \mathbf{u}^{l+1}[i+1]}{\partial \mathbf{s}^{l+1}[i]} \cdot \frac{\partial \mathbf{s}^{l+1}[i]}{\partial \mathbf{u}^{l+1}[i]}$$

代入 LIF 动力学后展开为：

$$\frac{d\mathbf{u}^{l+1}[i+1]}{d\mathbf{u}^{l+1}[i]} = \lambda \mathbf{I} - \lambda V_{th} \mathbf{I} \cdot \sigma'(\mathbf{u}^{l+1}[i] - V_{th})$$

本部分核心结构

1. 前向时空动态与LIF离散方程
2. BPTT完整梯度公式（含颜色标记）
3. 公式拆解：误差传入、当前直连项
4. 公式拆解：时间传播核（泄漏 vs 重置路径）
5. 代理梯度（SG）、STBP严格定义及BPTT固有瓶颈

PPT 1: 前向时空动态与不可微源头

a) **PPT内容要点：**

- 时空参数：层索引 l ，时间步 t 。
- 神经元状态：膜电位 $u_i^l[t]$ ，脉冲 $s_i^l[t]$ 。
- LIF离散动力学（泄漏 + 硬重置）与脉冲生成（阶跃函数，不可导）：

$$\begin{cases} u_i[t+1] = \lambda(u_i[t] - V_{th}s_i[t]) + \sum_j w_{ij}s_j[t] + b_i, \\ s_i[t+1] = H(u_i[t+1] - V_{th}), \end{cases} \quad (3)$$

b) 讲稿：

- 训练时网络沿时间和空间双向展开，构成时空计算图。
- 每个节点由 (u, s) 描述，更新遵循LIF方程。
- 方程含两项传播机制：泄漏项 λu （记忆衰减）与重置项 $-V_{th}s$ （硬复位）。
- 脉冲函数 H 几乎处处导数为0，此为BPTT需代理梯度的根本原因。

PPT 2: BPTT完整梯度公式（标准形式）

c) PPT内容要点：

- 损失定义：

$$L[t] = \frac{1}{T} \mathcal{L}(s^N[t], y), L = \sum_{t=1}^T L[t] \quad (4)$$

- 对权重 $\mathbf{W}^l$ 的梯度（论文式(3)）：

$$\frac{\partial L}{\partial \mathbf{W}^l} = \sum_{t=1}^T \frac{\partial L}{\partial \mathbf{s}^{l+1}[t]} \cdot \frac{\partial \mathbf{s}^{l+1}[t]}{\partial \mathbf{u}^{l+1}[t]} \cdot \left(\frac{\partial \mathbf{u}^{l+1}[t]}{\partial \mathbf{W}^l} + \sum_{\tau < t} \left[\prod_{i=\tau}^{t-1} \left(\frac{\partial \mathbf{u}^{l+1}[i+1]}{\partial \mathbf{u}^{l+1}[i]} + \frac{\partial \mathbf{u}^{l+1}[i+1]}{\partial \mathbf{s}^{l+1}[i]} \cdot \frac{\partial \mathbf{s}^{l+1}[i]}{\partial \mathbf{u}^{l+1}[i]} \right) \right] \cdot \frac{\partial \mathbf{u}^{l+1}[\tau]}{\partial \mathbf{W}^l} \right)$$

d) 讲稿：

- 公式总体大结构：外层对 t 求和，根据上述的 $L = \sum_{t=1}^T L[t]$ ，内部由“当前的膜电位的贡献”与“历史回溯的膜电位的贡献”相加。
- 红色项 $\frac{\partial s}{\partial u}$ ：脉冲对膜电位的敏感度（不可导，后续用代理梯度替代）。
- 绿色项 $\frac{\partial u[i+1]}{\partial u[i]}$ ：膜电位随着时间自动地进行衰减，等于 $\lambda \mathbf{I}$ （泄漏路径）。
- 青色项 $\frac{\partial u[i+1]}{\partial s[i]}$ ：脉冲对下一时刻膜电位的影响，等于 $-\lambda V_{th} \mathbf{I}$ （重置路径）。
- $\text{CyanPart} \times \text{RedPart} + \text{GreenPart}$ 两项在连乘内相加，代表误差沿时间的两条并行传播通道。

PPT 3: $\frac{\partial L}{\partial \mathbf{W}^l}$ 的完整传播路径与“当前直连项”

e) PPT内容要点：

- 计算目标：损失 L 对第 l 层权重 $\mathbf{W}^l$ 的梯度。该权重连接上游层 l （脉冲 s^l ）与下游层 $l+1$ （膜电位 $\mathbf{u}^{l+1}$ ）；
- 时间下标约定：严格按公式， $\mathbf{u}^{l+1}[t+1]$ 由 $s^l[t]$ 驱动。用 t 表示当前响应时刻。因此梯度公式中写为 $\frac{\partial \mathbf{u}^{l+1}[t]}{\partial \mathbf{W}^l} = s^l[t]$ ；
- 外层求和 $\sum_{t=1}^T$ ：权重在所有时刻共享，需累加各时刻的梯度贡献。
- 误差传入项 $\frac{\partial L}{\partial \mathbf{s}^{l+1}[t]}$ ：由输出层通过空间反向传播（层间BP）递推到节点 $(l+1, t)$ 的脉冲端。
- 红色代理梯度 $\frac{\partial s}{\partial u}$ ：在同一节点 $(l+1, t)$ 内部，将误差从“脉冲”映射到“膜电位”。
- 当前直连项 $\frac{\partial \mathbf{u}^{l+1}[t]}{\partial \mathbf{W}^l} = s^l[t]$ ：空间上的直接传播。由上游节点 (l, t) 的脉冲，通过权重 $\mathbf{W}^l$ 直接传到下游节点 $(l+1, t)$ 的膜电位。
- 无时间回溯：当前项只依赖当前时刻输入 $s^l[t]$ ，不含 $\prod$ 或 $\sum_{\tau < t}$ ，纯空间部分

f) 讲稿：：

- 整个梯度刻画的是：上游层 l 在所有时刻的脉冲，如何通过权重影响下游层 $l+1$ 的膜电位，并最终改变损失。
- 为统一符号，论文将层间延迟吸收进时间索引，故 $\frac{\partial u^{l+1}[t]}{\partial W^l} = s^l[t]$ 在约定下精确成立。
- 当前项的计算路径：节点 (l, t) 脉冲 $\xrightarrow{W^l}$ 节点 $(l+1, t)$ 膜电位。
- 反向传播时：高层误差 $\frac{\partial L}{\partial s^{l+1}[t]}$ 到达节点 $(l+1, t)$ 脉冲端。
- 乘以红色代理梯度，将误差从脉冲传至同一节点的膜电位。
- 随后该膜电位误差乘以 $\frac{\partial u^{l+1}[t]}{\partial s^l[t]} = W^l$ ，沿空间反向传回上层节点 (l, t) 的脉冲端。
- 当前项不含连乘或历史求和，因为膜电位对权重的直接导数只依赖当前输入脉冲，不依赖过去状态。
- 整体相乘因子为：误差项 $\times$ 代理梯度 $\times$ 当前输入脉冲。

PPT 4: 公式拆解（核心）—— 时间传播核与“相乘、相加”的数学本质

g) PPT内容要点：：

- 历史回溯项结构：

$$\sum_{\tau < t} \left[\prod_{i=t-1}^{\tau} (\lambda \mathbf{I} + (-\lambda V_{th} \mathbf{I}) \cdot \sigma') \right] \cdot \frac{\partial u[\tau]}{\partial W}$$

- 节点传播路径（时间维度）：同一层 $l+1$ 内部，历史时刻 τ 的膜电位节点 $u[\tau]$ ，通过神经元内部动态，一步一步传播到当前时刻 t 的膜电位节点 $u[t]$ 。
- 足迹项 $\frac{\partial u[\tau]}{\partial W} = s[\tau]$ ：历史时刻上游输入的脉冲。
- 相乘（ $\prod$ ）：链式法则：从 τ 到 t 必须经过中间所有时刻 $t-1, t-2, \dots, \tau$ ，复合函数嵌套求导，根据链式法则，连续相乘。
- 括号内相加（+）：全微分：同一个时间步 $i \rightarrow i+1$ 膜电位更新包含两项：

$$u[i+1] = \lambda u[i] - \lambda V_{th} s[i] + \dots$$

$u[i+1]$ 对 $u[i]$ 的依赖有两条并行路径：直接泄漏（绿色）和通过脉冲的间接重置（青色 $\times$ 红色）。两路径同时存在，总导数为二者之和（全微分公式： $\frac{dz}{dx} = \frac{\partial z}{\partial x} + \frac{\partial z}{\partial y} \frac{dy}{dx}$ ）。

- 外层求和（ $\sum_{\tau < t}$ ）：所有历史时刻 $\tau = 1, \dots, t-1$ 都是独立的源头，各自通过时序核影响当前，总贡献为各源头之和。
- 青色项精确值（依据本论文公式(2)）：

$$\frac{\partial u[i+1]}{\partial s[i]} = -\lambda V_{th} \mathbf{I}$$

（对线性重置项 $-\lambda V_{th} s[i]$ 直接求导）

h) 讲稿：：

- 历史回溯项计算的是：过去时刻 τ 的输入脉冲，经过下游神经元内部时间演化，对当前时刻 t 膜电位的影响。
- 节点路径：同一层内部 $u[\tau] \rightarrow u[\tau+1] \rightarrow \dots \rightarrow u[t]$ 。

- 为什么有连乘 ($\prod$)? 因为时间推进是顺序发生的, 复合函数链式法则要求每一步的局部导数连续相乘。这就是“串联”关系。
- 为什么括号内是相加 (+)? 因为在相邻时间步 $i \rightarrow i+1$ 中, 膜电位受两种并行物理机制控制: 泄漏 (绿色) 和重置 (青色 $\times$ 红色)。二者互不排斥, 同时作用。根据全微分原理, 总传播系数等于各路径贡献的线性叠加。这就是“并联”关系。
- 青色项严格等于 $-\lambda V_{th}$ 。注意: 这不是对阶跃函数求导, 而是对线性项 $-\lambda V_{th}s[i]$ 求导, 自变量是 s , 故直接得常数。
- 外层求和 ($\sum_{\tau < t}$) 是因为每个历史时刻都是独立的误差源头, 总影响是各源头贡献的总和。

PPT 5: 代理梯度 (SG)、STBP严格定义与BPTT固有瓶颈

i) PPT内容要点:

- 代理梯度 (Surrogate Gradient) 的数学形式: 因 $\frac{\partial s}{\partial u} = 0$ (a.e.), 反向传播时用光滑函数导数替代。常用形式:

$$\sigma'(x) = \frac{1}{a} \text{sign} \left(|x - V_{th}| < \frac{a}{2} \right) \quad \text{或} \quad \sigma'(x) = \frac{1}{a} \frac{e^{(V_{th}-x)/a}}{(1 + e^{(V_{th}-x)/a})^2}.$$

- 使用范围: 代理梯度仅用于反向传播 (红色项), 前向传播仍为原始阶跃函数, 不改变脉冲离散性。
- STBP的严格学术定义:

STBP (Spatio-Temporal Backpropagation) $\equiv$ BPTT + Surrogate Gradient (SG).

STBP并非独立新算法, 而是BPTT在SNN场景下的工程化命名, 其核心特征为完整的时间展开配合代理梯度。

• BPTT的固有瓶颈:

- 内存复杂度 $\mathcal{O}(T)$: 反向传播时必须存储全部时刻的膜电位 $u[t]$ 和脉冲 $s[t]$, 以计算时序核连乘。
- 非流式 (Non-streaming): 必须等整个长度为 T 的序列处理完毕后才能计算梯度并更新权重, 无法在线学习。
- 无法适配神经形态硬件: 生物神经系统和Loihi等芯片要求逐时刻实时更新, BPTT的批处理特性与之矛盾。

j) 讲稿:

- 代理梯度是解决脉冲函数不可导的必要工程近似, 仅反向使用, 不影响前向计算。
- STBP在严格意义上就是BPTT配合代理梯度, 二者数学等价, 只是命名侧重点不同。
- BPTT的核心问题来源于时序核的连乘结构, 必须存储全轨迹, 内存随 T 线性增长。
- BPTT需整段序列处理完才能更新, 属于离线批处理, 与生物在线学习机制不兼容。
- OTTT通过丢弃重置耦合路径, 将双向时序回溯简化为前向指数衰减累积, 从而打破 $\mathcal{O}(T)$ 内存限制并支持逐时刻更新。
- 理解标准BPTT的这些瓶颈, 是理解OTTT贡献的绝对前提。

总结

- BPTT完整保留泄漏与重置两条时间传播路径。
- 代理梯度唯一负责处理脉冲不可导性。
- 理解BPTT的每一项是理解OTTT改进的前提。

III. OTTT 与 NDOT: 针对 SNN 的在线训练方法

本部分核心结构

- 1 **BPTT 标准形式与核心瓶颈**: 时间展开、代理梯度依赖、 $\mathcal{O}(T)$ 内存。
- 2 **OTTT 的近似解耦**: 丢弃重置路径, 时序核退化为固定 $\lambda^{t-\tau}$, 实现 $\mathcal{O}(1)$ 在线学习。
- 3 **NDOT 的物理重参数化**: 从连续 LIF 微分方程导出动态比值 $e[t]$, 替代固定 λ 。
- 4 **NDOT 完整推导 (Appendix A.1)**: 动态核 $\mathbf{P}_{k,t}$ 的化简与递推公式的严格证明。
- 5 **本质区别汇总**: 固定衰减 vs. 动态比值、近似 vs. 精确、变量定义对照表。

PPT 1: BPTT 标准形式与核心瓶颈

a) *PPT*内容要点 (含完整变量定义): :

- 离散 LIF 动力学:

$$\mathbf{u}^l[t+1] = \lambda(\mathbf{u}^l[t] - V_{th}\mathbf{s}^l[t]) + \mathbf{W}^l\mathbf{s}^{l-1}[t+1]$$

其中 $\mathbf{u}^l[t]$ 为第 l 层 t 时刻膜电位, $\mathbf{s}^l[t]$ 为脉冲, λ 为泄漏常数, V_{th} 为阈值, $\mathbf{W}^l$ 为待训练权重。

- BPTT 标准梯度公式:

$$\frac{\partial L}{\partial \mathbf{W}^l} = \sum_{t=1}^T \frac{\partial L}{\partial \mathbf{s}^{l+1}[t]} \frac{\partial \mathbf{s}^{l+1}[t]}{\partial \mathbf{u}^{l+1}[t]} \left(\frac{\partial \mathbf{u}^{l+1}[t]}{\partial \mathbf{W}^l} + \sum_{\tau < t} \prod_{i=t-1}^{\tau} \left(\frac{\partial \mathbf{u}^{l+1}[i+1]}{\partial \mathbf{u}^{l+1}[i]} + \frac{\partial \mathbf{u}^{l+1}[i+1]}{\partial \mathbf{s}^{l+1}[i]} \frac{\partial \mathbf{s}^{l+1}[i]}{\partial \mathbf{u}^{l+1}[i]} \right) \frac{\partial \mathbf{u}^{l+1}[\tau]}{\partial \mathbf{W}^l} \right)$$

- 各项精确定义:

- 红色项 $\frac{\partial \mathbf{s}}{\partial \mathbf{u}}$: 脉冲发放函数对膜电位的导数 (Heaviside 不可微, 需代理梯度 SG)。
- 绿色项 $\frac{\partial \mathbf{u}[i+1]}{\partial \mathbf{u}[i]}$: 膜电位自传播, 严格等于 $\lambda \mathbf{I}$ (泄漏路径)。
- 青色项 $\frac{\partial \mathbf{u}[i+1]}{\partial \mathbf{s}[i]}$: 脉冲对下一时刻膜电位的直接影响, 严格等于 $-\lambda V_{th} \mathbf{I}$ (重置路径)。

- BPTT 两大瓶颈:

- 1) 时序连乘中因含 $\frac{\partial \mathbf{s}}{\partial \mathbf{u}}$, 必须使用代理梯度 (近似, 理论不清晰)。
- 2) 需存储全部 T 个时刻的 $\mathbf{u}$ 和 $\mathbf{s}$ 以计算连乘, 内存复杂度 $\mathcal{O}(T)$, 且无法在线更新。

b) 讲稿：

- 离散 LIF 动力学由泄漏项、重置项、输入项三部分构成。
- BPTT 展开后，梯度包含“当前直接贡献”与“历史回溯贡献”两部分。
- 历史回溯中的连乘每步含两条路径：绿色（泄漏）和青色×红色（重置耦合）。
- 红色项因不可微必须用 SG，是 BPTT 近似性的根源。
- 连乘结构迫使反向传播时必须访问所有历史状态，导致内存随 T 线性增长。

PPT 2: OTTT 的近似解耦与递推实现

c) PPT 内容要点（含完整推导）：

- **核心近似：**在时序连乘中，不对红色项施加代理梯度，而是直接使用其真实导数（几乎处处为 0）：

$$\frac{\partial \mathbf{u}[i+1]}{\partial \mathbf{s}[i]} \frac{\partial \mathbf{s}[i]}{\partial \mathbf{u}[i]} \approx 0 \implies \prod_{i=\tau}^{t-1} (\lambda \mathbf{I} + 0) = \lambda^{t-\tau} \mathbf{I}$$

- 简化后的梯度公式 [3]:

$$\frac{\partial L}{\partial \mathbf{W}^l} = \sum_{t=1}^T \frac{\partial L}{\partial \mathbf{s}^{l+1}[t]} \frac{\partial \mathbf{s}^{l+1}[t]}{\partial \mathbf{u}^{l+1}[t]} \left(\sum_{\tau \leq t} \lambda^{t-\tau} \frac{\partial \mathbf{u}^{l+1}[\tau]}{\partial \mathbf{W}^l} \right)$$

- 定义追踪变量 $\hat{\mathbf{a}}^l[t]$ （突触前活动踪迹）：

$$\hat{\mathbf{a}}^l[t] \triangleq \sum_{\tau=1}^t \lambda^{t-\tau} \mathbf{s}^l[\tau]$$

由于 $\frac{\partial \mathbf{u}^{l+1}[\tau]}{\partial \mathbf{W}^l} = \mathbf{s}^l[\tau]$ （对权重的直接偏导等于输入脉冲），上式可重写为：

$$\nabla_{\mathbf{W}^l} L = \sum_{t=1}^T \mathbf{g}_{\mathbf{u}^{l+1}}[t] (\hat{\mathbf{a}}^l[t])^\top$$

其中 $\mathbf{g}_{\mathbf{u}^{l+1}}[t] = \left(\frac{\partial L}{\partial \mathbf{s}^{l+1}[t]} \frac{\partial \mathbf{s}^{l+1}[t]}{\partial \mathbf{u}^{l+1}[t]} \right)^\top$ 为空间梯度。

- 前向递推（在线计算）：

$$\hat{\mathbf{a}}^l[t] = \lambda \hat{\mathbf{a}}^l[t-1] + \mathbf{s}^l[t]$$

此式仅依赖上一时刻的 $\hat{\mathbf{a}}$ ，无需存储历史轨迹。

- **OTTT 简化效果：**

- 时序依赖退化为固定指数衰减 $\lambda^{t-\tau}$ 。
- 内存复杂度降至 $\mathcal{O}(1)$ （与 T 无关）。
- 红色项仅在空间传播入口处保留（仍用 SG），时序回溯中完全消除。

d) 讲稿：

- OTTT 将连乘中的重置路径直接置零，因为其依赖的代理梯度不可靠。
- 时序核简化为纯泄漏 $\lambda^{t-\tau}$ ，成为固定常数衰减。
- 定义追踪变量 $\hat{a}[t]$ 为历史输入脉冲的加权和，权重为 $\lambda^{t-\tau}$ 。
- 利用 $\frac{\partial u[\tau]}{\partial W} = s[\tau]$ ，梯度可分解为空间梯度 $\mathbf{g}$ 与追踪变量 $\hat{a}$ 的外积。
- $\hat{a}$ 可前向递推计算，只需保留上一时刻值，实现常数内存。
- 但固定 λ 无法反映神经元状态的实际波动，这是 OTTT 的精度瓶颈。

PPT 3: NDOT 的物理重参数化—— $e[t]$ 的严格推导

e) **PPT**: :

- **OTTT 的局限**: 固定 λ 是常数, 但神经元膜电位的实际演化受充电、泄漏、重置共同影响, 衰减率应动态变化。
- **NDOT 核心观点**: 用连续 LIF 微分方程推导出的 $e(t)$, *representing the continuous temporal dependency* 替代固定 λ 。
- **Step 1**: 连续 LIF 方程 [4]:

$$u'(t) = -u(t) + I(t)$$

其中 $I(t)$ 为输入电流。

- **Step 2**: 定义连续时序依赖 $e(t)$ (隐函数关系):

$$e(t) \triangleq \frac{\partial u(t+1)}{\partial u(t)} = \frac{u'(t+1)}{u'(t)}$$

推导依据: 由隐函数定理, $u(t+1)$ 对 $u(t)$ 的偏导等于两者对时间导数之比。

- **Step 3**: 代入 LIF 方程消去 $I(t)$:

$$e(t) = \frac{-u(t+1) + I(t+1)}{-u(t) + I(t)} = \frac{u(t+1) - I(t+1)}{u(t) - I(t)}$$

- **Step 4**: 离散化并代入离散 LIF 方程: 在离散时间步 t , $I[t]$ 满足 $u[t+1] = \lambda(u[t] - V_{th}s[t]) + I[t+1]$ 。因此 $u[t+1] - I[t+1] = \lambda(u[t] - V_{th}s[t])$ 。同时由前一时刻方程 $I[t] = u[t] - \lambda^{-1}u[t-1]$, 代入分母化简得:

$$\mathbf{e}^l[t] = \frac{\mathbf{u}^l[t] - V_{th}\mathbf{s}^l[t]}{\mathbf{u}^l[t-1] - V_{th}\mathbf{s}^l[t-1]}$$

注意: 此式完全不包含代理梯度, 纯为前向可计算的动态比值。

- **变量定义**: $\mathbf{e}^l[t]$ 表示第 l 层从时刻 $t-1$ 到 t 的膜电位状态缩放因子, 是 NDOT 的核心时序核。

f) **讲稿**: :

- OTTT 的固定 λ 是常数, 无法适应膜电位的实际波动。
- NDOT 从连续 LIF 微分方程出发, 利用隐函数关系定义动态敏感度 $e(t)$ 。
- 通过代入连续方程消去输入电流, 再离散化并代入离散 LIF 方程, 最终得到闭式解 $\mathbf{e}[t]$ 。
- $\mathbf{e}[t]$ 是相邻时刻“重置后膜电位”的比值, 完全由前向状态决定。
- 该推导全程无需任何代理梯度, 因此比 OTTT 的固定衰减更忠实于神经元物理。

PPT 4: NDOT 完整梯度推导 (严格依据 Appendix A.1)

g) **PPT 内容要点 (含完整推导链)**: :

- **Step 1**: 定义动态时序传播核 $\mathbf{P}_{k,t}^l$ (NDOT 论文式(9)):

$$\mathbf{P}_{k,t}^l \triangleq \prod_{i=k}^{t-1} \mathbf{e}^l[i] = \mathbf{e}^l[k] \odot \mathbf{e}^l[k+1] \odot \cdots \odot \mathbf{e}^l[t-1]$$

其中 $\odot$ 为逐元素乘法（保持维度匹配）。

- **Step 2:** 代入 $\mathbf{e}[i]$ 并执行化简：

$$\begin{aligned}\mathbf{P}_{k,t}^l &= \frac{u[k] - V_{th}s[k]}{u[k-1] - V_{th}s[k-1]} \odot \frac{u[k+1] - V_{th}s[k+1]}{u[k] - V_{th}s[k]} \odot \dots \odot \frac{u[t-1] - V_{th}s[t-1]}{u[t-2] - V_{th}s[t-2]} \\ &= \frac{\mathbf{u}^l[t-1] - V_{th}\mathbf{s}^l[t-1]}{\mathbf{u}^l[k-1] - V_{th}\mathbf{s}^l[k-1]}\end{aligned}$$

中间项全部抵消，仅剩首尾比值。

- **Step 3:** 定义时序追踪变量 $\hat{\mathbf{a}}^{l-1}[t]$ （NDOT 论文式(11)）：

$$\hat{\mathbf{a}}^{l-1}[t] \triangleq \mathbf{s}^{l-1}[t] + \sum_{k < t} \mathbf{P}_{k,t}^{l-1} \odot \mathbf{s}^{l-1}[k]$$

该变量累加所有历史时刻 k 的输入脉冲，经动态核 $\mathbf{P}_{k,t}$ 缩放后求和。

- **Step 4:** 推导相邻时刻递推关系（Appendix A.1 核心证明）：由定义展开 $\hat{\mathbf{a}}[t-1]$ ：

$$\hat{\mathbf{a}}[t-1] = \mathbf{s}[t-1] + \sum_{k < t-1} \mathbf{P}_{k,t-1} \odot \mathbf{s}[k]$$

利用 $\mathbf{P}_{k,t} = \mathbf{e}[t-1] \odot \mathbf{P}_{k,t-1}$ （核递推性质）：

$$\begin{aligned}\mathbf{e}[t-1] \odot \hat{\mathbf{a}}[t-1] &= \mathbf{e}[t-1] \odot \mathbf{s}[t-1] + \sum_{k < t-1} \mathbf{P}_{k,t} \odot \mathbf{s}[k] \\ &= \mathbf{P}_{t-1,t} \odot \mathbf{s}[t-1] + \sum_{k < t-1} \mathbf{P}_{k,t} \odot \mathbf{s}[k] \\ &= \sum_{k < t} \mathbf{P}_{k,t} \odot \mathbf{s}[k]\end{aligned}$$

因此：

$$\hat{\mathbf{a}}^l[t] = \mathbf{e}^l[t-1] \odot \hat{\mathbf{a}}^l[t-1] + \mathbf{s}^l[t]$$

- **Step 5:** 完整梯度公式（NDOT 论文式(10)）：

$$\nabla_{\mathbf{W}^l} \mathcal{L} = \sum_{t=1}^T \mathbf{g}_{\mathbf{u}^l}[t] (\hat{\mathbf{a}}^{l-1}[t])^\top$$

其中 $\mathbf{g}_{\mathbf{u}^l}[t] = \left(\frac{\partial \mathcal{L}}{\partial \mathbf{s}^l[t]} \frac{\partial \mathbf{s}^l[t]}{\partial \mathbf{u}^l[t]} \right)^\top$ 为空间梯度（仍含 SG）。

h) 讲稿：

- NDOT 定义动态核 $\mathbf{P}_{k,t}$ 为 $\mathbf{e}$ 的连乘，替代 OTTT 的 $\lambda^{t-\tau}$ 。
- 因 $\mathbf{e}$ 是分式比值，连乘形成效应，化简为首尾比值，极大简化计算。
- 定义追踪变量 $\hat{\mathbf{a}}[t]$ 为所有历史脉冲经动态核缩放后的总和。
- 利用 $\mathbf{P}_{k,t}$ 的递推性质，严格推导出 $\hat{\mathbf{a}}[t] = \mathbf{e}[t-1] \odot \hat{\mathbf{a}}[t-1] + \mathbf{s}[t]$ 。
- 该递推式与 OTTT 形式一致，但核心系数从固定 λ 换为动态 $\mathbf{e}[t-1]$ 。
- 最终梯度分解为空间梯度 $\mathbf{g}$ 与追踪变量 $\hat{\mathbf{a}}$ 的外积，实现 $\mathcal{O}(1)$ 在线计算。

PPT 5: OTTT 与 NDOT 本质区别汇总

i) PPT内容要点（单条目对照）：

- 时序核（单步）：
 - OTTT: $\epsilon[i] = \lambda$, 固定常数。
 - NDOT: $e[i] = \frac{u[i] - V_{th}s[i]}{u[i-1] - V_{th}s[i-1]}$, 动态状态比值。
- 历史传播核：
 - OTTT: λ^{t-k} , 固定指数衰减。
 - NDOT: $P_{k,t} = \prod_{i=k}^{t-1} e[i] = \frac{u[t-1] - V_{th}s[t-1]}{u[k-1] - V_{th}s[k-1]}$, 动态化简。
- 追踪变量递推：
 - OTTT: $\hat{a}[t] = \lambda \hat{a}[t-1] + s[t]$ 。
 - NDOT: $\hat{a}[t] = e[t-1] \odot \hat{a}[t-1] + s[t]$ 。
- 额外存储：
 - OTTT: 无。
 - NDOT: 需存 $u[t] - V_{th}s[t]$ 以计算 $e[t]$ 。
- 方法论本质：
 - OTTT: 对 BPTT 做近似删除（丢弃重置路径），时序退化为固定衰减。
 - NDOT: 对 BPTT 做物理重参数化（用连续动力学比值 e 替代离散近似 ϵ ），时序核变为动态状态比值。

j) 共同基础：

- 均实现 $\mathcal{O}(1)$ 内存与在线更新。
- 梯度最终形式均为 $\nabla L[t] = \mathbf{g}[t](\hat{a}[t])^\top$ 。
- 空间传播入口处均保留红色项 $\frac{\partial s}{\partial u}$ ，使用代理梯度。

k) 讲稿（提纲式）：

- OTTT 和 NDOT 都解决了 BPTT 的内存瓶颈，但路径不同。
- OTTT 删除重置路径，用固定 λ 做指数衰减，简单但损失时序精度。
- NDOT 用连续物理方程导出的动态 $e[t]$ 替代 λ ，保留完整时序信息，且利用望远镜化简不增加计算负担。
- 递推形式完全一致，仅固定系数换为动态系数。
- NDOT 是 OTTT 的精度升级版，相同内存成本，更准确的梯度估计。
- 核心差异一句话：OTTT 是“删近似”，NDOT 是“用精确物理量替代近似”。

IV. S-TLLR 与 TESS：时间本地化与空间本地化学习

本部分核心结构

1 背景：BPTT 的瓶颈与三因子学习规则的机遇

2 S-TLLR：时间本地化学习规则——广义 STDP 资格迹、次级激活函数 Ψ 、因果/非因果融合

3 TESS：时空全本地化学习规则——从 $\mathbf{tr}$ 到 $\mathbf{q/h}$ 的实例化、本地学习信号生成（LSG）

4 资格迹的进化：从抽象 $\mathbf{tr}$ 到显式张量 $\mathbf{q}$ 与 $\mathbf{h}$

5 核心算法对比总结——公式对照、复杂度差异、本地化维度进化

PPT 1: 背景——BPTT 的瓶颈与三因子学习规则的机遇

a) *PPT* 内容要点: :

- BPTT 的计算瓶颈:

$$\frac{d\mathcal{L}}{d\mathbf{W}^{(l)}} = \sum_{t=1}^T \frac{\partial \mathcal{L}}{\partial \mathbf{u}^{(l)}[t]} \frac{\partial \mathbf{u}^{(l)}[t]}{\partial \mathbf{W}^{(l)}}$$

内存复杂度 $O(TLn)$, 时间复杂度 $O(TLn^2)$, 随 T 线性增长

- 三因子学习规则 (3F) 的一般形式:

$$\Delta w_{ij} = \sum_t \delta_i[t] \cdot e_{ij}[t]$$

其中 $e_{ij}[t]$ 为资格迹编码突触前/后活动历史, 这个部分为时间信号

$\delta_i[t]$ 为学习信号解决空间信用分配

- 标准资格迹的瓶颈:

$$e_{ij}[t] = \beta e_{ij}[t-1] + f(y_i[t])g(x_j[t])$$

内存复杂度 $O(n^2)$, 不适用于深度卷积 SNN。

- STDP 的启示: 同时利用因果 (前→后) 和非因果 (后→前) 时序关系

b) 讲稿 (提纲式): :

- BPTT 的时间展开机制导致内存和计算成本随 T 线性增长, 不适合边缘设备。
- 三因子学习规则提供生物学合理的替代方案, 但标准资格迹的内存复杂度为 $O(n^2)$ 。
- STDP 同时利用因果和非因果时序关系, 这启发了 S-TLLR 的设计。
- S-TLLR 和 TESS 分别从“时间本地”和“时空全本地”两个层面解决上述问题。

PPT 2: S-TLLR 的完整推导与时间本地化实现

c) *PPT* 内容要点 (S-TLLR 核心算法公式): :

- 广义 STDP 资格迹 [5]:

$$e_{ij}[t] = \alpha_{pre} \Psi(u_i[t]) \sum_{t'=0}^t \lambda_{pre}^{t-t'} x_j[t'] + \alpha_{post} x_j[t] \sum_{t'=0}^{t-1} \lambda_{post}^{t-t'} \Psi(u_i[t'])$$

– 红色项 (因果): 当前后突触活动 $\Psi(u_i[t]) \times$ 前突触历史踪迹

– 蓝色项 (非因果): 当前前突触脉冲 $x_j[t] \times$ 后突触历史踪迹

- 次级激活函数 Ψ 的作用 (论文附录):

- Ψ 是一个以阈值为中心的钟形/三角形函数。
- 衡量“神经元离发放脉冲还有多远”, 即使神经元未发放也能产生非零信号。
- 典型形式: 三角形 $\Psi(u) = 0.3 \times \max(1 - |u - v_{th}|, 0)$ 。

- 与代理梯度（SG）的区别：SG 用于反向传播（解决 $\frac{\partial s}{\partial u}$ 不可导）， Ψ 用于前向资格迹计算（衡量膜电位接近阈值的程度）。

- 前向踪迹递推（时间本地化关键）：

$$\text{tr}(x_j)[t] = \lambda_{pre} \text{tr}(x_j)[t-1] + x_j[t]$$

$$\text{tr}(\Psi(u_i))[t] = \lambda_{post} \text{tr}(\Psi(u_i))[t-1] + \Psi(u_i[t-1])$$

- 前向形式的资格迹 [5]：

$$e_{ij}[t] = \alpha_{pre} \Psi(u_i[t]) \text{tr}(x_j)[t] + \alpha_{post} x_j[t] (\text{tr}(\Psi(u_i))[t] - \Psi(u_i[t]))$$

- 学习信号与权重更新 [5]：

$$\delta_i^{(l)}[t] = \begin{cases} \frac{\partial \mathcal{L}(\mathbf{y}^L[t], \mathbf{y}^*)}{\partial y_i^{(l)}[t]} & t \geq T_l \\ 0 & \text{otherwise} \end{cases}$$

$$w_{ij} := w_{ij} + \rho \sum_{t=T_l}^T \delta_i[t] e_{ij}[t]$$

（学习信号通过 BP 或 DFA 生成——时间本地，但空间非本地）

- 复杂度：内存 $O(Ln)$ ，时间 $O(Ln^2)$ 。

d) 讲稿（提纲式）：

- S-TLLR 的资格迹包含两项：因果项（红色，前→后）和非因果项（蓝色，后→前）。
- 次级激活函数 Ψ 与代理梯度不同——它在前向计算中衡量膜电位的“发放潜力”，即使神经元沉默也能产生学习信号。
- 通过踪迹变量的前向递推，资格迹可在当前时刻完全计算，无需存储历史状态。
- 学习信号 δ 仍来自 BP 或 DFA，实现时间本地但空间非本地。
- α_{post} 控制非因果项：-1 惩罚非因果，+1 奖励同步性，0 排除。
- 内存复杂度 $O(Ln)$ ，证明了“时间本地学习”的可行性。

PPT 3: TESS 的时空全本地化实现与资格迹进化

e) PPT 内容要点（TESS 核心算法公式）：

- 使用显式张量 $\mathbf{q}$ 与 $\mathbf{h}$
 - S-TLLR 的 $\text{tr}(x_j) \rightarrow$ TESS 的 $\mathbf{q}^{(l)}[t]$ （前突触踪迹张量）
 - S-TLLR 的 $\text{tr}(\Psi(u_i)) \rightarrow$ TESS 的 $\mathbf{h}^{(l)}[t]$ （后突触踪迹张量）
- 前突触踪迹 $\mathbf{q}$ （[6](7)）：

$$\mathbf{q}^{(l)}[t] = \lambda_{pre} \mathbf{q}^{(l)}[t-1] + \mathbf{o}^{(l-1)}[t]$$

存储输入历史，维度 $n^{(l-1)}$ 。

- 后突触踪迹 $\mathbf{h}$ （[6](9)）：

$$\mathbf{h}^{(l)}[t] = \lambda_{post} \mathbf{h}^{(l)}[t-1] + \Psi(\mathbf{u}^{(l)}[t-1])$$

存储膜电位活跃历史，维度 $n^{(l)}$ 。

- 资格迹的向量化形式（[6](8)(10)）：

$$\mathbf{e}_{pre}^{(l)}[t] = \alpha_{pre} \Psi(\mathbf{u}^{(l)}[t]) \otimes \mathbf{q}^{(l)}[t]$$

$$\mathbf{e}_{post}^{(l)}[t] = \alpha_{post} \mathbf{h}^{(l)}[t] \otimes \mathbf{o}^{(l-1)}[t]$$

- 进化 2：学习信号的本地生成——LSG 机制（[6](11)）：

$$\mathbf{v}_m^{(l)}[t] = \mathbf{B}^{(l)\top} (f(\mathbf{B}^{(l)} \mathbf{o}^{(l)}[t]) - \mathbf{y}^*)$$

- $\mathbf{B}^{(l)}$ ：固定二进制矩阵（列向量为方波函数，准正交）
- $f(\cdot)$ ：softmax（分类）或 identity（回归）
- 完全在层内生成，不依赖其他层状态 → 空间本地化

- 完整权重更新（[6](12)-(14)）：

$$\Delta \mathbf{W}_{pre}^{(l)}[t] = (\mathbf{v}_m^{(l)}[t] \odot \alpha_{pre} \Psi(\mathbf{u}^{(l)}[t])) \otimes \mathbf{q}^{(l)}[t]$$

$$\Delta \mathbf{W}_{post}^{(l)}[t] = (\mathbf{v}_m^{(l)}[t] \odot \alpha_{post} \mathbf{h}^{(l)}[t]) \otimes \mathbf{o}^{(l-1)}[t]$$

$$\Delta \mathbf{W}^{(l)}[t] = \Delta \mathbf{W}_{pre}^{(l)}[t] + \Delta \mathbf{W}_{post}^{(l)}[t]$$

- 复杂度：内存 $O(Ln)$ ，时间 $O(LCn)$ （ C 为类别数， $C \ll n$ ）。

f) 讲稿（提纲式）：

- TESS 将 S-TLLR 中抽象的 tr 函数实例化为两个显式张量： $\mathbf{q}$ （前突触踪迹）和 $\mathbf{h}$ （后突触踪迹）。
- 这一实例化使算法能够以标准的张量运算高效运行于 VGG、ResNet 等深度架构。
- 更根本的进化是 LSG 机制：用固定矩阵 $\mathbf{B}$ 直接在当前层输出上生成学习信号，彻底切断层间依赖。
- $\mathbf{B}$ 的列向量为方波函数，准正交且硬件友好。
- TESS 实现了真正的“时空全本地”学习——时间和空间信用分配均只依赖本地信息。
- 时间复杂度从 S-TLLR 的 $O(Ln^2)$ 降至 $O(LCn)$ 。

PPT 4: S-TLLR 与 TESS 的本质区别汇总

g) PPT 内容要点（核心算法对比）：：区别 1：学习信号的生成方式（最关键）

- S-TLLR（论文式(10)）：

$$\delta_i^{(l)}[t] = \frac{\partial \mathcal{L}}{\partial y_i^{(l)}[t]} \quad (\text{依赖 BP/DFA, 空间非本地})$$

- TESS（[6](11)）：

$$\mathbf{v}_m^{(l)}[t] = \mathbf{B}^{(l)\top} (f(\mathbf{B}^{(l)} \mathbf{o}^{(l)}[t]) - \mathbf{y}^*) \quad (\text{完全层内生成, 空间本地})$$

区别 2：资格迹的形式（抽象 vs. 实例化）

- **S-TLLR**（标量， [5](9)）：

$$e_{ij}[t] = \alpha_{pre} \Psi(u_i[t]) \text{tr}(x_j)[t] + \alpha_{post} x_j[t] (\text{tr}(\Psi(u_i))[t] - \Psi(u_i[t]))$$

- **TESS**（向量化， [6](8)(10)）：

$$\mathbf{e}_{pre}^{(l)}[t] = \alpha_{pre} \Psi(\mathbf{u}^{(l)}[t]) \otimes \mathbf{q}^{(l)}[t], \quad \mathbf{e}_{post}^{(l)}[t] = \alpha_{post} \mathbf{h}^{(l)}[t] \otimes \mathbf{o}^{(l-1)}[t]$$

区别 3：时间复杂度

- S-TLLR: $\text{MAC}_{\text{S-TLLR}} = 3(T - T_l) \sum n^{(l)} n^{(l-1)} = O(Ln^2)$
- TESS: $\text{MAC}_{\text{TESS}} = (T - t_l) \sum 2 \times n^{(l)} \times C = O(LCn)$

区别 4：本地化维度

- S-TLLR: **仅时间本地**（时间信用分配本地化，空间依赖 BP/DFA）
- TESS: **时空全本地**（时间 + 空间信用分配均本地化）

h) 讲稿（提纲式）：

- S-TLLR 和 TESS 的核心区别在于学习信号的生成方式。
- S-TLLR 使用 BP/DFA 生成 δ ，依赖全局误差信号；TESS 使用 LSG 生成 $\mathbf{v}_m$ ，完全本地。
- 资格迹形式上，S-TLLR 为标量抽象，TESS 为向量化张量。
- 时间复杂度上，TESS 通过 LSG 将 $O(Ln^2)$ 降至 $O(LCn)$ 。
- TESS 是 S-TLLR 的自然进化，从“时间本地”到“时空全本地”。

PPT 5：总结——从 S-TLLR 到 TESS 的进化路线图

i) PPT 内容要点：

- 共同基础：
 - 均基于三因子学习规则（资格迹 + 学习信号）
 - 均受 STDP 启发，融合因果与非因果时序关系
 - 均实现 $O(Ln)$ 内存复杂度，与时间步数 T 无关
 - 均使用次级激活函数 Ψ （但角色略有不同）
- 关键进化：
 - 学习信号：BP/DFA（S-TLLR）→ LSG（TESS）——从“误差分发”到“目标投射”
 - 踪迹表示：抽象 tr （S-TLLR）→ 显式张量 $\mathbf{q}/\mathbf{h}$ （TESS）
 - 复杂度： $O(Ln^2)$ （S-TLLR）→ $O(LCn)$ （TESS）
 - 本地化维度：仅时间本地 → 时空全本地
- 方法论本质：

S-TLLR 证明了“时间本地学习”是可行的；TESS 在此基础上用 LSG 替换 BP，实现了“时空全本地学习”，在不增加内存的前提下大幅降低计算复杂度。

- 一句话总结：

S-TLLR 是将 STDP 生物机制融入时间维度的尝试；TESS 通过固定随机投影将误差信号也彻底本地化，实现了完全意义上的时空本地学习，在保持接近 BPTT 精度的同时将计算成本降低 205–661 倍。

j) 讲稿（提纲式）：：

- 两篇工作共同构建了从“时间本地”到“时空全本地”的完整技术路线。
- S-TLLR 证明时间本地学习的可行性；TESS 证明全本地学习的可行性。
- 核心进化：LSG 机制用固定随机投影替代 BP，切断了层间依赖。
- 两者均保持 $O(Ln)$ 内存，但 TESS 将时间复杂度降至 $O(LCn)$ 。
- 这是一个从“误差分发”到“目标投射”的方法论飞跃。
- 两者共同为边缘设备上的高效 SNN 训练提供了理论基础与算法支撑。

V. RTRL 与 E-PROP：从 BPTT 到在线学习（暂缓）

参考文献

- [1] R. J. Williams and D. Zipser, “A learning algorithm for continually running fully recurrent neural networks,” *Neural computation*, vol. 1, no. 2, pp. 270–280, 1989.
- [2] G. Bellec, F. Scherr, A. Subramoney, E. Hajek, D. Salaj, R. Legenstein, and W. Maass, “A solution to the learning dilemma for recurrent networks of spiking neurons,” *Nature Communications*, vol. 11, no. 1, p. 3625, Jul. 2020. [Online]. Available: <https://doi.org/10.1038/s41467-020-17236-y>
- [3] M. Xiao, Q. Meng, Z. Zhang, D. He, and Z. Lin, “Online Training Through Time for Spiking Neural Networks,” in *Advances in Neural Information Processing Systems*, S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, and A. Oh, Eds., vol. 35. Curran Associates, Inc., 2022, pp. 20717–20730. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2022/file/82846e19e6d42ebfd4ace4361def29ae-Paper-Conference.pdf
- [4] H. Jiang, G. D. Masi, H. Xiong, and B. Gu, “NDOT: Neuronal Dynamics-based Online Training for Spiking Neural...” [Online]. Available: <https://openreview.net/forum?id=eIF0QoBSFV>
- [5] M. P. E. Apolinario and K. Roy, “S-TLLR: STDP-inspired Temporal Local Learning Rule for Spiking Neural Networks,” Oct. 2024, arXiv:2306.15220 [cs]. [Online]. Available: <http://arxiv.org/abs/2306.15220>
- [6] M. P. E. Apolinario, K. Roy, and C. Frenkel, “TESS: A Scalable Temporally and Spatially Local Learning Rule for Spiking Neural Networks,” in *2025 International Joint Conference on Neural Networks (IJCNN)*, Jun. 2025, pp. 1–9, iSSN: 2161-4407. [Online]. Available: <https://ieeexplore.ieee.org/abstract/document/11227652>