

SNN Information Reconstruction

author

IEEEauthorblockA

摘要

abstract abstract abstract

Keywords

IEEEkeywords IEEEkeywords IEEEkeywords

I. INTRODUCTION

Introduction

[?]

II. 时间反向传播（BPTT）：完整时序梯度计算

BPTT（Backpropagation Through Time）是训练时序神经网络（RNN/SNN）的标准方法，其核心思想是：通过时间展开，将递归网络转化为深度前馈网络，并计算完整的时空梯度。

A. 网络动态（前向过程）

考虑一个时间序列输入 $\{x[t]\}_{t=1}^T$ ，神经元状态满足：

$$h[t] = f(h[t-1], x[t]; \theta)$$

输出为：

$$y[t] = g(h[t]; \theta)$$

总损失为：

$$L = \sum_{t=1}^T \ell(y[t], y^*[t])$$

B. 关键问题：时间信用分配 (*Temporal Credit Assignment*)

由于当前状态依赖历史：

$$h[t] \rightarrow h[t+1] \rightarrow \dots \rightarrow h[T]$$

因此权重 W 在时间 s 的影响会传递到未来所有时间：

$$\frac{\partial L}{\partial W} = \sum_{t=1}^T \frac{\partial L}{\partial h[t]} \frac{\partial h[t]}{\partial W}$$

C. 完整梯度展开 (核心公式)

展开时间依赖：

$$\frac{\partial L}{\partial W} = \sum_{t=1}^T \frac{\partial L}{\partial h[t]} \left(\sum_{s=1}^t \frac{\partial h[t]}{\partial h[s]} \frac{\partial h[s]}{\partial W} \right)$$

含义：

- 内层求和：时间依赖传播 (history effect)
- 外层求和：所有时间步的损失贡献

D. 反向传播递推 (核心递推公式)

定义误差信号：

$$\delta[t] = \frac{\partial L}{\partial h[t]}$$

递推关系：

$$\delta[t] = \frac{\partial L[t]}{\partial h[t]} + \delta[t+1] \frac{\partial h[t+1]}{\partial h[t]}$$

说明：

- 梯度从 $T \rightarrow 1$ 反向传播 - 每一步累积未来影响

E. 参数梯度

$$\frac{\partial L}{\partial W} = \sum_{t=1}^T \delta[t] \frac{\partial h[t]}{\partial W}$$

F. 问题与局限

- 需要存储所有时间状态 (内存 $O(T)$)
- 无法在线学习
- 梯度消失/爆炸

BPTT 能够精确地计算包含长期依赖的梯度，但在长序列上存在梯度消失和爆炸的问题。梯度消失会导致早期时间步贡献极小，而梯度爆炸会导致训练不稳定。

III. S-TLLR方法的完整推导与分析 [?]

A. 神经元动力学模型

我们使用离散时间下的LIF（泄露积分发放）神经元模型，该模型在论文中作为基础动力学定义。脉冲神经元状态更新公式为：

$$u_i[t] = \gamma(u_i[t-1] - v_{th} y_i[t-1]) + \sum_j w_{ij} x_j[t], \quad (1)$$

$$y_i[t] = H(u_i[t] - v_{th}), \quad (2)$$

其中：

- $u_i[t]$ 表示第 i 个神经元在时间 t 的膜电位；
- $y_i[t]$ 是基于膜电位的二值脉冲输出；
- γ 是膜电位的泄露系数；
- $H(\cdot)$ 是阶跃函数；
- w_{ij} 是从第 j 个前馈神经元到第 i 个神经元的权重；
- $x_j[t]$ 是前一层的输入脉冲。

这一模型表明：膜电位既受到自身历史状态累积的影响，也受到当前时刻输入的驱动，这样的时序依赖是SNN训练难点的基础。

B. 三因子学习规则的形式

S-TLLR属于广义三因子学习规则，即权重更新由三个信号共同决定：

$$\Delta w_{ij}[t] = \delta_i[t] \cdot e_{ij}[t], \quad (3)$$

其中：

- $\delta_i[t]$ 是自顶向下的学习信号（第三因子），负责将全局监督误差信息传递至局部；
- $e_{ij}[t]$ 是资格迹（**eligibility trace**），表示前后脉冲序列之间的时间相关性；
- 这一乘积形式使得学习同时考虑误差信号和局部时序痕迹。

三因子结构是许多生物启发学习机制的基础，其优点是局部可计算、可用于在线学习。

C. STDP启发的资格迹定义

S-TLLR 引入了受 STDP 原理启发的资格迹表达式，既包含“因果”时间相关成分，也包含“非因果”成分：

$$e_{ij}[t] = \alpha_{\text{pre}} \sum_{\tau=0}^t \lambda^{t-\tau} x_j[\tau] \Psi(u_i[t]) + \alpha_{\text{post}} \sum_{\tau=0}^{t-1} \lambda^{t-\tau} \Psi(u_i[\tau]) x_j[t]. \quad (4)$$

其中：

- $e_{ij}[t]$ 表示从神经元 j 到神经元 i 在时间 t 的资格迹；

- λ 是指数衰减因子（类似于时间常数）；
- α_{pre} 和 α_{post} 分别是预反馈和后反馈的权重参数；
- $\Psi(u)$ 是次级激活函数（surrogate function），用于平滑处理 u 对学习规则的影响；
- 第一项代表因果贡献：过去的前馈输入 $x_j[\tau]$ 影响当前膜电位；
- 第二项代表非因果贡献：当前前馈 spike 与过去后膜电位的相关性。

该资格迹将 STDP 的时间先后关系转化为可累积的因果/非因果成分，从而对时序信息进行编码。

D. 公式中各部分的深层含义

对于第一项：

$$\alpha_{\text{pre}} \sum_{\tau=0}^t \lambda^{t-\tau} x_j[\tau] \Psi(u_i[t]), \quad (5)$$

它捕捉了历史前馈输入 $x_j[\tau]$ 随时间衰减对当前膜电位的影响，这是 STDP 中 “pre leads post” 的生物现象。

第二项：

$$\alpha_{\text{post}} \sum_{\tau=0}^{t-1} \lambda^{t-\tau} \Psi(u_i[\tau]) x_j[t], \quad (6)$$

则将当前的前馈 spike 与过去的后膜电位相乘，这是一种 “非因果” 关联，其重要性在于增强时间相关性信息的捕获。

这两部分共同构成了 S-TLLR 的资格迹，其优势在于：

1. 保留了前后脉冲时间相关性（比纯因果 STDP 更强）；
2. 无需展开时间，可以在线计算；
3. 比传统三因子规则更简洁、内存复杂度低至 $O(n)$ 。

E. 学习信号的来源

学习信号 $\delta_i[t]$ 有两种生成方式：

- 利用误差反向传播产生的梯度信号（基于 BPTT 或逐层 BP）；
- 利用固定随机反馈矩阵直接从输出层生成学习信号（Random Feedback Alignment）。

这使得 S-TLLR 既可以在监督学习场景中使用反向误差信号，也可以在更生物可实现的随机反馈场景中估计全局误差信息。

F. 完整更新算法公式

在时间循环中，S-TLLR 的权重更新可以写为：

$$\Delta w_{ij}^{(l)}[t] = \delta_i^{(l)}[t] e_{ij}^{(l-1)}[t], \quad (7)$$

该公式由两部分组成：

- $\delta_i^{(l)}[t]$ 是来自上一层的学习信号,
- $e_{ij}^{(l-1)}[t]$ 是资格迹 (由式(??)定义)。

在第 L 层 (输出层) 中更新则为:

$$\Delta w_{ij}^{(L)}[t] = \delta_i^{(L)}[t] y_j^{(L-1)}[t], \quad (8)$$

其中 $y_j^{(L-1)}[t]$ 是上一层的输出 spike。

在隐藏层:

$$\Delta w_{ij}^{(l)}[t] = \delta_i^{(l)}[t] e_{ij}^{(l-1)}[t], \quad (9)$$

这一结构体现出 三因子更新依赖局部时序信息和全局误差信号。

G. 递推计算与内存复杂度

虽然资格迹中包含历史求和, 但可以用递推方式实现在线更新:

$$(\text{pre causal trace}) \quad a_j^{\text{pre}}[t] = \lambda a_j^{\text{pre}}[t-1] + x_j[t], \quad (10)$$

$$(\text{post non-causal trace}) \quad b_i^{\text{post}}[t] = \lambda b_i^{\text{post}}[t-1] + \Psi(u_i[t]), \quad (11)$$

再组合:

$$e_{ij}[t] = \alpha_{\text{pre}} a_j^{\text{pre}}[t] \Psi(u_i[t]) + \alpha_{\text{post}} b_i^{\text{post}}[t-1] x_j[t]. \quad (12)$$

这样实现表明 S-TLLR 所需内存仅与神经元数线性相关, 而不是与时间步成比例。

H. 方法的整体作用与优势

S-TLLR 的设计优势在于:

- **时间 locality:** 资格迹只依赖过去活动, 不依赖未来;
- **空间 locality:** 权重更新只需要局部 synapse 信息, 不依赖全局梯度展开;
- **非因果整合:** 同时考虑了因果和非因果的 STDP 型信息, 有助于更稳定的学习;
- **低内存复杂度:** 资格迹可在线递推计算, 不需要保存整段历史。

这些特性使 S-TLLR 适合在低资源、在线实时场景中训练深度 SNN, 而不需要昂贵的 BPTT。

IV. S-TLLR与TESS方法的统一分析与对比

A. 问题背景：时空信用分配

在脉冲神经网络中，梯度可写为：

$$\frac{\partial L}{\partial W} = \sum_{\tau} \underbrace{s[\tau]}_{\text{历史输入}} \underbrace{\sum_{t \geq \tau} \delta[t] \cdot \frac{\partial u[t]}{\partial u[\tau]}}_{\text{时间信用分配}} \quad (13)$$

其中：

- 时间维度： $\frac{\partial u[t]}{\partial u[\tau]}$
- 空间维度： $\delta[t]$ 来自其他层

因此学习问题本质是：

$$\text{Credit Assignment} = \text{Temporal} + \text{Spatial} \quad (14)$$

B. S-TLLR的推导与结构

1) 三因子学习规则：S-TLLR采用三因子学习框架：

$$\Delta W_{ij}[t] = \delta_i[t] \cdot e_{ij}[t] \quad (15)$$

其中：

- $e_{ij}[t]$: eligibility trace (局部时间信息)
- $\delta_i[t]$: 误差信号 (非局部)

2) *Eligibility Trace*的定义：S-TLLR构造如下资格迹：

$$e_{ij}[t] = \alpha_{\text{pre}} \sum_{\tau \leq t} \lambda^{t-\tau} x_j[\tau] \Psi(u_i[t]) + \alpha_{\text{post}} \sum_{\tau < t} \lambda^{t-\tau} \Psi(u_i[\tau]) x_j[t] \quad (16)$$

该表达式可拆为：

$$e_{ij}[t] = e^{\text{causal}} + e^{\text{non-causal}} \quad (17)$$

3) 递推形式：定义：

$$a_j[t] = \lambda a_j[t-1] + x_j[t] \quad (18)$$

$$b_i[t] = \lambda b_i[t-1] + \Psi(u_i[t]) \quad (19)$$

则：

$$e_{ij}[t] = \alpha_{\text{pre}} a_j[t] \Psi(u_i[t]) + \alpha_{\text{post}} b_i[t-1] x_j[t] \quad (20)$$

4) *S-TLLR*的关键特点:

- 时间局部性:

$$e_{ij}[t] \text{ 仅依赖 } t \text{ 及过去} \quad (21)$$

- 空间非局部性:

$$\delta_i[t] = \text{通过反向传播获得} \quad (22)$$

因此:

$$\text{S-TLLR} = \text{Temporal Local} + \text{Spatial Non-local} \quad (23)$$

C. *TESS*的推导与结构

*TESS*同样基于三因子学习:

$$\Delta W_{ij}[t] = m_i[t] \cdot e_{ij}[t] \quad (24)$$

关键区别在于学习信号 $m_i[t]$ 。

1) *Temporal*部分 (与*S-TLLR*相同): *TESS*直接继承*S-TLLR*的资格迹:

$$e_{ij}[t] = \alpha_{\text{pre}} a_j[t] \Psi(u_i[t]) + \alpha_{\text{post}} b_i[t-1] x_j[t] \quad (25)$$

即:

$$\text{Temporal part (TESS)} = \text{S-TLLR} \quad (26)$$

2) *Spatial*部分 (核心创新): *TESS*不使用反向传播, 而是构造:

$$m^{(l)}[t] = B^{(l)\top} (f(B^{(l)} o^{(l)}[t]) - y^*) \quad (27)$$

其中:

- $B^{(l)}$: 固定随机投影矩阵
- $f(\cdot)$: 任务函数 (如softmax)
- y^* : 标签

3) 推导解释: 定义中间变量:

$$z^{(l)}[t] = B^{(l)} o^{(l)}[t] \quad (28)$$

则误差:

$$\epsilon^{(l)}[t] = f(z^{(l)}[t]) - y^* \quad (29)$$

再投影回神经元空间:

$$m^{(l)}[t] = B^{(l)\top} \epsilon^{(l)}[t] \quad (30)$$

4) 关键性质：该构造满足：

$$m^{(l)}[t] \approx \delta^{(l)}[t] \quad (31)$$

但完全不依赖：

$$\frac{\partial L}{\partial u^{(l)}} \text{ 的反向传播} \quad (32)$$

5) *TESS*的结构总结：

$$\text{TESS} = \text{Temporal Local} + \text{Spatial Local} \quad (33)$$

D. 两者的统一表达

将两者统一写为：

$$\Delta W_{ij}[t] = \underbrace{e_{ij}[t]}_{\text{历史信息}} \cdot \underbrace{\eta_i[t]}_{\text{误差信号}} \quad (34)$$

其中：

$$\eta_i[t] = \begin{cases} \delta_i[t] & \text{S-TLLR} \\ m_i[t] & \text{TESS} \end{cases} \quad (35)$$

E. 信息流对比（核心结论）

1) *S-TLLR*：

$$\eta_i[t] = \delta_i[t] \quad (36)$$

依赖：

$$\delta_i[t] = \sum_k W_{ki}^{(l+1)} \delta_k^{(l+1)}[t] \quad (37)$$

特点：

- 需要跨层传播
- 非局部

2) *TESS*：

$$\eta_i[t] = m_i[t] \quad (38)$$

仅依赖：

$$o^{(l)}[t], \quad y^* \quad (39)$$

特点：

- 完全局部生成
- 无跨层依赖

F. 复杂度对比

$$\text{Mem}_{\text{S-TLLR}} = O(Ln) \quad (40)$$

$$\text{Mem}_{\text{TESS}} = O(Ln) \quad (41)$$

但计算复杂度:

$$\text{Time}_{\text{S-TLLR}} = O(Ln^2) \quad (42)$$

$$\text{Time}_{\text{TESS}} = O(LCn) \quad (43)$$

其中 $C \ll n$ 。

G. 方法本质总结

- S-TLLR:

使用真实误差 + 局部时间信息 (44)

- TESS:

使用局部近似误差 + 局部时间信息 (45)

H. 最终核心差异

S-TLLR $\Rightarrow$ 保留空间梯度信息 (46)

TESS $\Rightarrow$ 近似空间梯度信息 (47)

V. NDOT方法的完整推导与机制分析

A. 问题背景: BPTT的梯度结构

对于多层SNN, BPTT的梯度可写为:

$$\frac{\partial L}{\partial W^l} = \sum_{t=1}^T \frac{\partial L}{\partial s^l[t]} \frac{\partial s^l[t]}{\partial u^l[t]} \left(\frac{\partial u^l[t]}{\partial W^l} + \sum_{k < t} \prod_{i=k}^{t-1} \left(\frac{\partial u^l[i+1]}{\partial u^l[i]} + \frac{\partial u^l[i+1]}{\partial s^l[i]} \frac{\partial s^l[i]}{\partial u^l[i]} \right) \frac{\partial u^l[k]}{\partial W^l} \right) \quad (48)$$

1) 含义分析: 该公式包含两个关键部分:

- 空间梯度:

$$\frac{\partial L}{\partial s^l[t]} \frac{\partial s^l[t]}{\partial u^l[t]}$$

- 时间梯度:

$$\prod_{i=k}^{t-1} (\cdot)$$

2) 问题本质:

BPTT困难点: 时间展开、存储所有历史状态 (49)

B. *NDOT*核心思想: 梯度分解

*NDOT*提出:

$$\frac{\partial L}{\partial W^l} = \sum_{t=1}^T g_u^l[t] \cdot \hat{a}^{l-1}[t]^T \quad (50)$$

其中:

$$g_u^l[t] = \left(\frac{\partial L}{\partial s^l[t]} \frac{\partial s^l[t]}{\partial u^l[t]} \right)^T \quad (51)$$

1) 核心分解:

$$\text{Full Gradient} = \underbrace{g_u^l[t]}_{\text{空间}} \times \underbrace{\hat{a}^{l-1}[t]}_{\text{时间}} \quad (52)$$

C. 关键突破一: *Temporal Dependency* 重构

1) *BPTT*中的时间依赖: 定义离散时间依赖:

$$\epsilon^l[t] = \frac{\partial u^l[t+1]}{\partial u^l[t]} + \frac{\partial u^l[t+1]}{\partial s^l[t]} \frac{\partial s^l[t]}{\partial u^l[t]} \quad (53)$$

2) *NDOT*提出连续形式:

$$e(t) \triangleq \frac{\partial u(t+1)}{\partial u(t)} \quad (54)$$

3) 推导 (关键步骤): 由链式法则:

$$\frac{du(t+1)}{dt} = \frac{\partial u(t+1)}{\partial u(t)} \frac{du(t)}{dt} \quad (55)$$

得到:

$$e(t) = \frac{u'(t+1)}{u'(t)} \quad (56)$$

4) 代入神经动力学: 由LIF模型:

$$e(t) = \frac{u(t+1) - I(t+1)}{u(t) - I(t)} \quad (57)$$

5) 离散化结果 (核心公式):

$$e^l[t] = \frac{u^l[t] - V_{th}s^l[t]}{u^l[t-1] - V_{th}s^l[t-1]} \quad (58)$$

6) 关键意义:

- 用神经元动力学替代BPTT链式展开
- 不需要存储所有历史
- 时间依赖被“隐式编码”

D. 关键突破二: *Temporal Gradient*递推

定义:

$$\hat{a}^{l-1}[t] = s^{l-1}[t] + \sum_{k < t} P_{k,t}^{l-1} \odot s^{l-1}[k] \quad (59)$$

其中:

$$P_{k,t}^l = \prod_{i=k}^{t-1} e^l[i] \quad (60)$$

1) 递推形式 (核心公式):

$$\hat{a}^{l-1}[t] = e^{l-1}[t-1] \odot \hat{a}^{l-1}[t-1] + s^{l-1}[t] \quad (61)$$

2) 推导解释: 展开递推:

$$\hat{a}[t] = s[t] + e[t-1]s[t-1] + e[t-1]e[t-2]s[t-2] + \dots \quad (62)$$

3) 含义:

$$\hat{a}[t] = \text{带衰减的历史累积} \quad (63)$$

4) 本质: NDOT的本质是什么

$$\text{BPTT的链式乘积} \rightarrow \text{递推形式} \quad (64)$$

E. 关键突破三: 完整梯度表达

$$\nabla_{W^l} L = \sum_{t=1}^T g_u^l[t] \cdot \hat{a}^{l-1}[t]^T \quad (65)$$

1) 空间梯度:

$$g_u^l[t] = \left(\frac{\partial L[t]}{\partial s^N[t]} \prod_{j=l}^{N-1} \frac{\partial s^{j+1}[t]}{\partial u^j[t]} \frac{\partial s^l[t]}{\partial u^l[t]} \right)^T \quad (66)$$

2) 关键性质:

- 不依赖未来时间
- 可在线计算

F. 关键突破四: *Instantaneous Loss*

$$L[t] = (1 - \alpha)\ell_{CE}(s^N[t], y) + \alpha\ell_{MSE}(s^N[t], y) \quad (67)$$

1) 意义:

- 避免依赖全时间序列
- 支持在线学习

G. *NDOT*完整更新规则

$$\Delta W^l[t] = g_u^l[t] \cdot \hat{a}^{l-1}[t]^T \quad (68)$$

H. 算法本质总结

$$\text{NDOT} = \text{空间梯度 (局部时间)} + \text{时间梯度 (动力学递推)} \quad (69)$$

VI. OTTT方法的完整推导与信息结构分析

A. 脉冲神经元模型与时间依赖

考虑离散时间下的脉冲神经元，其状态更新满足：

$$u_i[t+1] = \lambda(u_i[t] - V_{th}s_i[t]) + \sum_j W_{ij}s_j[t] + b_i \quad (70)$$

$$s_i[t+1] = H(u_i[t+1] - V_{th}) \quad (71)$$

该模型体现出以下两个重要性质：

- 状态 $u[t]$ 依赖于过去状态 $u[t-1]$ （时间递归）
- 输出 $s[t]$ 通过非线性阈值函数生成（不可导）

因此整个系统具有强烈的时间耦合特性，这也是训练困难的根本来源。

B. *BPTT*中的完整梯度表达

定义总损失：

$$L = \sum_{t=1}^T L[t] \quad (72)$$

根据链式法则，对权重求导：

$$\frac{\partial L}{\partial W_l} = \sum_{t=1}^T \frac{\partial L}{\partial s^{l+1}[t]} \frac{\partial s^{l+1}[t]}{\partial u^{l+1}[t]} \frac{\partial u^{l+1}[t]}{\partial W_l} + \sum_{t=1}^T \frac{\partial L}{\partial s^{l+1}[t]} \frac{\partial s^{l+1}[t]}{\partial u^{l+1}[t]} \sum_{\tau < t} \frac{\partial u^{l+1}[t]}{\partial u^{l+1}[\tau]} \frac{\partial u^{l+1}[\tau]}{\partial W_l} \quad (73)$$

该表达式包含两部分：

- 第一项：当前时间步的直接梯度贡献
- 第二项：历史时间通过状态传播影响当前输出

进一步展开时间传播项：

$$\frac{\partial u[t]}{\partial u[\tau]} = \prod_{i=\tau}^{t-1} \left(\frac{\partial u[i+1]}{\partial u[i]} + \frac{\partial u[i+1]}{\partial s[i]} \frac{\partial s[i]}{\partial u[i]} \right) \quad (74)$$

该项描述了从时间 τ 到时间 t 的所有路径贡献，是时间信用分配的核心。

C. 时间传播结构的物理含义

上述乘积项可以解释为：

$$\text{时间传播} = \text{状态传播} + \text{脉冲触发路径} \quad (75)$$

其中：

- $\frac{\partial u[i+1]}{\partial u[i]}$ ：连续状态传播（leaky dynamics）
- $\frac{\partial u[i+1]}{\partial s[i]}$ ：reset路径

这意味着梯度不仅沿状态传播，还沿脉冲触发路径传播。

D. OTTT的关键近似：去除reset梯度路径

OTTT做出核心近似：

$$\frac{\partial u[i+1]}{\partial s[i]} \frac{\partial s[i]}{\partial u[i]} \approx 0 \quad (76)$$

理由如下：

- $H(\cdot)$ 的导数在绝大多数点为0
- reset路径对梯度贡献极小

因此：

$$\frac{\partial u[i+1]}{\partial u[i]} = \lambda \quad (77)$$

E. 时间传播的简化形式

于是时间传播项简化为：

$$\frac{\partial u[t]}{\partial u[\tau]} = \lambda^{t-\tau} \quad (78)$$

将其代入梯度表达式：

$$\frac{\partial L}{\partial W_l} = \sum_{t=1}^T g_u[t] \sum_{\tau \leq t} \lambda^{t-\tau} s^l[\tau] \quad (79)$$

其中：

$$g_u[t] = \frac{\partial L}{\partial s[t]} \cdot \frac{\partial s[t]}{\partial u[t]} \quad (80)$$

F. Eligibility Trace的引入

定义：

$$\hat{a}[t] = \sum_{\tau \leq t} \lambda^{t-\tau} s[\tau] \quad (81)$$

该变量具有以下意义：

- 表示过去所有输入的指数加权累积
- 是时间信息的压缩表示

为了实现在线计算，将其写为递推形式：

$$\hat{a}[t+1] = \lambda \hat{a}[t] + s[t+1] \quad (82)$$

这一递推消除了对历史序列的存储需求。

G. 梯度表达的最终形式

梯度可写为：

$$\frac{\partial L}{\partial W_l} = \sum_{t=1}^T g_u[t] \hat{a}[t]^T \quad (83)$$

对应单个连接：

$$\Delta W_{ij} = \hat{a}_i[t] \cdot \delta_j[t] \quad (84)$$

H. 瞬时损失的引入

传统损失依赖整个时间序列：

$$L = L \left(\frac{1}{T} \sum_t s[t] \right) \quad (85)$$

OTTT改为：

$$L = \sum_{t=1}^T L[t], \quad L[t] = \frac{1}{T} L(s[t], y) \quad (86)$$

该修改使得梯度仅依赖当前时间步，从而实现在线更新 [?].

I. 信息结构分析

BPTT梯度可以重写为:

$$\frac{\partial L}{\partial W} = \sum_{\tau} s[\tau] \sum_{t \geq \tau} \delta[t] \lambda^{t-\tau} \quad (87)$$

该表达式包含:

- 历史输入 $s[\tau]$
- 当前误差 $\delta[\tau]$
- 未来误差 $\delta[t], t > \tau$

而OTTT近似为:

$$\frac{\partial L}{\partial W} = \sum_t \delta[t] \hat{a}[t] \quad (88)$$

即:

$$\text{OTTT} \approx \text{BPTT} - \text{未来误差项} \quad (89)$$

J. 三因子学习结构

最终更新形式:

$$\Delta W_{ij} = \underbrace{\hat{a}_i[t]}_{\text{历史输入}} \cdot \underbrace{f(u_j[t])}_{\text{神经元响应}} \cdot \underbrace{\delta_j[t]}_{\text{误差信号}} \quad (90)$$

该结构对应典型三因子学习规则:

- presynaptic trace
- postsynaptic activity
- global error

K. 方法本质总结

OTTT通过以下三个步骤实现在线化:

- 1) 删除时间反向传播路径 (reset路径)
- 2) 使用eligibility trace压缩历史信息
- 3) 使用瞬时损失消除未来依赖

其本质可以写为:

$$g_{\text{OTTT}} = g_{\text{past}} + g_{\text{present}} \quad (91)$$

相比BPTT缺失:

$$g_{\text{future}} \quad (92)$$

这一缺失构成其性能与近似误差的根本来源。

OTTT 和 NDOT 的核心区别在于：

OTTT通过假设时间梯度为一个固定衰减因子，忽略了神经元发放带来的非线性影响，从而实现了在线训练，但代价是丢失了大量时间信息。

而 NDOT 则从神经元动力学出发，用膜电位的变化关系构造时间依赖项，将复杂的时间梯度用一个动态变量 $e[t]$ 表示，从而在保持在线性的同时，更准确地逼近真实梯度。

VII. 局部学习算法的信息分解与统一分析

A. 完整梯度的信息结构

对于时序神经网络，基于BPTT的完整梯度可以表示为：

$$\frac{\partial L}{\partial W} = \sum_{\tau} \underbrace{s[\tau]}_{\text{历史输入}} \underbrace{\sum_{t \geq \tau} \delta[t] \cdot \frac{\partial u[t]}{\partial u[\tau]}}_{\text{时间与未来误差传播}} \quad (93)$$

该表达式包含三类关键信息：

- 历史信息（past）：输入序列 $s[\tau]$
- 当前信息（present）：误差信号 $\delta[\tau]$
- 未来信息（future）： $\delta[t], t > \tau$

B. 局部学习方法的统一视角

现有在线或局部学习算法的核心目标是：

$$\text{降低计算复杂度} \Rightarrow \text{减少或近似梯度中的某些信息项} \quad (94)$$

因此，不同方法可以统一理解为对上述梯度表达式的不同近似。

C. OTTT的信息近似

OTTT采用如下近似：

$$\sum_{t \geq \tau} \delta[t] \lambda^{t-\tau} \approx \delta[\tau] \quad (95)$$

其核心特点是：

- 完全删除未来误差传播项
- 使用当前误差替代未来误差

D. *NDOT*的信息近似

*NDOT*并不直接删除时间依赖，而是引入神经元动力学变量：

$$e[t] \approx \frac{\partial u[t+1]}{\partial u[t]} \quad (96)$$

并构造递推形式：

$$\hat{a}[t] = e[t-1]\hat{a}[t-1] + s[t] \quad (97)$$

其中：

- 通过神经动力学近似的时间信息
- 仍然缺失精确的未来误差传播

E. *S-TLLR*的信息结构

*S-TLLR*采用STDP形式构造eligibility trace：

$$\Delta W_{ij}[t] = \delta_i[t] \cdot e_{ij}[t] \quad (98)$$

其中：

$$e_{ij}[t] = \text{因果项} + \text{非因果项} \quad (99)$$

特点：

- 时间完全局部（通过trace表示）
- 空间仍依赖全局误差（ δ ）

F. *TESS*的信息结构

*TESS*进一步将误差信号本地化：

$$\Delta W_{ij}[t] = m_i[t] \cdot e_{ij}[t] \quad (100)$$

其中：

$$m^{(l)}[t] = B^{(l)\top} (f(B^{(l)}o^{(l)}[t]) - y^*) \quad (101)$$

其特点为：

- 时间局部
- 空间局部
- 使用近似误差信号替代真实梯度

G. 统一比较与结论

H. 核心结论

所有局部学习方法的本质可以统一为：

$$\text{Local Learning} = \text{Information Compression of BPTT Gradient} \quad (102)$$

其中：

- OTTT：删除未来信息
- NDOT：用动力学近似时间信息
- S-TLLR：用STDP近似时间关系
- TESS：进一步近似空间误差

因此，核心研究问题可以表述为：

$$\text{如何在局部约束下最大程度保留梯度信息？} \quad (103)$$

VIII. 问题

BPTT的S与T的解耦的近似条件近似了什么内容

预测性从哪里来

迭代信息

损失的信息的补全

内容是否有干扰项目

一种思路在大模型上建立小修改

随机矩阵问题

1. 证明可行性
2. 如何使用特定随机方案进行优化（雅各比矩阵，噪音矩阵，正交矩阵）

参考文献

- [1] M. P. Apolinario, K. Roy, and C. Frenkel, "Tess: A scalable temporally and spatially local learning rule for spiking neural networks," in *2025 International Joint Conference on Neural Networks (IJCNN)*. IEEE, 2025, pp. 1–9.
- [2] M. P. E. Apolinario and K. Roy, "S-tllr: Stdp-inspired temporal local learning rule for spiking neural networks," *arXiv preprint arXiv:2306.15220*, 2023.
- [3] M. Xiao, Q. Meng, Z. Zhang, D. He, and Z. Lin, "Online training through time for spiking neural networks," *Advances in neural information processing systems*, vol. 35, pp. 20 717–20 730, 2022.