SNN Information Reconstruction

author

IEEEauthorblockA

摘要

abstract abstract abstract

Keywords

IEEEkeywords IEEEkeywords IEEEkeywords

I. Introduction

Introduction

[1]

II. 时间反向传播（BPTT）：完整时序梯度计算

BPTT（Backpropagation Through Time）是训练时序神经网络（RNN/SNN）的标准方法，其核心思想是： **通过时间展开，将递归网络转化为深度前馈网络，并计算完整的时空梯度。**

A. 网络动态（前向过程）

考虑一个时间序列输入 $\{x[t]\}_{t=1}^{T}$，神经元状态满足：

$$h[t] = f(h[t-1], x[t]; \theta)$$

输出为：

$$y[t] = g(h[t]; \theta)$$

总损失为：

$$L = \sum_{t=1}^{T} \ell(y[t], y^*[t])$$

B. 关键问题：时间信用分配（*Temporal Credit Assignment*）

由于当前状态依赖历史：

$$h[t] \to h[t+1] \to \cdots \to h[T]$$

因此权重 W 在时间 s 的影响会传递到未来所有时间：

$$\frac{\partial L}{\partial W} = \sum_{t=1}^{T} \frac{\partial L}{\partial h[t]} \frac{\partial h[t]}{\partial W}$$

C. 完整梯度展开（核心公式）

展开时间依赖：

$$\frac{\partial L}{\partial W} = \sum_{t=1}^{T} \frac{\partial L}{\partial h[t]} \left(\sum_{s=1}^{t} \frac{\partial h[t]}{\partial h[s]} \frac{\partial h[s]}{\partial W} \right)$$

含义：

- 内层求和：时间依赖传播（history effect）
- 外层求和：所有时间步的损失贡献

D. 反向传播递推（核心递推公式）

定义误差信号：

$$\delta[t] = \frac{\partial L}{\partial h[t]}$$

递推关系：

$$\delta[t] = \frac{\partial L[t]}{\partial h[t]} + \delta[t+1] \frac{\partial h[t+1]}{\partial h[t]}$$

说明：

- 梯度从 $T \to 1$ 反向传播 - 每一步累积未来影响

E. 参数梯度

$$\frac{\partial L}{\partial W} = \sum_{t=1}^{T} \delta[t] \frac{\partial h[t]}{\partial W}$$

F. 问题与局限

- 需要存储所有时间状态（内存 $O(T)$）
- 无法在线学习
- 梯度消失/爆炸

BPTT 能够精确地计算包含长期依赖的梯度，但在长序列上存在梯度消失和爆炸的问题。梯度消失会导致早期时间步贡献极小，而梯度爆炸会导致训练不稳定。

III. S-TLLR方法的完整推导与分析 [2]

A. 神经元动力学模型

我们使用离散时间下的LIF（泄露积分发放）神经元模型，该模型在论文中作为基础动力学定义。脉冲神经元状态更新公式为：

$$u_i[t] = \gamma(u_i[t-1] - v_{th}\, y_i[t-1]) + \sum_j w_{ij}\, x_j[t], \tag{1}$$

$$y_i[t] = H(u_i[t] - v_{th}), \tag{2}$$

其中：

- $u_i[t]$ 表示第 i 个神经元在时间 t 的膜电位；
- $y_i[t]$ 是基于膜电位的二值脉冲输出；
- γ 是膜电位的泄露系数；
- $H(\cdot)$ 是阶跃函数；
- w_{ij} 是从第 j 个前馈神经元到第 i 个神经元的权重；
- $x_j[t]$ 是前一层的输入脉冲。

这一模型表明：膜电位既受到自身历史状态累积的影响，也受到当前时刻输入的驱动，这样的时序依赖是SNN训练难点的基础。

B. 三因子学习规则的形式

S-TLLR属于广义三因子学习规则，即权重更新由三个信号共同决定：

$$\Delta w_{ij}[t] = \delta_i[t] \cdot e_{ij}[t], \tag{3}$$

其中：

- $\delta_i[t]$ 是自顶向下的学习信号（第三因子），负责将全局监督误差信息传递至局部；
- $e_{ij}[t]$ 是资格迹（eligibility trace），表示前后脉冲序列之间的时间相关性；
- 这一乘积形式使得学习同时考虑误差信号和局部时序痕迹。

三因子结构是许多生物启发学习机制的基础，其优点是局部可计算、可用于在线学习。

C. STDP启发的资格迹定义

S-TLLR 引入了受 STDP 原理启发的资格迹表达式，既包含“因果”时间相关成分，也包含“非因果”成分：

$$e_{ij}[t] = \alpha_{\text{pre}} \sum_{\tau=0}^{t} \lambda^{t-\tau}\, x_j[\tau]\, \Psi(u_i[t]) + \alpha_{\text{post}} \sum_{\tau=0}^{t-1} \lambda^{t-\tau}\, \Psi(u_i[\tau])\, x_j[t]. \tag{4}$$

其中：

- $e_{ij}[t]$ 表示从神经元 j 到神经元 i 在时间 t 的资格迹；

- λ 是指数衰减因子（类似于时间常数）；
- α_{pre} 和 α_{post} 分别是预反馈和后反馈的权重参数；
- $\Psi(u)$ 是次级激活函数（surrogate function），用于平滑处理 u 对学习规则的影响；
- 第一项代表因果贡献：过去的前馈输入 $x_j[\tau]$ 影响当前膜电位；
- 第二项代表非因果贡献：当前前馈 spike 与过去后膜电位的相关性。

该资格迹将 STDP 的时间先后关系转化为可累积的因果/非因果成分，从而对时序信息进行编码。

D. 公式中各部分的深层含义

对于第一项：

$$\alpha_{\text{pre}} \sum_{\tau=0}^{t} \lambda^{t-\tau}\, x_j[\tau]\, \Psi(u_i[t]), \tag{5}$$

它捕捉了历史前馈输入 $x_j[\tau]$ 随时间衰减对当前膜电位的影响，这是 STDP 中“pre leads post”的生物现象。

第二项：

$$\alpha_{\text{post}} \sum_{\tau=0}^{t-1} \lambda^{t-\tau}\, \Psi(u_i[\tau])\, x_j[t], \tag{6}$$

则将当前的前馈 spike 与过去的后膜电位相乘，这是一种“非因果”关联，其重要性在于增强时间相关性信息的捕获。

这两部分共同构成了S-TLLR的资格迹，其优势在于：

1. **保留了前后脉冲时间相关性**（比纯因果 STDP 更强）； 2. **无需展开时间，可以在线计算**； 3. **比传统三因子规则更简洁、内存复杂度低至 $O(n)$**。

E. 学习信号的来源

学习信号 $\delta_i[t]$ 有两种生成方式：

- 利用误差反向传播产生的梯度信号（基于 BPTT 或逐层 BP）；
- 利用固定随机反馈矩阵直接从输出层生成学习信号（Random Feedback Alignment）。

这使得 S-TLLR **既可以在监督学习场景中使用反向误差信号**，也可以在更生物可实现的随机反馈场景中估计全局误差信息。

F. 完整更新算法公式

在时间循环中，S-TLLR 的权重更新可以写为：

$$\Delta w_{ij}^{(l)}[t] = \delta_i^{(l)}[t]\, e_{ij}^{(l-1)}[t], \tag{7}$$

该公式由两部分组成：

- $\delta_i^{(l)}[t]$ 是来自上一层的学习信号，
- $e_{ij}^{(l-1)}[t]$ 是资格迹（由式(4)定义）。

在第 L 层（输出层）中更新则为：

$$\Delta w_{ij}^{(L)}[t] = \delta_i^{(L)}[t]\, y_j^{(L-1)}[t], \tag{8}$$

其中 $y_j^{(L-1)}[t]$ 是上一层的输出 spike。
在隐藏层：

$$\Delta w_{ij}^{(l)}[t] = \delta_i^{(l)}[t]\, e_{ij}^{(l-1)}[t], \tag{9}$$

这一结构体现出 **三因子更新依赖局部时序信息和全局误差信号**。

G. 递推计算与内存复杂度

虽然资格迹中包含历史求和，但可以用递推方式实现在线更新：

$$\text{(pre causal trace)} \quad a_j^{\text{pre}}[t] = \lambda a_j^{\text{pre}}[t-1] + x_j[t], \tag{10}$$

$$\text{(post non-causal trace)} \quad b_i^{\text{post}}[t] = \lambda b_i^{\text{post}}[t-1] + \Psi(u_i[t]), \tag{11}$$

再组合：

$$e_{ij}[t] = \alpha_{\text{pre}}\, a_j^{\text{pre}}[t]\, \Psi(u_i[t]) + \alpha_{\text{post}}\, b_i^{\text{post}}[t-1]\, x_j[t]. \tag{12}$$

这样实现表明 S-TLLR 所需内存仅与神经元数线性相关，而不是与时间步成比例。

H. 方法的整体作用与优势

S-TLLR 的设计优势在于：

- **时间 locality**：资格迹只依赖过去活动，不依赖未来；
- **空间 locality**：权重更新只需要局部 synapse 信息，不依赖全局梯度展开；
- **非因果整合**：同时考虑了因果和非因果的 STDP 型信息，有助于更稳定的学习；
- **低内存复杂度**：资格迹可在线递推计算，不需要保存整段历史。

这些特性使 S-TLLR 适合在低资源、在线实时场景中训练深度 SNN，而不需要昂贵的 BPTT。

IV. S-TLLR与TESS方法的统一分析与对比

A. 问题背景：时空信用分配

在脉冲神经网络中，梯度可写为：

$$\frac{\partial L}{\partial W} = \sum_{\tau} \underbrace{s[\tau]}_{\text{历史输入}} \underbrace{\sum_{t \geq \tau} \delta[t] \cdot \frac{\partial u[t]}{\partial u[\tau]}}_{\text{时间信用分配}} \tag{13}$$

其中：

- 时间维度：$\frac{\partial u[t]}{\partial u[\tau]}$
- 空间维度：$\delta[t]$ 来自其他层

因此学习问题本质是：

$$\text{Credit Assignment} = \text{Temporal} + \text{Spatial} \tag{14}$$

B. S-TLLR的推导与结构

1) 三因子学习规则: S-TLLR采用三因子学习框架：

$$\Delta W_{ij}[t] = \delta_i[t] \cdot e_{ij}[t] \tag{15}$$

其中：

- $e_{ij}[t]$：eligibility trace（局部时间信息）
- $\delta_i[t]$：误差信号（非局部）

2) Eligibility Trace的定义: S-TLLR构造如下资格迹：

$$e_{ij}[t] = \alpha_{\text{pre}} \sum_{\tau \leq t} \lambda^{t-\tau} x_j[\tau] \Psi(u_i[t]) + \alpha_{\text{post}} \sum_{\tau < t} \lambda^{t-\tau} \Psi(u_i[\tau]) x_j[t] \tag{16}$$

该表达式可拆为：

$$e_{ij}[t] = e^{\text{causal}} + e^{\text{non-causal}} \tag{17}$$

3) 递推形式: 定义：

$$a_j[t] = \lambda a_j[t-1] + x_j[t] \tag{18}$$

$$b_i[t] = \lambda b_i[t-1] + \Psi(u_i[t]) \tag{19}$$

则：

$$e_{ij}[t] = \alpha_{\text{pre}} a_j[t] \Psi(u_i[t]) + \alpha_{\text{post}} b_i[t-1] x_j[t] \tag{20}$$

4) S-TLLR的关键特点:

- 时间局部性：

$$e_{ij}[t] \text{ 仅依赖 } t \text{ 及过去} \tag{21}$$

- 空间非局部性：

$$\delta_i[t] = \text{通过反向传播获得} \tag{22}$$

因此：

$$\text{S-TLLR} = \text{Temporal Local} + \text{Spatial Non-local} \tag{23}$$

C. TESS的推导与结构

TESS同样基于三因子学习：

$$\Delta W_{ij}[t] = m_i[t] \cdot e_{ij}[t] \tag{24}$$

关键区别在于学习信号 $m_i[t]$。

1) Temporal部分（与S-TLLR相同）: TESS直接继承S-TLLR的资格迹：

$$e_{ij}[t] = \alpha_{\text{pre}} a_j[t] \Psi(u_i[t]) + \alpha_{\text{post}} b_i[t-1] x_j[t] \tag{25}$$

即：

$$\text{Temporal part (TESS)} = \text{S-TLLR} \tag{26}$$

2) Spatial部分（核心创新）: TESS不使用反向传播，而是构造：

$$m^{(l)}[t] = B^{(l)\top} \left(f(B^{(l)} o^{(l)}[t]) - y^* \right) \tag{27}$$

其中：

- $B^{(l)}$：固定随机投影矩阵
- $f(\cdot)$：任务函数（如softmax）
- y^*：标签

3) 推导解释: 定义中间变量：

$$z^{(l)}[t] = B^{(l)} o^{(l)}[t] \tag{28}$$

则误差：

$$\epsilon^{(l)}[t] = f(z^{(l)}[t]) - y^* \tag{29}$$

再投影回神经元空间：

$$m^{(l)}[t] = B^{(l)\top} \epsilon^{(l)}[t] \tag{30}$$

4) 关键性质: 该构造满足：

$$m^{(l)}[t] \approx \delta^{(l)}[t] \tag{31}$$

但完全不依赖：

$$\frac{\partial L}{\partial u^{(l)}} \text{ 的反向传播} \tag{32}$$

5) TESS的结构总结:

$$\text{TESS} = \text{Temporal Local} + \text{Spatial Local} \tag{33}$$

D. 两者的统一表达

将两者统一写为：

$$\Delta W_{ij}[t] = \underbrace{e_{ij}[t]}_{\text{历史信息}} \cdot \underbrace{\eta_i[t]}_{\text{误差信号}} \tag{34}$$

其中：

$$\eta_i[t] = \begin{cases} \delta_i[t] & \text{S-TLLR} \\ m_i[t] & \text{TESS} \end{cases} \tag{35}$$

E. 信息流对比（核心结论）

1) S-TLLR:

$$\eta_i[t] = \delta_i[t] \tag{36}$$

依赖：

$$\delta_i[t] = \sum_k W_{ki}^{(l+1)} \delta_k^{(l+1)}[t] \tag{37}$$

特点：

- 需要跨层传播
- 非局部

2) TESS:

$$\eta_i[t] = m_i[t] \tag{38}$$

仅依赖：

$$o^{(l)}[t], \quad y^* \tag{39}$$

特点：

- 完全局部生成
- 无跨层依赖

F. 复杂度对比

$$\text{Mem}_{\text{S-TLLR}} = O(Ln) \tag{40}$$

$$\text{Mem}_{\text{TESS}} = O(Ln) \tag{41}$$

但计算复杂度：

$$\text{Time}_{\text{S-TLLR}} = O(Ln^2) \tag{42}$$

$$\text{Time}_{\text{TESS}} = O(LCn) \tag{43}$$

其中 $C \ll n$。

G. 方法本质总结

- S-TLLR：

$$\text{使用真实误差} + \text{局部时间信息} \tag{44}$$

- TESS：

$$\text{使用局部近似误差} + \text{局部时间信息} \tag{45}$$

H. 最终核心差异

$$\text{S-TLLR} \Rightarrow \text{保留空间梯度信息} \tag{46}$$

$$\text{TESS} \Rightarrow \text{近似空间梯度信息} \tag{47}$$

V. NDOT方法的完整推导与机制分析

A. 问题背景：*BPTT*的梯度结构

对于多层SNN，BPTT的梯度可写为：

$$\frac{\partial L}{\partial W^l} = \sum_{t=1}^{T} \frac{\partial L}{\partial s^l[t]} \frac{\partial s^l[t]}{\partial u^l[t]} \left(\frac{\partial u^l[t]}{\partial W^l} + \sum_{k<t} \prod_{i=k}^{t-1} \left(\frac{\partial u^l[i+1]}{\partial u^l[i]} + \frac{\partial u^l[i+1]}{\partial s^l[i]} \frac{\partial s^l[i]}{\partial u^l[i]} \right) \frac{\partial u^l[k]}{\partial W^l} \right) \tag{48}$$

1) 含义分析*:* 该公式包含两个关键部分：

- 空间梯度：

$$\frac{\partial L}{\partial s^l[t]} \frac{\partial s^l[t]}{\partial u^l[t]}$$

- 时间梯度：

$$\prod_{i=k}^{t-1} (\cdot)$$

2) 问题本质:

$$\text{BPTT困难点：时间展开、存储所有历史状态} \tag{49}$$

B. NDOT核心思想：梯度分解

NDOT提出：

$$\frac{\partial L}{\partial W^l} = \sum_{t=1}^{T} g_u^l[t] \cdot \hat{a}^{l-1}[t]^T \tag{50}$$

其中：

$$g_u^l[t] = \left(\frac{\partial L}{\partial s^l[t]} \frac{\partial s^l[t]}{\partial u^l[t]} \right)^T \tag{51}$$

1) 核心分解:

$$\text{Full Gradient} = \underbrace{g_u^l[t]}_{\text{空间}} \times \underbrace{\hat{a}^{l-1}[t]}_{\text{时间}} \tag{52}$$

C. 关键突破一：Temporal Dependency 重构

1) BPTT中的时间依赖: 定义离散时间依赖：

$$\epsilon^l[t] = \frac{\partial u^l[t+1]}{\partial u^l[t]} + \frac{\partial u^l[t+1]}{\partial s^l[t]} \frac{\partial s^l[t]}{\partial u^l[t]} \tag{53}$$

2) NDOT提出连续形式:

$$e(t) \triangleq \frac{\partial u(t+1)}{\partial u(t)} \tag{54}$$

3) 推导（关键步骤）: 由链式法则：

$$\frac{du(t+1)}{dt} = \frac{\partial u(t+1)}{\partial u(t)} \frac{du(t)}{dt} \tag{55}$$

得到：

$$e(t) = \frac{u'(t+1)}{u'(t)} \tag{56}$$

4) 代入神经动力学: 由LIF模型：

$$e(t) = \frac{u(t+1) - I(t+1)}{u(t) - I(t)} \tag{57}$$

5) 离散化结果（核心公式）:

$$e^l[t] = \frac{u^l[t] - V_{th} s^l[t]}{u^l[t-1] - V_{th} s^l[t-1]} \tag{58}$$

6) 关键意义:

- 用神经元动力学替代BPTT链式展开
- 不需要存储所有历史
- 时间依赖被“隐式编码”

D. 关键突破二：*Temporal Gradient*递推

定义：

$$\hat{a}^{l-1}[t] = s^{l-1}[t] + \sum_{k<t} P_{k,t}^{l-1} \odot s^{l-1}[k] \tag{59}$$

其中：

$$P_{k,t}^{l} = \prod_{i=k}^{t-1} e^{l}[i] \tag{60}$$

1) 递推形式（核心公式）:

$$\hat{a}^{l-1}[t] = e^{l-1}[t-1] \odot \hat{a}^{l-1}[t-1] + s^{l-1}[t] \tag{61}$$

2) 推导解释: 展开递推：

$$\hat{a}[t] = s[t] + e[t-1]s[t-1] + e[t-1]e[t-2]s[t-2] + \cdots \tag{62}$$

3) 含义:

$$\hat{a}[t] = \text{带衰减的历史累积} \tag{63}$$

4) 本质: NDOT的本质是什么

$$\text{BPTT的链式乘积} \rightarrow \text{递推形式} \tag{64}$$

E. 关键突破三：完整梯度表达

$$\nabla_{W^l} L = \sum_{t=1}^{T} g_u^l[t] \cdot \hat{a}^{l-1}[t]^T \tag{65}$$

1) 空间梯度:

$$g_u^l[t] = \left(\frac{\partial L[t]}{\partial s^N[t]} \prod_{j=l}^{N-1} \frac{\partial s^{j+1}[t]}{\partial u^j[t]} \frac{\partial s^l[t]}{\partial u^l[t]} \right)^T \tag{66}$$

2) 关键性质:

- 不依赖未来时间
- 可在线计算

F. 关键突破四：*Instantaneous Loss*

$$L[t] = (1-\alpha)\ell_{CE}(s^N[t], y) + \alpha\ell_{MSE}(s^N[t], y) \tag{67}$$

1) 意义:

- 避免依赖全时间序列
- 支持在线学习

G. *NDOT*完整更新规则

$$\Delta W^l[t] = g_u^l[t] \cdot \hat{a}^{l-1}[t]^T \tag{68}$$

H. 算法本质总结

$$\text{NDOT} = \text{空间梯度（局部时间）} + \text{时间梯度（动力学递推）} \tag{69}$$

VI. OTTT方法的完整推导与信息结构分析

A. 脉冲神经元模型与时间依赖

考虑离散时间下的脉冲神经元，其状态更新满足：

$$u_i[t+1] = \lambda(u_i[t] - V_{th}s_i[t]) + \sum_j W_{ij}s_j[t] + b_i \tag{70}$$

$$s_i[t+1] = H(u_i[t+1] - V_{th}) \tag{71}$$

该模型体现出以下两个重要性质：

- 状态 $u[t]$ 依赖于过去状态 $u[t-1]$（时间递归）
- 输出 $s[t]$ 通过非线性阈值函数生成（不可导）

因此整个系统具有强烈的时间耦合特性，这也是训练困难的根本来源。

B. *BPTT*中的完整梯度表达

定义总损失：

$$L = \sum_{t=1}^{T} L[t] \tag{72}$$

根据链式法则，对权重求导：

$$\frac{\partial L}{\partial W_l} = \sum_{t=1}^{T} \frac{\partial L}{\partial s^{l+1}[t]} \frac{\partial s^{l+1}[t]}{\partial u^{l+1}[t]} \frac{\partial u^{l+1}[t]}{\partial W_l} + \sum_{t=1}^{T} \frac{\partial L}{\partial s^{l+1}[t]} \frac{\partial s^{l+1}[t]}{\partial u^{l+1}[t]} \sum_{\tau<t} \frac{\partial u^{l+1}[t]}{\partial u^{l+1}[\tau]} \frac{\partial u^{l+1}[\tau]}{\partial W_l} \tag{73}$$

该表达式包含两部分：

- 第一项：当前时间步的直接梯度贡献
- 第二项：历史时间通过状态传播影响当前输出

进一步展开时间传播项：

$$\frac{\partial u[t]}{\partial u[\tau]} = \prod_{i=\tau}^{t-1} \left(\frac{\partial u[i+1]}{\partial u[i]} + \frac{\partial u[i+1]}{\partial s[i]} \frac{\partial s[i]}{\partial u[i]} \right) \tag{74}$$

该项描述了从时间 τ 到时间 t 的所有路径贡献，是时间信用分配的核心。

C. 时间传播结构的物理含义

上述乘积项可以解释为：

$$\text{时间传播} = \text{状态传播} + \text{脉冲触发路径} \tag{75}$$

其中：

- $\frac{\partial u[i+1]}{\partial u[i]}$：连续状态传播（leaky dynamics）
- $\frac{\partial u[i+1]}{\partial s[i]}$：reset路径

这意味着梯度不仅沿状态传播，还沿脉冲触发路径传播。

*D. OTTT*的关键近似：去除*reset*梯度路径

OTTT做出核心近似：

$$\frac{\partial u[i+1]}{\partial s[i]} \frac{\partial s[i]}{\partial u[i]} \approx 0 \tag{76}$$

理由如下：

- $H(\cdot)$ 的导数在绝大多数点为0
- reset路径对梯度贡献极小

因此：

$$\frac{\partial u[i+1]}{\partial u[i]} = \lambda \tag{77}$$

E. 时间传播的简化形式

于是时间传播项简化为：

$$\frac{\partial u[t]}{\partial u[\tau]} = \lambda^{t-\tau} \tag{78}$$

将其代入梯度表达式：

$$\frac{\partial L}{\partial W_l} = \sum_{t=1}^{T} g_u[t] \sum_{\tau \le t} \lambda^{t-\tau} s^l[\tau] \tag{79}$$

其中：

$$g_u[t] = \frac{\partial L}{\partial s[t]} \cdot \frac{\partial s[t]}{\partial u[t]} \tag{80}$$

*F. Eligibility Trace*的引入

定义：

$$\hat{a}[t] = \sum_{\tau \le t} \lambda^{t-\tau} s[\tau] \tag{81}$$

该变量具有以下意义：

- 表示过去所有输入的指数加权累积
- 是时间信息的压缩表示

为了实现在线计算，将其写为递推形式：

$$\hat{a}[t+1] = \lambda \hat{a}[t] + s[t+1] \tag{82}$$

这一递推消除了对历史序列的存储需求。

G. 梯度表达的最终形式

梯度可写为：

$$\frac{\partial L}{\partial W_l} = \sum_{t=1}^{T} g_u[t] \hat{a}[t]^T \tag{83}$$

对应单个连接：

$$\Delta W_{ij} = \hat{a}_i[t] \cdot \delta_j[t] \tag{84}$$

H. 瞬时损失的引入

传统损失依赖整个时间序列：

$$L = L\left(\frac{1}{T} \sum_{t} s[t]\right) \tag{85}$$

OTTT改为：

$$L = \sum_{t=1}^{T} L[t], \quad L[t] = \frac{1}{T} L(s[t], y) \tag{86}$$

该修改使得梯度仅依赖当前时间步，从而实现在线更新 [3]。

I. 信息结构分析

BPTT梯度可以重写为：

$$\frac{\partial L}{\partial W} = \sum_{\tau} s[\tau] \sum_{t \geq \tau} \delta[t] \lambda^{t-\tau} \tag{87}$$

该表达式包含：

- 历史输入 $s[\tau]$
- 当前误差 $\delta[\tau]$
- 未来误差 $\delta[t], t > \tau$

而OTTT近似为：

$$\frac{\partial L}{\partial W} = \sum_{t} \delta[t] \hat{a}[t] \tag{88}$$

即：

$$\text{OTTT} \approx \text{BPTT} - \text{未来误差项} \tag{89}$$

J. 三因子学习结构

最终更新形式：

$$\Delta W_{ij} = \underbrace{\hat{a}_i[t]}_{\text{历史输入}} \cdot \underbrace{f(u_j[t])}_{\text{神经元响应}} \cdot \underbrace{\delta_j[t]}_{\text{误差信号}} \tag{90}$$

该结构对应典型三因子学习规则：

- presynaptic trace
- postsynaptic activity
- global error

K. 方法本质总结

OTTT通过以下三个步骤实现在线化：

1) 删除时间反向传播路径（reset路径）
2) 使用eligibility trace压缩历史信息
3) 使用瞬时损失消除未来依赖

其本质可以写为：

$$g_{\text{OTTT}} = g_{\text{past}} + g_{\text{present}} \tag{91}$$

相比BPTT缺失：

$$g_{\text{future}} \tag{92}$$

这一缺失构成其性能与近似误差的根本来源。

参考文献

[1] M. P. Apolinario, K. Roy, and C. Frenkel, "Tess: A scalable temporally and spatially local learning rule for spiking neural networks," in *2025 International Joint Conference on Neural Networks (IJCNN)*. IEEE, 2025, pp. 1–9.

[2] M. P. E. Apolinario and K. Roy, "S-tllr: Stdp-inspired temporal local learning rule for spiking neural networks," *arXiv preprint arXiv:2306.15220*, 2023.

[3] M. Xiao, Q. Meng, Z. Zhang, D. He, and Z. Lin, "Online training through time for spiking neural networks," *Advances in neural information processing systems*, vol. 35, pp. 20 717–20 730, 2022.