

NDOT: Neuronal Dynamics-based Online Training for Spiking Neural Networks 论文详细汇总

I. 论文概述

本文总结自《NDOT: Neuronal Dynamics-based Online Training for Spiking Neural Networks》[1]。该工作提出了一种新的在线训练方法 NDOT，用于直接训练脉冲神经网络（SNNs），实现前向时间（forward-in-time）学习，避免传统 BPTT 中沿时间展开的高内存开销。

II. 问题背景

leftmargin=*

- 脉冲神经网络的激活函数是二值的脉冲发放函数，导致梯度不可导。常用的直接训练方式是使用替代梯度（surrogate gradient）结合时间反向传播（BPTT）。
- BPTT 需要保存所有时间步的中间状态，内存消耗随时间步数线性增长，无法满足在线训练与低延迟场景。
- 现有方法包括：ANN-to-SNN 转换、基于时序的 spike representation、OTTT 等在线近似方法。它们要么延迟较高，要么对时间依赖进行粗略近似，影响性能。

III. 核心思想与方法

A. SNN 基本模型

离散 LIF 模型定义为：

$$u_i[t+1] = \lambda(u_i[t] - V_{th}s_i[t]) + \sum_j W_{ij}s_j[t+1], \quad (1)$$

$$s_i[t] = H(u_i[t] - V_{th}), \quad (2)$$

其中 $s_i[t] \in \{0, 1\}$ ， H 为 Heaviside 阶跃函数， λ 为泄漏常数。

B. BPTT 中的时间依赖

BPTT 的全梯度可写作：

$$\frac{\partial L}{\partial W^l} = \sum_{t=1}^T \frac{\partial L}{\partial s^l[t]} \frac{\partial s^l[t]}{\partial u^l[t]} \left(\frac{\partial u^l[t]}{\partial W^l} + \sum_{k < t} \prod_{i=k}^{t-1} \varepsilon^l[i] \frac{\partial u^l[k]}{\partial W^l} \right), \quad (3)$$

其中离散时间依赖项定义为

$$\varepsilon^l[t] = \frac{\partial u^l[t+1]}{\partial u^l[t]} + \frac{\partial u^l[t+1]}{\partial s^l[t]} \frac{\partial s^l[t]}{\partial u^l[t]}. \quad (4)$$

该表达式需要沿时间步级联，导致 BPTT 保留全部历史状态。

C. NDOT 的关键突破

a) 连续神经元动力学表征: NDOT 用神经元动力学定义连续时间依赖:

$$e^l[t] = \frac{u^l[t] - V_{th}s^l[t]}{u^l[t-1] - V_{th}s^l[t-1]}. \quad (5)$$

该表示将神经元的充电、泄漏与发放动态整体封装为一个前向依赖系数。

b) 梯度解耦: NDOT 将全梯度分解为:

$$\nabla_{W^l} L = \sum_{t=1}^T g_l^u[t] \hat{a}^{l-1}[t]^\top, \quad (6)$$

其中: leftmargin=*

- $g_l^u[t]$ 表示空间梯度, 即当前时间步各层间的梯度传递;
- $\hat{a}^{l-1}[t]$ 表示时间梯度, 对应前一层跨时间步的梯度累积。

c) 时间梯度的递推: NDOT 通过前向递推得到时间梯度:

$$\hat{a}^{l-1}[t] = e^{l-1}[t-1] \odot \hat{a}^{l-1}[t-1] + s^{l-1}[t]. \quad (7)$$

该递推仅依赖前一时间步的状态, 从而实现前向时间在线计算。

D. 算法伪代码

leftmargin=*

1) 对于每个时间步 $t = 1, \dots, T$:

- 对每层 $l = 1, \dots, N$: 前向更新 $u^l[t]$, 生成 $s^l[t]$; 计算时间依赖 $e^l[t]$; 递推 $\hat{a}^l[t]$ 。
 - 反向遍历层 $l = N, \dots, 1$: 计算当前时间步的空间梯度 $g_l^u[t]$, 并用 $\nabla_{W^l} L = g_l^u[t] \hat{a}^{l-1}[t]^\top$ 更新权重。
- a) 瞬时损失函数: 为了支持在线学习, NDOT 使用瞬时损失:

$$L[t] = (1 - \alpha) \ell_{CE}(s^N[t], y) + \alpha \ell_{MSE}(s^N[t], y). \quad (8)$$

该损失可在每个时间步独立计算, 保证在线训练性。

IV. 算法优势

leftmargin=*

- 在线前向学习: 无需回溯时间维度即可计算完整梯度, 适用于低延迟与流式输入场景。
- 常数训练内存: 梯度计算仅保留当前时间步和前一时间步的必要状态, 避免 BPTT 的 $O(T)$ 内存开销。
- 更精确的时间依赖建模: 不同于 OTTT 直接近似时间导数为 0, NDOT 用神经元动力学显式刻画时间依赖, 提高梯度准确性。
- 兼容自动微分: 空间梯度 $g_l^u[t]$ 可交由 PyTorch 自动求导计算, 易于实现。

V. 实验结果

A. 数据集与设置

leftmargin=*

- 数据集: CIFAR-10、CIFAR-100、CIFAR10-DVS。
- 网络结构: VGG 变体 (含 64C3、128C3、256C3、512C3 等层级) + GAP + FC。
- 模型变体: NDOTO (每步实时更新) 与 NDOTA (跨时间步累积更新)。
- 训练细节: SGD 优化器, 无权重衰减, 初始学习率 0.1, cosine decay; LIF 参数 $V_{th} = 1, \lambda = 0.5$ 。

B. 主要性能

leftmargin=*

- CIFAR-10: NDOTO 在 $T = 6$ 时达 94.89%, NDOTA 达 94.90%, 均优于 OTTT 的 93.73%。
- CIFAR-100: NDOTO 在 $T = 6$ 时达 76.61%, 与 OTTT 的 71.11% 相比提升明显。
- DVS-CIFAR10: NDOTO 在 $T = 10$ 时达 77.50%, 优于 OTTT 的 77.10%。

C. 实验结论

NDOT 在同等时间步下, 显著优于现有前向时间在线方法, 尤其在复杂数据集 (CIFAR-100) 上表现提升更明显。这说明通过连续神经元动力学表示时间依赖, NDOT 能更好地保留时序信息并获得更准确的学习信号。

VI. 总结

NDOT 的核心贡献在于: leftmargin=*

- 提出基于神经元动力学的连续时间依赖表示, 替代传统 BPTT 的离散时间展开;
- 将梯度分解为空间梯度与时间梯度, 实现前向时间在线训练;
- 保持在线性空间, 避免增长的时间记忆开销;
- 在 CIFAR-10/100 及 DVS 数据集上展示出高性能与低时延训练的可行性。

参考文献

- [1] H. Jiang, G. D. Masi, H. Xiong, and B. Gu, "NDOT: Neuronal dynamics-based online training for spiking neural networks," in *Forty-first International Conference on Machine Learning*, 2024. [Online]. Available: <https://openreview.net/forum?id=eIF0QoBSFV>