

OTTT: Online Training Through Time for Spiking Neural Networks 论文详细汇总

I. 文章信息

本文基于原文 *Online Training Through Time for Spiking Neural Networks* [1] (arXiv:2210.04195v2, NeurIPS 2022) 进行整理，原文存放于仓库路径 `Algorithm/OTTT/2210.04195v2_OTTT.pdf`。

II. 研究背景与动机

leftmargin=*

- 脉冲神经网络（SNN）具有生物启发的事件驱动和能效优势，但其训练面临离散脉冲激活的不可导性问题。
- 目前主流训练方案包括：
 - 1) BPTT + 替代梯度（surrogate gradient），低时间步高性能，但需要沿时间展开计算，内存成本随时间步线性增长；
 - 2) 基于脉冲表示的闭式映射，优化理论更清晰，但通常需要更多时间步，带来高延迟和能耗；
- 两者均不符合生物在线学习的前向时间特性，也不完全适配神经形态芯片的在线学习需求。

III. 模型与预备知识

A. LIF 脉冲神经元模型

离散 LIF 模型的迭代形式为：

$$u_i[t+1] = \lambda(u_i[t] - V_{th}s_i[t]) + \sum_j W_{ij}s_j[t+1] + b_i, \quad (1)$$

$$s_i[t+1] = H(u_i[t+1] - V_{th}), \quad (2)$$

其中 $H(\cdot)$ 为 Heaviside 阶跃函数， $\lambda < 1$ 为泄漏项， $s_i[t] \in \{0, 1\}$ 表示脉冲。

连续时间下的 LIF 模型可写为：

$$\tau_m \frac{du}{dt} = -(u - u_{rest}) + R \cdot I(t), \quad u < V_{th}. \quad (3)$$

B. BPTT 训练梯度

传统 BPTT 的梯度表达式为：

$$\frac{\partial L}{\partial W^l} = \sum_{t=1}^T \frac{\partial L}{\partial s^{l+1}[t]} \frac{\partial s^{l+1}[t]}{\partial u^{l+1}[t]} \left(\frac{\partial u^{l+1}[t]}{\partial W^l} + \sum_{\tau < t} \prod_{i=\tau}^{t-1} \left(\frac{\partial u^{l+1}[i+1]}{\partial u^{l+1}[i]} + \frac{\partial u^{l+1}[i+1]}{\partial s^{l+1}[i]} \frac{\partial s^{l+1}[i]}{\partial u^{l+1}[i]} \right) \frac{\partial u^{l+1}[\tau]}{\partial W^l} \right). \quad (4)$$

其中非可导项 $\partial s / \partial u$ 由 surrogate derivative 近似，例如矩形函数或 sigmoid 函数。

IV. OTTT 方法

A. 核心理念

OTTT 的核心是**解耦时间依赖**，将 BPTT 中的时间传播信息从反向传播中剥离，转而使用前向跟踪的**突触前活动**（presynaptic activity）。

在 feedforward 条件下，若忽略 reset 路径中 Spike 导数的时间依赖，则脉冲神经元的时间依赖项可近似为 λI ，从而得到：

$$\frac{\partial L}{\partial W^l} = \sum_{t=1}^T g_{l+1}^u[t] \left(\sum_{\tau \leq t} \lambda^{t-\tau} s^l[\tau] \right)^\top, \quad (5)$$

其中

$$g_{l+1}^u[t] = \left(\frac{\partial L}{\partial s^{l+1}[t]} \frac{\partial s^{l+1}[t]}{\partial u^{l+1}[t]} \right)^\top \quad (6)$$

是当前时间步的空间梯度。

B. 前向跟踪的突触前活动

OTTT 通过以下递推式在前向过程中跟踪突触前活动：

$$\hat{a}^l[t+1] = \lambda \hat{a}^l[t] + s^l[t+1]. \quad (7)$$

该变量可以被看作类似于加权资格迹或加权脉冲发放累积。

因此，在每个时间步 t ，权重梯度可以直接计算为：

$$\nabla_{W^l} L[t] = g_{l+1}^u[t] (\hat{a}^l[t])^\top. \quad (8)$$

C. 瞬时损失与在线更新

OTTT 使用瞬时损失：

$$L[t] = \frac{1}{T} \mathcal{L}(s^N[t], y), \quad (9)$$

其中 $\mathcal{L}$ 可采用交叉熵或其他凸损失。整体损失 $L = \sum_{t=1}^T L[t]$ 是基于瞬时损失的上界。

该设计使梯度在每个时间步独立计算，并且无需展开时间维度，从而支持**前向时间在线学习**。

D. OTTT 算法流程

leftmargin=*

- 1) 初始化模型参数 W^l 和突触前活动 $\hat{a}^l[0] = 0$ 。
- 2) 对每个时间步 $t = 1, \dots, T$:
 - a) 前向计算每层膜电位与脉冲： $u^l[t], s^l[t]$ 。
 - b) 更新突触前活动： $\hat{a}^l[t] = \lambda \hat{a}^l[t-1] + s^l[t]$ 。
 - c) 计算当前时间步的瞬时损失 $L[t]$ 。
 - d) 计算每层空间梯度 $g_l^u[t]$ ，并通过 $\nabla_{W^{l-1}} L[t] = g_l^u[t] (\hat{a}^{l-1}[t])^\top$ 更新权重。
- 3) 可选策略：OTTT-O 立即更新参数，OTTT-A 累积 T 步梯度后再更新。

V. 理论分析

A. 与脉冲表示训练的连接

OTTT 将突触前活动 $\hat{a}[t] = \sum_{\tau \leq t} \lambda^{t-\tau} s[\tau]$ 与基于脉冲表示的加权发放率 $a[t]$ 联系起来, 后者可证明在输入收敛时趋于

$$a^*[T] \approx \sigma\left(\frac{1}{V_{th}} W a^*[T] + b\right). \quad (10)$$

基于该连接, 可得脉冲表示方法的梯度形式:

$$(\nabla_{W^l} L_{sr})_{sr} = \sum_{t=1}^T \left(\frac{1}{T \lambda^{T-t}} \frac{\partial L_{sr}}{\partial s^N[t]} \prod_{i=l}^{N-1} \frac{\partial a^{i+1}[T]}{\partial a^i[T]} \odot d^{l+1}[T] \right) (\hat{a}^l[T])^\top. \quad (11)$$

同时, OTTT 的梯度为:

$$\nabla_{W^l} L = \frac{1}{T} \sum_{t=1}^T \hat{g}_{l+1}^u[t] (\hat{a}^l[t])^\top. \quad (12)$$

在合理近似条件下, OTTT 的梯度与脉冲表示方法的梯度具有相似形式, 并且可证明其依然是下降方向。

B. 递归网络下的收敛保证

对于带有反馈连接的单层 SNN, 若输入 $x[t] \rightarrow x^*$ 收敛, 并且网络映射的雅可比矩阵满足一定谱半径条件, 则 OTTT 近似梯度同样保持下降方向。这表明 OTTT 在递归网络条件下也具有理论解释。

C. 三因子 Hebbian 学习形式

OTTT 的单个权重更新可写为:

$$\nabla W_{ij}[t] = \hat{a}_i[t] f(u_j[t]) \delta_j[t], \quad (13)$$

其中 $\hat{a}_i[t]$ 为突触前活动, $f(u_j[t])$ 为 surrogate derivative, $\delta_j[t]$ 为后突触误差信号。该表达式呈现经典的三因子 Hebbian 结构: 前突触信息、后突触激活变化与全局误差信号的乘积。

VI. 主要优势

leftmargin=*

- 常数训练内存: OTTT 不需要沿时间展开计算图, 训练内存与时间步数无关;
- 前向时间在线学习: 梯度计算仅依赖当前时间步和已跟踪的突触前活动;
- 理论可解释性: 证明了 OTTT 的梯度与脉冲表示方法的梯度具有相似下降方向, 补充了 BPTT + SG 的理论薄弱性;
- 生物可解释性: 权重更新形式对应三因子 Hebbian 规则, 更贴近神经形态在线学习;
- 可扩展性: 方案可同时适用于前向网络与递归网络, 并在大规模数据集上验证。

VII. 实验验证

leftmargin=*

- 数据集: CIFAR-10、CIFAR-100、ImageNet、CIFAR10-DVS、DVS128-Gesture;
- 网络结构: VGG 系列 (9.2M 参数) 用于 CIFAR 和 DVS; NF-ResNet-34 用于 ImageNet;
- 训练设置: $V_{th} = 1$, $\lambda = 0.5$, 使用 scaled weight standardization (sWS) 替代 batch normalization, 以保持在线可行性。

A. 实验结论

leftmargin=*

- OTTT 在 6 个时间步下, CIFAR-10 取得约 93.5% 的准确率, 超过同条件下 BPTT;
- OTTT 在 CIFAR-100 和 DVS 数据集上同样表现优异, 并且训练内存显著低于 BPTT;
- GPU 训练内存测试显示, BPTT 内存随着时间步线性增长, 而 OTTT 内存保持几乎不变, 最多可降低约 $2 \sim 3 \times$ 内存成本。

VIII. 总结

OTTT 提出了一种面向 SNN 的在线训练框架, 通过前向跟踪突触前活动和瞬时损失实现了前向时间学习。该方法将 BPTT、脉冲表示训练和三因子 Hebbian 规则连接起来, 理论上证明其梯度仍具有下降方向, 并在多个大规模静态与神经形态数据集上展示了良好的性能。

参考文献

- [1] M. Xiao, Q. Meng, Z. Zhang, D. He, and Z. Lin, "Online training through time for spiking neural networks," *Advances in neural information processing systems*, vol. 35, pp. 20 717–20 730, 2022.