

基于事件驱动神经网络的在线信息重构算法研究组会汇报

SNN 信息重构小组

摘要

本报告总结了我们在脉冲神经网络（SNN）在线训练与信息重构方向的研究进展，重点介绍四种代表性算法：*S-TLLR*、*TESS*、*NDOT* 和 *OTTT*。报告包括问题背景、算法原理、关键公式、实现流程、对比分析以及后续研究方向，旨在为组会汇报提供详细且易于理解的技术脉络。

I. 研究背景

近年来，脉冲神经网络（SNN）因其低功耗、事件驱动和时间动态特性，在神经形态计算与时序信号处理领域受到广泛关注。相比传统人工神经网络，SNN的训练面临以下挑战：

- 离散脉冲与不可微激活函数导致梯度传播困难；
- 在线学习与延迟误差反馈要求高效的时空依赖建模；
- 大规模网络训练需要兼顾实时性与生物可解释性。

为此，本组研读了四种在线训练算法：*S-TLLR*、*TESS*、*NDOT* 和 *OTTT*，分别代表了基于本地学习规则和基于时间追踪的两条技术路线。

II. 本工作概况

本研究主要工作包括：

- 1) 阅读与整理关键论文：*S-TLLR*、*TESS*、*NDOT* 和 *OTTT*；
- 2) 提取算法核心公式与伪代码，构建可读的 LaTeX 总结文档；
- 3) 对比四种方法在在线训练、时空局部性、复杂度和可实现性方面的差异；
- 4) 生成组会汇报材料，供后续讨论与实现参考。

本报告基于四篇论文，围绕在线 SNN 训练的不同技术路径展开分析。

III. 四种算法的核心思想

本组研读的四个算法所代表的技术方向如下：

- **S-TLLR**: 基于 STDP 的三因子时序局部学习规则，强调因果与非因果时序关系；
- **TESS**: 面向可扩展在线学习的时序与空间本地规则，强调完全本地的空间信用分配；
- **NDOT**: 基于神经元动力学的时间梯度分解方法，强调前向时间递推；
- **OTTT**: 通过时间追踪变量实现在线训练，避免完整时间反向传播。

这些算法背后的共同目标是：在不依赖完整 BPTT 的情况下，实现脉冲神经网络的高效在线训练与时序信息重构。相关工作见 [1]–[4]。

IV. S-TLLR 算法详细介绍

S-TLLR 是一种受生物学启发的三因子学习规则，旨在实现低内存、低计算代价的在线 SNN 训练。

A. 神经元模型

S-TLLR 使用离散时间 LIF 模型：

$$u_i[t] = \gamma(u_i[t-1] - v_{th}y_i[t-1]) + \sum_j w_{ij}x_j[t], \quad (1)$$

$$y_i[t] = \Theta(u_i[t] - v_{th}), \quad (2)$$

其中 u_i 为膜电位， y_i 为输出脉冲， x_j 为输入脉冲。

B. 三因子规则

S-TLLR 将权重更新表示为：

$$\Delta w_{ij}[t] = \eta m_i[t] e_{ij}[t], \quad (3)$$

其中 $e_{ij}[t]$ 是资格迹， $m_i[t]$ 是第三因子学习信号。

资格迹包含 STDP 的因果与非因果分量：

$$e_{ij}[t] = \sum_{\tau \leq t} \left(\alpha_{pre} \lambda_{pre}^{t-\tau} x_j[\tau] y_i[t] + \alpha_{post} \lambda_{post}^{t-\tau} x_j[t] y_i[\tau] \right). \quad (4)$$

这一结构使 S-TLLR 能同时利用过去前突触活动和过去后突触活动的信息。

C. 本地第三因子

S-TLLR 的第三因子 $m_i[t]$ 可以由层间误差信号或固定随机反馈生成，进而调制资格迹。这样既保留了误差指导能力，又保持了时序上的本地更新特性。

D. 算法优势

S-TLLR 的优点包括：

- 内存复杂度与神经元数线性相关，不依赖时间步长；
- 乘加运算显著减少，适合能耗敏感的边缘设备；
- 同时利用因果与非因果时间特征，提高时序泛化能力。

相关研究见 [1]。

V. TESS 算法详细介绍

TESS 是一种可扩展的时序与空间本地学习规则，目标是在深层 SNN 上实现真正的本地在线训练。

A. 核心机制

TESS 通过以下两部分实现在线训练:

- **资格迹:** 保留历史活动信息, 用于 **temporal credit assignment**;
- **本地学习信号:** 利用神经元活动同步或固定基向量生成, 解决 **spatial credit assignment**。

B. 更新形式

TESS 的权重更新同样采用三因子形式:

$$\Delta w_{ij}[t] = \eta m_i[t] e_{ij}[t]. \quad (5)$$

其中 $e_{ij}[t]$ 为资格迹, $m_i[t]$ 为完全本地构造的学习信号。

C. 空间信用分配

与依赖跨层误差传播的规则不同, TESS 用层内信号构造空间信用分配, 使每层权重更新仅依赖本层或相邻层的局部信息。这一点是其可扩展性的关键。

D. 性能总结

TESS 在论文中展示:

- CIFAR10-DVS 上精度仅比 BPTT 低约 1.4%;
- 在 IBM DVS Gesture、CIFAR10、CIFAR100 等任务上实现与 BPTT 相近性能;
- 资源消耗大幅降低, 适合在边缘设备上部署。

相关研究见 [2]。

VI. NDOT 算法详细介绍

NDOT 提出了一种基于神经元动力学的时间梯度分解方法, 通过前向递推实现在线训练。

A. 模型与符号

对第 l 层神经元, 定义:

$$u^l[t] = \alpha u^l[t-1] + W^l s^{l-1}[t] - s^l[t-1], \quad (6)$$

$$s^l[t] = H(u^l[t] - \vartheta). \quad (7)$$

其中 α 为泄漏因子, ϑ 为阈值。

B. 梯度分解

NDOT 将梯度分解为空间梯度和时间梯度:

$$g_l^u[t] = \frac{\partial L}{\partial u^l[t]}, \quad (8)$$

$$a^l[t] = \frac{\partial u^l[t]}{\partial u^l[t-1]} = \alpha - \beta \sigma'(u^l[t] - \vartheta). \quad (9)$$

C. 在线递推

引入时间梯度累积量：

$$e^l[t] = a^l[t] \odot e^l[t-1] + g_l^u[t], \quad (10)$$

$$\nabla_{w^l} L[t] = e^l[t] (s^{l-1}[t])^\top. \quad (11)$$

这种前向递推机制使得 **NDOT** 能够在每个时间步立即计算梯度。

D. 实践价值

NDOT 的优势包括：

- 利用神经元动力学的连续性，避免回溯整个时间序列；
- 适合在线时序信号处理与信息重构场景；
- 具有较强的理论解释性。

相关研究见 [3]。

VII. OTTT 算法详细介绍

OTTT 通过前向时间追踪变量实现在线训练，避免完整时间反向传播。

A. 时间追踪变量

OTTT 定义：

$$\hat{a}^l[t] = \alpha \hat{a}^l[t-1] + s^{l-1}[t]. \quad (12)$$

该变量用于近似当前时间步对历史输入的累积响应。

B. 梯度近似

梯度表示为：

$$\nabla_{w^l} L[t] = g_{l+1}^u[t] (\hat{a}^l[t])^\top. \quad (13)$$

其中 $g_{l+1}^u[t]$ 是后层误差信号对膜电位的灵敏度。

C. 实现意义

OTTT 的主要优势是：

- 采用前向递推实现在线更新；
- 简化了时间维度的误差传播过程；
- 适合对即时响应和低延迟有要求的应用。

VIII. 四种算法的对比分析

A. 时空局部性

- S-TLLR 与 TESS 最强调时空本地性；
- NDOT 强调时间梯度的前向递推；
- OTTT 强调前向时间追踪变量。

B. 适用场景

- S-TLLR 和 TESS 适合边缘设备与低功耗在线学习；
- NDOT 适合理论分析和动力学驱动的在线训练；
- OTTT 适合即时在线更新与快速部署。

IX. 我们的成果与后续规划

A. 已有成果

- 阅读并整理了四种在线 SNN 算法；
- 提取核心公式、算法流程和实现要点；
- 完成面向组会的详细对比和技术总结。

B. 后续方向

- 基于四种算法搭建统一实验框架；
- 对 S-TLLR、TESS、NDOT 和 OTTT 进行性能对比；
- 探索算法在信息重构任务中的实际效果。

X. 结论

本报告系统性地总结了 S-TLLR、TESS、NDOT 和 OTTT 四类在线 SNN 训练算法。S-TLLR 与 TESS 提供了基于本地资格迹的可扩展在线学习方案，NDOT 提供了基于动力学的时间梯度分解方法，OTTT 提供了基于时间追踪变量的在线更新策略。后续工作可围绕实现、对比和硬件适配开展。

参考文献

- [1] M. P. E. Apolinario and K. Roy, "S-TLLR: STDP-inspired Temporal Local Learning Rule for Spiking Neural Networks," Oct. 2024, arXiv:2306.15220 [cs]. [Online]. Available: <http://arxiv.org/abs/2306.15220>
- [2] M. P. Apolinario, K. Roy, and C. Frenkel, "Tess: A scalable temporally and spatially local learning rule for spiking neural networks," in *2025 International Joint Conference on Neural Networks (IJCNN)*. IEEE, 2025, pp. 1–9.
- [3] H. Jiang, G. D. Masi, H. Xiong, and B. Gu, "NDOT: Neuronal dynamics-based online training for spiking neural networks," in *Forty-first International Conference on Machine Learning*, 2024. [Online]. Available: <https://openreview.net/forum?id=elF0QoBSFV>
- [4] M. Xiao, Q. Meng, Z. Zhang, D. He, and Z. Lin, "Online training through time for spiking neural networks," *Advances in neural information processing systems*, vol. 35, pp. 20 717–20 730, 2022.