

# SNN 信用分配：从原公式到在线/局部化近似

## 摘要

本方案以六篇与 SNN 在线/局部信用分配密切相关的核心论文为理论主线，从每篇的原公式出发，逐步推导它们各自的梯度计算方式。

**研究基准：**从 BPTT 与 RTRL 两类精确信用分配基准出发（reverse-mode / forward-mode），分析在线/局部算法在 **temporal representation**、**eligibility** 与 **learning signal** 上进行了何种重组或近似。

**总研究问题：**What information is lost by temporal/spatial localization, and how do the losses interact?

三条研究路径：

- **时间近似：**BPTT  $\rightarrow$  OTTT  $\rightarrow$  NDOT，研究 temporal dependency  $e^l[t]$  如何被  $\lambda I$  或  $\text{diag}(e^l[t])$  替代；
- **精确到局部：**RTRL  $\rightarrow$  e-prop，研究 RTRL 的 full forward sensitivity 与 e-prop 的 local eligibility + learning-signal factorization 之间的关系；
- **生物局部化：**STDP  $\rightarrow$  S-TLLR  $\rightarrow$  TESS，研究预突触-突触后时序信息如何逐步引入 task credit 与空间局部性。

**核心研究问题：**这些在线/局部化操作到底保留了什么 credit information，丢失了什么 credit information，以及这些差异什么时候真正影响学习。

## 文章汇总

**RTRL: A learning algorithm for continually running fully recurrent neural networks** [1];

**E-prop: A solution to the learning dilemma for recurrent networks of spiking neurons** [2];

**OTTT: Online Training Through Time for Spiking Neural Networks** [3];

**NDOT: NDOT: Neuronal Dynamics-based Online Training for Spiking Neural Networks** [4];

**S-TLLR: S-TLLR: STDP-inspired Temporal Local Learning Rule for Spiking Neural Networks** [5];

**TESS: TESS: A Scalable Temporally and Spatially Local Learning Rule for Spiking Neural Networks** [6].

## I. 研究背景与核心问题

### A. SNN 训练的根本困难

SNN 用二进制脉冲  $s_j^t \in \{0, 1\}$  传递信息：神经元只有在膜电位达到阈值时才发放一个脉冲，脉冲本身是二值的、不可微的。这带来两个层面的信用分配困难：

- 1) **时间信用分配：**一个输出时刻的损失，可能由多个时间步之前的输入决定；要把这个损失归因到具体某个时刻的突触权重上，需要追踪“过去  $\rightarrow$  现在”的因果链；
- 2) **空间信用分配：**损失发生在输出层，但要归因到每个隐藏层的权重上；需要把误差从输出层反向传播到各隐藏层。

BPTT 是求解这两个问题的标准方法。它的核心思想是：把 SNN 沿时间展开成一个很深的 feedforward 计算图，然后在这个展开图上调用反向传播。代价是需要保存所有时间步的 forward

states (每个时刻的膜电位  $u^l[t]$ 、脉冲  $s^l[t]$  等), 内存  $O(TLn)$ , 且必须等整个序列前向完成后才能开始反向, 这排除了在线学习。

关于”精确”的约定: BPTT 与 RTRL 对一个可微 recurrent computational graph 分别给出 reverse-mode 和 forward-mode exact gradient。但 SNN 的脉冲发放  $s = H(u - V_{th})$  几乎处处导数为零, 不是可微函数; 实际训练中所有方法都用 surrogate  $\Psi'_{SG}$  替代  $\partial s / \partial u$ 。因此本文所用的 reference 是 **BPTT-with-SG / RTRL under the same surrogate rule**, 其”精确”仅指相对于选定 surrogate backward rule 的精确计算, 不代表连续动力学的真实导数。下文所有  $g_{BPTT}$  均指 **BPTT-with-SG reference estimator**, 不称为”exact gradient”。

## B. 已有工作

**时间近似主线:** OTTT [3] 注意到在 BPTT 的 temporal chain 里, spike-mediated path 通常极稀疏 (因为  $H$  几乎处处导数为零), 于是丢弃该路径, 把时序依赖退化为固定指数衰减  $\lambda^{t-\tau}$ ; NDOT [4] 进一步从连续 LIF 微分方程推导动态比率  $e^l[t]$ , 替代固定  $\lambda$ 。

**精确到局部主线:** RTRL [1] 用 forward-mode 计算参数敏感度  $P_t$ , 是完全 forward-in-time 的精确梯度方法, 但内存  $O(n^3)$ ; e-prop [2] 重新组织 chain rule, 把梯度分解为”局部 eligibility  $\times$  learning signal”, 大幅降低内存。

**生物局部化主线:** STDP 用 pre/post 时序定义突触可塑性; S-TLLR [5] 引入 STDP 形式的因果与非因果资格迹, 再用 learning signal 调制; TESS [6] 通过本地学习信号生成实现时空全局部。

关于”联合局部化”的现状: 时空联合局部学习本身已经被研究过——TESS [6] 已把 temporal eligibility 与 layer-local spatial signal 结合; Traces Propagation 等工作也处理时空联合的 forward-only learning。因此本研究不以”首次实现时空联合”作为 novelty。

本研究的问题不是”能否联合”, 而是”联合局部化时各自损失了什么、损失如何耦合”:

- 时间局部化 (例如 OTTT 的固定  $\lambda$ 、NDOT 的  $\text{diag}(e^l)$ ) 在 temporal dependency 上引入了何种结构性误差?
- 空间局部化 (例如 Mostafa-style local classifier) 在目标替换上引入了何种结构性误差?
- 当两种局部化同时施加时, 误差是简单叠加还是产生 interaction?

## C. 核心研究问题

**总问题:** What information is lost by temporal/spatial localization, and how do the losses interact?

**三条研究路径下的具体问题:**

- 路径一:  $e^l[t] \rightarrow \lambda I$  或  $\text{diag}(e^l[t])$  到底改变了多少 temporal credit? 在什么样的  $T, \lambda$  下差异显现?
- 路径二: RTRL 的 full forward sensitivity 与 e-prop 的 local eligibility + learning signal factorization 是同维度对象吗? 它们各自保留了什么?
- 路径三: STDP-inspired eligibility 中的 causal / non-causal timing 分别提供什么? layer-local spatial learning signal 与 cross-layer BP learning signal 的差别落在哪?

## II. 数学基础

### A. LIF 神经元 (*feedforward* 形式)

$$u_j^l[t+1] = \lambda(u_j^l[t] - V_{th} s_j^l[t]) + \sum_i W_{ji}^{l \leftarrow l-1} s_i^{l-1}[t+1] + b_j^l, \quad s_j^l[t] = H(u_j^l[t] - V_{th}). \quad (1)$$

这个公式在说什么：第  $l$  层神经元  $j$  的膜电位  $u_j^l[t+1]$  由三部分决定——上一时刻膜电位经过衰减后剩下的“记忆”、来自上一层神经元的加权输入、以及偏置。当膜电位达到阈值  $V_{th}$  时，神经元发放一个脉冲  $s_j^l[t] = 1$ 。

逐项拆解：

- $\lambda(u_j^l[t] - V_{th} s_j^l[t])$ ：这是**leak**加**reset**。
  - $u_j^l[t]$  乘  $\lambda$  表示膜电位随时间指数衰减（“leak”）。 $\lambda = e^{-\delta t / \tau_m} < 1$ ， $\delta t$  越小或  $\tau_m$  越大， $\lambda$  越接近 1，膜电位衰减越慢、记忆越长；
  - $-V_{th} s_j^l[t]$  是**reset by subtraction**：如果  $t$  时刻发放了脉冲（ $s_j^l[t] = 1$ ），则从上一步膜电位中减去  $V_{th}$ ，防止膜电位一直累积。整个括号项先做 **reset**、再被  $\lambda$  衰减（注意： $\lambda$  作用在 **reset** 之后的量上）。
- $\sum_i W_{ji}^{l \leftarrow l-1} s_i^{l-1}[t+1]$ ：来自上一层的加权输入。 $s_i^{l-1}[t+1]$  是上一层神经元  $i$  在  $t+1$  时刻的脉冲；如果是 **feedforward** 结构，输入到达的时刻和神经元更新同步。
- $b_j^l$ ：偏置项，用来调整该神经元的兴奋程度基线。
- $s_j^l[t] = H(u_j^l[t] - V_{th})$ ：**Heaviside** 阶跃函数  $\mathbb{I}[x \geq 0]$ 。当膜电位达到或超过阈值时输出 1，否则输出 0。这一项在训练中**前向不可导**，是 **SNN** 训练困难的核心来源。

参数解释：

| 符号                          | 数学定义 / 形状                               | 物理含义与典型取值                                         |
|-----------------------------|-----------------------------------------|---------------------------------------------------|
| $l \in \{1, \dots, L\}$     | 整数层索引                                   | $l = 0$ 为输入层， $l = L$ 为输出层                        |
| $j$                         | 当前层神经元索引                                | 遍历 $1, \dots, n^{(l)}$                            |
| $i$                         | 上一层神经元索引                                | <b>BPTT-OTTT-NDOT</b> 主线中只指 $l-1$ 层               |
| $u_j^l[t]$                  | $\mathbb{R}$ （标量）                       | 第 $l$ 层 $j$ 号神经元 $t$ 时刻的膜电位，是 <b>hidden state</b> |
| $s_j^l[t]$                  | $\{0, 1\}$ （标量）                         | 是否发放： $u_j^l[t] \geq V_{th}$ 时为 1                 |
| $W_{ji}^{l \leftarrow l-1}$ | $\mathbb{R}^{n^{(l)} \times n^{(l-1)}}$ | 从 $l-1$ 层 $i$ 到 $l$ 层 $j$ 的突触权重                   |
| $b_j^l$                     | $\mathbb{R}$                            | 偏置项                                               |
| $V_{th}$                    | 正实数                                     | 发放阈值，本文取 $V_{th} = 1$                             |
| $\lambda$                   | $e^{-\delta t / \tau_m} \in (0, 1)$     | 膜衰减因子； $\tau_m$ 为膜时间常数， $\delta t$ 为离散步长          |
| $H(x)$                      | $\mathbb{I}[x \geq 0]$                  | <b>Heaviside</b> 阶跃函数，前向不可导                       |

### B. Surrogate Gradient

$$\frac{\partial s_j^l[t]}{\partial u_j^l[t]} \rightarrow \Psi'_{SG}(u_j^l[t] - V_{th}), \quad \Psi'_{SG}(x) = \frac{1}{(1 + \beta|x|)^2}, \quad \beta = 4. \quad (2)$$

为什么需要 **surrogate**: Heaviside 函数  $H(x)$  在  $x = 0$  处不可导, 在其他地方导数为零。如果严格按导数反向传播, 梯度将处处为零, 训练无法进行。surrogate gradient 的做法是: 前向仍然使用真正的 Heaviside 产生脉冲, 反向把  $\partial s/\partial u$  替换成一个光滑、有界的函数, 让梯度能够回流。

为什么选 **fast-sigmoid**:  $\Psi'_{SG}(x) = 1/(1 + \beta|x|)^2$  在  $x = 0$  处取最大值 1, 随着  $|x|$  增大迅速衰减。它有两个好处:

- 当膜电位接近阈值 ( $u - V_{th} \approx 0$ ) 时, 神经元处于“决策边界”, 梯度最大, 学习信号最强;
- 当膜电位远离阈值 ( $|u - V_{th}|$  很大) 时, 梯度快速衰减到零, 避免已经在“确定发放/确定不发放”状态的神经元继续被扰动。

参数解释:

- $\Psi'_{SG}$ : surrogate derivative, 用于反向替代不可导的  $\partial s/\partial u$ ;
- $\beta$ : 锐度参数, 本文取  $\beta = 4$ ;  $\beta$  越大, surrogate 越接近真正的阶跃导数 (几乎处处为零), 训练信号越稀疏;
- $D_{\Psi,t} = \text{diag}[\Psi'_{SG}(u_j^l[t] - V_{th})]_j$ : 把所有神经元  $j$  的 surrogate 导数排成对角矩阵,  $D_{\Psi,t} \in \mathbb{R}^{n^{(l)} \times n^{(l)}}$ ;
- 该 surrogate 是本文的实验选择, 不是原论文的统一规定。选择它只是为了在实验对照中固定一个明确的 surrogate 形式。

### C. BPTT: 时间反向传播 (原论文形式)

**Step 1: ordered temporal product.**

$$\mathcal{E}_{t,\tau} := \epsilon[t-1] \epsilon[t-2] \cdots \epsilon[\tau], \quad \tau < t. \quad (3)$$

解释: 从时间步  $\tau$  的 state 到时间步  $t$  的 state, 需要经过一连串状态转移。链式法则要求把每一步的 Jacobian  $\epsilon[i] = \partial u[i+1]/\partial u[i]$  按时间顺序乘起来。注意矩阵乘法不可交换: 从  $\tau$  到  $t$  的传播必须先应用  $\epsilon[\tau]$ 、再  $\epsilon[\tau+1]$ 、……、最后  $\epsilon[t-1]$ , 所以写成从  $t-1$  到  $\tau$  的下降顺序。 $\mathcal{E}_{t,t} = I$  (空乘积约定)。

**Step 2: BPTT 主公式。**

对权重  $W^{l \leftarrow l-1}$ , 损失  $L$  的梯度由两部分组成:

$$\frac{\partial L}{\partial W^{l \leftarrow l-1}} = \sum_{t=1}^T \frac{\partial L}{\partial s^l[t]} \frac{\partial s^l[t]}{\partial u^l[t]} \left( \frac{\partial u^l[t]}{\partial W^{l \leftarrow l-1}} + \sum_{\tau < t} \mathcal{E}_{t,\tau} \frac{\partial u^l[\tau]}{\partial W^{l \leftarrow l-1}} \right). \quad (4)$$

这个公式在说什么: 对每一时刻  $t$ , 权重  $W^{l \leftarrow l-1}$  影响  $u^l[t]$  有两条路径:

- **直接影响** (第一项  $\partial u^l[t]/\partial W^{l \leftarrow l-1}$ ): 当前时刻  $t$ , 权重的输入直接进入  $u^l[t]$ ;
- **历史路径** (第二项): 权重在某个过去时刻  $\tau$  注入的输入, 经过  $t-\tau$  次状态转移传到现在。 $\mathcal{E}_{t,\tau}$  就是这个传播链。

外面乘的  $\partial L/\partial s^l[t] \cdot \partial s^l[t]/\partial u^l[t]$  把  $u^l[t]$  对  $L$  的贡献转换成“该时刻该层神经元收到的 error signal”。

**temporal dependency 的定义:**

$$\epsilon^l[i] = \frac{\partial u^l[i+1]}{\partial u^l[i]} + \frac{\partial u^l[i+1]}{\partial s^l[i]} \frac{\partial s^l[i]}{\partial u^l[i]}. \quad (5)$$

为什么有两项： $u^l[i+1]$  依赖  $u^l[i]$  有两条路径：

- 第一项  $\partial u^l[i+1]/\partial u^l[i]$ ：通过膜电位自身的 leak 传播。 $u^l[i+1] = \lambda u^l[i] + \dots$ ，所以  $\partial u^l[i+1]/\partial u^l[i] = \lambda I$ ；
- 第二项  $\partial u^l[i+1]/\partial s^l[i] \cdot \partial s^l[i]/\partial u^l[i]$ ：通过  $u^l[i]$  决定是否发放  $s^l[i]$ ，再通过 reset 项影响  $u^l[i+1]$ 。 $\partial u^l[i+1]/\partial s^l[i] = -\lambda V_{th} I$  (reset 项系数)， $\partial s^l[i]/\partial u^l[i] = D_{\Psi,i}$  (surrogate)，所以该项 =  $-\lambda V_{th} D_{\Psi,i}$ 。

参数解释：

- $\epsilon^l[i] \in \mathbb{R}^{n^{(l)} \times n^{(l)}}$ ：第  $l$  层从时间步  $i$  到  $i+1$  的 temporal Jacobian；
- $\mathcal{E}_{t,\tau}$ ：从  $\tau$  传播到  $t$  的 ordered temporal product；
- $\partial L/\partial s^l[t] \in \mathbb{R}^{n^{(l)}}$ ：第  $l$  层脉冲  $s^l[t]$  接收到的 same-time/spatial error signal (从输出层反向传播到本层)；
- $\partial s^l[t]/\partial u^l[t] = D_{\Psi,t}$ ：surrogate derivative。

**Step 3: 代入 LIF。**

把  $\partial u^l[i+1]/\partial u^l[i] = \lambda I$  与  $\partial u^l[i+1]/\partial s^l[i] = -\lambda V_{th} I$  代入  $\epsilon^l[i]$ ：

$$\epsilon^l[i] = \lambda I - \lambda V_{th} D_{\Psi,i}. \quad (6)$$

解释： $\lambda I$  来自 leak， $-\lambda V_{th} D_{\Psi,i}$  来自 reset。 $D_{\Psi,i}$  是对角矩阵，其  $j$  号对角元  $\Psi'(u_j - V_{th})$  越接近 1，说明神经元  $j$  处于阈值附近、是否发放对  $u$  非常敏感，reset 项的贡献就越大。

内存来源：BPTT 在反向时需要  $\epsilon^l[i]$ ，而  $\epsilon^l[i]$  依赖  $u^l[i]$  与  $s^l[i]$ 。这意味着反向过程需要访问所有时间步的 forward states。典型实现要么把它们全部保存 (内存  $O(TLn)$ )，要么在前向过程中 checkpoint 一些、反向时重算，总之无法做到  $O(1)$  与  $T$  无关的内存。

#### D. STDP: 局部突触可塑性基础

经典 STDP。令  $\Delta t = t_{\text{post}} - t_{\text{pre}}$ ：

$$\Delta w = \begin{cases} A_+ e^{-\Delta t/\tau_+}, & \Delta t > 0 \text{ (potentiation)}, \\ -A_- e^{\Delta t/\tau_-}, & \Delta t < 0 \text{ (depression)}. \end{cases} \quad (7)$$

这个公式在说什么：如果突触前神经元先发放、突触后神经元后发放 ( $\Delta t > 0$ )，权重增强 (potentiation)；反之如果突触后先发放、突触前后发放 ( $\Delta t < 0$ )，权重减弱 (depression)。这正是 Hebbian "fire together, wire together" 思想的时序版本。

参数解释：

- $A_+, A_- > 0$ ：因果/非因果分支的振幅；
- $\tau_+, \tau_- > 0$ ：两个分支的时间常数； $\Delta t$  越大 (越"不相关")，效应越弱；
- 这个规则是严格 online 的：只需要当前和过去的信息，不需要未来。

**Generalized trace-based STDP form** (S-TLLR 所采用的形式)：

$$\Delta w_{ij}[t] = \alpha_{\text{pre}} y_i[t] \sum_{t'=0}^t \lambda_{\text{pre}}^{t-t'} x_j[t'] + \alpha_{\text{post}} x_j[t] \sum_{t'=0}^{t-1} \lambda_{\text{post}}^{t-t'} y_i[t']. \quad (8)$$

这个公式在说什么：把 STDP 从单次 pre/post 事件对推广到脉冲序列。第一项是因果项：当前时刻 post 发放  $y_i[t] = 1$ ，与过去 pre 脉冲的加权和（权重随时间指数衰减）相关；第二项是非因果项：当前时刻 pre 发放  $x_j[t] = 1$ ，与过去 post 脉冲的加权和（注意上界是  $t-1$ ，不包含当前  $y_i[t]$ ）相关。

**参数解释：**

- $x_j[t] \in \{0, 1\}$ : pre 神经元  $j$  在  $t$  时刻的脉冲；
- $y_i[t] \in \{0, 1\}$ : post 神经元  $i$  在  $t$  时刻的脉冲；
- $\lambda_{\text{pre}}, \lambda_{\text{post}} \in (0, 1)$ : pre/post 迹的指数衰减因子；与 LIF 的膜衰减  $\lambda$  不同，它们是独立超参；
- $\alpha_{\text{pre}}, \alpha_{\text{post}}$ : 因果/非因果项的强度； $\alpha_{\text{post}} = 0$  时只保留因果项。

**STDP 的局限：**它只使用 pre/post 时序，不包含任务误差信号。因此它本身不是监督学习中的完整 credit assignment 方案——它更新的是“最近同时活跃的突触”，而不是“让损失下降的突触”。

**从 STDP 到 three-factor rule:** 引入任务信号  $\delta_i[t]$  作为“第三个因子”来调制 eligibility:

$$\Delta w_{ij}[t] = \delta_i[t] e_{ij}[t]. \quad (9)$$

**解释：** $e_{ij}[t]$  是由 STDP 时序决定的 eligibility (“该突触最近是否值得被修改”)， $\delta_i[t]$  是任务学习信号 (“该修改是否有助于降低损失”)。两者相乘给出最终的权重更新。这个三因子结构是 S-TLLR 与 TESS 的基础。

### III. 前向敏感度与局部资格迹：RTRL 与 E-PROP

#### A. RTRL: forward-mode 参数敏感度

**Step 1: 一般 RNN 状态方程。**

$$h_t = F(h_{t-1}, x_t, W). \quad (10)$$

$h_t$  是  $t$  时刻的 hidden state (LIF 中  $h_t = u_t$ )， $F$  是状态转移函数， $W$  是所有可学习参数 (flatten 后为  $r$  维向量)。

**Step 2: 参数敏感度。**

$$P_t := \frac{\partial h_t}{\partial W} \in \mathbb{R}^{n \times r}. \quad (11)$$

这个量在说什么： $P_t$  的  $(i, k)$  元素  $\partial h_{t,i} / \partial W_k$  表示“第  $k$  个参数变化一个单位， $t$  时刻第  $i$  个 hidden state 变化多少”。它包含了从初始时刻到  $t$  时刻所有参数作用的累计影响。

**Step 3-4: 链式法则与两个 Jacobian。**

$$\frac{\partial h_t}{\partial W} = \frac{\partial h_t}{\partial h_{t-1}} \cdot \frac{\partial h_{t-1}}{\partial W} + \frac{\partial h_t}{\partial W} \Big|_{h_{t-1} \text{ fixed}}. \quad (12)$$

**解释：** $h_t$  通过两条路径依赖  $W$ ——一是“经过  $h_{t-1}$ ” (即过去权重的累积影响被当前 dynamics 继续传播)，二是“当前时刻  $W$  直接进入  $F$ ” ( $h_{t-1}$  固定时  $W$  对  $h_t$  的直接作用)。定义  $A_t = \partial h_t / \partial h_{t-1}$ 、 $B_t = \partial h_t / \partial W|_{h_{t-1} \text{ fixed}}$  后：

**Step 5: RTRL 核心递推。**

$$P_t = A_t P_{t-1} + B_t. \quad (13)$$

这个公式在说什么：这是一个**forward-in-time** 递推。 $P_{t-1}$  是过去所有参数作用的累计敏感度，乘以  $A_t$  表示“过去的敏感度被当前 dynamics 继续传播”；再加上  $B_t$  表示“当前时刻  $W$  新注入的影响”。每前向一个时间步，就更新一次  $P_t$ ，不需要等整个序列完成。

**Step 6: 当前 loss 梯度。**  $\nabla_W \ell_t = \partial \ell_t / \partial h_t \cdot P_t$ 。

参数解释：

- $P_t$ : 截至  $t$  时刻累计的参数敏感度；
- $A_t \in \mathbb{R}^{n \times n}$ : hidden state 的自 Jacobian；
- $B_t \in \mathbb{R}^{n \times r}$ : 参数的直接注入 Jacobian；
- $\ell_t$ : 当前时刻的 loss； $\partial \ell_t / \partial h_t$  是当前 loss 对 hidden state 的梯度。

**复杂度：**对 fully recurrent  $n$ -unit RNN、 $r = O(n^2)$  时， $P_t$  需保存  $n \times r = O(n^3)$  个元素，每步更新  $P_t = A_t P_{t-1} + B_t$  需要  $O(n^4)$  运算。多层结构的具体复杂度取决于 connectivity。

**与 BPTT 的关系：**BPTT 是 reverse-mode（从  $T$  反向传播到 1），RTRL 是 forward-mode（从 1 前向传播到  $T$ ）。对一个可微 computational graph 两者都是精确的，只是方向不同、内存分布不同。

**B. e-prop: 从 RTRL 到局部资格迹 + 学习信号**

**Step 1: RTRL 的问题。**  $P_t$  的维度是  $n \times r$ ，对 SNN 来说太大（ $n$  是神经元数， $r$  是权重总数）。e-prop 的核心想法是：不直接保存  $P_t$ ，而是把它重新组织成“局部 eligibility  $\times$  learning signal”。

**Step 2: 从经典 recurrent gradient factorization 出发。**

$$\frac{dE}{dW_{ji}} = \sum_{t'} \frac{dE}{dh_j^{t'}} \frac{\partial h_j^{t'}}{\partial W_{ji}} \Big|_{h_j^{t'-1} \text{ fixed}}. \quad (14)$$

这个公式在说什么：损失对突触  $W_{ji}$  的梯度，可以写成“对每个时间步  $t'$ ，hidden state  $h_j^{t'}$  对损失的贡献  $\times$  该突触对  $h_j^{t'}$  的直接影响”。

**Step 3: 递归展开  $dE/dh_j^{t'}$ 。**

$dE/dh_j^{t'}$  本身是  $h_j^{t'}$  通过两条路径对  $E$  的贡献：一是当前时刻  $h_j^{t'}$  直接影响  $z_j^{t'}$ （进而影响  $E$ ），二是  $h_j^{t'}$  通过  $h_j^{t'+1}$  影响未来。写成递归：

$$\frac{dE}{dh_j^{t'}} = L_j^{t'} \frac{\partial z_j^{t'}}{\partial h_j^{t'}} + \frac{dE}{dh_j^{t'+1}} \frac{\partial h_j^{t'+1}}{\partial h_j^{t'}}, \quad L_j^{t'} := \frac{dE}{dz_j^{t'}}. \quad (15)$$

**解释：**这是一个反向递归（从  $t' = T$  往回算）。 $L_j^{t'} = dE/dz_j^{t'}$  是 ideal learning signal，包含所有从当前脉冲  $z_j^{t'}$  出发、经其他神经元与后续时间步、最终影响  $E$  的 downstream pathways。

把递归展开到  $T$ 、代回 Step 2、交换求和顺序（先对  $t$  求和、再对  $t'$  求和），可以重新组织成：

$$\frac{dE}{dW_{ji}} = \sum_t L_j^t e_{ji}^t, \quad e_{ji}^t := \left[ \frac{dz_j^t}{dW_{ji}} \right]_{\text{local}}. \quad (16)$$

关于  $e_{ji}^t$  的语义：它是 chain-rule rearrangement 之后可由突触及 postsynaptic neuron 的局部 forward variables 计算的部分。其他 downstream 影响—— $z_j^t$  通过未来其他神经元、再回头影响  $E$

的部分——并未被丢弃，而是全部进入了  $L_j^t$ 。因此这个分解是精确恒等式，不是“删掉某些路径后的近似”。

**Step 4: eligibility vector 递推。**

$e_{ji}^t$  可以通过 eligibility vector  $\xi_{ji}^t$  前向递推得到：

$$e_{ji}^t = \frac{\partial z_j^t}{\partial h_j^t} \xi_{ji}^t, \quad \xi_{ji}^{t+1} = \lambda \xi_{ji}^t + z_i^t. \quad (17)$$

**解释：** $\xi_{ji}^t$  是“滤波后的 presynaptic spike”，满足一个 leaky integrator 形式的递推。 $\lambda$  是 leak 系数， $z_i^t$  是突触  $i \rightarrow j$  的 pre 神经元  $i$  在  $t$  时刻的脉冲。 $\partial z_j^t / \partial h_j^t$  是 surrogate derivative（LIF 中等于  $\Psi'(u_j^t - V_{th})$ ）。

**Step 5: ideal  $\rightarrow$  online  $\rightarrow$  actual update。**

(a) **Ideal learning signal.**  $L_j^t = dE/dz_j^t$  是精确的、future-aware 的，但需要 BPTT 才能算出。

(b) **Online learning signal.** e-prop 用当前可得的信息近似它：

Regression:  $\hat{L}_j^t = \sum_k B_{jk}(y_k^t - y_k^{*,t})$ ; Classification:  $\hat{L}_j^t = \sum_k B_{jk}(\pi_k^t - \pi_k^{*,t})$ 。

**解释：** $y_k^t$  是输出神经元  $k$  的（滤波后）输出， $y_k^{*,t}$  是目标； $\pi_k^t$  是 softmax 概率； $B_{jk}$  是 feedback 权重，表示“神经元  $j$  到输出  $k$  的误差路由权重”。三种选择：symmetric e-prop 用真实 readout 权重  $W_{kj}^{\text{out}}$ 、random e-prop 用固定随机权重、adaptive e-prop 局部可塑性学习权重。

(c) **Actual synaptic update.** 由于 readout 是 leaky integrator，实际权重更新使用滤波后的 **eligibility**  $\bar{e}_{ji}^t = \mathcal{F}_\kappa(e_{ji}^t)$ ：

$$\Delta W_{ji}^{\text{rec}} = -\eta \sum_t \left[ \sum_k B_{jk}(y_k^t - y_k^{*,t}) \right] \bar{e}_{ji}^t. \quad (18)$$

注意被低通滤波的是 eligibility  $\bar{e}_{ji}^t$ ，不是 error  $y_k^t - y_k^{*,t}$ 。

**参数解释：**

- $\lambda$  (e-prop 原文中记作  $\alpha$ )：postsynaptic state 的衰减因子；
- $\xi_{ji}^t$ ：eligibility vector，保存突触  $i \rightarrow j$  的局部历史；
- $e_{ji}^t$ ：observable eligibility trace；
- $\kappa$ ：readout dynamics 的低通衰减参数；
- $B_{jk}$ ：output error 到 recurrent neuron  $j$  的 feedback weight；
- $W_{kj}^{\text{out}}$ ：神经元  $j$  到 readout  $k$  的 forward weight；
- $\eta$ ：学习率。

**与 RTRL 的关系：**RTRL 的  $P_t = A_t P_{t-1} + B_t$  保存了完整网络的 Jacobian；e-prop 的  $\xi_{ji}^t = A_{j,t}^{\text{loc}} \xi_{ji}^{t-1} + B_{ji,t}^{\text{loc}}$  只保留了单突触级的局部路径。二者递推结构相似，但对象完全不同—— $P_t \in \mathbb{R}^{n \times r}$  与  $\xi_{ji}^t \in \mathbb{R}$  不是同维度、同语义的对象，不直接做数值距离比较。

## IV. 时间在线训练：OTTT 与 NDOT

### A. 从 BPTT 到 temporal dependency $\epsilon[i]$

BPTT 的 temporal dependency：

$$\epsilon[i] = \frac{\partial u[i+1]}{\partial u[i]} + \frac{\partial u[i+1]}{\partial s[i]} \frac{\partial s[i]}{\partial u[i]} = \lambda I - \lambda V_{th} D_{\Psi,i}. \quad (19)$$

**OTTT 与 NDOT 的区别就在于如何近似  $\epsilon[i]$ 。**

**B. OTTT:**  $\epsilon[i] \approx \lambda I$

**Step 1: 丢弃 spike-mediated path.** 注意到 Heaviside 几乎处处导数为零,  $\partial s[i]/\partial u[i] = D_{\Psi,i}$  在大多数时间步上很小, 因此:

$$\frac{\partial u[i+1]}{\partial s[i]} \frac{\partial s[i]}{\partial u[i]} \approx 0. \quad (20)$$

这个近似在说什么: 忽略“ $u[i]$  通过 spike  $s[i]$  的 reset 影响  $u[i+1]$ ”这条路径。这样做的理由是——Heaviside 的导数在真正发放时可能很大, 但在非发放时几乎为零, 平均来看  $D_{\Psi,i}$  对时间连乘的贡献远小于  $\lambda I$ 。

**Step 2:  $\epsilon[i]$  退化。**

$$\epsilon[i] \approx \lambda I. \quad (21)$$

**Step 3: temporal trace.**

$\mathcal{E}_{t,\tau} = \epsilon[t-1] \cdots \epsilon[\tau] \approx \lambda^{t-\tau} I$ . 定义预突触活动的指数衰减迹:

$$\hat{a}^l[t] := \sum_{\tau \leq t} \lambda^{t-\tau} s^l[\tau], \quad \hat{a}^l[t+1] = \lambda \hat{a}^l[t] + s^l[t+1]. \quad (22)$$

这个公式在说什么:  $\hat{a}^l[t]$  是对第  $l$  层神经元从时刻 1 到  $t$  的所有历史脉冲  $s^l[\tau]$  做指数加权求和。越近的脉冲权重越大 ( $\lambda^{t-\tau}$  大), 越早的脉冲权重越小。它满足一个简单的**前向递推**:  $\hat{a}^l[t+1]$  等于  $\hat{a}^l[t]$  衰减一点、再加上  $s^l[t+1]$ 。这只需要存储一个向量, 不需要保存历史  $s^l$ 。

**Step 4: instantaneous loss.** OTTT 为实现 online gradient, 把传统依赖整段序列的 firing-rate loss 替换为逐时间步损失:

$$L[t] = \frac{1}{T} \mathcal{L}(s^N[t], y). \quad (23)$$

**解释:**  $s^N[t]$  是输出层在  $t$  时刻的脉冲,  $y$  是标签,  $\mathcal{L}$  是任务损失 (如 CE)。每个时间步的损失独立计算, 不再依赖整个序列。原论文明确指出: 即使使用 instantaneous loss, OTTT 的 gradient 与使用 instantaneous loss 的 BPTT 在多层/循环网络上仍然不同, 因为 OTTT 不保留 future influence。

**Step 5: OTTT 瞬时梯度。** 按 OTTT 原文的层索引  $W^l: l \rightarrow l+1$  (即本文的  $W^{l+1 \leftarrow l}$ ):

$$\nabla_{W^l} L[t] = g_{u^{l+1}}[t] \hat{a}^l[t]^\top, \quad g_{u^{l+1}}[t] = \left( \frac{\partial L[t]}{\partial s^{l+1}[t]} \frac{\partial s^{l+1}[t]}{\partial u^{l+1}[t]} \right)^\top. \quad (24)$$

这个公式在说什么: 当前时间步  $t$  的权重梯度可以分解为“空间梯度  $\times$  时间迹”的外积。 $g_{u^{l+1}}[t]$  是当前时刻 loss 对  $u^{l+1}[t]$  的梯度 (只需要当前时刻的 autograd, 不需要跨时间反传);  $\hat{a}^l[t]$  是历史 presynaptic spikes 的加权迹。

**Step 6: 两种 update mode.**

$$\text{OTTT}_O: \text{每个 } t \text{ 立即用 } \nabla_{W^l} L[t] \text{ 更新} \quad (25)$$

$$\text{OTTT}_A: \text{累计 } \sum_t \nabla_{W^l} L[t] \text{ 后统一更新}$$

**解释:**  $O$  表示 online, 每个时间步更新一次参数;  $A$  表示 accumulated, 把整段序列的梯度累加后再更新。前者更“在线”, 后者在梯度保真比较中更接近 BPTT 的评估点。

**参数解释:**  $\lambda$  是膜衰减, 同时成为 temporal trace decay;  $\hat{a}^l[t]$  是历史 presynaptic spikes 的加权迹;  $g_{u^{l+1}}[t]$  是当前时刻 spatial gradient;  $T$  是序列长度;  $V_{th}$  决定发放阈值并通过 surrogate derivative 影响 spatial gradient, 但不进入 trace 的递推。

**复杂度:** 额外 memory  $O(Ln)$  (每层存一个 trace 向量), per-step computation  $O(Ln^2)$ 。

C. *NDOT*:  $\epsilon[i] \approx e[i]$

**Step 1: OTTT 的问题。** OTTT 假设  $\epsilon[i] = \lambda I$ ，完全忽略了 spike 路径。但在某些时间步上，reset 路径的贡献可能并不小。NDOT 要保留  $\epsilon[i]$  的动态性。

**Step 2: 从连续动力学定义  $e(t)$ 。**

NDOT 引入隐式神经元动力学  $u(t+1) = \text{Im}(u(t))$ ，对其求时间导数：

$$\frac{du(t+1)}{dt} = \frac{\partial u(t+1)}{\partial u(t)} \cdot \frac{du(t)}{dt}. \quad (26)$$

由此定义 continuous temporal dependency:

$$e(t) \triangleq \frac{\partial u(t+1)}{\partial u(t)} = \frac{u'(t+1)}{u'(t)}. \quad (27)$$

这个公式在说什么： $e(t)$  是“下一时刻膜电位对当前时刻膜电位的偏导”，等于两个时刻膜电位变化率的比值。

**Step 3: 代入 LIF 连续方程。** LIF 的连续膜电位方程是  $u'(t) = (-u(t) + I(t))/\tau$ ，其中  $I(t)$  是输入电流， $\tau$  是膜时间常数。代入得：

$$e(t) = \frac{u'(t+1)}{u'(t)} = \frac{u(t+1) - I(t+1)}{u(t) - I(t)}. \quad (28)$$

**Step 4: 映射到离散 SNN。** 将上述连续形式在离散时间步上取值，并结合论文采用的离散 LIF 更新方程，得到：

$$e^l[t] = \begin{cases} u^l[1] - V_{th}s^l[1], & t = 1, \\ \frac{u^l[t] - V_{th}s^l[t]}{u^l[t-1] - V_{th}s^l[t-1]}, & t > 1. \end{cases} \quad (29)$$

这个公式在说什么： $e^l[t]$  是“reset 后的膜电位” ( $u^l[t] - V_{th}s^l[t]$ ) 在相邻两个时刻的逐元素比值。 $t = 1$  时用特殊初始化（NDOT 原文 Eq.(8) 后的 footnote 明确指出），避免  $u^l[0] - V_{th}s^l[0]$  的退化处理。

需要强调： $e^l[t]$  不是由离散 BPTT Jacobian  $e^l[t]$  严格代数化简得到的量。NDOT 的核心假设是： $e[t]$  与  $\epsilon[t]$  刻画相同的 temporal-dependency characteristic，因此可以用  $e[t]$  近似替代  $\epsilon[t]$ 。

**层索引关系：**NDOT 原文针对  $W^l$ （即  $l-1 \rightarrow l$ ）的具体梯度公式中， $e^l[i]$  被 **presynaptic layer** 的  $e^{l-1}[i]$  替代（不是  $e^l[i]$ ），然后用逐元素乘法构造  $\hat{a}^{l-1}[t]$ 。

**Step 5: temporal trace。**

$$\hat{a}^{l-1}[t] = e^{l-1}[t-1] \odot \hat{a}^{l-1}[t-1] + s^{l-1}[t], \quad (30)$$

展开为历史求和：

$$\hat{a}^{l-1}[t] = s^{l-1}[t] + \sum_{k < t} \mathcal{E}_{t,k}^{\text{NDOT}} \odot s^{l-1}[k], \quad \mathcal{E}_{t,k}^{\text{NDOT}} := e^{l-1}[t-1] \odot \dots \odot e^{l-1}[k]. \quad (31)$$

**解释：**与 OTTT 的结构完全相同，只是把固定标量  $\lambda$  换成动态逐元素比率  $e^{l-1}[t]$ 。 $\odot$  是逐元素乘法，所以每个神经元有自己独立的时间衰减系数。

**Step 6: instantaneous loss。** NDOT 使用 CE 与 MSE 的加权和：

$$L[t] = (1 - \alpha)\ell_{\text{CE}}(s^N[t], y) + \alpha\ell_{\text{MSE}}(s^N[t], y). \quad (32)$$

$\alpha \in [0, 1]$  是权重系数，实验里通常取较小的值（让 CE 主导）。

**Step 7: NDOT 瞬时权重梯度与两种 update mode。**

$$\nabla_{W^l} L[t] = g_{u^l}[t] \hat{a}^{l-1}[t]^\top. \quad (33)$$

这是当前时间步的 instantaneous weight gradient。完整累计更新为：

$$\begin{aligned} \text{NDOT}_O &: \text{每个 } t \text{ 立即更新} \\ \text{NDOT}_A &: \text{累计 } \sum_t \nabla_{W^l} L[t] \text{ 后统一更新} \end{aligned} \quad (34)$$

**参数解释：**

- $e^l[t] \in \mathbb{R}^{n^{(l)}}$ : neuron-wise dynamic temporal coefficient, 逐元素比值；
- $\hat{a}^{l-1}[t] \in \mathbb{R}^{n^{(l-1)}}$ : temporal trace；
- $g_{u^l}[t] \in \mathbb{R}^{n^{(l)}}$ : 当前时刻 spatial gradient（含从输出层反向传播到第  $l$  层的完整 same-time spatial chain）；
- $\odot$ : 逐元素乘法；
- $I(t)$ : 连续膜电位方程中的输入电流； $\tau$ : 膜时间常数；
- $V_{th}$ : 发放阈值； $\alpha$ : CE 与 MSE 的权重； $T$ : 序列长度。

**数值稳定性（NDOT 原文 Appendix A.2）：**当  $e^l[t]$  的分母  $u^l[t-1] - V_{th}s^l[t-1]$  等于零时，NDOT 使用退化情况下的稳定策略：先根据膜电位符号处理，再用 clamping 把结果限制在  $[-\lambda, \lambda]$ 。这个 clamp 只对分母为零的退化情况生效，不是  $e^l[t]$  在所有时间步的一般定义。

**OTTT 与 NDOT 的关系：**

$$\begin{aligned} \text{OTTT: } e^l[t] &\approx \lambda I \text{ (matrix coefficient)} \\ \text{NDOT: } e^l[t] &\approx \text{diag}(e^l[t]) \text{ (diagonal dynamic coefficient)} \end{aligned} \quad (35)$$

**复杂度：**额外 memory  $O(Ln)$ , per-step computation  $O(Ln^2)$ , 另加计算  $e^l[t]$  的逐元素除法开销。

## V. STDP-INSPIRED 本地学习: S-TLLR

**Step 1: three-factor rule。**  $\Delta w_{ij}[t] = \delta_i[t] e_{ij}[t]$ 。

**Step 2: eligibility。** 把 generalized trace-based STDP form 中的 post 脉冲  $y_i[t]$  替换为 secondary activation  $\Psi_{\text{STLLR}}(u_i[t])$  ( $\Psi_{\text{STLLR}} \neq \Psi'_{\text{SG}}$ ):

$$e_{ij}[t] = \alpha_{\text{pre}} \Psi_{\text{STLLR}}(u_i[t]) \sum_{t'=0}^t \lambda_{\text{pre}}^{t-t'} x_j[t'] + \alpha_{\text{post}} x_j[t] \sum_{t'=0}^{t-1} \lambda_{\text{post}}^{t-t'} \Psi_{\text{STLLR}}(u_i[t']). \quad (36)$$

**这个公式在说什么：**第一项是因果项——当前 post 状态（用  $\Psi_{\text{STLLR}}(u_i[t])$  而非离散脉冲  $y_i[t]$  表示）与过去 pre 脉冲的加权相关；第二项是非因果项——当前 pre 脉冲与过去 post 状态的加权相关。使用连续的  $\Psi_{\text{STLLR}}(u_i[t])$  而非二值  $y_i[t]$ ，可以让 eligibility 更平滑，便于学习。

**重要澄清：non-causal  $\neq$  偷看未来。** S-TLLR 所谓 “non-causal” 是 STDP timing relation 意义上的 non-causal——当前 pre spike 与过去 post activity 的相关性。它仍然只使用当前和过去的信息，不需要访问未来时间步，因此仍是 online / temporally local。

**Step 3: 前向递推形式。** 定义两个迹变量:

$$\text{tr}(x_j)[t] = \lambda_{\text{pre}} \text{tr}(x_j)[t-1] + x_j[t], \quad \text{tr}(\Psi_{\text{STLLR}}(u_i))[t] = \lambda_{\text{post}} \text{tr}(\Psi_{\text{STLLR}}(u_i))[t-1] + \Psi_{\text{STLLR}}(u_i[t]), \quad (37)$$

$$e_{ij}[t] = \alpha_{\text{pre}} \Psi_{\text{STLLR}}(u_i[t]) \text{tr}(x_j)[t] + \alpha_{\text{post}} x_j[t] (\text{tr}(\Psi_{\text{STLLR}}(u_i))[t] - \Psi_{\text{STLLR}}(u_i[t])). \quad (38)$$

括号里减去  $\Psi_{\text{STLLR}}(u_i[t])$  是因为 non-causal 项的求和上界是  $t-1$ ，不包含当前时刻。

**Step 4: recurrent synapse extension。** 对 recurrent connection:

$$u_i[t] = \gamma(u_i[t-1] - v_{th} y_i[t-1]) + W^{\text{ff}} x[t] + W^{\text{rec}} y[t-1], \quad (39)$$

presynaptic activity 变成上一时刻的  $y_k[t-1]$ ，eligibility 相应调整为:

$$e_{ik}^{\text{rec}}[t] = \alpha_{\text{pre}} \Psi_{\text{STLLR}}(u_i[t]) \sum_{t'=1}^t \lambda_{\text{pre}}^{t-t'} y_k[t'-1] + \alpha_{\text{post}} y_k[t-1] \sum_{t'=0}^{t-1} \lambda_{\text{post}}^{t-t'} \Psi_{\text{STLLR}}(u_i[t']). \quad (40)$$

**Step 5-6: learning signal 与更新。**

$$w_{ij} := w_{ij} + \rho \sum_{t=T_l}^T \delta_i[t] e_{ij}[t]. \quad (41)$$

**参数解释:**

- $\Psi_{\text{STLLR}}$ : secondary activation function, 与 firing function 不同, 不必等于  $\Psi'_{\text{SG}}$ ;
- $\alpha_{\text{pre}}, \alpha_{\text{post}}$ : 因果/非因果项强度;  $\alpha_{\text{post}} = 0$  只保留因果;
- $\lambda_{\text{pre}}, \lambda_{\text{post}} \in (0, 1)$ : 因果/非因果迹的衰减因子;
- $x_j[t], y_i[t]$ : pre/post 脉冲;
- $T_l$ : learning signal 起始时间步,  $t < T_l$  时  $\delta_i[t] = 0$ ; 典型值为最后几步;
- $\rho$ : 学习率;
- recurrent extension 中  $\gamma, v_{th}, W^{\text{ff}}, W^{\text{rec}}, y_k$  分别为膜衰减、发放阈值、feedforward weights、recurrent weights、recurrent presynaptic spike。

**复杂度:** 额外 memory  $O(Ln)$  (瞬时 eligibility, 不保存 synapse-wise 状态), per-step computation  $O(Ln^2)$ 。

**与 BPTT 的区别:** S-TLLR 显式引入 STDP-inspired **non-causal timing component**; 该 component 不是由 BPTT 的 **causal temporal chain-rule gradient** 推导得到的。BPTT 及其近似只利用 causal relations, 而 S-TLLR 显式增加 causal + non-causal spike-timing relations。

**与 e-prop 的区别:** S-TLLR 的 eligibility 不要求  $\lambda$  与膜衰减一致,  $\lambda_{\text{pre}}, \lambda_{\text{post}}$  是独立超参。

## VI. 时空全局部学习: TESS

**TESS 与 S-TLLR 的关系:**

$$\begin{aligned} \text{S-TLLR: } & \text{local temporal eligibility} + \text{instantaneous BP learning signal} \\ \text{TESS: } & \text{local temporal eligibility} + \text{explicitly layer-local generated learning signal} \end{aligned} \quad (42)$$

**解释:** S-TLLR 的 temporal 部分是局部的 (eligibility 只依赖 pre/post), 但 spatial 部分仍然要跨层 BP 生成 learning signal  $\delta_i[t]$ 。TESS 的推进是把 learning signal 也本地化——每层通过固定 basis matrix  $B^{(l)}$  独立生成, 无需跨层 BP。

**Step 1-2: 因果迹与非因果迹。**

$$q^{(l)}[t] = \lambda_{\text{pre}} q^{(l)}[t-1] + o^{(l-1)}[t], \quad h^{(l)}[t] = \lambda_{\text{post}} h^{(l)}[t-1] + \Psi_{\text{STLLR}}(u^{(l)}[t-1]). \quad (43)$$

$q^{(l)}$  是 presynaptic trace (因果迹),  $h^{(l)}$  是 postsynaptic activation trace (非因果迹)。

**Step 3: 本地学习信号 (LSG)。**

$$m^{(l)}[t] = B^{(l)\top} (f(B^{(l)} o^{(l)}[t]) - y^*). \quad (44)$$

这个公式在说什么: 把本层输出  $o^{(l)}[t]$  用固定二值矩阵  $B^{(l)}$  投影到任务空间 ( $C$  维), 应用 softmax/identity 得到预测, 与标签  $y^*$  比较得到误差, 再投影回来。这个  $m^{(l)}[t]$  是本层自己产生的 learning signal, 不需要从其他层反传。

**Step 4: 逐时刻权重增量。**

$$\Delta W^{(l)}[t] = (m^{(l)}[t] \odot \alpha_{\text{pre}} \Psi_{\text{STLLR}}(u^{(l)}[t])) \otimes q^{(l)}[t] + (m^{(l)}[t] \odot \alpha_{\text{post}} h^{(l)}[t]) \otimes o^{(l-1)}[t]. \quad (45)$$

第一项是因果贡献 (pre trace  $q$  与本层 activation 的外积), 第二项是非因果贡献 (本层 post trace  $h$  与 pre 输出的外积)。

**Step 5: 最终权重更新与初始化。**

$$W^{(l)} \leftarrow W^{(l)} + \eta \sum_{t=t_l}^T \Delta W^{(l)}[t], \quad q^{(l)}[0] = 0, \quad h^{(l)}[0] = 0. \quad (46)$$

且  $m^{(l)}[t]$  与  $\Delta W^{(l)}[t]$  只在  $t \geq t_l$  时计算。

**参数解释:**

- $B^{(l)} \in \mathbb{R}^{C \times n^{(l)}}$ : 固定二值投影矩阵, 列为方波函数, 各列准正交; 不参与训练;  $C$  是类别数,  $n^{(l)}$  是第  $l$  层神经元数;
- $o^{(l)}[t] \in \mathbb{R}^{n^{(l)}}$ : 第  $l$  层  $t$  时刻的输出脉冲;
- $q^{(l)}[t] \in \mathbb{R}^{n^{(l-1)}}$ : presynaptic trace (因果迹), 维度由输入神经元数决定;
- $h^{(l)}[t] \in \mathbb{R}^{n^{(l)}}$ : postsynaptic activation trace (非因果迹), 维度由本层神经元数决定;
- $m^{(l)}[t] \in \mathbb{R}^{n^{(l)}}$ : 本层本地生成的 learning signal;
- $f$ : softmax (分类) 或 identity (回归);
- $\Psi_{\text{STLLR}}$ : secondary activation, 与  $\Psi'_{\text{SG}}$  不同;
- $\lambda_{\text{pre}}, \lambda_{\text{post}}$ : 因果/非因果迹衰减;
- $\alpha_{\text{pre}}, \alpha_{\text{post}}$ : 因果/非因果强度;
- $t_l$ : 开始生成 learning signal 的时刻;  $\eta$ : 学习率。


**形状检查:**  $\Psi_{\text{STLLR}}(u^{(l)}[t]) \in \mathbb{R}^{n^{(l)}}$ ,  $q^{(l)}[t] \in \mathbb{R}^{n^{(l-1)}}$ ,  $\Psi_{\text{STLLR}}(u^{(l)}[t]) \otimes q^{(l)}[t] \in \mathbb{R}^{n^{(l)} \times n^{(l-1)}}$ , 与  $W^{(l)}$  形状一致。

**复杂度:** 额外 memory  $O(Ln)$ , learning-signal generation computation  $O(LCn)$  ( $C$  为类别数,  $C \ll n$ )。

**与 S-TLLR 的区别:** S-TLLR 的  $\delta_i[t]$  由跨层 BP 生成 (也可用 DFA); TESS 的  $m^{(l)}[t]$  完全在层内生成。

## VII. 算法关系与核心研究问题

### A. 三条研究路径



关于  $\mathbf{RTRL} \rightarrow \mathbf{e-prop}$  箭头：这是本文的研究比较路径，不意味着  $\mathbf{e-prop}$  是直接由  $\mathbf{RTRL}$  的  $P_t$  局部截断所得。

### B. 路径一： $\mathbf{BPTT} \rightarrow \mathbf{OTTT} \rightarrow \mathbf{NDOT}$ （时间近似）

核心问题： $\epsilon^l[t] \rightarrow \lambda I$  或  $\text{diag}(e^l[t])$  改变了多少 temporal credit?

实验分两类：

- **A. Paper-faithful reproduction:** 各方法按原论文 loss / update mode 跑。
- **B. Controlled mechanism comparison:** 统一 controlled instantaneous objective

$$\ell_{\text{ctrl}}[t] = m[t] \ell_{\text{CE}}(r[t], y[t]), \quad L_{\text{ctrl}} = \sum_{t=1}^T \ell_{\text{ctrl}}[t]. \tag{48}$$

$\mathbf{BPTT}$ 、 $\mathbf{OTTT}$ 、 $\mathbf{NDOT}$  三个 gradient estimator 全部基于同一个  $L_{\text{ctrl}}$ 。

受控比较的唯一变量 = temporal dependency treatment:

$$\epsilon^l[t] \quad \text{vs} \quad \lambda I \quad \text{vs} \quad \text{diag}(e^l[t]). \tag{49}$$

**Representation fidelity**（同层比较）：

$$D_{\epsilon, \lambda}^l[t] = \frac{\|\epsilon^l[t] - \lambda I\|_F}{\|\epsilon^l[t]\|_F + \varepsilon_{\text{num}}}, \quad D_{\epsilon, e}^l[t] = \frac{\|\epsilon^l[t] - \text{diag}(e^l[t])\|_F}{\|\epsilon^l[t]\|_F + \varepsilon_{\text{num}}}, \quad t \geq 2. \tag{50}$$

**Weight-gradient** 层面：

$$D_{\text{OTTT}} = \frac{\|g_{\text{OTTT}} - g_{\text{BPTT}}\|}{\|g_{\text{BPTT}}\| + \varepsilon_{\text{num}}}, \quad D_{\text{NDOT}} = \frac{\|g_{\text{NDOT}} - g_{\text{BPTT}}\|}{\|g_{\text{BPTT}}\| + \varepsilon_{\text{num}}}, \tag{51}$$

$$\cos(g_{\text{OTTT}}, g_{\text{BPTT}}), \quad \cos(g_{\text{NDOT}}, g_{\text{BPTT}}). \tag{52}$$

**One-step loss change:** 对每个 gradient estimator  $\hat{g}$ ，在固定  $W$  处测量一步更新后的损失变化：

$$\Delta L(\hat{g}) := L_{\text{ctrl}}(W - \eta \hat{g}) - L_{\text{ctrl}}(W). \tag{53}$$

对  $g_{\text{BPTT}}, g_{\text{OTTT}}, g_{\text{NDOT}}$  分别计算并比较。

- 它回答的问题比  $\cos$  更直接：方向大致对，但是否真的导致 loss 下降？
- $\Delta L < 0$  表示该 estimator 在当前点仍然是一个 descent direction；
- $\Delta L \geq 0$  表示该 estimator 可能不是有效的下降方向，即使  $\cos(g, g_{\text{BPTT}}) > 0$ ；
- 这一步是 gradient similarity 与 final accuracy 之间的桥梁。

**多步优化与任务性能：**由 one-step 结果再推导 multi-step training trajectory 与最终 task accuracy 是否被 same interaction structure 解释。

### C. 路径二：RTRL $\rightarrow$ e-prop（精确到局部）

**核心问题：**RTRL 如何在 forward mode 保存完整网络 sensitivity？e-prop 如何通过 local eligibility + learning signal 重新组织相同的 gradient credit？

**研究思路：**tiny recurrent network 上实现并验证 RTRL 递推；独立实现 e-prop eligibility；比较 memory、computation、locality；研究 ideal  $L_j^t$  替换为 online  $\hat{L}_j^t$  后 gradient error 多大。

### D. 路径三：STDP $\rightarrow$ S-TLLR $\rightarrow$ TESS（生物局部化）

**单因素 ablation：**

**Ablation 1：**固定 temporal trace，替换 learning signal。fixed trace  $\times \{\delta_{\text{BP}}[t], m_{\text{TESS}}^{(l)}[t]\}$ 。

**Ablation 2：**固定 learning signal，替换 trace。fixed signal  $\times \{\text{causal-only}, \text{causal+non-causal}\}$ 。

## VIII. 符号约定与复杂度口径

### A. 符号统一

以下三个  $e$  是不同对象：

$$\begin{aligned} e_{\text{NDOT}}^l[t] &\in \mathbb{R}^{n^{(l)}} && \text{神经元动力学 temporal coefficient} \\ e_{ji, \text{e-prop}}^t &\in \mathbb{R} && \text{突触级 eligibility trace} \\ e_{ij, \text{STLLR}}[t] &\in \mathbb{R} && \text{STDP-inspired eligibility} \end{aligned} \tag{54}$$

e-prop 原论文将其 eligibility vector 记为  $\epsilon_{ji}^t$ ；本文重命名为  $\xi_{ji}^t$ ，避免与  $\epsilon^l[t]$  混淆。

两种  $\Psi$  也要区分：

$$\Psi'_{\text{SG}}(u) \neq \Psi_{\text{STLLR}}(u). \tag{55}$$

BPTT 中的  $\Psi'_{\text{SG}}$  是 spike surrogate derivative；S-TLLR/TESS 中的  $\Psi_{\text{STLLR}}$  是 secondary activation function。

### B. 层索引与论文原下标映射

OTTT 原论文  $W^l$  表示  $l \rightarrow l+1$ ；NDOT 原论文  $W^l$  表示  $l-1 \rightarrow l$ 。本文基础部分统一使用  $W^{l \leftarrow l-1}$  表示从第  $l-1$  层到第  $l$  层的权重。

### C. 复杂度统一口径

复杂度仅在相同网络假设下直接比较。

| 算法     | 额外 memory | per-step computation          |
|--------|-----------|-------------------------------|
| BPTT   | $O(TLn)$  | $O(Ln^2)$                     |
| RTRL   | $O(n^3)$  | $O(n^4)$                      |
| e-prop | $O(Ln^2)$ | $O(Ln^2)$                     |
| OTTT   | $O(Ln)$   | $O(Ln^2)$                     |
| NDOT   | $O(Ln)$   | $O(Ln^2)$ + ratio computation |
| S-TLLR | $O(Ln)$   | $O(Ln^2)$                     |
| TESS   | $O(Ln)$   | $O(LCn)$                      |

## IX. 下一步实验与实现方案

### A. 实现顺序 (Level 0 / 1 / 2)

#### Level 0: 必须自己实现

- **BPTT-SG reference estimator:** 作为 oracle, 提供  $g_{\text{BPTT}}$ ;
- **Temporal-local primitive:** OTTT 风格的固定衰减 trace ( $\hat{a}^l[t] = \lambda \hat{a}^l[t-1] + s^l[t]$ );
- **Spatial-local primitive:** Mostafa-style fixed random local classifier, 每层独立 local objective。

这是实验真正需要控制的三个核心组件。

#### Level 1: 必须验证

- **e-prop:** 作为 eligibility-trace / learning-signal 分解的经典理论基线; 实现 ideal factorization 与 online  $\hat{L}_j^t$  两种。

#### Level 2: external validation (优先使用作者代码)

- **OTTT 与 NDOT:** 官方实现已公开, 优先使用原代码;
- **S-TLLR 与 TESS:** TESS 官方仓库已区分 S-TLLR baseline 与 TESS full;
- **Traces Propagation** 等后续工作: 作为额外 external check, 不要求从零重写。

不需要在第一阶段把五个算法全部从零重写。

### B. 基础验证: 按三条论文路径组织

**路径一:** 验证 BPTT 手写梯度与 autograd 一致; 验证 OTTT 的 trace 递推与闭式求和一致; 验证 NDOT 的 trace 递推与历史展开式一致。

**路径二:** 验证 RTRL 递推与 autograd full Jacobian 一致; 验证 ideal e-prop identity; 验证 eligibility vector 局部递推; 再单独研究 online learning signal。

**路径三:** 验证 S-TLLR 的显式历史求和与 recursive trace 实现一致; 验证 TESS 的  $m^{(l)}[t]$  与最终  $W^{(l)} \leftarrow W^{(l)} + \eta \sum_{t=t_l}^T \Delta W^{(l)}[t]$ 。

### C. Synthetic task 定义与 readout

**Readout** 定义（所有实验统一）：

$$r[t] = W_{\text{out}} s^N[t] + b_{\text{out}}, \quad W_{\text{out}} \in \mathbb{R}^{C \times n^N}, \quad b_{\text{out}} \in \mathbb{R}^C. \quad (56)$$

**Readout** 参数在 **gradient fidelity diagnostic** 阶段固定，不参与训练。这确保被比较的 gradient estimator 是关于同一组被训练参数（hidden / feedforward weights）的。

**Delayed Copy:**

- 输入：  $x[1] \in \{0, 1\}$ ,  $x[2], \dots, x[k] = 0$ ;
- 目标：  $y[k+1] = x[1]$ ;
- mask：  $m[k+1] = 1$ , 其余  $m[t] = 0$ 。

**Delayed XOR:**

- 输入：  $x[1] = b_1$ ,  $x[2] = b_2$ ; 之后  $x[t] = 0$ ;
- 目标：  $y[k+2] = b_1 \oplus b_2$ ;
- mask：  $m[k+2] = 1$ , 其余  $m[t] = 0$ 。

关于 **Delayed XOR** 中  $k$  的定义：  $k$  是  $b_2$ （最后一个 informative input）与 target 之间的 delay。从  $x[1]$  到 target 实际是  $k+1$ 。

### D. 第一组实验

路径一：单层。参数网格：

$$T \in \{4, 8, 16, 32, 64\}, \quad k \in \{1, 2, 4, 8, 16, 32\} \cap [1, T-1]. \quad (57)$$

建议实验设计：

- 固定  $T = 64$  扫描  $k \in \{1, 2, 4, 8, 16, 32\}$ ;
- 固定  $k = 8$  扫描  $T \in \{16, 32, 64\}$ 。

**Gradient fidelity** 测量：默认使用 A-mode（frozen- $W$  diagnostic）。BPTT oracle 使用同一 controlled loss  $L_{\text{ctrl}}$ 。

绘制  $D_{\text{OTTT}}(k)$ 、 $D_{\text{NDOT}}(k)$ 、 $\cos$  曲线、 $\Delta L(k)$  曲线，以及同层 representation fidelity。

路径二：tiny recurrent network 上比较 RTRL 与 e-prop 的 memory、computation、locality 与 gradient error。

路径三：单因素 ablation。

### E. 后续扩展原则与 decision criterion

后续研究方向不预先固定。首先完成上述三条研究路径，依据实验发现的 failure mode 决定后续方向。

判断后续是否进入机制设计，使用 **effect-size / statistical criterion**，不用 **accuracy** 百分比阈值：

- **Gradient-level:**  $\Delta \cos(\hat{g}, g_{\text{BPTT}})$  是否稳定且跨任务复现；

- **Optimization-level:** one-step loss change  $\Delta L(\hat{g})$  是否具有稳定的符号与量级;
- **Task-level:** task accuracy 的变化是否与 gradient-level / optimization-level 的效应一致。

任何 single-number 的 accuracy 阈值 (例如 1%) 都不构成科学判据。

**新机制的引入原则:** 只有在存在稳定、可重复、真正影响优化或资源效率的 failure mode 后, 才进一步设计新算法。

## 参考文献

- [1] R. J. Williams and D. Zipser, "A learning algorithm for continually running fully recurrent neural networks," *Neural computation*, vol. 1, no. 2, pp. 270–280, 1989.
- [2] G. Bellec, F. Scherr, A. Subramoney, E. Hajek, D. Salaj, R. Legenstein, and W. Maass, "A solution to the learning dilemma for recurrent networks of spiking neurons," *Nature Communications*, vol. 11, no. 1, p. 3625, Jul. 2020. [Online]. Available: <https://doi.org/10.1038/s41467-020-17236-y>
- [3] M. Xiao, Q. Meng, Z. Zhang, D. He, and Z. Lin, "Online Training Through Time for Spiking Neural Networks," in *Advances in Neural Information Processing Systems*, S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, and A. Oh, Eds., vol. 35. Curran Associates, Inc., 2022, pp. 20 717–20 730. [Online]. Available: [https://proceedings.neurips.cc/paper\\_files/paper/2022/file/82846e19e6d42ebfd4ace4361def29ae-Paper-Conference.pdf](https://proceedings.neurips.cc/paper_files/paper/2022/file/82846e19e6d42ebfd4ace4361def29ae-Paper-Conference.pdf)
- [4] H. Jiang, G. D. Masi, H. Xiong, and B. Gu, "NDOT: Neuronal Dynamics-based Online Training for Spiking Neural..." [Online]. Available: <https://openreview.net/forum?id=elF0QoBSFV>
- [5] M. P. E. Apolinario and K. Roy, "S-TLLR: STDP-inspired Temporal Local Learning Rule for Spiking Neural Networks," Oct. 2024, arXiv:2306.15220 [cs]. [Online]. Available: <http://arxiv.org/abs/2306.15220>
- [6] M. P. E. Apolinario, K. Roy, and C. Frenkel, "TESS: A Scalable Temporally and Spatially Local Learning Rule for Spiking Neural Networks," in *2025 International Joint Conference on Neural Networks (IJCNN)*, Jun. 2025, pp. 1–9, iSSN: 2161-4407. [Online]. Available: <https://ieeexplore.ieee.org/abstract/document/11227652>