

SNN 信用分配：从原公式到在线/局部化近似

摘要

本方案以六篇与 SNN 在线/局部信用分配密切相关的核心论文为理论主线，从每篇的原公式出发，逐步推导它们各自的梯度计算方式。

研究基准：从 BPTT 与 RTRL 两类精确信用分配基准出发（reverse-mode / forward-mode），分析在线/局部算法在 **temporal representation**、**eligibility** 与 **learning signal** 上进行了何种重组或近似。

总研究问题：What information is lost by temporal/spatial localization, and how do the losses interact?

资源效率问题：在单位资源消耗下，哪个算法保留的有效梯度信息最多？

三条研究路径：

- **时间近似：**BPTT $\rightarrow$ OTTT $\rightarrow$ NDOT，研究 temporal dependency $\epsilon^l[t]$ 如何被 λI 或 $\text{diag}(\epsilon^l[t])$ 替代；
- **精确到局部：**RTRL $\rightarrow$ e-prop，研究 RTRL 的 full forward sensitivity 与 e-prop 的 local eligibility + learning-signal factorization 之间的关系；
- **生物局部化：**STDP $\rightarrow$ S-TLLR $\rightarrow$ TESS，研究预突触-突触后时序信息如何逐步引入 task credit 与空间局部性。

核心研究问题：这些在线/局部化操作到底保留了什么 credit information，丢失了什么 credit information，以及这些差异什么时候真正影响学习。

文章汇总

RTRL: A learning algorithm for continually running fully recurrent neural networks [1];

E-prop: A solution to the learning dilemma for recurrent networks of spiking neurons [2];

OTTT: Online Training Through Time for Spiking Neural Networks [3];

NDOT: NDOT: Neuronal Dynamics-based Online Training for Spiking Neural Networks [4];

S-TLLR: S-TLLR: STDP-inspired Temporal Local Learning Rule for Spiking Neural Networks [5];

TESS: TESS: A Scalable Temporally and Spatially Local Learning Rule for Spiking Neural Networks [6].

I. 研究背景与核心问题

A. SNN 训练的根本困难

SNN 用二进制脉冲 $s_j^t \in \{0, 1\}$ 传递信息：神经元只有在膜电位达到阈值时才发放一个脉冲，脉冲本身是二值的、不可微的。这带来两个层面的信用分配困难：

- 1) **时间信用分配：**一个输出时刻的损失，可能由多个时间步之前的输入决定；要把这个损失归因到具体某个时刻的突触权重上，需要追踪“过去 $\rightarrow$ 现在”的因果链；
- 2) **空间信用分配：**损失发生在输出层，但要归因到每个隐藏层的权重上；需要把误差从输出层反向传播到各隐藏层。

BPTT 是求解这两个问题的标准方法。它的核心思想是：把 SNN 沿时间展开成一个很深的 feedforward 计算图，然后在这个展开图上调用反向传播。代价是需要保存所有时间步的 forward states（每个时刻的膜电位 $u^l[t]$ 、脉冲 $s^l[t]$ 等），内存 $O(TLn)$ ，且必须等整个序列前向完成后才能开始反向，这排除了在线学习。

关于“精确”的约定：BPTT 与 RTRL 对一个可微 recurrent computational graph 分别给出 reverse-mode 和 forward-mode exact gradient。但 SNN 的脉冲发放 $s = H(u - V_{th})$ 几乎处处导数为零，不是可微函数；实际训练中所有方法都用 surrogate Ψ'_{SG} 替代 $\partial s / \partial u$ 。因此本文所用的 reference 是 **BPTT-with-SG / RTRL under the same surrogate rule**，其“精确”仅指相对于选定 surrogate backward rule 的精确计算，不代表连续动力学的真实导数。下文所有 g_{BPTT} 均指 **BPTT-with-SG reference estimator**，不称为“exact gradient”。

B. 已有工作

时间近似主线：OTTT [3] 注意到在 BPTT 的 temporal chain 里，spike-mediated path 通常极稀疏（因为 H 几乎处处导数为零），于是丢弃该路径，把时序依赖退化为固定指数衰减 $\lambda^{t-\tau}$ ；NDOT [4] 进一步从连续 LIF 微分方程推导动态比率 $e^l[t]$ ，替代固定 λ 。

精确到局部主线：RTRL [1] 用 forward-mode 计算参数敏感度 P_t ，是完全 forward-in-time 的精确梯度方法，但内存 $O(n^3)$ ；e-prop [2] 重新组织 chain rule，把梯度分解为“局部 eligibility $\times$ learning signal”，大幅降低内存。

生物局部化主线：STDP 用 pre/post 时序定义突触可塑性；S-TLLR [5] 引入 STDP 形式的因果与非因果资格迹，再用 learning signal 调制；TESS [6] 通过本地学习信号生成实现时空全局部。

关于“联合局部化”的现状：时空联合局部学习本身已经被研究过——TESS [6] 已把 temporal eligibility 与 layer-local spatial signal 结合；Traces Propagation 等工作也处理时空联合的 forward-only learning。因此本研究不以“首次实现时空联合”作为 novelty。

本研究的问题不是“能否联合”，而是“联合局部化时各自损失了什么、损失如何耦合”：

- 时间局部化（例如 OTTT 的固定 λ 、NDOT 的 $\text{diag}(e^l)$ ）在 temporal dependency 上引入了何种结构性误差？
- 空间局部化（例如 Mostafa-style local classifier）在目标替换上引入了何种结构性误差？
- 当两种局部化同时施加时，误差是简单叠加还是产生 interaction？

C. 核心研究问题

总问题：What information is lost by temporal/spatial localization, and how do the losses interact?

三条研究路径下的具体问题：

- 路径一： $e^l[t] \rightarrow \lambda I$ 或 $\text{diag}(e^l[t])$ 到底改变了多少 temporal credit？在什么样的 T, λ 下差异显现？
- 路径二：RTRL 的 full forward sensitivity 与 e-prop 的 local eligibility + learning signal factorization 是同维度对象吗？它们各自保留了什么？
- 路径三：STDP-inspired eligibility 中的 causal / non-causal timing 分别提供什么？layer-local spatial learning signal 与 cross-layer BP learning signal 的差别落在哪？

II. 数学基础

A. LIF 神经元 (feedforward 形式)

$$u_j^l[t+1] = \lambda(u_j^l[t] - V_{th} s_j^l[t]) + \sum_i W_{ji}^{l \leftarrow l-1} s_i^{l-1}[t+1] + b_j^l, \quad s_j^l[t] = H(u_j^l[t] - V_{th}). \quad (1)$$

这个公式在说什么：第 l 层神经元 j 的膜电位 $u_j^l[t+1]$ 由三部分决定——上一时刻膜电位经过衰减后剩下的“记忆”、来自上一层神经元的加权输入、以及偏置。当膜电位达到阈值 V_{th} 时，神经元发放一个脉冲 $s_j^l[t] = 1$ 。

逐项拆解：

- $\lambda(u_j^l[t] - V_{th} s_j^l[t])$ ：这是**leak**加**reset**。
 - $u_j^l[t]$ 乘 λ 表示膜电位随时间指数衰减 (“leak”)。 $\lambda = e^{-\delta t / \tau_m} < 1$ ， δt 越小或 τ_m 越大， λ 越接近 1，膜电位衰减越慢、记忆越长；
 - $-V_{th} s_j^l[t]$ 是**reset by subtraction**：如果 t 时刻发放了脉冲 ($s_j^l[t] = 1$)，则从上一步膜电位中减去 V_{th} ，防止膜电位一直累积。整个括号项先做 reset、再被 λ 衰减。
- $\sum_i W_{ji}^{l \leftarrow l-1} s_i^{l-1}[t+1]$ ：来自上一层的加权输入。
- b_j^l ：偏置项。
- $s_j^l[t] = H(u_j^l[t] - V_{th})$ ：**Heaviside** 阶跃函数 $\mathbb{I}[x \geq 0]$ 。前向不可导，是 SNN 训练困难的核心来源。

参数解释：

符号	数学定义 / 形状	物理含义与典型取值
$l \in \{1, \dots, L\}$	整数层索引	$l = 0$ 为输入层， $l = L$ 为输出层
j	当前层神经元索引	遍历 $1, \dots, n^{(l)}$
i	上一层神经元索引	BPTT-OTTT-NDOT 主线中只指 $l-1$ 层
$u_j^l[t]$	$\mathbb{R}$ (标量)	膜电位 (hidden state)
$s_j^l[t]$	$\{0, 1\}$ (标量)	是否发放
$W_{ji}^{l \leftarrow l-1}$	$\mathbb{R}^{n^{(l)} \times n^{(l-1)}}$	突触权重
b_j^l	$\mathbb{R}$	偏置项
V_{th}	正实数	发放阈值，本文取 $V_{th} = 1$
λ	$e^{-\delta t / \tau_m} \in (0, 1)$	膜衰减因子
$H(x)$	$\mathbb{I}[x \geq 0]$	Heaviside 阶跃函数

B. Surrogate Gradient

$$\frac{\partial s_j^l[t]}{\partial u_j^l[t]} \rightarrow \Psi'_{SG}(u_j^l[t] - V_{th}), \quad \Psi'_{SG}(x) = \frac{1}{(1 + \beta|x|)^2}, \quad \beta = 4. \quad (2)$$

为什么需要 **surrogate**：Heaviside 函数 $H(x)$ 在 $x = 0$ 处不可导，在其他地方导数为零。surrogate gradient 的做法是：前向仍然使用真正的 Heaviside 产生脉冲，反向把 $\partial s / \partial u$ 替换成一个光滑、有界的函数。

为什么选 **fast-sigmoid**: $\Psi'_{\text{SG}}(x) = 1/(1 + \beta|x|)^2$ 在 $x = 0$ 处取最大值 1, 随着 $|x|$ 增大迅速衰减。膜电位接近阈值时梯度最大, 远离阈值时梯度快速衰减。

参数解释:

- Ψ'_{SG} : surrogate derivative;
- β : 锐度参数, 本文取 $\beta = 4$;
- $D_{\Psi,t} = \text{diag}[\Psi'_{\text{SG}}(u_j^l[t] - V_{th})]_j \in \mathbb{R}^{n^{(l)} \times n^{(l)}}$;
- 该 surrogate 是本文的实验选择, 不是原论文的统一规定。

C. BPTT: 时间反向传播 (原论文形式)

Step 1: ordered temporal product.

$$\mathcal{E}_{t,\tau} := \epsilon[t-1] \epsilon[t-2] \cdots \epsilon[\tau], \quad \tau < t. \quad (3)$$

从时间步 τ 的 state 到时间步 t 的 state, 需要经过一连串状态转移。矩阵乘法不可交换, 所以乘积顺序按时间从 $t-1$ 到 τ 。 $\mathcal{E}_{t,t} = I$ (空乘积约定)。

Step 2: BPTT 主公式。

对权重 $W^{l \leftarrow l-1}$:

$$\frac{\partial L}{\partial W^{l \leftarrow l-1}} = \sum_{t=1}^T \frac{\partial L}{\partial s^l[t]} \frac{\partial s^l[t]}{\partial u^l[t]} \left(\frac{\partial u^l[t]}{\partial W^{l \leftarrow l-1}} + \sum_{\tau < t} \mathcal{E}_{t,\tau} \frac{\partial u^l[\tau]}{\partial W^{l \leftarrow l-1}} \right). \quad (4)$$

这个公式在说什么: 对每一时刻 t , 权重影响 $u^l[t]$ 有两条路径——直接影响 (第一项) 和历史路径 (第二项)。外面乘的 $\partial L / \partial s^l[t] \cdot \partial s^l[t] / \partial u^l[t]$ 把 $u^l[t]$ 对 L 的贡献转换成 error signal。

temporal dependency 的定义:

$$\epsilon^l[i] = \frac{\partial u^l[i+1]}{\partial u^l[i]} + \frac{\partial u^l[i+1]}{\partial s^l[i]} \frac{\partial s^l[i]}{\partial u^l[i]}. \quad (5)$$

为什么有两项: 第一项通过膜电位自身的 leak 传播; 第二项通过 $u^l[i]$ 决定是否发放 $s^l[i]$, 再通过 reset 项影响 $u^l[i+1]$ 。

Step 3: 代入 LIF.

$$\epsilon^l[i] = \lambda I - \lambda V_{th} D_{\Psi,i}. \quad (6)$$

内存来源: BPTT 在反向时需要 $\epsilon^l[i]$, 而 $\epsilon^l[i]$ 依赖 $u^l[i]$ 与 $s^l[i]$ 。这意味着反向过程需要访问所有时间步的 forward states。典型实现额外 activation memory 为 $O(TLn)$ 。

D. STDP: 局部突触可塑性基础

经典 **STDP**。令 $\Delta t = t_{\text{post}} - t_{\text{pre}}$:

$$\Delta w = \begin{cases} A_+ e^{-\Delta t / \tau_+}, & \Delta t > 0 \text{ (potentiation)}, \\ -A_- e^{\Delta t / \tau_-}, & \Delta t < 0 \text{ (depression)}. \end{cases} \quad (7)$$

Generalized trace-based STDP form:

$$\Delta w_{ij}[t] = \alpha_{\text{pre}} y_i[t] \sum_{t'=0}^t \lambda_{\text{pre}}^{t-t'} x_j[t'] + \alpha_{\text{post}} x_j[t] \sum_{t'=0}^{t-1} \lambda_{\text{post}}^{t-t'} y_i[t']. \quad (8)$$

从 STDP 到 three-factor rule:

$$\Delta w_{ij}[t] = \delta_i[t] e_{ij}[t]. \quad (9)$$

参数解释:

- $x_j[t], y_i[t] \in \{0, 1\}$: pre/post 脉冲;
- $\lambda_{\text{pre}}, \lambda_{\text{post}} \in (0, 1)$: 迹的衰减因子, 与 LIF 的 λ 不同;
- $\alpha_{\text{pre}}, \alpha_{\text{post}}$: 因果/非因果项强度;
- $\delta_i[t]$: task learning signal; $e_{ij}[t]$: eligibility。

III. 前向敏感度与局部资格迹: RTRL 与 E-PROP

A. RTRL: forward-mode 参数敏感度

Step 1: 一般 RNN 状态方程。 $h_t = F(h_{t-1}, x_t, W)$ 。

Step 2: 参数敏感度。 $P_t := \partial h_t / \partial W \in \mathbb{R}^{n \times r}$, $r = |W|$ 。

Step 3–4: 链式法则与两个 Jacobian。

$$\frac{\partial h_t}{\partial W} = \frac{\partial h_t}{\partial h_{t-1}} \cdot \frac{\partial h_{t-1}}{\partial W} + \frac{\partial h_t}{\partial W} \Big|_{h_{t-1} \text{ fixed}}. \quad (10)$$

定义 $A_t = \partial h_t / \partial h_{t-1}$ 、 $B_t = \partial h_t / \partial W|_{h_{t-1} \text{ fixed}}$ 。

Step 5: RTRL 核心递推。

$$P_t = A_t P_{t-1} + B_t. \quad (11)$$

这个公式在说什么: forward-in-time 递推。 P_{t-1} 是过去所有参数作用的累计敏感度, 乘以 A_t 表示“过去的敏感度被当前 dynamics 继续传播”; 再加上 B_t 表示“当前时刻 W 新注入的影响”。

Step 6: 当前 loss 梯度。 $\nabla_W \ell_t = \partial \ell_t / \partial h_t \cdot P_t$ 。

复杂度: $r = O(n^2)$ 时, memory $O(n^3)$, per-step time $O(n^4)$ 。多层结构取决于 connectivity。

与 BPTT 的关系: BPTT 是 reverse-mode, RTRL 是 forward-mode。二者对一个可微 computational graph 都是精确的, 只是方向不同、内存分布不同。

B. e-prop: 从 RTRL 到局部资格迹 + 学习信号

Step 1: RTRL 的问题。 P_t 的维度是 $n \times r$, 对 SNN 来说太大。e-prop 重新组织 chain rule。

Step 2: 从经典 recurrent gradient factorization 出发。

$$\frac{dE}{dW_{ji}} = \sum_{t'} \frac{dE}{dh_j^{t'}} \frac{\partial h_j^{t'}}{\partial W_{ji}} \Big|_{h_j^{t'-1} \text{ fixed}}. \quad (12)$$

Step 3: 递归展开 $dE/dh_j^{t'}$ 。

$$\frac{dE}{dh_j^{t'}} = L_j^{t'} \frac{\partial z_j^{t'}}{\partial h_j^{t'}} + \frac{dE}{dh_j^{t'+1}} \frac{\partial h_j^{t'+1}}{\partial h_j^{t'}}, \quad L_j^{t'} := \frac{dE}{dz_j^{t'}}. \quad (13)$$

展开至 T 、交换求和顺序后：

$$\frac{dE}{dW_{ji}} = \sum_t L_j^t e_{ji}^t, \quad e_{ji}^t := \left[\frac{dz_j^t}{dW_{ji}} \right]_{\text{local}}. \quad (14)$$

关于 e_{ji}^t 的语义：它是 chain-rule **rearrangement** 之后可由突触及 postsynaptic neuron 的局部 forward variables 计算的部分。其他 downstream 影响全部进入了 L_j^t 。因此这个分解是精确恒等式，不是“删掉某些路径后的近似”。

Step 4: eligibility vector 递推。

$$e_{ji}^t = \frac{\partial z_j^t}{\partial h_j^t} \xi_{ji}^t, \quad \xi_{ji}^{t+1} = \lambda \xi_{ji}^t + z_i^t. \quad (15)$$

Step 5: ideal $\rightarrow$ online $\rightarrow$ actual update.

Ideal learning signal: $L_j^t = dE/dz_j^t$ 。

Online learning signal: Regression $\hat{L}_j^t = \sum_k B_{jk}(y_k^t - y_k^{*,t})$; Classification $\hat{L}_j^t = \sum_k B_{jk}(\pi_k^t - \pi_k^{*,t})$ 。

Actual synaptic update (滤波后的 eligibility $\bar{e}_{ji}^t = \mathcal{F}_\kappa(e_{ji}^t)$):

$$\Delta W_{ji}^{\text{rec}} = -\eta \sum_t \left[\sum_k B_{jk}(y_k^t - y_k^{*,t}) \right] \bar{e}_{ji}^t. \quad (16)$$

参数解释：

- λ (e-prop 原文中记作 α): postsynaptic state 的衰减因子；
- ξ_{ji}^t : eligibility vector; e_{ji}^t : observable eligibility trace;
- κ : readout dynamics 的低通衰减参数；
- B_{jk} : output error 到 recurrent neuron j 的 feedback weight;
- η : 学习率。

与 **RTRL** 的关系: RTRL 的 $P_t = A_t P_{t-1} + B_t$ 保存了完整网络的 Jacobian; e-prop 的 $\xi_{ji}^t = A_{j,t}^{\text{loc}} \xi_{ji}^{t-1} + B_{ji,t}^{\text{loc}}$ 只保留了单突触级的局部路径。二者递推结构相似，但对象完全不同。

IV. 时间在线训练: OTTT 与 NDOT

A. 从 BPTT 到 temporal dependency $\epsilon[i]$

$$\epsilon[i] = \lambda I - \lambda V_{th} D_{\Psi,i}. \quad (17)$$

OTTT 与 NDOT 的区别就在于如何近似 $\epsilon[i]$ 。

B. OTTT: $\epsilon[i] \approx \lambda I$

Step 1: 丢弃 spike-mediated path.

$$\frac{\partial u[i+1]}{\partial s[i]} \frac{\partial s[i]}{\partial u[i]} \approx 0. \quad (18)$$

Step 2: $\epsilon[i]$ 退化。

$$\epsilon[i] \approx \lambda I. \quad (19)$$

Step 3: temporal trace.

$$\hat{a}^l[t] := \sum_{\tau \leq t} \lambda^{t-\tau} s^l[\tau], \quad \hat{a}^l[t+1] = \lambda \hat{a}^l[t] + s^l[t+1]. \quad (20)$$

Step 4: instantaneous loss.

$$L[t] = \frac{1}{T} \mathcal{L}(s^N[t], y). \quad (21)$$

Step 5: OTTT 瞬时梯度。

$$\nabla_{W^l} L[t] = g_{u^{l+1}}[t] \hat{a}^l[t]^\top, \quad g_{u^{l+1}}[t] = \left(\frac{\partial L[t]}{\partial s^{l+1}[t]} \frac{\partial s^{l+1}[t]}{\partial u^{l+1}[t]} \right)^\top. \quad (22)$$

Step 6: 两种 update mode.

$$\begin{aligned} \text{OTTT}_O: & \text{ 每个 } t \text{ 立即更新} \\ \text{OTTT}_A: & \text{ 累计 } \sum_t \nabla_{W^l} L[t] \text{ 后统一更新} \end{aligned} \quad (23)$$

参数解释: λ 是膜衰减, 同时成为 temporal trace decay; $\hat{a}^l[t]$ 是历史 presynaptic spikes 的加权迹; $g_{u^{l+1}}[t]$ 是当前时刻 spatial gradient。

复杂度: 额外 memory $O(Ln)$, per-step computation $O(Ln^2)$ 。

C. NDOT: $\epsilon[i] \approx e[i]$

Step 1: OTTT 的问题。 OTTT 假设 $\epsilon[i] = \lambda I$, 忽略 spike 路径。

Step 2: 从连续动力学定义 $e(t)$ 。

$$e(t) \triangleq \frac{\partial u(t+1)}{\partial u(t)} = \frac{u'(t+1)}{u'(t)}. \quad (24)$$

Step 3: 代入 LIF 连续方程。 $u'(t) = (-u(t) + I(t))/\tau$:

$$e(t) = \frac{u'(t+1)}{u'(t)} = \frac{u(t+1) - I(t+1)}{u(t) - I(t)}. \quad (25)$$

Step 4: 映射到离散 SNN。

$$e^l[t] = \begin{cases} u^l[1] - V_{th} s^l[1], & t = 1, \\ \frac{u^l[t] - V_{th} s^l[t]}{u^l[t-1] - V_{th} s^l[t-1]}, & t > 1. \end{cases} \quad (26)$$

层索引关系: NDOT 原文针对 W^l 的具体梯度公式中, $\epsilon^l[i]$ 被 presynaptic layer 的 $e^{l-1}[i]$ 替代。

Step 5: temporal trace.

$$\hat{a}^{l-1}[t] = e^{l-1}[t-1] \odot \hat{a}^{l-1}[t-1] + s^{l-1}[t]. \quad (27)$$

Step 6: instantaneous loss.

$$L[t] = (1 - \alpha) \ell_{\text{CE}}(s^N[t], y) + \alpha \ell_{\text{MSE}}(s^N[t], y). \quad (28)$$

Step 7: NDOT 瞬时权重梯度与两种 update mode.

$$\nabla_{W^l} L[t] = g_{u^l}[t] \hat{a}^{l-1}[t]^\top. \quad (29)$$

$$\begin{aligned} \text{NDOT}_O: & \text{ 每个 } t \text{ 立即更新} \\ \text{NDOT}_A: & \text{ 累计 } \sum_t \nabla_{w^l} L[t] \text{ 后统一更新} \end{aligned} \quad (30)$$

OTTT 与 NDOT 的关系:

$$\begin{aligned} \text{OTTT: } \epsilon^l[t] &\approx \lambda I \\ \text{NDOT: } \epsilon^l[t] &\approx \text{diag}(\epsilon^l[t]) \end{aligned} \quad (31)$$

复杂度: 额外 memory $O(Ln)$, per-step computation $O(Ln^2)$ 。

V. STDP-INSPIRED 本地学习: S-TLLR

Step 1: three-factor rule. $\Delta w_{ij}[t] = \delta_i[t] e_{ij}[t]$ 。

Step 2: eligibility.

$$e_{ij}[t] = \alpha_{\text{pre}} \Psi_{\text{STLLR}}(u_i[t]) \sum_{t'=0}^t \lambda_{\text{pre}}^{t-t'} x_j[t'] + \alpha_{\text{post}} x_j[t] \sum_{t'=0}^{t-1} \lambda_{\text{post}}^{t-t'} \Psi_{\text{STLLR}}(u_i[t']). \quad (32)$$

重要澄清: non-causal 是 STDP timing relation 意义上的 non-causal——当前 pre spike 与过去 post activity 的相关性。它不需要访问未来, 仍是 online。

Step 3: 前向递推形式。

$$e_{ij}[t] = \alpha_{\text{pre}} \Psi_{\text{STLLR}}(u_i[t]) \text{tr}(x_j)[t] + \alpha_{\text{post}} x_j[t] (\text{tr}(\Psi_{\text{STLLR}}(u_i))[t] - \Psi_{\text{STLLR}}(u_i[t])). \quad (33)$$

Step 4: recurrent synapse extension.

$$u_i[t] = \gamma(u_i[t-1] - v_{th} y_i[t-1]) + W^{\text{ff}} x[t] + W^{\text{rec}} y[t-1]. \quad (34)$$

Step 5–6: learning signal 与更新。

$$w_{ij} := w_{ij} + \rho \sum_{t=T_l}^T \delta_i[t] e_{ij}[t]. \quad (35)$$

参数解释: Ψ_{STLLR} 是 secondary activation; $\alpha_{\text{pre}}, \alpha_{\text{post}}$ 是强度; $\lambda_{\text{pre}}, \lambda_{\text{post}}$ 是衰减; T_l 是 learning signal 起始; ρ 是学习率。

复杂度: 额外 memory $O(Ln)$, per-step computation $O(Ln^2)$ 。

VI. 时空全局部学习: TESS

TESS 与 S-TLLR 的关系:

$$\begin{aligned} \text{S-TLLR: } & \text{local temporal eligibility + instantaneous BP learning signal} \\ \text{TESS: } & \text{local temporal eligibility + explicitly layer-local generated learning signal} \end{aligned} \quad (36)$$

Step 1–2: 因果迹与非因果迹。

$$q^{(l)}[t] = \lambda_{\text{pre}} q^{(l)}[t-1] + o^{(l-1)}[t], \quad h^{(l)}[t] = \lambda_{\text{post}} h^{(l)}[t-1] + \Psi_{\text{STLLR}}(u^{(l)}[t-1]). \quad (37)$$

Step 3: 本地学习信号 (LSG)。

$$m^{(l)}[t] = B^{(l)\top} (f(B^{(l)} o^{(l)}[t]) - y^*). \quad (38)$$

Step 4: 逐时刻权重增量。

$$\Delta W^{(l)}[t] = (m^{(l)}[t] \odot \alpha_{\text{pre}} \Psi_{\text{STLLR}}(u^{(l)}[t])) \otimes q^{(l)}[t] + (m^{(l)}[t] \odot \alpha_{\text{post}} h^{(l)}[t]) \otimes o^{(l-1)}[t]. \quad (39)$$

Step 5: 最终权重更新与初始化。


$$W^{(l)} \leftarrow W^{(l)} + \eta \sum_{t=t_l}^T \Delta W^{(l)}[t], \quad q^{(l)}[0] = 0, \quad h^{(l)}[0] = 0. \quad (40)$$

参数解释: $B^{(l)} \in \mathbb{R}^{C \times n^{(l)}}$ 是固定二值投影矩阵; $o^{(l)}[t] \in \mathbb{R}^{n^{(l)}}$; $q^{(l)}[t] \in \mathbb{R}^{n^{(l-1)}}$; $h^{(l)}[t] \in \mathbb{R}^{n^{(l)}}$; $m^{(l)}[t] \in \mathbb{R}^{n^{(l)}}$; f 是 softmax 或 identity; t_l 是起始时刻; η 是学习率。

复杂度: 额外 memory $O(Ln)$, learning-signal generation computation $O(LCn)$ 。

VII. 算法关系与核心研究问题

A. 三条研究路径



关于 $\mathbf{RTRL} \rightarrow \mathbf{e-prop}$ 箭头: 这是本文的研究比较路径, 不意味着 $\mathbf{e-prop}$ 是直接由 $\mathbf{RTRL}$ 的 P_t 局部截断所得。

B. 路径一: $\mathbf{BPTT} \rightarrow \mathbf{OTTT} \rightarrow \mathbf{NDOT}$

核心问题: $\epsilon^l[t] \rightarrow \lambda I$ 或 $\text{diag}(e^l[t])$ 改变了多少 temporal credit?

受控比较的唯一变量 = temporal dependency treatment:

$$\epsilon^l[t] \quad \text{vs} \quad \lambda I \quad \text{vs} \quad \text{diag}(e^l[t]). \quad (42)$$

C. 路径二: $\mathbf{RTRL} \rightarrow \mathbf{e-prop}$

核心问题: $\mathbf{RTRL}$ 如何在 forward mode 保存完整网络 sensitivity? $\mathbf{e-prop}$ 如何通过 local eligibility + learning signal 重新组织相同的 gradient credit?

D. 路径三: $\mathbf{STDP} \rightarrow \mathbf{S-TLLR} \rightarrow \mathbf{TESS}$

单因素 ablation: 固定 temporal trace, 替换 learning signal; 固定 learning signal, 替换 trace。

VIII. 信息保真度与资源效率分析

A. 两个分析分支

不同算法优化的目标不同，不能强行放在同一个指标下比较。本研究分为两个分析分支：

Branch A: 全局目标近似 (Global-objective approximation)

包括 BPTT、OTTT、NDOT、e-prop、S-TLLR、TESS。它们的梯度都在同一个目标函数下计算，可以直接比较”相对 BPTT 的梯度保真度”。

$$g_{\text{alg}} \approx g_{\text{BPTT}} \quad (\text{在同一目标函数下}) \quad (43)$$

研究问题：梯度信息损失了多少？

Branch B: 目标局部化 (Objective localization)

包括 Mostafa-style local classifier 等本地学习方法。它们优化的是每层的局部目标：

$$E_{\text{local}} \neq E_{\text{global}} \quad (44)$$

此时 $\cos(g_{\text{local}}, g_{\text{BPTT}})$ 没有严格意义。研究问题改为：全局目标被局部目标替代后，任务性能与资源开销发生了什么变化？

两个 branch 使用不同的指标，不做统一对比。

B. Branch A: 梯度保真度分三层

第一层：方向保真度 (Direction fidelity)

$$F_{\text{dir}} = \cos(g_{\text{alg}}, g_{\text{BPTT}}) = \frac{g_{\text{alg}}^{\top} g_{\text{BPTT}}}{\|g_{\text{alg}}\| \|g_{\text{BPTT}}\|} \quad (45)$$

回答：算法是否朝着 BPTT 的方向走？

第二层：梯度误差 (Gradient error)

$$D_g = \frac{\|g_{\text{alg}} - g_{\text{BPTT}}\|}{\|g_{\text{BPTT}}\| + \varepsilon_{\text{num}}} \quad (46)$$

回答：算法偏离 BPTT 多远？

辅助分解：

$$c_{\parallel} = \frac{g^{\top} g_{\text{BPTT}}}{\|g_{\text{BPTT}}\|^2}, \quad R_{\perp} = \frac{\|g - c_{\parallel} g_{\text{BPTT}}\|}{\|g_{\text{BPTT}}\|}. \quad (47)$$

$c_{\parallel}$ 是平行分量， $R_{\perp}$ 是垂直分量。

第三层：优化有效性 (Optimization utility)

$$\Delta L(g) = L_{\text{ctrl}}(W - \eta g) - L_{\text{ctrl}}(W). \quad (48)$$

回答：用这个近似梯度更新一步，loss 是否下降？

$$\Delta L_{\text{ratio}}(g) = \frac{L(W) - L(W - \eta g)}{L(W) - L(W - \eta g_{\text{BPTT}}) + \varepsilon_{\text{num}}} \quad (49)$$

ΔL_{ratio} 度量”相对于 BPTT，保留了多少实际优化能力”。

C. Branch A: 梯度维度 (Gradient diversity)

除了方向保真度，还要单独度量梯度样本的分布维度。给定梯度矩阵

$$G = \begin{bmatrix} g^{(1)} & g^{(2)} & \dots & g^{(m)} \end{bmatrix} \in \mathbb{R}^{n \times m}, \quad (50)$$

做 SVD 得奇异值 $\sigma_1 \geq \sigma_2 \geq \dots$ ，定义谱熵

$$p_i = \frac{\sigma_i}{\sum_j \sigma_j}, \quad H_{\text{spec}} = - \sum_i p_i \log p_i, \quad (51)$$

有效秩

$$\text{erank}(G) = e^{H_{\text{spec}}}. \quad (52)$$

重要说明：erank 度量”梯度样本在参数空间中的有效维度”，不是”梯度保真度”。二者是不同概念。

定义 ratio:

$$R_{\text{erank}} = \frac{\text{erank}(G_{\text{alg}})}{\text{erank}(G_{\text{BPTT}})}. \quad (53)$$

R_{erank} 可以大于 1，不代表算法信息更多。

D. 资源消耗指标

维度	指标	测量方式
内存	Peak GPU memory	max_memory_allocated
计算	Training time / FLOPs	Wall-clock / profiler
通信	层间通信量	按层统计传输字节
可扩展性	T 增大时的增长	扫描 $T \in \{4, 8, 16, 32, 64\}$

理论上界:

算法	额外 memory	per-step computation
BPTT	$O(TLn)$	$O(Ln^2)$
RTRL	$O(n^3)$	$O(n^4)$
e-prop	$O(Ln^2)$	$O(Ln^2)$
OTTT	$O(Ln)$	$O(Ln^2)$
NDOT	$O(Ln)$	$O(Ln^2)$
S-TLLR	$O(Ln)$	$O(Ln^2)$
TESS	$O(Ln)$	$O(LCn)$

通信量总量估计：

$$\text{Communication} = \text{每步传输量} \times T \times L. \quad (54)$$

E. Pareto 分析（不合成单一指标）

不做如下合成：

$$\eta = \frac{\text{Info}}{\text{Cost}}. \quad (55)$$

原因：Info 的定义不唯一（cos、 $1 - D_g$ 、erank 三者意义不同），除以 Cost 没有物理意义。

改为 **Pareto** 分析：绘制三张散点图：

$$(\text{Memory, Fidelity}), \quad (\text{Time, Fidelity}), \quad (\text{Communication, Fidelity}). \quad (56)$$

每个算法一个点，横轴资源、纵轴保真度。越靠近左上角，信息效率越高。

判断是否存在明显 Pareto frontier，以及各算法在 frontier 上的位置。

IX. 符号约定与复杂度口径

A. 符号统一

以下三个 e 是不同对象：

$$\begin{aligned} e_{\text{NDOT}}^l[t] &\in \mathbb{R}^{n^{(l)}} && \text{神经元动力学 temporal coefficient} \\ e_{ji, \text{e-prop}}^t &\in \mathbb{R} && \text{突触级 eligibility trace} \\ e_{ij, \text{STLLR}}[t] &\in \mathbb{R} && \text{STDP-inspired eligibility} \end{aligned} \quad (57)$$

e-prop 原论文将其 eligibility vector 记为 ϵ_{ji}^t ；本文重命名为 ξ_{ji}^t ，避免与 $\epsilon^l[t]$ 混淆。

两种 Ψ 也要区分：

$$\Psi'_{\text{SG}}(u) \neq \Psi_{\text{STLLR}}(u). \quad (58)$$

BPTT 中的 Ψ'_{SG} 是 spike surrogate derivative；S-TLLR/TESS 中的 Ψ_{STLLR} 是 secondary activation function。

B. 层索引与论文原下标映射

OTTT 原论文 W^l 表示 $l \rightarrow l+1$ ；NDOT 原论文 W^l 表示 $l-1 \rightarrow l$ 。本文基础部分统一使用 $W^{l \leftarrow l-1}$ 表示从第 $l-1$ 层到第 l 层的权重。

X. 下一步实验与实现方案

A. 实现顺序 (*Level 0 / 1 / 2*)

Level 0: 必须自己实现

- **BPTT-SG reference estimator:** 作为 oracle, 提供 g_{BPTT} ;
- **Temporal-local primitive:** OTTT 风格的固定衰减 trace;
- **Spatial-local primitive:** Mostafa-style fixed random local classifier.

Level 1: 必须验证

- **e-prop:** eligibility-trace / learning-signal 分解的经典理论基线。

Level 2: external validation (优先使用作者代码)

- **OTTT 与 NDOT:** 官方实现已公开;
- **S-TLLR 与 TESS:** 优先使用作者公开代码。

不需要在第一阶段把五个算法全部从零重写。

B. 基础验证

路径一: 验证 BPTT 手写梯度与 autograd 一致; 验证 OTTT 的 trace 递推与闭式求和一致; 验证 NDOT 的 trace 递推与历史展开式一致。

路径二: 验证 RTRL 递推与 autograd full Jacobian 一致; 验证 ideal e-prop identity; 验证 eligibility vector 局部递推。

路径三: 验证 S-TLLR 的显式历史求和与 recursive trace 实现一致; 验证 TESS 的 $m^{(l)}[t]$ 与最终权重更新。

C. Synthetic task 定义与 readout

Readout 定义 (所有实验统一):

$$r[t] = W_{\text{out}} s^N[t] + b_{\text{out}}, \quad W_{\text{out}} \in \mathbb{R}^{C \times n^N}, \quad b_{\text{out}} \in \mathbb{R}^C. \quad (59)$$

Readout 参数在 gradient fidelity diagnostic 阶段固定, 不参与训练。

Delayed Copy:

- 输入: $x[1] \in \{0, 1\}$, $x[2], \dots, x[k] = 0$;
- 目标: $y[k+1] = x[1]$;
- mask: $m[k+1] = 1$, 其余 $m[t] = 0$ 。

Delayed XOR:

- 输入: $x[1] = b_1$, $x[2] = b_2$; 之后 $x[t] = 0$;
- 目标: $y[k+2] = b_1 \oplus b_2$;
- mask: $m[k+2] = 1$ 。

k 是 b_2 与 target 之间的 delay。

D. 核心实验

实验 1: T-sweep 上的梯度保真度

固定 k , 扫描 $T \in \{4, 8, 16, 32, 64\}$, 绘制

$$\cos(g_{\text{alg}}(T), g_{\text{BPTT}}(T)) \quad (60)$$

回答: approximation error 如何随 temporal horizon 增长?

实验 2: 逐层梯度保真度

$$\cos_l = \cos(g_l^{\text{alg}}, g_l^{\text{BPTT}}), \quad l = 1, \dots, L. \quad (61)$$

回答: 信息损失发生在浅层还是深层?

实验 3: One-step optimization utility

对每个算法测量 $\Delta L(g_{\text{alg}})$, 比较是否仍是有效的下降方向。

实验 4: 保真度-资源散点图

对每个算法绘制 (Memory, Fidelity)、(Time, Fidelity)、(Communication, Fidelity), 分析 Pareto frontier。

E. 后续扩展原则

后续研究方向不预先固定。首先完成上述实验, 依据实验发现的 failure mode 决定后续方向。

判断后续是否进入机制设计, 使用 **effect-size / statistical criterion**, 不用 **accuracy** 百分比阈值:

- **Gradient-level:** $\Delta \cos(\hat{g}, g_{\text{BPTT}})$ 是否稳定且跨任务复现;
- **Optimization-level:** one-step loss change $\Delta L(\hat{g})$ 是否具有稳定的符号与量级;
- **Task-level:** task accuracy 的变化是否与 gradient-level / optimization-level 的效应一致。

新机制的引入原则: 只有在存在稳定、可重复、真正影响优化或资源效率的 failure mode 后, 才进一步设计新算法。

参考文献

- [1] R. J. Williams and D. Zipser, "A learning algorithm for continually running fully recurrent neural networks," *Neural computation*, vol. 1, no. 2, pp. 270–280, 1989.
- [2] G. Bellec, F. Scherr, A. Subramoney, E. Hajek, D. Salaj, R. Legenstein, and W. Maass, "A solution to the learning dilemma for recurrent networks of spiking neurons," *Nature Communications*, vol. 11, no. 1, p. 3625, Jul. 2020. [Online]. Available: <https://doi.org/10.1038/s41467-020-17236-y>
- [3] M. Xiao, Q. Meng, Z. Zhang, D. He, and Z. Lin, "Online Training Through Time for Spiking Neural Networks," in *Advances in Neural Information Processing Systems*, S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, and A. Oh, Eds., vol. 35. Curran Associates, Inc., 2022, pp. 20 717–20 730. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2022/file/82846e19e6d42ebfd4ace4361def29ae-Paper-Conference.pdf
- [4] H. Jiang, G. D. Masi, H. Xiong, and B. Gu, "NDOT: Neuronal Dynamics-based Online Training for Spiking Neural..." [Online]. Available: <https://openreview.net/forum?id=elF0QoBSFV>
- [5] M. P. E. Apolinario and K. Roy, "S-TLLR: STDP-inspired Temporal Local Learning Rule for Spiking Neural Networks," Oct. 2024, arXiv:2306.15220 [cs]. [Online]. Available: <http://arxiv.org/abs/2306.15220>

- [6] M. P. E. Apolinario, K. Roy, and C. Frenkel, "TESS: A Scalable Temporally and Spatially Local Learning Rule for Spiking Neural Networks," in *2025 International Joint Conference on Neural Networks (IJCNN)*, Jun. 2025, pp. 1–9, iSSN: 2161-4407. [Online]. Available: <https://ieeexplore.ieee.org/abstract/document/11227652>