

# SNN 信用分配：从原公式到在线/局部化近似

## 摘要

本方案以六篇与 SNN 在线/局部信用分配密切相关的核心论文为理论主线，从每篇的原公式出发，逐步推导它们各自的梯度计算方式。

**研究基准：**从 BPTT 与 RTRL 两类精确信用分配基准出发（reverse-mode / forward-mode），分析在线/局部算法在 **temporal representation**、**eligibility** 与 **learning signal** 上进行了何种重组或近似。

三条研究路径：

- **时间近似：**BPTT  $\rightarrow$  OTTT  $\rightarrow$  NDOT，研究 temporal dependency  $e^l[t]$  如何被  $\lambda I$  或  $\text{diag}(e^l[t])$  替代；
- **精确到局部：**RTRL  $\rightarrow$  e-prop，研究 RTRL 的 full forward sensitivity 与 e-prop 的 local eligibility + learning-signal factorization 之间的关系；
- **生物局部化：**STDP  $\rightarrow$  S-TLLR  $\rightarrow$  TESS，研究预突触-突触后时序信息如何逐步引入 task credit 与空间局部性。

**核心研究问题：**这些在线/局部化操作到底保留了什么 credit information，丢失了什么 credit information，以及这些差异什么时候真正影响学习。

## 文章汇总

**RTRL: A learning algorithm for continually running fully recurrent neural networks** [1];

**E-prop: A solution to the learning dilemma for recurrent networks of spiking neurons** [2];

**OTTT: Online Training Through Time for Spiking Neural Networks** [3];

**NDOT: NDOT: Neuronal Dynamics-based Online Training for Spiking Neural Networks** [4];

**S-TLLR: S-TLLR: STDP-inspired Temporal Local Learning Rule for Spiking Neural Networks** [5];

**TESS: TESS: A Scalable Temporally and Spatially Local Learning Rule for Spiking Neural Networks** [6].

## I. 符号约定与复杂度口径

### A. 复杂度统一口径

后文复杂度只报告训练额外状态与计算，统一符号： $L$  层数； $n$  单层神经元数（第  $l$  层  $n^{(l)}$ ）； $T$  时间步数； $S$  synapse 数量； $C$  类别数或回归输出维度。对 RTRL 一节的  $n$  特指 fully recurrent RNN 的单元数。

**重要免责：**复杂度仅在相同网络假设下直接比较；当论文原报告采用不同架构假设时（例如 RTRL 是 fully recurrent RNN、TESS 是 multilayer SNN），保留原文口径，不进行机械横比。

### B. 同名符号不是同一对象

以下三个  $e$  是不同对象，不要混用：

|                           |                                     |     |
|---------------------------|-------------------------------------|-----|
| $e_{\text{NDOT}}^l[t]$    | 神经元动力学 temporal coefficient (逐元素比值) | (1) |
| $e_{ji, \text{e-prop}}^t$ | 突触级 eligibility trace               |     |
| $e_{ij, \text{STLLR}}[t]$ | STDP-inspired eligibility           |     |

e-prop 原论文将其 eligibility vector 记为  $\epsilon_{ji}^t$ ；为避免与 OTTT/NDOT 的 temporal dependency  $\epsilon^l[t]$  混淆，本文将其重命名为  $\xi_{ji}^t$ ，数学对象不变。

两种  $\Psi$  也要区分：

$$\Psi'_{\text{SG}}(u) \neq \Psi_{\text{STLLR}}(u). \quad (2)$$

BPTT 中的  $\Psi'_{\text{SG}}$  是 spike surrogate derivative；S-TLLR/TESS 中的  $\Psi_{\text{STLLR}}$  是 **secondary activation function**，作用于膜电位以生成 eligibility trace，不是 firing function 的 surrogate，也不必等于  $\Psi'_{\text{SG}}$ 。

### C. 层索引与论文原下标映射

不同原论文对  $W^l$  的定义不同：

- **OTTT 原论文**：  $W^l$  表示  $l \rightarrow l+1$  的权重；
- **NDOT 原论文**：  $W^l$  表示  $l-1 \rightarrow l$  的权重。

本文基础部分统一使用  $W^{l \leftarrow l-1}$  表示从第  $l-1$  层到第  $l$  层的权重。复现 OTTT 时其原论文  $W^l$  对应本文的  $W^{l+1 \leftarrow l}$ ：

|            |          |                           |     |
|------------|----------|---------------------------|-----|
| OTTT $W^l$ | $\equiv$ | 本文 $W^{l+1 \leftarrow l}$ | (3) |
| NDOT $W^l$ | $\equiv$ | 本文 $W^{l \leftarrow l-1}$ |     |

## II. 研究背景与核心问题

### A. SNN 训练的根本困难

SNN 用二进制脉冲  $s_j^t \in \{0, 1\}$  传递信息，但给监督训练带来两个难点：

- 1) **时间信用分配**：输出时刻的损失要归因到过去多个时间步的突触权重上；
- 2) **空间信用分配**：损失要跨层归因到每一层的权重上。

BPTT 是精确求解这两个问题的标准方法，但需要保存所有时间步的 forward states，内存  $O(TLn)$ ，且必须离线反向传播。

关于“精确”的约定：BPTT 与 RTRL 对一个可微 recurrent computational graph 分别给出 reverse-mode 和 forward-mode exact gradient。对于硬脉冲 SNN，本文使用的 reference 是 **BPTT-with-SG / RTRL under the same surrogate rule**，其“精确”仅指相对于选定 surrogate backward rule 的精确计算，不是连续动力学的真实导数。

## B. 已有工作

**时间近似主线：**OTTT 丢弃 BPTT 时间连乘中的 spike-mediated path，将时序依赖退化为固定指数衰减；NDOT 从连续 LIF 微分方程推导动态比率，替代固定  $\lambda$ 。

**精确到局部主线：**RTRL 给出 forward-mode 精确参数敏感度；e-prop 把梯度分解为 learning signal 与 local eligibility。

**生物局部化主线：**STDP 用 pre/post 时序定义突触可塑性；S-TLLR 引入 STDP 形式的因果与非因果资格迹；TESS 通过本地学习信号生成实现时空全局部。

## C. 核心研究问题

这些在线/局部化算法相对于 BPTT 到底改变了哪一项 credit information?  
保留了什么，丢失了什么，差异什么时候真正影响优化？

(4)

## III. 数学基础

### A. LIF 神经元 (*feedforward* 形式)

$$u_j^l[t+1] = \lambda(u_j^l[t] - V_{th} s_j^l[t]) + \sum_i W_{ji}^{l \leftarrow l-1} s_i^{l-1}[t+1] + b_j^l, \quad s_j^l[t] = H(u_j^l[t] - V_{th}). \quad (5)$$

符号：

- $l$  层索引； $j$  当前层神经元索引； $i$  上一层神经元索引（BPTT-OTTT-NDOT 主线中  $i$  只指上一层；recurrent connection 在 RTRL/e-prop 和 S-TLLR recurrent extension 中单独引入）；
- $u_j^l[t]$ ：膜电位（hidden state）；
- $s_j^l[t] \in \{0, 1\}$ ：脉冲；
- $W_{ji}^{l \leftarrow l-1}$ ：从第  $l-1$  层  $i$  到第  $l$  层  $j$  的突触权重；
- $V_{th}$ ：发放阈值；
- $\lambda = e^{-\delta t / \tau_m} \in (0, 1)$ ：膜衰减因子；
- $H(x) = \mathbb{I}[x \geq 0]$ ：Heaviside 阶跃函数。

### B. Surrogate Gradient

$H$  几乎处处导数为零。用 surrogate  $\Psi'_{SG}$  替换：

$$\frac{\partial s_j^l[t]}{\partial u_j^l[t]} \rightarrow \Psi'_{SG}(u_j^l[t] - V_{th}). \quad (6)$$

本文后续 **controlled experiment** 默认采用 fast-sigmoid surrogate：

$$\Psi'_{SG}(x) = \frac{1}{(1 + \beta|x|)^2}, \quad \beta = 4. \quad (7)$$

这是本文的实验选择，不是原论文的统一规定。记  $D_{\Psi, t} = \text{diag}[\Psi'_{SG}(u_j^l[t] - V_{th})]_j$ 。

### C. BPTT: 时间反向传播（原论文形式）

#### Step 1: ordered temporal product.

$$\mathcal{E}_{t,\tau} := \epsilon[t-1] \epsilon[t-2] \cdots \epsilon[\tau], \quad \tau < t, \quad (8)$$

其中  $\epsilon[i]$  是时间步  $i \rightarrow i+1$  的 temporal Jacobian。矩阵乘法不可交换，乘积顺序按时间从  $t-1$  到  $\tau$ 。

#### Step 2: BPTT 主公式。

对权重  $W^{l \leftarrow l-1}$ :

$$\frac{\partial L}{\partial W^{l \leftarrow l-1}} = \sum_{t=1}^T \frac{\partial L}{\partial s^l[t]} \frac{\partial s^l[t]}{\partial u^l[t]} \left( \frac{\partial u^l[t]}{\partial W^{l \leftarrow l-1}} + \sum_{\tau < t} \mathcal{E}_{t,\tau} \frac{\partial u^l[\tau]}{\partial W^{l \leftarrow l-1}} \right). \quad (9)$$

temporal dependency:

$$\epsilon^l[i] = \frac{\partial u^l[i+1]}{\partial u^l[i]} + \frac{\partial u^l[i+1]}{\partial s^l[i]} \frac{\partial s^l[i]}{\partial u^l[i]}. \quad (10)$$

符号:

- $\partial L / \partial s^l[t]$ : 第  $l$  层脉冲  $s^l[t]$  接收到的 same-time/spatial error signal;
- $\partial s^l[t] / \partial u^l[t]$ : surrogate derivative;
- $\partial u^l[t] / \partial W^{l \leftarrow l-1}$ : 当前时刻权重的直接影响;
- $\mathcal{E}_{t,\tau}$ : 从  $\tau$  传播到  $t$  的 temporal credit.

#### Step 3: 代入 LIF.

$$\epsilon^l[i] = \lambda I - \lambda V_{th} D_{\Psi,i}. \quad (11)$$

内存来源: BPTT 需要保存（或反向时重建）各时间步的 forward states——膜电位  $u^l[t]$ 、脉冲  $s^l[t]$ 、以及其它影响 Jacobian 的中间量。这正是 OTTT 原文所述 "maintain the computational graph of previous time" 的问题。典型实现的额外 activation memory 为  $O(TLn)$ 。BPTT 实现通常不显式保存所有  $\mathcal{E}_{t,\tau}$ 。

### D. STDP: 局部突触可塑性基础

经典 STDP。令  $\Delta t = t_{\text{post}} - t_{\text{pre}}$ :

$$\Delta w = \begin{cases} A_+ e^{-\Delta t / \tau_+}, & \Delta t > 0 \text{ (potentiation)}, \\ -A_- e^{\Delta t / \tau_-}, & \Delta t < 0 \text{ (depression)}. \end{cases} \quad (12)$$

Generalized trace-based STDP form (S-TLLR 所采用的形式):

$$\Delta w_{ij}[t] = \alpha_{\text{pre}} y_i[t] \sum_{t'=0}^t \lambda_{\text{pre}}^{t-t'} x_j[t'] + \alpha_{\text{post}} x_j[t] \sum_{t'=0}^{t-1} \lambda_{\text{post}}^{t-t'} y_i[t'], \quad (13)$$

$x_j[t]$  pre 脉冲,  $y_i[t]$  post 脉冲。

STDP 的局限: 只有 pre/post 时序, 没有任务误差信号。

从 STDP 到 three-factor rule:

$$\Delta w_{ij}[t] = \delta_i[t] e_{ij}[t]. \quad (14)$$

#### IV. 前向敏感度与局部资格迹: RTRL 与 E-PROP

##### A. RTRL: forward-mode 参数敏感度

**Step 1: 一般 RNN 状态方程。**

$$h_t = F(h_{t-1}, x_t, W), \quad (15)$$

$h_t \in \mathbb{R}^n$  是 hidden state (LIF 中  $h_t = u_t$ ),  $W$  是所有可学习参数。

**Step 2: 参数敏感度。**

$$P_t := \frac{\partial h_t}{\partial W} \in \mathbb{R}^{n \times r}, \quad r = |W|. \quad (16)$$

**Step 3: 链式法则。**

$$\frac{\partial h_t}{\partial W} = \frac{\partial h_t}{\partial h_{t-1}} \frac{\partial h_{t-1}}{\partial W} + \frac{\partial h_t}{\partial W} \Big|_{h_{t-1} \text{ fixed}}. \quad (17)$$

**Step 4: 两个 Jacobian。**

$$A_t := \frac{\partial h_t}{\partial h_{t-1}}, \quad B_t := \frac{\partial h_t}{\partial W} \Big|_{h_{t-1} \text{ fixed}}. \quad (18)$$

**Step 5: RTRL 核心递推。**

$$\boxed{P_t = A_t P_{t-1} + B_t}. \quad (19)$$

**Step 6: 当前 loss 梯度。**

$$\nabla_W \ell_t = \frac{\partial \ell_t}{\partial h_t} P_t. \quad (20)$$

**逐项解释:**  $P_t$  截至  $t$  时刻所有过去权重作用对当前 state 的累计敏感度;  $A_t P_{t-1}$  过去 influence 被当前 dynamics 继续传播;  $B_t$  当前时刻新的 parameter influence; RTRL 完全 forward-in-time。

**复杂度 (原论文口径):** 对 fully recurrent  $n$ -unit RNN, 若可训练权重数为  $r$ , 则需要保存  $nr$  个 sensitivity elements。经典 RTRL 原文给出 fully interconnected network ( $r = O(n^2)$ ):

$$\boxed{\text{memory} = O(n^3), \quad \text{per-step time} = O(n^4)}. \quad (21)$$

注意这里写 **per-step time**, 不是整段  $T$  sequence 的总时间; 总时间在此基础上再乘  $T$ 。多层结构的具体复杂度取决于 connectivity。

**与 BPTT 的关系:**

$$\boxed{\begin{array}{l} \text{BPTT: reverse-mode temporal gradient propagation} \\ \text{RTRL: forward-mode parameter sensitivity propagation} \end{array}} \quad (22)$$

两者对一个可微 computational graph 都是精确的; 对硬脉冲 SNN, 二者都在同一 surrogate backward rule 下计算。

B. *e-prop*: 从 RTRL 到局部资格迹 + 学习信号

**Step 1: RTRL 的问题。**  $P_t$  的维度是  $n \times r$ , 对 SNN 太大。e-prop 重新组织 chain rule, 使突触级的局部历史依赖进入 eligibility, 而跨神经元/未来的影响进入 learning signal。

**Step 2: 从经典 recurrent gradient factorization 出发。**

$$\frac{dE}{dW_{ji}} = \sum_{t'} \frac{dE}{dh_j^{t'}} \frac{\partial h_j^{t'}}{\partial W_{ji}} \Big|_{h_j^{t'-1} \text{ fixed}}. \quad (23)$$

**Step 3: 递归展开  $dE/dh_j^{t'}$  并交换求和顺序。**

e-prop 原文从如下递归式出发 (对应论文 Eq.(16)):

$$\frac{dE}{dh_j^{t'}} = L_j^{t'} \frac{\partial z_j^{t'}}{\partial h_j^{t'}} + \frac{dE}{dh_j^{t'+1}} \frac{\partial h_j^{t'+1}}{\partial h_j^{t'}}, \quad L_j^{t'} := \frac{dE}{dz_j^{t'}}. \quad (24)$$

将该递归式不断展开至  $T$ , 可得

$$\frac{dE}{dh_j^{t'}} = \sum_{t \geq t'} L_j^t \frac{\partial z_j^t}{\partial h_j^t} \left( \frac{\partial h_j^t}{\partial h_j^{t-1}} \cdots \frac{\partial h_j^{t'+1}}{\partial h_j^{t'}} \right). \quad (25)$$

**边界约定:**  $t = t'$  时, 上面的连乘按空乘积约定取单位矩阵  $I$ 。

代回 Step 2, 再交换  $(t, t')$  求和顺序, 历史部分被收进 eligibility vector:

$$\frac{dE}{dW_{ji}} = \sum_t L_j^t e_{ji}^t, \quad L_j^t := \frac{dE}{dz_j^t}, \quad e_{ji}^t := \left[ \frac{dz_j^t}{dW_{ji}} \right]_{\text{local}}. \quad (26)$$

关于  $e_{ji}^t$  的语义:  $e_{ji}^t = [dz_j^t/dW_{ji}]_{\text{local}}$  是 chain-rule **rearrangement** 之后可以由突触及 postsynaptic neuron 的局部 forward variables 计算的部分。其余 downstream network / future-loss influence 并未被丢弃, 而是全部进入 learning signal  $L_j^t = dE/dz_j^t$ 。因此 e-prop 的 factorization 是精确恒等式, 不是“删掉若干路径后的近似”。

**Step 4: eligibility vector 递推。**

$$e_{ji}^t = \frac{\partial z_j^t}{\partial h_j^t} \xi_{ji}^t, \quad \xi_{ji}^t = A_{j,t}^{\text{loc}} \xi_{ji}^{t-1} + B_{ji,t}^{\text{loc}}, \quad (27)$$

$$A_{j,t}^{\text{loc}} = \frac{\partial h_j^t}{\partial h_j^{t-1}}, \quad B_{ji,t}^{\text{loc}} = \frac{\partial h_j^t}{\partial W_{ji}} \Big|_{h_j^{t-1} \text{ fixed}}. \quad (28)$$

**Step 5: LIF eligibility derivation.**

e-prop 主文对 LIF:  $h_j^t = v_j^t$ , 更新函数  $v_j^t = M(v_j^{t-1}, z^{t-1}, x^t, W_j)$ , 主文推导给出:

$$\frac{\partial v_j^{t+1}}{\partial v_j^t} = \alpha, \quad \frac{\partial v_j^t}{\partial W_{ji}} = z_i^{t-1} \text{ (recurrent synapse)}. \quad (29)$$

reset-aware eligibility 另见 Supplementary Note 1。

本文的简化 LIF eligibility derivation:

$$\xi_{ji}^{t+1} = \lambda \xi_{ji}^t + z_i^t, \quad e_{ji}^{t+1} = \Psi'_{\text{SG}}(u_j^{t+1} - V_{th}) \xi_{ji}^{t+1}. \quad (30)$$

input synapse 的时间索引:

$$B_{ji,t}^{\text{loc,input}} = x_i^t, \quad \xi_{ji}^{t+1} = \lambda \xi_{ji}^t + x_i^{t+1}. \quad (31)$$

**Step 6: ideal  $\rightarrow$  online  $\rightarrow$  actual update.**

**(a) Ideal learning signal.**

$$L_j^t = \frac{dE}{dz_j^t}. \quad (32)$$

$L_j^t$  汇总的是从当前脉冲  $z_j^t$  出发、经其他神经元与后续时间步、最终影响总损失  $E$  的所有 **downstream pathways**。它是一个 future-aware 的量，需要 BPTT 才能精确计算。e-prop 通过交换时间求和，把这一 “downstream credit” 提到 learning signal 中，把 “upstream local history” 收进 eligibility。

**(b) Online learning signal.**

Regression:  $\hat{L}_j^t = \sum_k B_{jk}(y_k^t - y_k^{*,t})$ ; Classification:  $\hat{L}_j^t = \sum_k B_{jk}(\pi_k^t - \pi_k^{*,t})$ ,  $\pi_k^t = \text{softmax}_k(y_1^t, \dots, y_K^t)$ 。

$B_{jk}$  是 feedback 权重: symmetric e-prop  $B_{jk} = W_{kj}^{\text{out}}$ ; random e-prop 固定随机; adaptive e-prop 局部可塑性学习。

**(c) Actual synaptic update.**

滤波后的 eligibility:  $\bar{e}_{ji}^t = \mathcal{F}_\kappa(e_{ji})^t$ 。

Regression (e-prop Eq.(28)):

$$\Delta W_{ji}^{\text{rec}} = -\eta \sum_t \left[ \sum_k B_{jk}(y_k^t - y_k^{*,t}) \right] \bar{e}_{ji}^t. \quad (33)$$

被低通滤波的是 eligibility  $\bar{e}_{ji}^t$ ，不是 error  $y_k^t - y_k^{*,t}$ 。

Classification (e-prop Eq.(29)):

$$\Delta W_{ji}^{\text{rec}} = -\eta \sum_t \left[ \sum_k B_{jk}(\pi_k^t - \pi_k^{*,t}) \right] \bar{e}_{ji}^t. \quad (34)$$

**参数解释:**

- $\alpha$  (本文简化实现记作  $\lambda$ ): postsynaptic state 的衰减因子;
- $\xi_{ji}^t$ : eligibility vector, 保存突触  $i \rightarrow j$  的局部历史;
- $e_{ji}^t$ : observable eligibility trace;
- $\kappa$ : readout dynamics 的低通衰减参数, 决定  $\bar{e}_{ji}^t = \mathcal{F}_\kappa(e_{ji})^t$  的过滤;
- $B_{jk}$ : output error 到 recurrent neuron  $j$  的 feedback weight;
- $W_{kj}^{\text{out}}$ : 神经元  $j$  到 readout  $k$  的 forward weight;
- $\eta$ : 学习率。

**复杂度摘要:** dense recurrent eligibility 按 synapse 保存, 典型额外 memory  $O(Ln^2)$ , per-step computation  $O(Ln^2)$ 。

与 RTRL 的关系:

$$\begin{array}{ll} \text{RTRL: } P_t = A_t P_{t-1} + B_t \text{ (full parameter sensitivity)} \\ \text{e-prop: } \xi_{ji}^t = A_{j,t}^{\text{loc}} \xi_{ji}^{t-1} + B_{ji,t}^{\text{loc}} \text{ (local eligibility)} \end{array} \quad (35)$$

$P_t \in \mathbb{R}^{n \times r}$  保留完整网络 Jacobian,  $\xi_{ji}^t$  是单突触级的局部量。它们不是同维度、同语义的对象, 不直接做数值距离比较。

## V. 时间在线训练: OTTT 与 NDOT

A. 从 BPTT 到 temporal dependency  $\epsilon[i]$

$$\epsilon[i] = \frac{\partial u[i+1]}{\partial u[i]} + \frac{\partial u[i+1]}{\partial s[i]} \frac{\partial s[i]}{\partial u[i]} = \lambda I - \lambda V_{th} D_{\Psi,i}. \quad (36)$$

OTTT 与 NDOT 的区别就在于如何近似  $\epsilon[i]$ 。

B. OTTT:  $\epsilon[i] \approx \lambda I$

**Step 1: 丢弃 spike-mediated path.**

$$\frac{\partial u[i+1]}{\partial s[i]} \frac{\partial s[i]}{\partial u[i]} \approx 0. \quad (37)$$

**Step 2:  $\epsilon[i]$  退化。**

$$\boxed{\epsilon[i] \approx \lambda I}. \quad (38)$$

**Step 3: temporal trace.**

$$\boxed{\hat{a}^l[t] := \sum_{\tau \leq t} \lambda^{t-\tau} s^l[\tau]}, \quad \hat{a}^l[t+1] = \lambda \hat{a}^l[t] + s^l[t+1]. \quad (39)$$

**Step 4: instantaneous loss.**

OTTT 为实现 online gradient, 将传统依赖整个时间窗口的 firing-rate loss 替换为逐时间步损失:

$$\boxed{L[t] = \frac{1}{T} \mathcal{L}(s^N[t], y)}, \quad L = \sum_{t=1}^T L[t]. \quad (40)$$

其中  $s^N[t]$  是输出层脉冲,  $y$  是标签,  $T$  是序列长度。原论文明确指出: OTTT 的 instantaneous gradient 与使用 instantaneous loss 的 BPTT 在多层/循环网络上仍然不同, 因为 OTTT 不保留 future influence。

**Step 5: OTTT 瞬时梯度。**

按 OTTT 原文的层索引  $W^l: l \rightarrow l+1$  (即本文的  $W^{l+1 \leftarrow l}$ ):

$$\boxed{\nabla_{W^l} L[t] = g_{u^{l+1}}[t] \hat{a}^l[t]^\top}, \quad g_{u^{l+1}}[t] = \left( \frac{\partial L[t]}{\partial s^{l+1}[t]} \frac{\partial s^{l+1}[t]}{\partial u^{l+1}[t]} \right)^\top. \quad (41)$$

**Step 6: 两种 update mode.**

$$\begin{array}{ll} \text{OTTT}_O: & \text{每个 } t \text{ 立即用 } \nabla_{W^l} L[t] \text{ 更新} \\ \text{OTTT}_A: & \text{累计 } \sum_t \nabla_{W^l} L[t] \text{ 后统一更新} \end{array} \quad (42)$$

参数解释:

- $\lambda$ : 膜衰减, 同时成为 temporal trace decay;
- $\hat{a}^l[t]$ : 历史 presynaptic spikes 的指数加权迹;
- $g_{u^{l+1}}[t]$ : 当前时刻 spatial gradient;
- $T$ : 序列长度;
- $V_{th}$ : 决定脉冲发放阈值, 并通过 current-step surrogate derivative 影响 spatial gradient; 在 OTTT 的 temporal trace coefficient 中不显式出现。

复杂度摘要: 额外 memory  $O(Ln)$ , per-step computation  $O(Ln^2)$ 。

C. *NDOT*:  $\epsilon[i] \approx e[i]$

**Step 1: OTTT 的问题。** OTTT 假设  $\epsilon[i] = \lambda I$ , 忽略 spike 路径。NDOT 保留  $\epsilon[i]$  的动态性。

**Step 2:** 从连续动力学定义  $e(t)$ 。

$$u(t+1) = \text{Im}(u(t)), \quad \frac{du(t+1)}{dt} = \frac{\partial u(t+1)}{\partial u(t)} \cdot \frac{du(t)}{dt}, \quad (43)$$

$$e(t) \triangleq \frac{\partial u(t+1)}{\partial u(t)} = \frac{u'(t+1)}{u'(t)}. \quad (44)$$

**Step 3:** 代入 LIF 连续方程。LIF  $u'(t) = \frac{-u(t) + I(t)}{\tau}$ , 因此

$$e(t) = \frac{u'(t+1)}{u'(t)} = \frac{u(t+1) - I(t+1)}{u(t) - I(t)}. \quad (45)$$

**Step 4:** 映射到离散 SNN。

$$e^l[t] = \begin{cases} u^l[1] - V_{th}s^l[1], & t = 1, \\ \frac{u^l[t] - V_{th}s^l[t]}{u^l[t-1] - V_{th}s^l[t-1]}, & t > 1. \end{cases} \quad (46)$$

$t = 1$  的特殊初始化来自 NDOT 原文 Eq.(8) 后的 footnote, 避免  $u^l[0] - V_{th}s^l[0]$  的退化处理。 $e^l[t]$  不是由离散 BPTT Jacobian  $\epsilon^l[t]$  严格代数化简得到的量。NDOT 的核心假设是  $e[t]$  与  $\epsilon[t]$  刻画相同 temporal-dependency characteristic。

**层索引关系:** 在 NDOT 针对  $W^l$  ( $l-1 \rightarrow l$ , 本文  $W^{l \leftarrow l-1}$ ) 的具体梯度公式中,  $\epsilon^l[i]$  被 presynaptic layer 的  $e^{l-1}[i]$  替代, 并用逐元素乘法构造  $\hat{a}^{l-1}[t]$ 。

**Step 5: temporal trace。**

$$\hat{a}^{l-1}[t] = e^{l-1}[t-1] \odot \hat{a}^{l-1}[t-1] + s^{l-1}[t], \quad (47)$$

$$\hat{a}^{l-1}[t] = s^{l-1}[t] + \sum_{k < t} \mathcal{E}_{t,k}^{\text{NDOT}} \odot s^{l-1}[k], \quad \mathcal{E}_{t,k}^{\text{NDOT}} := e^{l-1}[t-1] \odot \dots \odot e^{l-1}[k]. \quad (48)$$

**Step 6: instantaneous loss 与 spatial gradient。**

NDOT 使用 instantaneous loss:

$$L[t] = (1 - \alpha)\ell_{\text{CE}}(s^N[t], y) + \alpha \ell_{\text{MSE}}(s^N[t], y) \quad (49)$$

当前时刻 spatial gradient:

$$g_u[t] = \left( \frac{\partial L[t]}{\partial s^l[t]} \frac{\partial s^l[t]}{\partial u^l[t]} \right)^\top. \quad (50)$$

这里  $\partial L[t]/\partial s^l[t]$  已经包含当前时间步从输出层反向传播到第  $l$  层的完整 **same-time spatial BP chain** ( $\prod_{j=l}^{N-1} \partial s^{j+1}[t]/\partial u^j[t] \cdot \partial s^l[t]/\partial u^l[t]$ ), 由 PyTorch autograd 计算; 它不包含跨时间反传。

**Step 7: NDOT 瞬时权重梯度与两种 update mode。**

NDOT 原文 Algorithm 1 / Remark 4.1:

$$\boxed{\nabla_{W^l} L[t] = g_u[t] \hat{a}^{l-1}[t]^\top}. \quad (51)$$

这是当前时间步的 **instantaneous weight gradient**, 不是 full gradient。完整累计更新取决于:

$$\boxed{\begin{array}{l} \text{NDOT}_O: \text{ 每个 } t \text{ 立即更新} \\ \text{NDOT}_A: \text{ 累计 } \sum_t \nabla_{W^l} L[t] \text{ 后统一更新} \end{array}} \quad (52)$$

**核心结构:** NDOT 将当前时间步的权重梯度分解为 same-time spatial gradient 与 forward temporal trace 的外积。

**数值稳定性 (Appendix A.2):** 当  $e^l[t]$  的分母  $u^l[t-1] - V_{th}s^l[t-1]$  等于零时, NDOT 使用退化情况稳定策略: 先根据膜电位符号处理, 再用 **clamping** 把结果限制在  $[-\lambda, \lambda]$ 。只对分母为零的退化情况生效。

**参数解释:**

- $e^l[t]$ : neuron-wise dynamic temporal coefficient;
- $\hat{a}^{l-1}[t]$ : temporal trace;
- $g_u[t]$ : 当前时刻 spatial gradient;
- $\odot$ : 逐元素乘法;
- $I(t)$ : 连续膜电位方程中的输入电流;
- $\tau$ : 膜时间常数;  $V_{th}$ : 发放阈值;
- $\alpha$ : CE 与 MSE 的权重;  $T$ : 序列长度。

**OTTT 与 NDOT 的关系:**

$$\boxed{\begin{array}{l} \text{OTTT: } e^l[t] \approx \lambda I \text{ (matrix coefficient)} \\ \text{NDOT: } e^l[t] \approx \text{diag}(e^l[t]) \text{ (diagonal dynamic coefficient)} \end{array}} \quad (53)$$

注意这两种写法是同层 **representation** 意义上的近似。NDOT 实际构造  $W^l$  的 temporal trace 时, 使用的是 **presynaptic layer** 的  $e^{l-1}[t]$  (见 Step 5), 而不是直接把  $\text{diag}(e^l[t])$  乘到当前层的权重梯度上。

**复杂度摘要:** NDOT 与 OTTT 训练额外 memory 同阶  $O(Ln)$ ; per-step computation  $O(Ln^2)$  (与 OTTT 相同), 另加计算  $e^l[t]$  的逐元素除法开销。

## VI. STDP-INSPIRED 本地学习: S-TLLR

### Step 1: three-factor rule.

$$\Delta w_{ij}[t] = \delta_i[t] e_{ij}[t]. \quad (54)$$

### Step 2: eligibility.

基于 generalized trace-based STDP form, 将 post 脉冲  $y_i[t]$  替换为 secondary activation  $\Psi_{\text{STLLR}}(u_i[t])$  ( $\Psi_{\text{STLLR}} \neq \Psi'_{\text{SG}}$ ):

$$e_{ij}[t] = \alpha_{\text{pre}} \Psi_{\text{STLLR}}(u_i[t]) \sum_{t'=0}^t \lambda_{\text{pre}}^{t-t'} x_j[t'] + \alpha_{\text{post}} x_j[t] \sum_{t'=0}^{t-1} \lambda_{\text{post}}^{t-t'} \Psi_{\text{STLLR}}(u_i[t']). \quad (55)$$

**重要澄清: non-causal  $\neq$  偷看未来。**

S-TLLR 所谓 "non-causal" 是 **STDP timing relation** 意义上的 **non-causal**——当前 pre spike 与过去 post activity 的相关性。它仍然只使用当前和过去的信息, 不需要访问未来时间步, 因此仍是 online / temporally local.

### Step 3: 前向递推形式。

$$\text{tr}(x_j)[t] = \lambda_{\text{pre}} \text{tr}(x_j)[t-1] + x_j[t], \quad \text{tr}(\Psi_{\text{STLLR}}(u_i))[t] = \lambda_{\text{post}} \text{tr}(\Psi_{\text{STLLR}}(u_i))[t-1] + \Psi_{\text{STLLR}}(u_i[t]), \quad (56)$$

$$e_{ij}[t] = \alpha_{\text{pre}} \Psi_{\text{STLLR}}(u_i[t]) \text{tr}(x_j)[t] + \alpha_{\text{post}} x_j[t] (\text{tr}(\Psi_{\text{STLLR}}(u_i))[t] - \Psi_{\text{STLLR}}(u_i[t])). \quad (57)$$

### Step 4: recurrent synapse extension.

$$u_i[t] = \gamma(u_i[t-1] - v_{th} y_i[t-1]) + W^{\text{ff}} x[t] + W^{\text{rec}} y[t-1], \quad (58)$$

$$e_{ik}^{\text{rec}}[t] = \alpha_{\text{pre}} \Psi_{\text{STLLR}}(u_i[t]) \sum_{t'=1}^t \lambda_{\text{pre}}^{t-t'} y_k[t'-1] + \alpha_{\text{post}} y_k[t-1] \sum_{t'=0}^{t-1} \lambda_{\text{post}}^{t-t'} \Psi_{\text{STLLR}}(u_i[t']). \quad (59)$$

### Step 5: learning signal.

$$\delta_i^{(l)}[t] = \begin{cases} \frac{\partial \mathcal{L}(y^L[t], y^*)}{\partial y_i^{(l)}[t]}, & t \geq T_l, \\ 0, & t < T_l. \end{cases} \quad (60)$$

### Step 6: 权重更新。

$$w_{ij} := w_{ij} + \rho \sum_{t=T_l}^T \delta_i[t] e_{ij}[t]. \quad (61)$$

**参数解释:**

- $\Psi_{\text{STLLR}}$ : secondary activation function, 与 firing function 不同, 不必等于  $\Psi'_{\text{SG}}$ ;
- $\alpha_{\text{pre}}, \alpha_{\text{post}}$ : 因果/非因果项强度;
- $\lambda_{\text{pre}}, \lambda_{\text{post}}$ : 因果/非因果迹的衰减因子;
- $T_l$ : learning signal 起始时间步;
- $\rho$ : 学习率。

**recurrent extension 参数:**

- $\gamma$ : 膜衰减因子 (recurrent LIF);
- $v_{th}$ : 发放阈值;
- $W^{ff}$ : feedforward synaptic weights;
- $W^{rec}$ : 同层 recurrent synaptic weights;
- $y_k[t-1]$ : recurrent presynaptic neuron  $k$  的上一时刻 spike。

**复杂度摘要:** 额外 memory  $O(Ln)$  (瞬时 eligibility, 不保存 synapse-wise 状态), per-step computation  $O(Ln^2)$ 。

与 **BPTT** 的区别: S-TLLR 显式引入 STDP-inspired **non-causal timing component**; 该 component 不是由 **BPTT** 的 **causal temporal chain-rule gradient** 推导得到的。

与 **e-prop** 的区别: S-TLLR 的 eligibility 不要求  $\lambda$  与膜衰减一致,  $\lambda_{pre}, \lambda_{post}$  是独立超参。

## VII. 时空全局学习: TESS

**TESS 与 S-TLLR 的关系:**

|                                                                                                                                                                                                                |      |
|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------|
| <p>S-TLLR: local temporal eligibility + instantaneous BP learning signal<br/>(主设置; 亦可用 DFA 实现 spatial locality)</p> <p>TESS: local temporal eligibility + explicitly layer-local generated learning signal</p> | (62) |
|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------|

TESS 的关键推进是每层通过固定 **basis matrix**  $B^{(l)}$  独立生成  $m^{(l)}[t]$ , 无需跨层 **BP**。

**Step 1: 因果迹。**

$$q^{(l)}[t] = \lambda_{pre} q^{(l)}[t-1] + o^{(l-1)}[t], \quad e_{pre}^{(l)}[t] = \alpha_{pre} \Psi_{STLLR}(u^{(l)}[t]) \otimes q^{(l)}[t]. \quad (63)$$

**Step 2: 非因果迹。**

$$h^{(l)}[t] = \lambda_{post} h^{(l)}[t-1] + \Psi_{STLLR}(u^{(l)}[t-1]), \quad e_{post}^{(l)}[t] = \alpha_{post} h^{(l)}[t] \otimes o^{(l-1)}[t]. \quad (64)$$

$\otimes$  是外积。

**Step 3: 本地学习信号 (LSG)。**

$$m^{(l)}[t] = B^{(l)\top} (f(B^{(l)} o^{(l)}[t]) - y^*). \quad (65)$$

把本层输出  $o^{(l)}[t]$  用固定二值矩阵  $B^{(l)}$  投影到任务空间, 应用  $f$ , 与标签  $y^*$  比较, 再投影回来。

**Step 4: 逐时刻权重增量。**

$$\Delta W^{(l)}[t] = (m^{(l)}[t] \odot \alpha_{pre} \Psi_{STLLR}(u^{(l)}[t])) \otimes q^{(l)}[t] + (m^{(l)}[t] \odot \alpha_{post} h^{(l)}[t]) \otimes o^{(l-1)}[t]. \quad (66)$$

**Step 5: 最终权重更新与初始化。**

$$W^{(l)} \leftarrow W^{(l)} + \eta \sum_{t=t_l}^T \Delta W^{(l)}[t], \quad q^{(l)}[0] = 0, \quad h^{(l)}[0] = 0, \quad (67)$$

且  $m^{(l)}[t]$  与  $\Delta W^{(l)}[t]$  只在  $t \geq t_l$  时计算。

**参数解释:**

- $B^{(l)} \in \mathbb{R}^{C \times n^{(l)}}$ : 固定二值投影矩阵;  $C$  类别数,  $n^{(l)}$  第  $l$  层神经元数;

- $o^{(l)}[t] \in \mathbb{R}^{n^{(l)}}$ : 第  $l$  层输出脉冲;
- $q^{(l)}[t] \in \mathbb{R}^{n^{(l-1)}}$ : presynaptic trace (因果迹);
- $h^{(l)}[t] \in \mathbb{R}^{n^{(l)}}$ : postsynaptic activation trace (非因果迹);
- $m^{(l)}[t] \in \mathbb{R}^{n^{(l)}}$ : 本层本地生成的 learning signal;
- $f = \begin{cases} \text{softmax, classification} \\ \text{identity, regression} \end{cases}$ ;
- $\Psi_{\text{STLLR}}$ : secondary activation;
- $\lambda_{\text{pre}}, \lambda_{\text{post}}$ : 因果/非因果迹衰减;
- $\alpha_{\text{pre}}, \alpha_{\text{post}}$ : 因果/非因果强度;
- $t_l$ : 开始生成 learning signal 的时刻;  $\eta$ : 学习率。


**形状检查:**  $\Psi_{\text{STLLR}}(u^{(l)}[t]) \in \mathbb{R}^{n^{(l)}}$ ,  $q^{(l)}[t] \in \mathbb{R}^{n^{(l-1)}}$ ,  $\Psi_{\text{STLLR}}(u^{(l)}[t]) \otimes q^{(l)}[t] \in \mathbb{R}^{n^{(l)} \times n^{(l-1)}}$ , 与  $W^{(l)}$  形状一致。

**复杂度摘要:** 额外 memory  $O(Ln)$ , learning-signal generation computation  $O(LCn)$  ( $C$  为类别数,  $C \ll n$ )。

**与 S-TLLR 的区别:** S-TLLR 的  $\delta_i[t]$  由跨层 BP 生成 (也可用 DFA); TESS 的  $m^{(l)}[t]$  完全在层内生成。

## VIII. 算法关系与核心研究问题

### A. 三条研究路径



**关于 RTRL → e-prop 箭头:** 这表示本文的研究比较路径, 并不意味着 e-prop 是直接由 RTRL 的  $P_t$  做局部截断所得。  $P_t$  与  $\xi_{ji}^t$  是不同维度、不同语义的对象。e-prop 的核心是 chain-rule rearrangement。

### B. 路径一: $BPTT \rightarrow OTTT \rightarrow NDOT$ (时间近似)

核心问题:

$$\epsilon[t] \rightarrow \lambda I \text{ 或 } \text{diag}(e[t]) \quad (69)$$

到底改变了多少 temporal credit?

实验分两类:

- **A. Paper-faithful reproduction:** 各方法按原论文 loss / update mode 跑:

$$L_{\text{OTTT}}[t] = \frac{1}{T} \mathcal{L}(s^N[t], y), \quad L_{\text{NDOT}}[t] = (1 - \alpha) \ell_{\text{CE}} + \alpha \ell_{\text{MSE}}. \quad (70)$$

- **B. Controlled mechanism comparison:** 统一使用本文定义的 controlled instantaneous objective

$$\ell_{\text{ctrl}}[t] = m[t] \ell_{\text{CE}}(r[t], y[t]), \quad (71)$$

其中  $m[t] \in \{0, 1\}$  是 target mask,  $r[t]$  是 readout logits (见下一小节), 并定义

$$L_{\text{ctrl}} = \sum_{t=1}^T \ell_{\text{ctrl}}[t]. \quad (72)$$

BPTT、OTTT、NDOT 三个梯度全部基于同一个  $L_{\text{ctrl}}$ :

$$g_{\text{BPTT}}^{\text{ctrl}} = \nabla_W L_{\text{ctrl}}, \quad g_{\text{OTTT}}^{\text{ctrl}}, g_{\text{NDOT}}^{\text{ctrl}} \text{ 基于同一组 } \ell_{\text{ctrl}}[t]. \quad (73)$$

受控比较的唯一变量 = temporal dependency treatment:

$$\epsilon^l[t] \text{ vs } \lambda I \text{ vs } \text{diag}(e^l[t]). \quad (74)$$

其余全部固定:

$$\text{same network} + \text{same current-step/spatial SG} + \text{same } L_{\text{ctrl}} + \text{same A-mode}. \quad (75)$$

注意: 这里固定的是当前时刻的 **spatial surrogate function**, 而不是 temporal path 上的 SG treatment——后者本身正是实验变量 (OTTT 在 temporal path 上不使用 SG)。

**Gradient fidelity 比较默认使用 A-mode:** OTTT<sub>A</sub> vs NDOT<sub>A</sub>, 使整个 sequence 内参数  $W$  固定。O-mode 主要用于真正 online training 的性能、稳定性与资源开销比较, 不用于 gradient fidelity oracle comparison——因为 O-mode 在时间步之间更新  $W_t \rightarrow W_{t+1}$ ,  $\sum_t g[t]$  与单个 BPTT  $g$  不在同一 evaluation point。

**Representation fidelity (同层比较):** 对同一 neuron layer  $l$ ,

$$D_{\epsilon, \lambda}^l[t] = \frac{\|\epsilon^l[t] - \lambda I\|_F}{\|\epsilon^l[t]\|_F + \varepsilon_{\text{num}}}, \quad D_{\epsilon, e}^l[t] = \frac{\|\epsilon^l[t] - \text{diag}(e^l[t])\|_F}{\|\epsilon^l[t]\|_F + \varepsilon_{\text{num}}}, \quad t \geq 2. \quad (76)$$

$D_{\epsilon, e}^l[t]$  从  $t \geq 2$  起统计:  $t = 1$  是 NDOT 的 initialization case ( $e^l[1] = u^l[1] - V_{th} s^l[1]$ , 不是 ratio coefficient), 单独记录, 不进入平均 representation-fidelity metric。

实际 NDOT 对  $W^l$  的 trace 使用 presynaptic  $e^{l-1}[t]$ , 与此处同层 representation fidelity 是两件事。

**Weight-gradient 层面:**

$$D_{\text{OTTT}} = \frac{\|g_{\text{OTTT}} - g_{\text{BPTT}}\|}{\|g_{\text{BPTT}}\| + \varepsilon_{\text{num}}}, \quad D_{\text{NDOT}} = \frac{\|g_{\text{NDOT}} - g_{\text{BPTT}}\|}{\|g_{\text{BPTT}}\| + \varepsilon_{\text{num}}}, \quad (77)$$

$$\cos(g_{\text{OTTT}}, g_{\text{BPTT}}), \quad \cos(g_{\text{NDOT}}, g_{\text{BPTT}}). \quad (78)$$

### C. 路径二: $RTRL \rightarrow e\text{-prop}$ (精确到局部)

核心问题:

$$\boxed{\text{RTRL 如何在 forward mode 保存完整网络 sensitivity,}} \quad (79)$$

$$\boxed{\text{而 e-prop 如何通过 local eligibility + learning signal 重新组织相同的 gradient credit?}} \quad (80)$$

研究思路: tiny recurrent network 上实现并验证 RTRL 递推; 独立实现 e-prop eligibility; 比较 memory、computation、locality; 研究 ideal  $L_j^t$  替换为 online  $\hat{L}_j^t$  (symmetric/random/adaptive) 后 gradient error 多大。

### D. 路径三: $STDP \rightarrow S\text{-TLLR} \rightarrow TESS$ (生物局部化)

核心关系:  $STDP \rightarrow STDP \text{ eligibility} + \text{error} \rightarrow \text{fully local error}$ 。

单因素 ablation:

**Ablation 1:** 固定 temporal trace, 替换 learning signal。

$$\text{fixed trace} \times \begin{cases} \delta_{BP}[t] \text{ (S-TLLR style)} \\ m_{TESS}^{(l)}[t] \text{ (TESS style)} \end{cases} \quad (81)$$

**Ablation 2:** 固定 learning signal, 替换 trace。

$$\text{fixed signal} \times \begin{cases} \text{causal-only } (\alpha_{\text{post}} = 0) \\ \text{causal+non-causal } (\alpha_{\text{post}} \neq 0) \end{cases} \quad (82)$$

研究问题: causal/non-causal trace 中什么信息真正有效;  $\alpha_{\text{post}} = 0$  与  $\alpha_{\text{post}} \neq 0$  差异多大; S-TLLR 到 TESS 的 performance gap 来自 local learning signal 还是 eligibility; temporal locality 与 spatial locality 哪一个更容易损失性能。

## IX. 下一步实验与实现方案

### A. 实现顺序

- 1) 复现 **BPTT-OTTT-NDOT**。从最小 feedforward SNN 开始。固定 layer index mapping: 复现 OTTT 时把论文  $W^l$  映射到本文  $W^{l+1 \leftarrow l}$ , 复现 NDOT 时映射到  $W^{l \leftarrow l-1}$ 。记录  $\epsilon[t]$ 、 $\hat{a}[t]$  与 weight gradient。
- 2) 复现 **RTRL-e-prop**。tiny recurrent network 上完整保存  $P_t$ , 再独立实现 e-prop eligibility  $\xi_{ji}^t$ 。分别验证 symmetric/random/adaptive  $\hat{L}_j^t$ , 并实现 filtered eligibility  $\bar{e}_{ji}^t$ 。
- 3) 复现 **STDP-S-TLLR**。先单独可视化 pre/post traces, 再加入  $\delta_i[t]$ 。通过  $\alpha_{\text{post}} = 0$  做 causal-only baseline, 然后打开 non-causal term。补 recurrent extension。
- 4) 复现 **TESS**。沿用 S-TLLR 的 causal/non-causal STDP-inspired temporal structure, 实现 TESS 自身的  $q/h$  traces, 并重点研究跨层 BP learning signal 被 layer-local LSG 替代后的影响。
- 5) 统一比较。最终只比较四类结果: gradient similarity、task performance、memory、computation。

## B. 基础验证：按三条论文路径组织

### 路径一：BPTT-OTTT-NDOT。

验证 BPTT 手写梯度与 autograd 一致；验证 OTTT 的 trace 递推与闭式求和一致；验证 NDOT 的 trace 递推与历史展开式一致。

### 路径二：RTRL-e-prop。

验证 RTRL 递推与 autograd full Jacobian 一致；验证 ideal e-prop identity；验证 eligibility vector 局部递推；再单独研究 online learning signal。

### 路径三：STDP-S-TLLR-TESS。

验证 S-TLLR 的显式历史求和与 recursive trace 实现一致；验证 TESS 的  $m^{(l)}[t]$  与最终  $W^{(l)} \leftarrow W^{(l)} + \eta \sum_{t=t_l}^T \Delta W^{(l)}[t]$ 。

## C. Synthetic task 定义与 readout

**Readout 定义**（所有实验统一）：输出层脉冲  $s^N[t] \in \mathbb{R}^{n^N}$  经过固定线性 readout：

$$r[t] = W_{\text{out}} s^N[t] + b_{\text{out}}, \quad (83)$$

其中  $W_{\text{out}} \in \mathbb{R}^{C \times n^N}$ ,  $b_{\text{out}} \in \mathbb{R}^C$ ,  $r[t] \in \mathbb{R}^C$  是 logits,  $C$  是类别数。BPTT、OTTT、NDOT 都对完全相同的 **differentiable readout**  $r[t]$  和相同的 **controlled objective**  $\ell_{\text{ctrl}}[t] = m[t] \ell_{\text{CE}}(r[t], y[t])$  求梯度。这样避免了“ $s^N[t]$  既是二值 spike 又直接当 CE logits”的模糊。

### Delayed Copy（测纯记忆）：

- 输入：  $x[1] \in \{0, 1\}$ ,  $x[2], \dots, x[k] = 0$ （其余时间步输入为 0）；
- 目标：  $y[k+1] = x[1]$ ；
- target mask：  $m[k+1] = 1$ , 其余  $m[t] = 0$ ；
- 损失只在  $t = k+1$  处计算：  $\ell_{\text{ctrl}}[t] = m[t] \ell_{\text{CE}}(r[t], y[t])$ 。

### Delayed XOR（测非线性依赖）：

- 输入：  $x[1] = b_1$ ,  $x[2] = b_2$ ,  $b_1, b_2 \in \{0, 1\}$ ；之后  $x[t] = 0$ ；
- 目标：  $y[k+2] = b_1 \oplus b_2$ ；
- target mask：  $m[k+2] = 1$ , 其余  $m[t] = 0$ 。

关于 **Delayed XOR** 中  $k$  的定义： $k$  是第二个输入  $b_2$ （最后一个 informative input  $x[2]$ ）与 target 之间的 temporal delay。从  $x[1]$  到 target 实际是  $k+1$ 。因此在画  $D_{\text{OTTT}}(k)$ 、 $D_{\text{NDOT}}(k)$  曲线时，横轴  $k$  表示的是  $x[2]$  到 target 的延迟。

统一约定： $s^N[t]$  是输出层脉冲， $r[t]$  是其线性 readout logits；分类任务用 CE loss，回归任务用 MSE loss；两任务均只在 target 时刻计算 loss。

## D. 第一组实验

### 路径一：单层。参数网格：

$$T \in \{4, 8, 16, 32, 64\}, \quad k \in \{1, 2, 4, 8, 16, 32\} \cap [1, T-1]. \quad (84)$$

$k$  是 input-to-target temporal delay（Delayed XOR 中是  $x[2]$  到 target）。

### 建议实验设计:

- 固定  $T = 64$  扫描  $k \in \{1, 2, 4, 8, 16, 32\}$ ;
- 固定  $k = 8$  扫描  $T \in \{16, 32, 64\}$ 。

**Gradient fidelity 测量:** 默认使用 A-mode (frozen- $W$  diagnostic), 或在不更新权重的诊断 forward pass 中收集全部 instantaneous gradients。BPTT oracle 使用同一 controlled loss  $L_{\text{ctrl}} = \sum_t \ell_{\text{ctrl}}[t]$ 。

绘制  $D_{\text{OTTT}}(k)$ 、 $D_{\text{NDOT}}(k)$ 、cos 曲线, 以及同层 representation fidelity  $D_{\epsilon, \lambda}^l[t]$ 、 $D_{\epsilon, e}^l[t]$  ( $t \geq 2$ )。

路径二: tiny recurrent network 上比较 RTRL 与 e-prop 的 memory、computation、locality, 以及 ideal  $L_j^t$  与 online  $\hat{L}_j^t$  (symmetric/random/adaptive) 带来的 gradient error。

路径三: 单因素 ablation——固定 trace, 比较  $\delta_{\text{BP}}[t]$  vs  $m_{\text{TESS}}^{(l)}[t]$ ; 固定 signal, 比较 causal-only vs causal+non-causal trace。

### E. 复杂度摘要

以下复杂度仅在相同网络假设下直接比较; 论文原文采用不同架构假设时, 保留原文口径, 不进行机械横比。

| 算法     | 额外 memory | per-step computation          |
|--------|-----------|-------------------------------|
| BPTT   | $O(TLn)$  | $O(Ln^2)$                     |
| RTRL   | $O(n^3)$  | $O(n^4)$                      |
| e-prop | $O(Ln^2)$ | $O(Ln^2)$                     |
| OTTT   | $O(Ln)$   | $O(Ln^2)$                     |
| NDOT   | $O(Ln)$   | $O(Ln^2)$ + ratio computation |
| S-TLLR | $O(Ln)$   | $O(Ln^2)$                     |
| TESS   | $O(Ln)$   | $O(LCn)$                      |

其中  $L$  层数,  $n$  单层神经元数,  $T$  时间步数,  $C$  类别数或输出维度。

### F. 后续扩展原则

后续研究方向不预先固定。首先完成上述三条研究路径, 依据实验发现的主要 failure mode 决定继续改进 temporal dependency、eligibility trace, 还是 learning signal / spatial locality。

只有在存在稳定、可重复、真正影响优化或资源效率的问题后, 才进一步设计新算法:

Only design a new mechanism if a reproducible, optimization-relevant failure mode is identified.

(85)

### 参考文献

- [1] R. J. Williams and D. Zipser, "A learning algorithm for continually running fully recurrent neural networks," *Neural computation*, vol. 1, no. 2, pp. 270–280, 1989.
- [2] G. Bellec, F. Scherr, A. Subramoney, E. Hajek, D. Salaj, R. Legenstein, and W. Maass, "A solution to the learning dilemma for recurrent networks of spiking neurons," *Nature Communications*, vol. 11, no. 1, p. 3625, Jul. 2020. [Online]. Available: <https://doi.org/10.1038/s41467-020-17236-y>

- [3] M. Xiao, Q. Meng, Z. Zhang, D. He, and Z. Lin, "Online Training Through Time for Spiking Neural Networks," in *Advances in Neural Information Processing Systems*, S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, and A. Oh, Eds., vol. 35. Curran Associates, Inc., 2022, pp. 20 717–20 730. [Online]. Available: [https://proceedings.neurips.cc/paper\\_files/paper/2022/file/82846e19e6d42ebfd4ace4361def29ae-Paper-Conference.pdf](https://proceedings.neurips.cc/paper_files/paper/2022/file/82846e19e6d42ebfd4ace4361def29ae-Paper-Conference.pdf)
- [4] H. Jiang, G. D. Masi, H. Xiong, and B. Gu, "NDOT: Neuronal Dynamics-based Online Training for Spiking Neural..." [Online]. Available: <https://openreview.net/forum?id=elF0QoBSFV>
- [5] M. P. E. Apolinario and K. Roy, "S-TLLR: STDP-inspired Temporal Local Learning Rule for Spiking Neural Networks," Oct. 2024, arXiv:2306.15220 [cs]. [Online]. Available: <http://arxiv.org/abs/2306.15220>
- [6] M. P. E. Apolinario, K. Roy, and C. Frenkel, "TESS: A Scalable Temporally and Spatially Local Learning Rule for Spiking Neural Networks," in *2025 International Joint Conference on Neural Networks (IJCNN)*, Jun. 2025, pp. 1–9, iSSN: 2161-4407. [Online]. Available: <https://ieeexplore.ieee.org/abstract/document/11227652>