

SNN信用分配的解剖学：从状态动力学到任务信号的受控分解

摘要

本方案以“SNN在线/局部学习中，哪些信用分配信息是必要的，哪些信息可以被安全移除或替代？”为核心研究问题。

总问题：

$$\boxed{\text{Which components of credit assignment are necessary for successful local SNN learning?}} \quad (1)$$

核心贡献：

$$\boxed{\text{controlled intervention-based decomposition of credit assignment}} \quad (2)$$

即在相同 forward trajectory、相同神经元动力学和相同 eligibility mechanism 下，主动移除特定 credit information，测量其对 gradient fidelity 和 optimization utility 的影响。

时间索引 **convention**: 全文与代码永久统一为

$$u_t = \lambda(u_{t-1} - V_{th}s_{t-1}) + W_{ff}x_t + W_{rec}s_{t-1} + b, \quad s_t = H(u_t - V_{th}) \quad (3)$$

由此 $B_t^{W_{ff}} \propto x_t$, $B_t^{W_{rec}} \propto s_{t-1}$, $B_t^b = I$ 。

Hidden-state convention: 本文 LIF-RSNN 中统一定义

$$\boxed{\mathbf{h}_t \equiv \mathbf{u}_t} \quad (4)$$

即膜电位 $\mathbf{u}_t$ 是 recurrent hidden state，而

$$\mathbf{s}_t = H(\mathbf{u}_t - V_{th}) \quad (5)$$

被视为由 hidden state 决定的 deterministic output。因此

$$A_t = \frac{\partial \mathbf{u}_t}{\partial \mathbf{u}_{t-1}}, \quad (6)$$

且本文所有 A_t 、 P_t 和 adjoint 公式均采用该 state convention。

符号统一: 全文 $z_j^{l,t}$ 始终表示 neuron spike/output; r_l^t 始终表示 local readout logits; per-step learning signal / adjoint / eligibility states 写作 λ_t 、 L_t 、 $\xi_{ji}^{l,t}$ 、 $e_{ji}^{l,t}$ 。

Recurrent connectivity convention: Paper 1 中固定 $\text{diag}(W_{rec}) = 0$ ，即不允许 autaptic/self-recurrent connections。因此在 detached-reset LIF 下，postsynaptic neuron 的 local state Jacobian 为 $A_{j,t}^{loc} = \lambda$ 。

核心数学框架采用两种互补且平行的信用分配视角。

(1) **Full forward-sensitivity / RTRL view**:

$$P_t^{\text{full}} = A_t^{\text{full}} P_{t-1}^{\text{full}} + B_t^{\text{full}} \quad (7)$$

(2) **Local eligibility / e-prop view**:

$$\xi_{ji}^t = A_{j,t}^{loc} \xi_{ji}^{t-1} + B_{ji,t}^{loc}, \quad e_{ji}^t = C_{j,t} \xi_{ji}^t \quad (8)$$

两种视角描述同一个 credit-assignment problem 的不同组织方式，不是上下游关系。 P_t^{full} 与 ξ_{ji}^t 是不同数学对象。

Paper 1 永久固定: DR reset、no-autapse、fast sigmoid。

四层比较结构: Level 1 是 state-transition comparison (A_t), Level 2 是 parameter-sensitivity comparison (P_t), Level 3 是 synaptic-eligibility comparison (e_t), Level 4 是 update-space comparison (G)。Paper 1 只操纵 learning-signal / objective 层; Level 1-3 在 Paper 1 只作为 diagnostic reference, 不作为 factorial 操纵变量。

递归SNN下的 A_t 公式: 对于含显式 W_{rec} 的 RSNN, $A_t = \lambda I - \lambda V_{th} D_{\Psi, t-1} + W_{\text{rec}} D_{\Psi, t-1}$, 可分解为 intrinsic dynamics $D_t = \lambda I - \lambda V_{th} D_{\Psi, t-1}$ 和 recurrent interaction $R_t = W_{\text{rec}} D_{\Psi, t-1}$ 。

两种 operational oracle: A_t^{DR} (detached-reset) 用于 Paper 1 的 controlled factorial; A_t^{RA} (reset-aware) 用于 Paper 2 的 temporal-mechanism reference。两个 oracle 必须明确标记, 不能混用。

Local objective parameter block: $\Theta_l = \{W_{\text{ff}}^{(l)}, W_{\text{rec}}^{(l)}, b^{(l)}\}$ 。每个 $E_L^{(l)}$ 只对 Θ_l 提供 credit。Hidden layers 使用 local objective, output layer 始终使用 E_G 。所有 estimator 具有相同维度、相同参数顺序。

四个受控估计器条件为: FG 、 BG 、 FL 、 BL 。所有四个 estimator 使用完全相同的 e_{ji}^t , 只改变 learning signal。

研究假设三阶段: H1 (Fidelity)、H2 (Utility)、H3 (Beneficial deviation)。研究设置 negative-result stopping rule。Paper 1 只保留 Mostafa-style random local objective, claim 明确限定为 fixed LIF dynamics。

与 e-prop / OTTT / NDOT 的时间索引与 reset convention 对照: e-prop 原始 LIF 动力学为 $v_j^{t+1} = \alpha v_j^t + \sum W_{\text{rec}} z_i^t + \sum W_{\text{in}} x_i^{t+1} - z_j^t v_{th}$, 其 reset 项不乘 α ; OTTT/NDOT 常见离散 LIF 为 $u_i[t+1] = \lambda(u_i[t] - V_{th} s_i[t]) + \sum_j W_{ij} s_j[t+1]$, 输入与 $u_i[t+1]$ 同步。本文统一采用 $u_t = \lambda(u_{t-1} - V_{th} s_{t-1}) + W_{\text{ff}} x_t + W_{\text{rec}} s_{t-1} + b$, 不复现原始离散更新, 而是将各算法核心近似映射到该约定下比较。所有 Gate 只验证本文约定下的 BPTT-SG oracle。本文的 factorization 是 exact local-eligibility factorization under the chosen operational dynamics, surrogate, and reset convention。

文章汇总

RTRL: A learning algorithm for continually running fully recurrent neural networks [1];

E-prop: A solution to the learning dilemma for recurrent networks of spiking neurons [2];

OTTT: Online Training Through Time for Spiking Neural Networks [3];

NDOT: NDOT: Neuronal Dynamics-based Online Training for Spiking Neural Networks [4];

S-TLLR: S-TLLR: STDP-inspired Temporal Local Learning Rule for Spiking Neural Networks [5];

TESS: TESS: A Scalable Temporally and Spatially Local Learning Rule for Spiking Neural Networks [6];

OSTL: Online Spatio-Temporal Learning in Deep Neural Networks [?];

ETLP: ETLP: Event-based Three-factor Local Plasticity for online learning with neuromorphic hardware [?];

OSTTP: Online Spatio-Temporal Learning with Projected Trajectory [?];

TP: Traces Propagation: Memory-Efficient and Scalable Forward-Only Learning in Spiking Neural Networks [?];

BrainTrace: Model-agnostic linear-memory online learning in spiking neural networks [?];

NeuroTrain: NeuroTrain: Surveying Local Learning Rules for Spiking Neural Networks with an Open Benchmarking Framework [?]

I. 研究背景与核心问题

A. 两条独立的研究主线与已有的时空联合工作

时间局部化主线：OTTT [3] 丢弃 BPTT 时间连乘中的重置路径，将时序依赖退化为固定指数衰减。NDOT [4] 从连续 LIF 微分方程推导动态核，替代固定 λ 。E-prop [2] 将梯度严格分解为学习信号与资格迹的乘积。S-TLLR [5] 引入 STDP 形式的因果与非因果资格迹。

空间局部化主线：DFA、本地误差学习、ETLP [?]。Mostafa 的原始工作明确指出，每层解决的是自己的局部优化问题。

时空联合工作：OSTL [?] 分离空间与时间梯度分量；OSTTP [?] 结合资格迹与目标投影；TESS [6] 通过本地学习信号生成实现空间局部化；TP [?] 提出无需辅助 layer-wise matrices 的 forward-only local learning。

OSTL 的特殊地位：OSTL 本身就强调 spatial gradient component 与 temporal gradient component 的分离，并明确声称对 shallow SNN 可以做到与 BPTT gradient-equivalent。因此本方案不能把“gradient 可以拆开”作为 novelty。本方案的 novelty 是：

$$\boxed{\text{把某一类 credit information 主动拿掉，然后测量究竟发生什么。}} \quad (9)$$

即：controlled intervention-based decomposition: intervene on specific credit-information components under matched trajectories, and quantify their controlled effects on gradient geometry and optimization utility。这是与 OSTL 的本质区别。

最新的 model-agnostic 在线学习框架：BrainTrace [?] 从 RTRL eligibility recursion 出发，将 hidden-state Jacobian 分解为 intrinsic neuronal dynamics D^t 和 neuronal interactions J^t ，先做 diagonal approximation 得到 D-RTRL，再将 eligibility 做 rank-one pre/post factorization 得到 pp-prop。BrainTrace 2026 已经明确支持 diverse neuronal dynamics、synaptic dynamics、linear-memory online learning。因此本方案的 Paper 1 claim 明确限定为 fixed LIF dynamics。

统一 benchmark 工作：NeuroTrain [?] 已提出统一 SNN 训练算法 taxonomy 和可扩展 benchmark framework。

B. 研究空白的精确表述

不能声称的研究空白一：“时空局部化尚未被研究”。

不能声称的研究空白二：“首次建立统一 SNN local learning benchmark”。

不能声称的研究空白三：“gradient 可以拆开”。

真正的研究空白：现有工作主要关注提出训练规则及其任务性能，而对于状态动力学传播、参数敏感度累积与任务学习信号分别被近似时所引入的信用分配失真能否被独立分解，尚缺乏系统的 controlled factorial analysis。具体而言，缺乏对不同 credit-information removal 操作进行 matched-trajectory、factorial、fidelity-utility 分析。

研究空白的分阶段表述：首先对 future-information restriction 与 objective substitution 做 controlled factorial decomposition；随后单独分析 temporal representation approximation，并在已识别的 failure regimes 中检验 temporal representation 是否调节前述 interaction：

$$D_{FL} = f(T, \lambda, L, k, A_{\text{approx}}) \quad (10)$$

C. 统一信用分配框架: *Forward Sensitivity* 与 *Local Eligibility* 两种平行视角

a) 1. *Full forward-sensitivity / RTRL view*: 定义完整网络状态为 $\mathbf{h}_t \equiv \mathbf{u}_t$, 则

$$A_t^{\text{full}} = \frac{\partial \mathbf{h}_t}{\partial \mathbf{h}_{t-1}} = \frac{\partial \mathbf{u}_t}{\partial \mathbf{u}_{t-1}} \quad (11)$$

表示完整的 state-transition Jacobian。

$$B_t^{\text{full}} = \left. \frac{\partial \mathbf{h}_t}{\partial W} \right|_{\mathbf{h}_{t-1} \text{ fixed}} \quad (12)$$

完整参数敏感度定义为:

$$P_t^{\text{full}} = \frac{d\mathbf{h}_t}{dW} \quad (13)$$

并满足 forward recursion:

$$\boxed{P_t^{\text{full}} = A_t^{\text{full}} P_{t-1}^{\text{full}} + B_t^{\text{full}}} \quad (14)$$

b) 2. *Local eligibility / e-prop view*: 对于连接 $i \rightarrow j$, 定义 postsynaptic neuron j 的局部 hidden-state sensitivity:

$$\xi_{ji}^t = A_{j,t}^{\text{loc}} \xi_{ji}^{t-1} + B_{ji,t}^{\text{loc}} \quad (15)$$

其中

$$A_{j,t}^{\text{loc}} = \frac{\partial h_j^t}{\partial h_j^{t-1}}, \quad B_{ji,t}^{\text{loc}} = \frac{\partial h_j^t}{\partial W_{ji}} \quad (16)$$

随后定义 synaptic eligibility:

$$\boxed{e_{ji}^t = C_{j,t} \xi_{ji}^t, \quad C_{j,t} = \frac{\partial z_j^t}{\partial h_j^t}} \quad (17)$$

e-prop 的 exact local-eligibility factorization under the chosen operational dynamics, surrogate, and reset convention 写为:

$$\boxed{\frac{dE}{dW_{ji}} = \sum_t L_j^t e_{ji}^t, \quad L_j^t = \frac{dE}{dz_j^t}} \quad (18)$$

因此, P_t^{full} 与 ξ_{ji}^t 是不同数学对象。

c) 3. 两种视角的平行结构:

$$\boxed{\begin{array}{l} (A_t^{\text{full}}, B_t^{\text{full}}) \longrightarrow P_t^{\text{full}} \\ \text{RTRL view} \\ \\ (A_{j,t}^{\text{loc}}, B_{ji,t}^{\text{loc}}) \longrightarrow \xi_{ji}^t \longrightarrow e_{ji}^t \\ \text{e-prop view} \end{array}} \quad (19)$$

e-prop branch 上进一步有 $\nabla_W E = \sum_{j,t} L_j^t e_{ji}^t$ 。

d) 4. B_t 与 P_t 的严格区分:

$$\boxed{B_t = \left. \frac{\partial h_t}{\partial W} \right|_{h_{t-1} \text{ fixed}}, \quad P_t = \frac{dh_t}{dW}, \quad P_t = A_t P_{t-1} + B_t} \quad (20)$$

B_t 是当前时刻直接影响 (偏导, h_{t-1} 固定); P_t 是截至当前时刻累计影响 (全导)。

e) 5. *Paper 1* 的受控估计器定义: Paper 1 完全只使用 e-prop local eligibility。所有四个 estimator 使用完全相同的 $e_{ji}^{l,t}$ 。

FG/BG 使用普通 (非 piecewise) 公式, 全层使用 global learning signal:

$$g_{FG}^{(l)} = \sum_{j,t} L_{G,j}^{F,l,t} e_{ji}^{l,t} \quad (21)$$

$$g_{BG}^{(l)} = \sum_{j,t} L_{G,j}^{B,l,t} e_{ji}^{l,t} \quad (22)$$

FL/BL 使用 piecewise 定义: hidden layers $l < L$ 使用 local learning signal, output layer $l = L$ 使用 global learning signal:

$$g_{FL}^{(l)} = \begin{cases} \sum_{j,t} L_{L,j}^{F,l,t} e_{ji}^{l,t}, & l < L, \\ \sum_{j,t} L_{G,j}^{F,L,t} e_{ji}^{L,t}, & l = L. \end{cases} \quad (23)$$

$$g_{BL}^{(l)} = \begin{cases} \sum_{j,t} L_{L,j}^{B,l,t} e_{ji}^{l,t}, & l < L, \\ \sum_{j,t} L_{G,j}^{B,L,t} e_{ji}^{L,t}, & l = L. \end{cases} \quad (24)$$

最终:

$$g_X = \text{concat}_{l=1}^L g_X^{(l)}, \quad X \in \{FG, BG, FL, BL\}. \quad (25)$$

learning signal 定义:

$$L_{G,j}^{F,l,t} = \frac{dE_G}{dz_j^{l,t}}, \quad L_{G,j}^{B,l,t} = \frac{\partial \ell_t}{\partial z_j^{l,t}}, \quad (26)$$

$$L_{L,j}^{F,l,t} = \frac{dE_L^{(l)}}{dz_j^{l,t}}, \quad L_{L,j}^{B,l,t} = \frac{\partial \ell_L^{(l)}[t]}{\partial z_j^{l,t}}. \quad (27)$$

全文统一: $z_j^{l,t}$ 始终表示 neuron spike/output; r_l^t 始终表示 local readout logits。

D. recurrent SNN 下的 A_t 公式

对于包含显式 W_{rec} 的 RSNN:

$$u_t = \lambda(u_{t-1} - V_{th}s_{t-1}) + W_{\text{ff}}x_t + W_{\text{rec}}s_{t-1} + b \quad (28)$$

由于 $s_{t-1} = H(u_{t-1} - V_{th})$, 所以:

$$\frac{\partial s_{t-1}}{\partial u_{t-1}} = D_{\Psi,t-1} \quad (29)$$

其中:

$$D_{\Psi,t-1} = \text{diag} [\Psi'(u_{1,t-1} - V_{th}), \dots, \Psi'(u_{n,t-1} - V_{th})] \quad (30)$$

因此正确的 total state Jacobian 是:

$$A_t = \lambda I - \lambda V_{th} D_{\Psi,t-1} + W_{\text{rec}} D_{\Psi,t-1} \quad (31)$$

Level A1 (无显式 W_{rec}): $A_t^{\text{A1}} = \lambda I - \lambda V_{th} D_{\Psi,t-1}$

Level A2 (引入 W_{rec}): $A_t = D_t + R_t$, 其中

$$D_t = \lambda I - \lambda V_{th} D_{\Psi,t-1}, \quad R_t = W_{\text{rec}} D_{\Psi,t-1} \quad (32)$$

重要提示: $A_t \equiv \frac{\partial h_t}{\partial h_{t-1}}$, 因此 A_t 内部所有来自 spike Jacobian 的项都必须使用 $D_{\Psi,t-1}$, 而不是 $D_{\Psi,t}$ 。这是时间索引统一后的直接结果。

E. 两种 *operational oracle*: DR 与 RA

Detached-reset oracle:

$$A_t^{\text{DR}} = \lambda I + W_{\text{rec}} D_{\Psi,t-1} \quad (33)$$

Reset path 被 stop-gradient。用于 **Paper 1** 的 **FG/BG/FL/BL controlled factorial**。

Reset-aware oracle:

$$A_t^{\text{RA}} = \lambda I - \lambda V_{th} D_{\Psi,t-1} + W_{\text{rec}} D_{\Psi,t-1} \quad (34)$$

Reset path 传播 surrogate gradient。用于 **Paper 2** 的 **temporal-mechanism reference**。

Paper 1 与 Paper 2 可以使用不同的 *operational oracle*, 但必须明确标记。

F. *Recurrent connectivity convention*

Paper 1 中固定:

$$\text{diag}(W_{\text{rec}}) = 0 \quad (35)$$

即不允许 autaptic/self-recurrent connections。这是为了保证在 detached-reset LIF 下, postsynaptic neuron 的 local state Jacobian 严格为:

$$A_{j,t}^{\text{loc}} = \lambda \quad (36)$$

如果存在 $W_{jj}^{\text{rec}} \neq 0$, 则 $A_{j,t}^{\text{loc}} = \lambda + W_{jj}^{\text{rec}} \Psi'(u_{j,t-1} - V_{th})$, 不再是简单的 λ 。禁止 self-recurrent connections 让 e-prop eligibility recursion 与 e-prop 简化 LIF eligibility 更容易对应。

G. *Paper 1* 采用 *detached-reset convention*

$$\text{Reset path is detached consistently in both BPTT-SG and e-prop eligibility.} \quad (37)$$

具体地: BPTT 的 A_t 使用 A_t^{DR} ; e-prop 的 $A_{j,t}^{\text{loc}} = \lambda$; 但 W_{rec} 的 recurrent interaction 保留。

Reset-aware surrogate propagation 作为 robustness experiment。

H. Local objective parameter block 与 detach boundary

$$r_l^t = M_l o_l^t, \quad p_l^t = \text{softmax}(r_l^t), \quad E_L^{(l)} = -\frac{1}{T} \sum_t \sum_c y_c \log p_{l,c}^t \quad (38)$$

参数块定义:

$$\Theta_l = \{W_{\text{ff}}^{(l)}, W_{\text{rec}}^{(l)}, b^{(l)}\} \quad (39)$$

Detach boundary:

$$\nabla_{\Theta_k} E_L^{(l)} = 0, \quad k \neq l \quad (40)$$

Output layer convention: hidden layers 使用各自的 local objective, final/output layer 始终使用 E_G 。因此:

$$g_{FL} = \text{concat} \left[\nabla_{\Theta_1}^{E_L^{(1)}}, \dots, \nabla_{\Theta_{L-1}}^{E_L^{(L-1)}}, \nabla_{\Theta_L}^{E_G} \right] \quad (41)$$

BL 同理, 只把 hidden local/global learning signal 改成 current-only。

I. Random local classifier 的尺度固定

$$M_{l,ij} \sim \mathcal{N} \left(0, \frac{1}{d_l} \right), \quad E_L^{(l)} = \frac{1}{T} \sum_{t=1}^T \ell_l[t] \quad (42)$$

所有 local 与 global loss 使用相同 reduction。

J. Bias parameter injection

Bias 参数对应当前时刻直接注入:

$$B_t^b = I, \quad \frac{\partial u_{j,t}}{\partial b_j} = 1 \quad (43)$$

这样三个 parameter block $W_{\text{ff}}, W_{\text{rec}}, b$ 在代码层面完整。

K. 符号统一

对象	统一符号	说明
State Jacobian	A_t	$\partial h_t / \partial h_{t-1}$
Parameter injection	B_t	parameter injection Jacobian (偏导)
Parameter sensitivity	P_t	full parameter sensitivity (全导)
Local sensitivity	ξ_{ji}^t	e-prop local eligibility state
Synaptic eligibility	e_{ji}^t	local eligibility factor
Learning signal	L_t	task credit
Weight update	G	$\sum_t L_t e_t$
Parameter block	Θ_l	$\{W_{\text{ff}}^{(l)}, W_{\text{rec}}^{(l)}, b^{(l)}\}$
Neuron spike/output	$z_j^{l,t}$	始终表示 neuron spike/output
Local readout logits	r_l^t	始终表示 local classifier logits
Adjoint	λ_t	BPTT reverse-mode adjoint

L. 四层比较结构

Level 1: state-transition comparison(A_t);
Level 2: parameter-sensitivity comparison(P_t);
Level 3: synaptic-eligibility comparison(e_t);
Level 4: update-space comparison(G).

(44)

Paper 1 只操纵 learning-signal / objective 层, 即 Level 4 的 G 。Level 1–3 在 Paper 1 只作为 diagnostic reference, 不作为 factorial 操纵变量。

M. 四个受控估计器条件

	Global objective	Local objective
Future-aware	FG	FL
Online / future-blind	BG	BL

(45)

具体定义:

- FG : $g_{FG} = \sum_t L_t^F e^t$ 。该分解应与 BPTT-with-SG 的梯度一致, 因此作为本研究的 oracle/reference。
- BG : $g_{BG} = \sum_t L_t^B e^t$, 其中 $L_t^B = \partial \ell_t / \partial z_t$ (temporal future-blind, spatial 上仍可 BP)。
- FL : hidden layers 使用 $g_{FL}^{(l)} = \sum_{j,t} L_{L,j}^{F,l,t} e_{ji}^{l,t}$ ($l < L$), output layer 使用 global future-aware learning signal。
- BL : hidden layers 使用

$$g_{BL}^{(l)} = \sum_{j,t} \frac{\partial \ell_L^{(l)}[t]}{\partial z_j^{l,t}} e_{ji}^{l,t}, \quad l < L, \quad (46)$$

output layer 使用 global current-only learning signal。因此 BL 同时施加 future-information restriction 与 hidden-layer objective substitution。核心关系:

$$L_{L,j}^{B,l,t} = \frac{\partial \ell_L^{(l)}[t]}{\partial z_j^{l,t}} \quad (47)$$

而非 $\frac{\partial E_L^{(l)}}{\partial z_j^{l,t}}$ 。

N. Future-blind learning signal 的操作定义

$$E_G = \sum_{t=1}^T \ell_t, \quad \left[L_t^F = \frac{dE_G}{dz_t}, \quad L_t^B = \frac{\partial \ell_t}{\partial z_t} \right] \quad (48)$$

O. Estimator-level factorial contrasts 与 discrepancy metrics

$$\Delta_F = g_{BG} - g_{FG}, \quad \Delta_L = g_{FL} - g_{FG}, \quad \Delta_{FL} = g_{BL} - g_{BG} - g_{FL} + g_{FG} \quad (49)$$

$$D_F = \frac{\|\Delta_F\|}{\|g_{FG}\| + \epsilon}, \quad D_L = \frac{\|\Delta_L\|}{\|g_{FG}\| + \epsilon}, \quad D_{FL} = \frac{\|\Delta_{FL}\|}{\|g_{FG}\| + \epsilon} \quad (50)$$

$D_F, D_L, D_{FL} \geq 0$ 恒成立。研究 interaction 是 synergistic 还是 antagonistic, 必须用有符号的 optimization interaction。

P. Surrogate gradient 作为固定控制变量

$$g_{\text{oracle}} = \nabla_W^{\text{BPTT-with-SG}} E \quad \text{under fixed surrogate } \Psi, \quad FG \equiv g_{\text{oracle}} \quad (51)$$

Q. Paper 1 的核心数学 Gate

$$\nabla_W^{\text{BPTT-SG}} E \approx \sum_{j,t} \frac{dE}{dz_j^t} e_{ji}^t \quad (52)$$

该验证必须在 same weights + same inputs + same spike trajectory + same fixed surrogate derivative + same detached-reset convention 条件下完成。

重要: $FG \neq BPTT$ 不是一个可以接受的算法现象。如果出现, 意味着至少有一个东西错了: eligibility derivation、reset convention、time indexing、recurrent weight indexing、surrogate、learning signal、autograd hook、parameter flattening。真正具有“e-prop approximation error”的是 BG , 而不是 FG 。

R. BPTT oracle 的 reverse-mode 表达

$$\lambda_t = \frac{dE}{dh_t}, \quad \lambda_t = \frac{\partial \ell_t}{\partial h_t} + A_{t+1}^\top \lambda_{t+1}, \quad \nabla_W E = \sum_t B_t^\top \lambda_t \quad (53)$$

注意: 这里的 $A_{t+1} = \partial h_{t+1} / \partial h_t$, 因此 A_{t+1} 内部使用 $D_{\Psi,t}$ 。不要把 adjoint 的 A_{t+1} 改成 A_t 。

S. 研究逻辑链条

RQ1: 未来信息移除造成多少 credit-assignment discrepancy? RQ2: 目标替换造成多少 credit-assignment discrepancy? RQ3: joint localization 是否引入 practically meaningful non-additive interaction? → Step 1: 单层 future-information restriction → Step 2: 两层 objective substitution → Step 3: 两层/三层 full factorial → Temporal representation analysis (moderator) → 条件性最小机制设计 → 论文: 诊断型或诊断+解决方案型	(54)
---	------

T. 最终研究问题

RQ1: Future information

Removing future-dependent task credit causes how much gradient discrepancy?	(55)
---	------

即 $FG \leftrightarrow BG$ 。

RQ2: Objective substitution

Replacing the global task objective with local hidden-layer objectives causes how much discrepancy?	(56)
---	------

即 $FG \leftrightarrow FL$ 。

RQ3: Non-additive interaction

Does joint localization introduce a practically meaningful non-additive interaction?	(57)
--	------

即 future-information restriction 与 objective substitution 的联合影响是否超出二者独立主效应的加和:

$$\Delta_{FL} = g_{BL} - g_{BG} - g_{FL} + g_{FG}, \quad D_{FL} = \frac{\|\Delta_{FL}\|}{\|g_{FG}\| + \epsilon} \quad (58)$$

II. 第一阶段: 基线平台建立

A. 阶段目标

第一轮实验严格限定为:

BPTT-with-SG (oracle), E-prop, Local Error (Mostafa-style)	(59)
--	------

关键实验原则:

- 固定神经元动力学 (仅使用 LIF), 只改变信用分配规则。
- 固定 surrogate gradient Ψ (W1/W2 只实现 fast sigmoid)。

- 固定 detached-reset convention。
- 固定 $\text{diag}(W_{\text{rec}}) = 0$ 。
- 固定 random local classifier 尺度 $M_{l,ij} \sim \mathcal{N}(0, 1/d_l)$ 。
- 固定 local/global loss reduction。
- 所有 fixed-state estimator comparison 必须在 same weights + same input + same spike trajectory 下进行。
- Multi-step optimization 允许 method-specific trajectories: $W_{t+1}^{FG} \neq W_{t+1}^{BG}$ 之后 trajectory 可以分叉。
- 时间索引永久统一为 $u_t = \lambda(u_{t-1} - V_{th}s_{t-1}) + W_{\text{ff}}x_t + W_{\text{rec}}s_{t-1} + b$ 。
- Paper 1 永久固定 DR、no-autapse、fast sigmoid。

B. 任务清单

任务1: 实现 LIF 神经元与单层/两层/三层循环 SNN

- 神经元动力学模块: LIF 离散更新 $u_t = \lambda(u_{t-1} - V_{th}s_{t-1}) + W_{\text{ff}}x_t + W_{\text{rec}}s_{t-1} + b$, $s_t = H(u_t - V_{th})$ 。模块需要返回 u_t 、 s_t 和 reset 状态, 支持批量处理。
- 单层循环 SNN 模块: $d_{\text{in}} = 10$, $d_{\text{out}} = 10$, $T = 10$, $\lambda = 0.9$, $V_{th} = 1.0$, 包含显式循环连接 W_{rec} , 且 $\text{diag}(W_{\text{rec}}) = 0$ 。
- 两层循环 SNN 模块: $d_{\text{in}} = 784$, $d_{\text{hidden}} = 128$, $d_{\text{out}} = 10$ 。
- 三层循环 SNN 模块: 用于 Step 3 的深度验证。
- 状态记录模块: 统一保存每个时间步的 u_t 、 s_t , 以及 per-step learning signal / adjoint / eligibility states (具体为 λ_t 、 L_t 、 $\xi_{ji}^{l,t}$ 、 $e_{ji}^{l,t}$), 避免 g_t 一词多义。

任务2: 实现 BPTT-with-SG oracle 与梯度分解

- BPTT 梯度模块: 采用 adjoint notation。实现 reverse recursion $\lambda_t = \frac{\partial \ell_t}{\partial h_t} + A_{t+1}^\top \lambda_{t+1}$, 以及 $\nabla_W E = \sum_t B_t^\top \lambda_t$ 。使用 detached-reset convention。
- State Jacobian 模块:
 - Level A1 (无 W_{rec}): $A_t^{\text{A1, DR}} = \lambda I$
 - Level A2 (含 W_{rec}): $A_t^{\text{A2, DR}} = \lambda I + W_{\text{rec}} D_{\Psi, t-1}$
 - 两种 oracle 均在代码中用 superscript 明确标记: A_t^{DR} 和 A_t^{RA} 。
- Parameter injection 模块: $B_t = \frac{\partial h_t}{\partial W} \Big|_{h_{t-1} \text{ fixed}}$ 。对于 W_{ff} , B_t 的对应分量是 x_t ; 对于 W_{rec} , 对应分量是 s_{t-1} ; 对于 bias b , $B_t^b = I$ 。
- Parameter sensitivity 模块: $P_t = A_t P_{t-1} + B_t$, 初始条件 $P_0 = 0$ 。Paper 1 只做 tiny-network sanity test。
- Surrogate gradient 接口: 接口预留 fast sigmoid (默认)、arctan、piecewise linear; W1/W2 只实现 fast sigmoid。其余两个作为主 Gate 通过后的 robustness。

Gate 0 (三个子 Gate):

首先验证 A_t 本身:

$$\boxed{A_t^{\text{manual, SG}} \approx A_t^{\text{AD, SG}}} \quad (60)$$

这里所有 Jacobian equality 均指固定 surrogate backward 所定义的 computational pseudo-Jacobian，它不被解释为 hard Heaviside forward dynamics 的 classical derivative。

然后验证 B_t 本身：

$$\boxed{B_t^{\text{manual}} \approx B_t^{\text{AD}}} \quad (61)$$

最后验证最终 gradient：

$$\boxed{g_{\text{BPTT}}^{\text{manual}} \approx g_{\text{BPTT}}^{\text{AD}}} \quad (62)$$

必须在 fixed Ψ and detached-reset convention 下完成。double precision 下最好做到 $10^{-6} \sim 10^{-8}$ 。如果最终 gradient 不一致，通过前面两个子 Gate 可以定位错误在 A_t 、 B_t 、adjoint 还是 flattening。

Gate 0.5 (finite difference): finite difference 只用于验证一个真正 smooth 的 forward model，例如 $s_t = \sigma_\beta(u_t - V_{th})$ 。在 smooth proxy 上验证 $g_{\text{FD}} \approx g_{\text{autograd}}$ 。不要对 pseudo-gradient 本身做有限差分证明。Hard spike + custom backward 应单独验证 $g_{\text{manual-SG}} \approx g_{\text{autograd-SG}}$ 。

Gate 0.6 (parameter-wise sensitivity check): 在 tiny network ($n = 2, T = 3$) 上验证 $P_t^{\text{full,manual}} \approx \frac{dh_t}{dW}$ ，以及局部 eligibility recursion $\xi_{ji}^t = A_{j,t}^{\text{loc}} \xi_{ji}^{t-1} + B_{ji,t}^{\text{loc}}$ ， $e_{ji}^t = C_{j,t} \xi_{ji}^t$ 。注意 e_{ji}^t 不应与完整导数 $\frac{dz_j^t}{dW_{ji}}$ 直接比较。

任务3：实现 E-prop (诊断工具)

- **E-prop 模块**: 资格迹递推 $\xi_{ji}^t = A_{j,t}^{\text{loc}} \xi_{ji}^{t-1} + B_{ji,t}^{\text{loc}}$ ， $e_{ji}^t = C_{j,t} \xi_{ji}^t$ 。使用 detached-reset convention，且 $\text{diag}(W_{\text{rec}}) = 0$ 保证 $A_{j,t}^{\text{loc}} = \lambda$ 。这一步不要复用 full P_t 。
- **第一轮实现限制**: 只支持 LIF 神经元。
- **严格措辞**: e-prop provides a locally computed eligibility factorization; the online approximation is primarily introduced through the learning signal, while the local eligibility should not be conflated with full network parameter sensitivity.

Gate 0.5b: 三层验证：

- 1) 验证本文统一动力学下的 analytic eligibility recursion;
- 2) 验证 future-aware local-eligibility factorization 与本文 operational BPTT-SG oracle 数值一致;
- 3) 将 eligibility 的结构、局部性与原始 e-prop 公式进行 qualitative/formula-level cross-check，而不要求由于动力学 convention 不同而产生的逐数值一致性。

任务4：实现 Local Error (目标替换诊断工具)

- **本地分类器模块**: 为每一隐藏层构建固定随机分类器 $r_l^t = M_l o_l^t$ ，初始化 $M_{l,ij} \sim \mathcal{N}(0, 1/d_l)$ 。
- **Mostafa-style random local objective**:

$$p_l^t = \text{softmax}(r_l^t), \quad r_l^t = M_l o_l^t, \quad E_L^{(l)} = -\frac{1}{T} \sum_t \sum_c y_c \log p_{l,c}^t \quad (63)$$

- **Layer-local hidden objectives with global output objective**:

$$\boxed{E_{\text{local,total}} = \sum_{l=1}^{L-1} E_L^{(l)} + E_G^{(L)}} \quad (64)$$

并遵守 detach boundary:

$$\nabla_{\Theta_k} E_L^{(l)} = 0, \quad k \neq l. \quad (65)$$

- **Local objective detach boundary:** $\nabla_{\Theta_k} E_L^{(l)} = 0, k \neq l$, 其中 $\Theta_l = \{W_{\text{ff}}^{(l)}, W_{\text{rec}}^{(l)}, b^{(l)}\}$ 。Hidden layers 使用 local objective, output layer 使用 E_G 。
- **Hybrid Loss:** $L = E_G + \alpha \sum_l E_l$ (hybrid baseline, optional robustness, 不进入 W5/W6 主分析)。
- **测量变量:** $q_l^{\text{local}} = \text{Acc}(\text{softmax}(r_l), y)$ (local-readout quality); $Q_l = \text{CosSim}(\nabla_{\Theta_l} E_L, \nabla_{\Theta_l} E_G)$ (local-objective alignment)。

q_l^{local} 是当前 representation 在特定随机 local readout 下的任务质量, 不是 representation 本身的 intrinsic quality。真正直接涉及 credit geometry 的仍然是 Q_l 。Paper 1 主分析可以把 Q_l 放前面, q_l^{local} 只作为解释变量。

任务5: 受控估计器族与主指标

- **Estimator-level factorial contrasts 模块:** $\Delta_F, \Delta_L, \Delta_{FL}$ 。
- **Credit-assignment discrepancy metrics 模块 (主指标):** D_F, D_L, D_{FL} 。
- **Gradient geometry 模块 (主指标):** $\cos(g, g_{FG})$, $c_{\parallel}(g) = \frac{g^{\top} g_{FG}}{\|g_{FG}\|^2}$, $R_{\perp}(g) = \frac{\|g - c_{\parallel}(g)g_{FG}\|}{\|g_{FG}\|}$ 。
- **Optimization utility 模块 (主指标):** Normalized one-step descent $D_{\text{dir}}(g) = E_G(W) - E_G(W - \eta \frac{g}{\|g\| + \epsilon})$ 。
- **Signed interaction (主指标):**

$$I_D^{\text{dir}} = D_{\text{dir}, BL} - D_{\text{dir}, BG} - D_{\text{dir}, FL} + D_{\text{dir}, FG} \quad (66)$$

$I_D^{\text{dir}} > 0$ 表示 positive/synergistic interaction in one-step optimization, $I_D^{\text{dir}} < 0$ 表示 negative/antagonistic interaction。

- **其他指标 (secondary / optional):** 角度分解 θ_i , 方向/幅度交互 $I_{\text{dir}}, I_{\text{norm}}$, Raw descent D_{raw} , 优化差距 C_{opt} , normalization 与 norm ratio。
- **统计检验模块:**
 - 主分析: paired permutation / bootstrap。
 - Minimum-effect / practically relevant deviation test: $H_0 : D_{FL} \leq \delta_{\text{practical}}$ vs. $H_1 : D_{FL} > \delta_{\text{practical}}$ 。重点看 $\text{LCB}_{95\%}(D_{FL}) > \delta_{\text{practical}}$ 。
 - Mixed-effects (推迟): 只有当 $N = 10$ 后发现 batch variance 明显时才上。

III. 第二阶段: 单层循环 SNN 上的时间分析 (STEP 1)

A. 阶段目标

在单层循环 SNN 上, 研究 future information restriction: $FG \leftrightarrow BG$ 。

B. 核心实验

任务1: 单层两个时间条件

计算 $g_{FG} = \sum_t L_t^F e^t$ 和 $g_{BG} = \sum_t L_t^B e^t$ 。验证在单层设定下, g_{FG} 与 $g_{\text{BPTT-with-SG}}$ 一致。每个条件运行 5 个随机种子。

任务2: 时间信用分配失真分析

$\Delta_F = g_{BG} - g_{FG}$, $D_F = \|\Delta_F\|/(\|g_{FG}\| + \epsilon)$, 角度分解 θ_{BG} , Oracle projection $c_{\parallel}(g_{BG}), R_{\perp}(g_{BG})$, 下降指标 D_{dir} 。

任务3: Temporal map T, λ, α

优先测试极端点 $(T, \lambda) \in \{(64, 0.99), (32, 0.95), (16, 0.9)\}$, 再补充均匀扫描 $T \in \{2, 4, 8, 16, 32\}$, $\lambda \in \{0.5, 0.7, 0.9, 0.95, 0.99\}$ 。

引入膜衰减时间尺度 $T_{\lambda}(\rho) = \frac{\log \rho}{\log \lambda}$ (membrane decay horizon, 不是 effective temporal credit horizon; $T_{\lambda} \neq T_{\text{credit}}$), 例如 $\rho = 0.01$ 表示衰减到原始值的 1%。

连续可控 temporal dependency strength benchmark:

$$y = \text{sign} \left(\sum_{\tau=1}^T \alpha^{T-\tau} x_{\tau} \right), \quad \alpha \in [0, 1] \quad (67)$$

任务4: 核心 synthetic task

Delayed Copy / Recall (测试纯记忆); Delayed XOR (测试 nonlinear dependency)。测试 $k \in \{1, 2, 4, 8, 16, 32, 64\}$ 。必须测 gradient fidelity $\cos(g_{\text{online}}, g_{\text{oracle}})$ 随 k 变化。

C. 扩展实验 (optional robustness)

Delayed Non-match-to-Sample; Task S (pure spatial task); Spike sparsity 扫描; Depth 扫描。

IV. 第三阶段: 两层循环 SNN 上的目标替换分析 (STEP 2)

A. 阶段目标

在两层循环 SNN 上, 研究 objective substitution: $FG \leftrightarrow FL$ 。

B. 任务清单

任务1: FG 与 FL 的对比

计算 $g_{FG} = \sum_t L_t^F e^t$ 和 $g_{FL} = \sum_t \frac{dE_L}{dz^t} e^t$ (hidden local, output global)。

任务2: 目标替换失真分析

$\Delta_L = g_{FL} - g_{FG}$, $D_L = \|\Delta_L\|/(\|g_{FG}\| + \epsilon)$, 角度分解 θ_{FL} , Oracle projection $c_{\parallel}(g_{FL}), R_{\perp}(g_{FL})$, 下降指标 D_{dir} 。

任务3: Local-readout quality 作为测量变量

核心变量: $q_l^{\text{local}} = \text{Acc}(\text{softmax}(r_l), y)$; $Q_l = \text{CosSim}(\nabla_{\Theta_l} E_L, \nabla_{\Theta_l} E_G)$ 。研究 $Q_l \rightarrow D_L$ 和 $q_l^{\text{local}} \rightarrow Q_l \rightarrow D_{\text{opt}}$ 。Paper 1 只使用 Mostafa-style random local objective。

任务4: Hybrid Loss 作为额外验证条件 (optional robustness)

$L_{\text{total}} = L_G + \alpha \sum L_l$ 。扫描 $\alpha \in \{0.01, 0.1, 0.5, 1.0, 2.0\}$ 。

任务5: 网络深度扫描

固定 $T = 16$, $\lambda = 0.9$, 扫描网络深度 $L \in \{1, 2, 3\}$ 。

V. 第四阶段: 两层/三层循环 SNN 上的完整因子分析 (STEP 3)

A. 阶段目标

在两层/三层循环 SNN 上, 回答 RQ3: joint localization 是否引入 practically meaningful non-additive interaction?

B. 任务清单

任务1：四个估计器条件的完整计算

计算 $g_{FG}, g_{BG}, g_{FL}, g_{BL}$ 。所有四个条件使用同一个 eligibility trace e^t 。每个条件运行 5 个随机种子 (exploratory), confirmatory configurations $N = 10$ 。

任务2：Estimator-level factorial contrasts 与 discrepancy metrics

$$\Delta_F = g_{BG} - g_{FG}, \Delta_L = g_{FL} - g_{FG}, \Delta_{FL} = g_{BL} - g_{BG} - g_{FL} + g_{FG}.$$

$$D_F = \|\Delta_F\|/(\|g_{FG}\| + \epsilon), D_L = \|\Delta_L\|/(\|g_{FG}\| + \epsilon), D_{FL} = \|\Delta_{FL}\|/(\|g_{FG}\| + \epsilon).$$

任务3：方向-角度-Oracle projection 分解 (secondary)

角度分解 $\theta_{BG}, \theta_{FL}, \theta_{BL}$; Oracle projection $c_{\parallel}(g_{BG}), c_{\parallel}(g_{FL}), c_{\parallel}(g_{BL}), R_{\perp}(g_{BG}), R_{\perp}(g_{FL}), R_{\perp}(g_{BL})$; 方向交互 I_{dir} (exploratory); 幅度交互 I_{norm} (exploratory)。

任务4：下降交互效应 (主指标)

Normalized 下降交互:

$$I_D^{\text{dir}} = D_{\text{dir}, BL} - D_{\text{dir}, BG} - D_{\text{dir}, FL} + D_{\text{dir}, FG} \quad (68)$$

Raw 下降交互 I_D^{raw} 作为 secondary。

任务5：统计检验

主分析: paired permutation / bootstrap。不使用普通 ANOVA 对 $1 - \cos(g, g_{FG})$ 做主检验, 因为 reference cell 是 structural zero。Mixed-effects 推迟。

任务6：Confirmatory Gate (W6)

$N = 10$ seeds (预注册式 confirmatory minimum, 不是 publication-level universal sample size); $L \in \{2, 3\}$; 三个 T, λ 区域; Minimum-effect / practically relevant deviation test 重点看 $\text{LCB}_{95\%}(D_{FL}) > \delta_{\text{practical}}$ 。

VI. 第五阶段：TEMPORAL REPRESENTATION ANALYSIS

A. 阶段目标

本阶段独立研究 temporal credit representation, 按照四个数学层级分层比较。Paper 1 使用 A_t^{DR} , Paper 2 使用 A_t^{RA} 。

B. Level A1: Intrinsic neuronal temporal dynamics

只比较真正同类的量 (无显式 W_{rec}): $A_t^{\text{A1, RA}}, A_t^{\text{OTTT-like under unified dynamics}} = \lambda I, A_t^{\text{NDOT}} \approx \text{diag}(e_t)$, 其中 e_t 表示 $t-1 \rightarrow t$ transition dependency。这里 $\text{diag}(e_t)$ 指 NDOT 中逐元素 temporal dependency ratio 的对角近似, 不是对 A_t^{RA} 的严格 Jacobian 复现。Level A1 比较的是各算法对 $t-1 \rightarrow t$ 状态传播的对角化/近似方式。

$$D_J^{\text{alg}} = \frac{\sum_t \|A_t^{\text{alg}} - A_t^{\text{A1, RA}}\|_F}{\sum_t \|A_t^{\text{A1, RA}}\|_F + \epsilon}.$$

任务1: 计算 $D_J^{\text{OTTT}}, D_J^{\text{NDOT}}$, 分析 D_J 随 T, λ, k 的变化。

C. Level A2: Network recurrence

引入 W_{rec} , 将 $A_t^{\text{RA}} = D_t + R_t$ 分解。研究 local methods 究竟丢失的是 intrinsic dynamics 还是 network interaction。加入 D-RTRL 和 pp-prop。

D. Level B: Induced weight-update fidelity

对于所有方法，统一映射到最终同维度的 weight-update space: $G_{\text{alg}} = \sum_t \Delta W_{\text{alg}}[t]$ 。计算 D_W^{alg} 、 $\cos(G_{\text{alg}}, G_{\text{oracle}})$ 、 $c_{\parallel}(G_{\text{alg}})$ 、 $R_{\perp}(G_{\text{alg}})$ 。

S-TLLR 的 $e_{ij}^{\text{STLLR}}[t]$ 是 STDP-inspired synaptic plasticity construct，故意加入 BPTT 中没有的 non-causal information。因此不能直接塞进 Level A。

任务4: 非因果项分析 (S-TLLR): S-TLLR provides an important empirical motivation for H2/H3。gradient fidelity $\neq$ necessarily task utility。

VII. 第六阶段：外部算法 VALIDATION (W7)

A. 阶段目标

验证现有算法是否表现出主实验发现的 interaction structure。

W7 初步计划做 OTTT + NDOT + S-TLLR 三个算法的 primary mechanistic validation。D-RTRL / pp-prop 放 Paper 2。TESS / TP 作为 external validation。具体 W6 结束后再决定是否做全部三个，不预先承诺。

验证问题: Do different online temporal estimators exhibit the same empirical locality-error structure? Does S-TLLR exhibit the qualitative behavior predicted by the factorial analysis?

实验矩阵:

实验	Temporal	Spatial	目的
FG	Future-aware	Global	reference
BG	Future-blind	Global	future information restriction
FL	Future-aware	Local	objective substitution
BL	Future-blind	Local	joint distortion
OTTT	OTTT	Global	primary mechanistic validation
NDOT	NDOT	Global	primary mechanistic validation
S-TLLR	S-TLLR	Global	external validation (incl. non-causal)

VIII. 第七阶段：条件性最小机制设计

A. 阶段目标

只有在实验中发现一个稳定、可重复、真正影响 optimization utility 的 failure mode 后，才进入算法设计。

核心原则:

Only design a new mechanism if a reproducible, optimization-relevant failure mode is identified.

(69)

failure mode 可以是 D_F 、 D_L 、 D_{FL} 任意一个，只要它:

稳定 + 可重复 + 真的影响 optimization utility. (70)

严格约束: 只允许一个机制，最多新增一个独立信息通路或一个标量控制量。

IX. 研究假设：三阶段假设

H1 — Fidelity: future restriction/objective substitution $\Rightarrow$ systematic gradient distortion。

H2 — Utility: gradient distortion $\nrightarrow$ performance degradation monotonically。

H3 — Beneficial deviation:

$$\boxed{\text{task-optimal local credit may intentionally deviate from BPTT credit}} \quad (71)$$

S-TLLR 与 TESS 的 non-causal eligibility 实验表明，包含 BPTT 中不存在的 non-causal 项可以提升部分任务性能，这为 H3 提供了 empirical motivation。evaluation 应一直同时保留 Gradient Fidelity 和 Optimization Utility。BPTT fidelity is the reference geometry, not necessarily the task-optimal geometry。

X. 因果层级

最终实验应该分成四个因果层级：

$$\begin{array}{c} \boxed{\begin{array}{l} \text{Level I: fixed-state estimator comparison} \\ \downarrow \\ \text{Level II: one-step optimization} \\ \downarrow \\ \text{Level III: multi-step optimization trajectory} \\ \downarrow \\ \text{Level IV: task performance} \end{array}} \end{array} \quad (72)$$

Experiment A (Estimator diagnostic): same trajectory。Experiment B (Optimization utility): method-specific trajectories。这两个实验不能混。

XI. 长期方向：MEMORY-ACCURACY-FIDELITY-MODEL GENERALITY

$$\boxed{\text{Memory} \times \text{Credit Fidelity} \times \text{Task Utility} \times \text{Model Generality}} \quad (73)$$

BrainTrace 2026 已经明确支持 model-agnostic online learning。因此 Paper 1 claim explicitly limited to fixed LIF dynamics。

A. 长期论文路线

- **Paper 1:** Credit-assignment discrepancy。核心: FG, BG, FL, BL + exact local-eligibility factorization under the chosen operational dynamics, surrogate, and reset convention + one-step descent + $c_{\parallel}(g), R_{\perp}(g), D_{\text{dir}}$ + synthetic temporal tasks + simple two/three-layer RSNN。
- **Paper 2:** Temporal representation。研究 $A_t^{\text{full}} \rightarrow A_t^{\text{diag}} \rightarrow A_t^{\text{OTTT/NDOT}}$ ，以及 $P_t/E_t \rightarrow pp\text{-prop}$ 。现在停止细化。
- **Paper 3:** Hardware-aware adaptive locality + model generality。现在停止细化。

XII. 代码架构（W1 范围）

W1 只做：

```
sanity/
  lif_tiny.py
  surrogate.py
  jacobian_check.py
  manual_bptt.py
  eprop_check.py
```

固定：

$$n = 2, \quad T = 3, \quad B = 1. \quad (74)$$

$$z_t = s_t. \quad (75)$$

Loss:

$$E_G = \frac{1}{2} \sum_t \|z_t - y_t\|^2. \quad (76)$$

W2 之后再扩展：

```
snn/
  lif.py
  surrogate.py
  reset.py

credit/
  dynamics/
    state_jacobian.py      # A_t (DR / RA variants, A1 / A2), D_{Psi,t-1}
    parameter_injection.py # B_t (偏导, h_{t-1} fixed; W_ff->x_t, W_rec->s_t)
    full_sensitivity.py    # P_t = A_t P_{t-1} + B_t (全导, tiny sanity only)

  eligibility/
    eprop.py               # \xi_{ji}^t, e_{ji}^t = C_t \xi_{ji}^t
    stllr_trace.py
    tess_trace.py

  learning_signal/
    future_aware.py        # L_t^F
    instantaneous.py       # L_t^B
    local_objective.py     # Mostafa-style, with detach boundary
    dfa.py
```

```

rules/
  ottd.py
  ndot.py
  stllr.py
  tess.py
  tp.py

oracle/
  bptt_sg.py          # adjoint notation, DR convention
  manual_bptt.py
  smooth_forward.py   # for finite difference check

estimator/
  compose.py          #  $G = \sum_t L_t E_t$ 
  normalization.py
  oracle_projection.py #  $c_{\text{par}}(g), R_{\text{perp}}(g)$ 
  angle.py

operators/
  factorial.py        # FG, BG, FL, BL

metrics/
  gradient.py         # CosSim, RelErr, NormRatio
  descent.py          # D_dir, D_raw
  optimization.py     # C_opt
  stats.py            # paired permutation/bootstrap
  memory.py
  compute.py

experiments/
  sanity/
  step1_single_layer_temporal/
  step2_two_layer_spatial/
  step3_factorial/
  level_a1_intrinsic_dynamics/
  level_a2_network_recurrence/
  level_b_weight_update/

```

```
validation/
synthetic_task/
  delayed_xor.py
  delayed_copy.py
  continuous_horizon.py
```

XIII. 八周执行计划

周	核心问题	必须产出
W1	Oracle 是否可信?	A_t^{DR}, B_t + three sub-Gates + smooth-forward FD check
W2	Factorization 是否可信?	e_t + e-prop consistency + parameter-wise gradient check
W3	Temporal pilot	$FG/BG, D_F$, Delayed Copy + Delayed XOR
W4	Temporal map	$T, \lambda, \alpha \rightarrow \text{fidelity}$
W5	Spatial pilot	$FG/FL, D_L, Q_l$
W6	Factorial	$FG/BG/FL/BL$, interaction (Confirmatory Gate)
W7	Validation	OTTT + NDOT + S-TLLR (W6 结束后决定是否全部做)
W8	Decision	Result freeze + paper figure set

W3 是 Pilot Decision Week, 只回答 FG, BG 相关问题, 不回答 interaction 问题。

W6 是 Confirmatory Gate, 回答 D_{FL} 是否跨越 T, λ, L, k, q_l 仍然存在。

XIV. 第一周 DAY-BY-DAY 执行细节

Day 1: 最小 LIF-RSNN, $n = 2, T = 3, B = 1$ 。动力学 $u_t = \lambda(u_{t-1} - V_{th}s_{t-1}) + W_{\text{ff}}x_t + W_{\text{rec}}s_{t-1} + b$, $s_t = H(u_t - V_{th})$ 。固定 $\lambda = 0.9, V_{th} = 1$ 。固定 surrogate 和 detached-reset convention。diag(W_{rec}) = 0。Tiny Gate 网络固定 $z_t = s_t$ 。

Day 1 固定 loss 为

$$E_G = \frac{1}{2} \sum_{t=1}^T \|z_t - y_t\|_2^2 \quad (77)$$

其中 $z_t = s_t$ 。第一轮使用 MSE, 不使用 softmax/CE, 以便逐项检查

$$\frac{\partial \ell_t}{\partial z_t} = z_t - y_t. \quad (78)$$

等主 Gate 通过后, 再切换到 classification loss。

Day 2: 做 BPTT oracle。先让 PyTorch autograd 给 g_{auto} 。然后自己实现 A_t^{DR} , 实现 reverse adjoint $\lambda_t = \ell_{h,t} + A_{t+1}^\top \lambda_{t+1}$, 再算 g_{manual} 。

三个子 Gate:

$$A_t^{\text{manual,SG}} \approx A_t^{\text{AD,SG}}, \quad B_t^{\text{manual}} \approx B_t^{\text{AD}}, \quad g_{\text{BPTT}}^{\text{manual}} \approx g_{\text{BPTT}}^{\text{AD}} \quad (79)$$

必须通过 $\frac{\|g_{\text{manual}} - g_{\text{auto}}\|}{\|g_{\text{auto}}\| + \epsilon} < 10^{-5}$ 。

Day 3: 做 e-prop local eligibility. 完全独立写 $\xi_{ji}^t = A_{j,t}^{\text{loc}} \xi_{ji}^{t-1} + B_{ji,t}^{\text{loc}}$, 然后 $e_{ji}^t = C_{j,t} \xi_{ji}^t$ 。使用 detached-reset convention。

Day 4: 验证核心恒等式。 $L_j^{F,t} = \frac{dE}{dz_j^t}$, $g_{FG} = \sum_{j,t} L_j^{F,t} e_{ji}^t$, 验证 $g_{FG} \approx g_{\text{BPTT}}$ 。这是真正 Gate D。

Day 5: 得到第一张真正实验图。 $L_t^B = \frac{\partial \ell_t}{\partial z_t}$, $g_{BG} = \sum_t L_t^B e_t$, 画横轴 k , 纵轴 $\cos(g_{BG}, g_{FG})$, $c_{\parallel}(g_{BG})$, $R_{\perp}(g_{BG})$, D_F 。

XV. 研究闸门 (RESEARCH GATE)

真正开实验之前, 只需要通过下面 4 条:

Gate A:

$$A_t^{\text{manual,SG}} \approx A_t^{\text{AD,SG}} \quad (80)$$

Gate B:

$$B_t^{\text{manual}} \approx B_t^{\text{AD}} \quad (81)$$

Gate C:

$$g_{\text{BPTT}}^{\text{manual}} \approx g_{\text{BPTT}}^{\text{AD}} \quad (82)$$

Gate D:

$$g_{FG} \approx g_{\text{BPTT}}. \quad (83)$$

Gate D 是 Paper 1 的真正 oracle gate。如果 $g_{FG} \neq g_{\text{BPTT}}$, 只能解释为实现/定义错误: eligibility、reset、time indexing、learning signal、parameter ordering、autograd hook, 不能解释成 “e-prop approximation”。

其他辅助 Gate:

- Gate 0.5: finite difference 只用于 smooth forward proxy。Hard spike + custom backward 单独验证 manual-SG vs autograd-SG。
- Gate 0.5b: E-prop 实现可信三层验证 (formula/structural cross-check, 不要求数值一致)。
- Gate 0.6: Parameter-wise sensitivity check。
- Gate 1: 因子实验。
- Gate 2: minimum-effect test: $\text{LCB}_{95\%}(D_{FL}) > \delta_{\text{practical}}$ 。
- Gate 3: failure mode 是否稳定、可重复、真正影响 optimization utility。

XVI. 负结果停止规则

在预先固定的实验空间中

($N = 10$ seeds, 至少三个 T_λ 区域, 三个网络深度)

如果 D_F 和 D_L 的practical effect均低于阈值 δ

则停止interaction-driven mechanism discovery

转向locality trade-off analysis

(84)

$N = 10$ 是预注册式 confirmatory minimum, 不是 publication-level universal sample size。

XVII. 风险与应对总表

风险	表现	应对
$g_{FG} \neq g_{BPTT}$	Gate D 失败	检查 eligibility derivation、reset convention、time indexing、surrogate、autograd hook、parameter flattening
$A_t^{\text{manual}} \neq A_t^{\text{AD}}$	Gate A 失败	检查 $D_{\Psi,t-1}$ 下标、surrogate、reset convention
$B_t^{\text{manual}} \neq B_t^{\text{AD}}$	Gate B 失败	检查 $W_{\text{ff}} \rightarrow x_t$ 、 $W_{\text{rec}} \rightarrow s_{t-1}$ 、 $b \rightarrow I$ 的对应关系
future information restriction 始终很小	无失效区域	转向分析 objective substitution
objective substitution 始终很小	无失效区域	转向分析 future information restriction
D_{FL} 显著非零	存在 gradient-level non-additivity	检查 I_D^{dir} 的符号与大小
$D_{FL} \approx 0$	时间与目标失真独立叠加	研究最优 locality 组合策略
$D_{FL} \neq 0$ 但 $I_D^{\text{dir}} \approx 0$	gradient 有 interaction 但 optimization 无	研究 gradient geometry 与 optimization dynamics 的关系
$I_D^{\text{dir}} > 0$	optimization-level positive interaction	分析联合近似是否产生互补效应
$I_D^{\text{dir}} < 0$	optimization-level negative interaction	分析两种近似是否相互放大误差
联合机制提升不明显	提升 1%	论文定位调整为 credit-assignment discrepancy 分析
统计显著性不足 找不到 interaction	$N = 5$ 方差过大 研究者自由度风险	关键验证 $N = 10$ 执行负结果停止规则

XVIII. 统一方法表

Method	A_t state dynamics	Eligibility	Learning signal	Spatial
BPTT	full	implicit exact	total future-aware	No
RTRL	full	exact forward sensitivity	current loss derivative / task signal	No
e-prop	local eligibility factorization	local forward	approximated online signal	Partial
OTTT	$A_t^{\text{OTTT-like under unified dynamics}} = \lambda I$	presynaptic trace	instantaneous BP	No
NDOT	$A_t \approx \text{diag}(e_t)$	dynamics-weighted trace	instantaneous BP	No
D-RTRL	diagonal A_t	sensitivity recursion	online	Partial
pp-prop	diagonal + rank-1	pre/post factorized	online	Partial
S-TLLR	STDP-inspired	causal + non-causal	BP/DFA	Partial
TESS	STDP-inspired	causal + non-causal	structured local target signal	Yes
TP	eligibility trace	forward local	local contrastive	Yes

XIX. 最终理论图

Reverse mode



BPTT

λ_t

Local factorization



e-prop

$L_j^t e_{ji}^t$

Forward mode



RTRL

P_t

三者都是同一个 credit-assignment problem 的不同组织方式。

XX. 总结

本方案以“SNN 在线/局部学习中，哪些信用分配信息是必要的，哪些信息可以被安全移除或替代？”为核心研究问题，建立统一的 credit-assignment anatomy。

核心数学框架：

$$\begin{array}{lcl}
 (A_t^{\text{full}}, B_t^{\text{full}}) & \longrightarrow & P_t^{\text{full}} \\
 \text{RTRL view} & & \\
 (A_{j,t}^{\text{loc}}, B_{ji,t}^{\text{loc}}) & \longrightarrow & \xi_{ji}^t \longrightarrow e_{ji}^t \\
 \text{e-prop view} & &
 \end{array} \tag{85}$$

主要约定：

- 1) 总问题：Which components of credit assignment are necessary for successful local SNN learning?
- 2) 核心贡献：controlled intervention-based decomposition of credit assignment。
- 3) 时间索引永久统一为 $u_t = \lambda(u_{t-1} - V_{th}s_{t-1}) + W_{ff}x_t + W_{rec}s_{t-1} + b$ 。
- 4) Hidden state convention: $\mathbf{h}_t \equiv \mathbf{u}_t$, $A_t = \partial \mathbf{u}_t / \partial \mathbf{u}_{t-1}$ 。
- 5) 符号统一: $z_j^{l,t}$ 始终表示 neuron spike/output; r_i^t 始终表示 local readout logits; per-step adjoint 写作 λ_t 。
- 6) Paper 1 永久固定 DR、no-autapse、fast sigmoid。
- 7) $A_t \equiv \partial h_t / \partial h_{t-1}$, 因此 A_t 内部所有 spike Jacobian 项使用 $D_{\Psi,t-1}$ 。

- 8) $A_t^{\text{DR}} = \lambda I + W_{\text{rec}} D_{\Psi, t-1}$, $A_t^{\text{RA}} = \lambda I - \lambda V_{th} D_{\Psi, t-1} + W_{\text{rec}} D_{\Psi, t-1}$ 。
- 9) $\text{diag}(W_{\text{rec}}) = 0$, 禁止 autaptic/self-recurrent connections。
- 10) B_t 是偏导, P_t 是全导, 递推 $P_t = A_t P_{t-1} + B_t$ 。 $B_t^{W_{\text{ff}}} \sim x_t$, $B_t^{W_{\text{rec}}} \sim s_{t-1}$, $B_t^b = I$ 。
- 11) Paper 1 只使用 e-prop local eligibility, 所有四个 estimator 使用同一个 $e_{ji}^{l,t}$ 。
- 12) FG/BG 使用普通公式, 全层使用 global learning signal; FL/BL 使用 piecewise 定义: hidden local, output global。
- 13) BL 的 hidden-layer learning signal 明确定义为 $L_{L,j}^{B,l,t} = \partial \ell_L^{(l)}[t] / \partial z_j^{l,t}$, 不使用 $\partial E_L^{(l)} / \partial z_j^{l,t}$ 。
- 14) Paper 1 oracle 唯一性 Gate: $\nabla_W^{\text{BPTT-SG}} E \approx \sum_{j,t} \frac{dE}{dz_j^t} e_{ji}^t$ 。
- 15) BPTT 用 adjoint notation: $\lambda_t = \frac{\partial \ell_t}{\partial h_t} + A_{t+1}^\top \lambda_{t+1}$, $\nabla_W E = \sum_t B_t^\top \lambda_t$ 。
- 16) Local objective parameter block: $\Theta_l = \{W_{\text{ff}}^{(l)}, W_{\text{rec}}^{(l)}, b^{(l)}\}$, $\nabla_{\Theta_k} E_L^{(l)} = 0, k \neq l$ 。
- 17) Random local classifier 尺度固定: $M_{l,ij} \sim \mathcal{N}(0, 1/d_l)$ 。
- 18) finite difference 只用于 smooth forward proxy。
- 19) $FG \neq BPTT$ 意味着 Gate 失败。
- 20) 术语采用 controlled intervention-based decomposition。
- 21) RQ3 措辞为 does joint localization introduce a practically meaningful non-additive interaction。
- 22) q_l^{local} 称为 local-readout quality, Q_l 是主分析指标。
- 23) S-TLLR 与 TESS 定位为 H2/H3 的 empirical motivation。
- 24) Gate 固定为 A/B/C/D 四条, A 对应 A_t 、B 对应 B_t 、C 对应 BPTT gradient、D 对应 $g_{FG} = g_{\text{BPTT}}$ 。
- 25) 主指标只保留 $D_F, D_L, D_{FL}, c_{\parallel}, R_{\perp}, D_{\text{dir}}$ 以及 signed interaction I_D^{dir} 。
- 26) $T_{\lambda}(\rho) = \frac{\log \rho}{\log \lambda}$, 避免与 numerical ϵ 混淆。
- 27) Hybrid Loss 降为 optional appendix。
- 28) arctan / piecewise SG 降为 robustness。
- 29) D-RTRL / pp-prop 放 Paper 2。
- 30) TESS / TP 放 related work / future validation。
- 31) Mixed-effects 数据需要时再用。
- 32) Extra synthetic tasks 在 Delayed Copy/XOR 不够时再加。
- 33) Gate 0.5b 只做 formula/structural cross-check, 不要求与官方 e-prop 实现数值一致。
- 34) W1/W2 只实现 fast sigmoid。
- 35) Day 1 tiny Gate 固定 MSE loss, 主 Gate 通过后再切换 classification loss。
- 36) “same trajectory” 只约束 fixed-state estimator comparison, multi-step optimization 允许 trajectory 分叉。
- 37) exact factorization 统一表述为 “exact local-eligibility factorization under the chosen operational dynamics, surrogate, and reset convention”。
- 38) Paper 1 只 factorial 操纵 learning-signal / objective 层 (Level 4); Level 1–3 只作为 diagnostic reference。
- 39) W7 是否完成全部三个外部算法验证在 W6 结束后决定, 不预先承诺。
- 40) 新算法 Gate: Only design a new mechanism if a reproducible, optimization-relevant failure mode is identified。

- 41) Paper 2、Paper 3 停止细化。
- 42) 统一方法表中 OTTT 一行写作 $A_t^{\text{OTTT-like under unified dynamics}}$ ，避免表格强于正文。
- 43) 统一方法表中 RTRL 一行的 learning signal 写作 current loss derivative / task signal。
- 44) 状态记录模块中不使用 g_t ，而是显式保存 λ_t 、 L_t 、 $\xi_{ji}^{l,t}$ 、 $e_{ji}^{l,t}$ 。
- 45) BL 的文字摘要与正式定义一致，learning signal 明确为 $\partial \ell_L^{(l)}[t] / \partial z_j^{l,t}$ ，不是 $\partial E_L^{(l)} / \partial z_j^{l,t}$ 。

最终回答的核心问题：

Which components of exact credit assignment are actually necessary for successful local SNN learning?

(86)

博士研究主线：

Paper 1: What information is necessary?

↓

Paper 2: How can necessary information be compressed?

↓

Paper 3: How should compressed credit assignment adapt to hardware/model constraints?

(87)

接下来最重要的事情：从 tiny $n = 2, T = 3$ RSNN 开始写代码，先做三个子 Gate：

$$A_t^{\text{manual,SG}} = A_t^{\text{AD,SG}} \quad (88)$$

$$B_t^{\text{manual}} = B_t^{\text{AD}} \quad (89)$$

$$g_{\text{BPTT}}^{\text{manual}} = g_{\text{BPTT}}^{\text{AD}} \quad (90)$$

这三条通过以后，再验证 $g_{FG} = g_{\text{BPTT}}$ ，然后正式进入 FG/BG 的 Delayed Copy 实验。

参考文献

- [1] R. J. Williams and D. Zipser, “A learning algorithm for continually running fully recurrent neural networks,” *Neural computation*, vol. 1, no. 2, pp. 270–280, 1989.
- [2] G. Bellec, F. Scherr, A. Subramoney, E. Hajek, D. Salaj, R. Legenstein, and W. Maass, “A solution to the learning dilemma for recurrent networks of spiking neurons,” *Nature Communications*, vol. 11, no. 1, p. 3625, Jul. 2020. [Online]. Available: <https://doi.org/10.1038/s41467-020-17236-y>
- [3] M. Xiao, Q. Meng, Z. Zhang, D. He, and Z. Lin, “Online Training Through Time for Spiking Neural Networks,” in *Advances in Neural Information Processing Systems*, S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, and A. Oh, Eds., vol. 35. Curran Associates, Inc., 2022, pp. 20717–20730. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2022/file/82846e19e6d42ebfd4ace4361def29ae-Paper-Conference.pdf
- [4] H. Jiang, G. D. Masi, H. Xiong, and B. Gu, “NDOT: Neuronal Dynamics-based Online Training for Spiking Neural...” [Online]. Available: <https://openreview.net/forum?id=elF0QoBSFV>
- [5] M. P. E. Apolinario and K. Roy, “S-TLLR: STDP-inspired Temporal Local Learning Rule for Spiking Neural Networks,” Oct. 2024, arXiv:2306.15220 [cs]. [Online]. Available: <http://arxiv.org/abs/2306.15220>
- [6] M. P. E. Apolinario, K. Roy, and C. Frenkel, “TESS: A Scalable Temporally and Spatially Local Learning Rule for Spiking Neural Networks,” in *2025 International Joint Conference on Neural Networks (IJCNN)*, Jun. 2025, pp. 1–9, ISSN: 2161-4407. [Online]. Available: <https://ieeexplore.ieee.org/abstract/document/11227652>