

SNN信用分配的解剖学：从原公式到受控分解

摘要

本方案以“SNN 在线/局部学习中，哪些信用分配信息是必要的，哪些信息可以被安全移除或替代”为核心研究问题。

统一视角：将每个 SNN 学习算法写成

$$\nabla_W E = \sum_t L_t e_t, \quad (1)$$

其中 L_t 是学习信号 (task credit), e_t 是资格迹 (eligibility)。

Paper 1 的受控设计：固定 e_t 为 e-prop 局部资格迹 $e_{ji}^{l,t}$ ，只改变 L_j^t ，形成 FG 、 BG 、 FL 、 BL 四个 estimator：

$$g_X^{(l)} = \sum_{j,t} L_{\bullet,j}^{l,t} e_{ji}^{l,t}, \quad X \in \{FG, BG, FL, BL\}. \quad (2)$$

研究未来信息移除 ($FG \leftrightarrow BG$)、目标替换 ($FG \leftrightarrow FL$)、以及二者的非加性交互 ($\Delta_{FL} = g_{BL} - g_{BG} - g_{FL} + g_{FG}$)。

固定约定：Paper 1 使用 detached reset (DR)、禁止 self-recurrent ($\text{diag}(W_{\text{rec}}) = 0$)、fast sigmoid、MSE loss。Paper 2 使用 reset-aware (RA)。

核心 Gate： $A_t^{\text{manual,SG}} \approx A_t^{\text{AD,SG}}$, $B_t^{\text{manual}} \approx B_t^{\text{AD}}$, $g_{\text{BPPT}}^{\text{manual}} \approx g_{\text{BPPT}}^{\text{AD}}$ ，以及 $g_{FG} \approx g_{\text{BPPT}}$ 。Gate D 不过即视为实现/定义错误，不解释为“e-prop approximation”。

后续工作：Paper 2 研究 temporal representation compression；Paper 3 研究 hardware-aware locality。新机制的引入遵循原则：只有在实验中发现稳定、可重复、真正影响 optimization utility 的 failure mode 时才设计。

文章汇总

RTRL: A learning algorithm for continually running fully recurrent neural networks [1];

E-prop: A solution to the learning dilemma for recurrent networks of spiking neurons [2];

OTTT: Online Training Through Time for Spiking Neural Networks [3];

NDOT: NDOT: Neuronal Dynamics-based Online Training for Spiking Neural Networks [4];

S-TLLR: S-TLLR: STDP-inspired Temporal Local Learning Rule for Spiking Neural Networks [5];

TESS: TESS: A Scalable Temporally and Spatially Local Learning Rule for Spiking Neural Networks [6];

OSTL: Online Spatio-Temporal Learning in Deep Neural Networks [?];

ETLP: ETLP: Event-based Three-factor Local Plasticity for online learning with neuromorphic hardware [?];

OSTTP: Online Spatio-Temporal Learning with Projected Trajectory [?];

TP: Traces Propagation: Memory-Efficient and Scalable Forward-Only Learning in Spiking Neural Networks [?];

BrainTrace: Model-agnostic linear-memory online learning in spiking neural networks [?];

NeuroTrain: NeuroTrain: Surveying Local Learning Rules for Spiking Neural Networks with an Open Benchmarking Framework [?]

I. 研究背景与核心问题

A. 两条研究主线

时间局部化主线：OTTT [3] 丢弃 BPTT 时间连乘中的 reset path，将时序依赖退化为固定指数衰减；NDOT [4] 从连续 LIF 微分方程推导动态核，替代固定 λ ；E-prop [2] 将梯度严格分解为学习信号与资格迹的乘积；S-TLLR [5] 引入 STDP 形式的因果与非因果资格迹。

空间局部化主线：DFA、本地误差学习、ETLP [?]。Mostafa 的原始工作明确指出，每层解决的是自己的局部优化问题。

时空联合工作：OSTL [?] 分离空间与时间梯度分量；OSTTP [?] 结合资格迹与目标投影；TESS [6] 通过本地学习信号生成实现空间局部化；TP [?] 提出 forward-only local learning。

B. 研究空白

不能声称的空白：（一）“时空局部化尚未被研究”；（二）“首次建立统一 benchmark”；（三）“gradient 可以拆开”（OSTL 已强调过）。

真正的研究空白：现有工作主要关注提出训练规则及其任务性能，而对于状态动力学传播、参数敏感度累积与任务学习信号分别被近似时所引入的信用分配失真，能否被独立分解，尚缺乏系统的 controlled factorial analysis。具体而言，缺乏对不同 credit-information removal 操作进行 matched-trajectory、factorial、fidelity–utility 分析。

Paper 1 的 novelty:

在相同 trajectory 与相同 eligibility 下，主动移除某一类 credit information，测量其受控效应。

(3)

II. 预备：LIF 神经元动力学

全文统一使用离散 LIF:

$$u_j^l[t+1] = \lambda(u_j^l[t] - V_{th} s_j^l[t]) + \sum_i W_{ji}^l s_i^{l-1}[t+1] + b_j^l, \quad s_j^l[t] = H(u_j^l[t] - V_{th}). \quad (4)$$

符号说明:

- $l \in \{1, \dots, L\}$: 层索引, $l = 0$ 是输入层;
- j : 当前层神经元索引; i : 上一层 (或同层 recurrent) 神经元索引;
- $u_j^l[t] \in \mathbb{R}$: 膜电位 (hidden state);
- $s_j^l[t] \in \{0, 1\}$: 脉冲 (observable state);
- W_{ji}^l : 从 i 到 j 的突触权重;
- b_j^l : 偏置;
- V_{th} : 发放阈值;

- $\lambda = e^{-\delta t/\tau_m} \in (0, 1)$: 膜衰减因子, τ_m 是膜时间常数, δt 是离散步长;
- $H(x) = \mathbb{I}[x \geq 0]$: Heaviside 阶跃函数, 前向不可导。

为什么用 $-V_{th}s_j^l[t]$ 而不是 $-V_{th}$: 这是”reset by subtraction”形式, 神经元发放后膜电位减去阈值。这种写法便于梯度推导, 因为 reset 项与 $s_j^l[t]$ 相乘, 与其他项保持同构。

反向传播用 surrogate:

$$\frac{\partial s_j^l[t]}{\partial u_j^l[t]} \rightarrow \Psi'(u_j^l[t] - V_{th}), \quad (5)$$

Paper 1 使用 fast sigmoid: $\Psi'(x) = \frac{1}{(1+\beta|x|)^2}$, $\beta = 4$ 。

全文统一: $\mathbf{h}_t \equiv \mathbf{u}_t$ (膜电位是 recurrent hidden state), $D_{\Psi,t} = \text{diag}[\Psi'(u_j^l[t] - V_{th})]_j$ 。

III. 六个算法的原公式 (逐步推导)

本节完整推导六个算法的梯度公式, 作为后续受控分解的数学基础。每个算法都从 LIF 动力学出发, 逐步展开, 不跳步。

A. BPTT: 完整链式法则

a) *Step 1*: 写出全导数。: 我们要计算 $\frac{dE}{dW_{ji}^l}$, 其中 E 是任务损失。按链式法则, E 通过所有时间步的 $u^{l+1}[t]$ 依赖 W_{ji}^l :

$$\frac{dE}{dW_{ji}^l} = \sum_{t=1}^T \frac{\partial E}{\partial u^{l+1}[t]} \cdot \frac{du^{l+1}[t]}{dW_{ji}^l}. \quad (6)$$

b) *Step 2*: 展开全导数 $du^{l+1}[t]/dW^l$ 。: 对 $u^{l+1}[t]$ 关于 W^l 求全导数。由 LIF 递推 $u^{l+1}[t] = \lambda(u^{l+1}[t-1] - V_{th}s^{l+1}[t-1]) + W^l s^l[t] + b^{l+1}$, 有:

$$\frac{du^{l+1}[t]}{dW^l} = \underbrace{\frac{\partial u^{l+1}[t]}{\partial W^l}}_{\text{直接项}} + \underbrace{\frac{\partial u^{l+1}[t]}{\partial u^{l+1}[t-1]}}_{\text{状态转移}} \cdot \frac{du^{l+1}[t-1]}{dW^l}. \quad (7)$$

注意 $\partial u^{l+1}[t]/\partial W^l = s^l[t]^\top$ (对权重矩阵的行展开)。

c) *Step 3*: 展开状态转移 Jacobian。:

$$\frac{\partial u^{l+1}[t]}{\partial u^{l+1}[t-1]} = \lambda I - \lambda V_{th} \frac{\partial s^{l+1}[t-1]}{\partial u^{l+1}[t-1]} = \lambda I - \lambda V_{th} D_{\Psi,t-1}. \quad (8)$$

这里 $D_{\Psi,t-1} = \text{diag}[\Psi'(u_j^{l+1}[t-1] - V_{th})]_j$ 。这是 BPTT 时间连乘的核心矩阵。

d) *Step 4*: 递归展开。: 将 Step 2 递归代入:

$$\frac{du^{l+1}[t]}{dW^l} = \frac{\partial u^{l+1}[t]}{\partial W^l} + \sum_{\tau < t} \left(\prod_{i=\tau+1}^t \frac{\partial u^{l+1}[i]}{\partial u^{l+1}[i-1]} \right) \cdot \frac{\partial u^{l+1}[\tau]}{\partial W^l}. \quad (9)$$

e) Step 5: 代入 Step 3 的表达式。:

$$\frac{dE}{dW^l} = \sum_{t=1}^T \underbrace{\left(\frac{\partial E}{\partial u^{l+1}[t]} \right)^\top}_{g_{u^{l+1}}[t]} \left[\underbrace{\frac{\partial u^{l+1}[t]}{\partial W^l}}_{\text{当前时刻直接}} + \underbrace{\sum_{\tau < t} \prod_{i=\tau+1}^t (\lambda I - \lambda V_{th} D_{\Psi, i-1}) \cdot \frac{\partial u^{l+1}[\tau]}{\partial W^l}}_{\text{历史路径}} \right]. \quad (10)$$

关键点: 时间连乘 $\prod_i (\lambda I - \lambda V_{th} D_{\Psi, i-1})$ 是 BPTT 内存 $O(T)$ 的来源。每一项都依赖前一个时间步的 D_{Ψ} , 必须保存所有历史。

与反向 **adjoint** 的等价形式: 定义 $\lambda_t = dE/du^{l+1}[t]$, 则

$$\lambda_t = \frac{\partial \ell_t}{\partial u^{l+1}[t]} + A_{t+1}^\top \lambda_{t+1}, \quad A_{t+1} = \frac{\partial u^{l+1}[t+1]}{\partial u^{l+1}[t]} = \lambda I - \lambda V_{th} D_{\Psi, t}, \quad (11)$$

$$\nabla_{W^l} E = \sum_t B_t^\top \lambda_t, \quad B_t = \left. \frac{\partial u^{l+1}[t]}{\partial W^l} \right|_{u^{l+1}[t-1] \text{ fixed}}. \quad (12)$$

这一形式在 Paper 1 的 Gate C 里用手写实现验证。

B. OTTT: 从 BPTT 到固定衰减迹

a) Step 1: 识别 BPTT 中的近似点。: 在 BPTT 的时间连乘里, 状态转移是 $\lambda I - \lambda V_{th} D_{\Psi, i-1}$ 。OTTT 观察到: Heaviside 几乎处处导数为零, 所以在时间依赖里忽略脉冲路径 (即 $D_{\Psi, i-1} \approx 0$):

$$\frac{\partial u^{l+1}[i+1]}{\partial u^{l+1}[i]} \approx \lambda I. \quad (13)$$

b) Step 2: 连乘退化。:

$$\prod_{i=\tau+1}^t (\lambda I) = \lambda^{t-\tau} I. \quad (14)$$

c) Step 3: 代入 BPTT 的历史路径项。:

$$\sum_{\tau < t} \lambda^{t-\tau} \frac{\partial u^{l+1}[\tau]}{\partial W^l} = \sum_{\tau \leq t} \lambda^{t-\tau} s^l[\tau]^\top = \hat{a}^l[t]^\top, \quad (15)$$

其中定义了预突触活动的指数衰减迹:

$$\hat{a}^l[t] := \sum_{\tau \leq t} \lambda^{t-\tau} s^l[\tau]. \quad (16)$$

d) Step 4: 前向递推。: $\hat{a}^l[t]$ 可写成递推:

$$\hat{a}^l[t] = \lambda \hat{a}^l[t-1] + s^l[t], \quad \hat{a}^l[0] = 0. \quad (17)$$

这就是 OTTT 的关键: 不需要保存历史 s^l , 只需要维护一个迹变量。

e) Step 5: OTTT 梯度。:

$$\frac{\partial \mathcal{L}}{\partial W^l} = \sum_{t=1}^T g_{u^{l+1}}[t] \hat{a}^l[t]^\top, \quad g_{u^{l+1}}[t] = \left(\frac{\partial \mathcal{L}[t]}{\partial s^{l+1}[t]} \frac{\partial s^{l+1}[t]}{\partial u^{l+1}[t]} \right)^\top. \quad (18)$$

参数: λ (论文取 0.5), V_{th} (取 1)。

与 BPTT 的区别: BPTT 时间连乘含 D_{Ψ} 项, OTTT 丢掉了它们。这相当于假设“时间上只通过膜衰减传播”, 不通过脉冲。

内存: OTTT 只保存 $\hat{a}^l[t]$, $O(n)$; BPTT 保存所有 $u^l[t], s^l[t]$, $O(Tn)$ 。

C. NDOT: 动态比率替代固定衰减

a) *Step 1*: OTTT 的局限。: OTTT 假设 $\partial u[i+1]/\partial u[i] = \lambda I$, 忽略了 $s[i]$ 的影响。NDOT 直接从 LIF 动力学算这个转移的逐元素版本。

b) *Step 2*: 从 LIF 递推提取比率。:

$$u^l[t+1] = \lambda(u^l[t] - V_{th}s^l[t]) + \underbrace{W^l s^{l-1}[t+1]}_{\text{输入项}}. \quad (19)$$

把输入项移到左边:

$$u^l[t+1] - W^l s^{l-1}[t+1] = \lambda(u^l[t] - V_{th}s^l[t]). \quad (20)$$

c) *Step 3*: 定义动态比率。:

$$e^l[t] := \frac{u^l[t] - V_{th}s^l[t]}{u^l[t-1] - V_{th}s^l[t-1]}. \quad (21)$$

注意: 它不是一个严格的 Jacobian $\partial u[t]/\partial u[t-1]$, 而是”reset 后的膜电位”在相邻时刻的逐元素比值。这个比值捕捉了 u 和 s 一起变化时对下一时刻的综合影响。

d) *Step 4*: 用动态比率替代固定衰减。: 把 BPTT 时间连乘里的固定 λ 替换为 $e^l[t]$:

$$\hat{a}^{l-1}[t] = e^{l-1}[t-1] \odot \hat{a}^{l-1}[t-1] + s^{l-1}[t]. \quad (22)$$

$\odot$ 是逐元素乘法。这就是 NDOT 的预突触迹。

e) *Step 5*: NDOT 梯度。:

$$\boxed{\nabla_{W^l} \mathcal{L} = \sum_{t=1}^T g_u[t] \hat{a}^{l-1}[t]^\top, \quad g_u[t] = \left(\frac{\partial \mathcal{L}[t]}{\partial s^l[t]} \frac{\partial s^l[t]}{\partial u^l[t]} \right)^\top.} \quad (23)$$

数值稳定性: 分母可能为零或接近零, NDOT 用 clip 把 $e^l[t]$ 限制在 $[-\lambda, \lambda]$ 。

与 OTTT 的区别: OTTT 用 λ (常数), NDOT 用 $e^l[t]$ (依赖 $u[t], s[t]$ 的动态量)。

D. e-prop: learning signal 与 eligibility 严格分离

a) *Step 1*: 从全导数出发。:

$$\frac{dE}{dW_{ji}} = \sum_t \frac{dE}{dz_j^t} \cdot \frac{dz_j^t}{dW_{ji}}. \quad (24)$$

b) *Step 2*: 分解 dz_j^t/dW_{ji} 。: 由 $z_j^t = f(h_j^t)$ (LIF 中 $f = H$, $h_j^t = u_j^t$), 有:

$$\frac{dz_j^t}{dW_{ji}} = \frac{\partial z_j^t}{\partial h_j^t} \cdot \frac{dh_j^t}{dW_{ji}}. \quad (25)$$

c) *Step 3*: dh_j^t/dW_{ji} 的递归。: h_j^t 依赖 h_j^{t-1} (状态递推) 和 W_{ji} (直接输入):

$$\frac{dh_j^t}{dW_{ji}} = \frac{\partial h_j^t}{\partial h_j^{t-1}} \cdot \frac{dh_j^{t-1}}{dW_{ji}} + \frac{\partial h_j^t}{\partial W_{ji}}. \quad (26)$$

d) *Step 4*: 定义 *local eligibility*。: 上面那个递推里, dh_j^{t-1}/dW_{ji} 里包含了”通过其他神经元 $k \neq j$ 的间接影响”。e-prop 的关键观察是: 把跨神经元的影响剥离掉, 只保留”从 W_{ji} 到 h_j 的局部路径”, 就可以得到一个可以前向计算的量。

定义 ξ_{ji}^t 为这个局部版本:

$$\xi_{ji}^t := A_{j,t}^{\text{loc}} \xi_{ji}^{t-1} + B_{ji,t}^{\text{loc}}, \quad A_{j,t}^{\text{loc}} := \frac{\partial h_j^t}{\partial h_j^{t-1}}, \quad B_{ji,t}^{\text{loc}} := \frac{\partial h_j^t}{\partial W_{ji}}. \quad (27)$$

e) *Step 5*: *synaptic eligibility*。:

$$e_{ji}^t := \frac{\partial z_j^t}{\partial h_j^t} \cdot \xi_{ji}^t. \quad (28)$$

f) *Step 6*: *e-prop* 梯度。:

$$\boxed{\frac{dE}{dW_{ji}} = \sum_t L_j^t e_{ji}^t, \quad L_j^t := \frac{dE}{dz_j^t}.} \quad (29)$$

推导性质: 这个分解是一个恒等式, 不是近似。近似发生在 L_j^t 上: 真正的 dE/dz_j^t 需要未来信息, 在线学习时用当前时刻的近似 $\hat{L}_j^t$ 替代。

g) *Step 7*: *LIF + DR* 的具体形式。: Paper 1 固定 DR (reset path 被 stop-gradient) 和 $\text{diag}(W_{\text{rec}}) = 0$, 所以:

$$A_{j,t}^{\text{loc}} = \lambda, \quad B_{ji,t}^{\text{loc}} = \bar{z}_i^t \text{ (滤波后的突触前脉冲)}, \quad (30)$$

$$\xi_{ji}^t = \lambda \xi_{ji}^{t-1} + \bar{z}_i^t, \quad e_{ji}^t = \Psi'(u_j^t - V_{th}) \xi_{ji}^t. \quad (31)$$

参数: λ (膜衰减), Ψ (surrogate), V_{th} 。

E. S-TLLR: STDP 形式的资格迹

a) *Step 1*: *STDP* 基础规则。: Spike-Timing Dependent Plasticity 描述了 pre 和 post 的发放时间差如何改变突触权重:

$$\Phi(t_i, t_j) = \begin{cases} \alpha_{\text{pre}} \lambda_{\text{pre}}^{t_i - t_j}, & t_i \geq t_j \text{ (因果: pre 早于 post)}, \\ \alpha_{\text{post}} \lambda_{\text{post}}^{t_j - t_i}, & t_i < t_j \text{ (非因果: pre 晚于 post)}. \end{cases} \quad (32)$$

其中 t_i 是 post 发放时刻, t_j 是 pre 发放时刻。

参数: α_{pre} (因果项强度), α_{post} (非因果项强度), $\lambda_{\text{pre}}, \lambda_{\text{post}} \in (0, 1)$ (衰减因子)。 $\alpha_{\text{post}} = 0$ 时只保留因果项。

b) *Step 2*: 对脉冲序列求和。: 对离散时间的脉冲序列 $x_j[t], y_i[t] \in \{0, 1\}$ (pre, post), 累积权重变化:

$$\Delta w_{ij}[t] = \alpha_{\text{pre}} y_i[t] \sum_{t'=0}^t \lambda_{\text{pre}}^{t-t'} x_j[t'] + \alpha_{\text{post}} x_j[t] \sum_{t'=0}^{t-1} \lambda_{\text{post}}^{t-t'} y_i[t']. \quad (33)$$

c) *Step 3*: 用迹变量简化。: 定义 pre 迹 $\text{tr}(x_j)[t] = \lambda_{\text{pre}} \text{tr}(x_j)[t-1] + x_j[t]$, 则

$$\Delta w_{ij}[t] = \alpha_{\text{pre}} y_i[t] \text{tr}(x_j)[t] + \alpha_{\text{post}} x_j[t] (\text{tr}(y_i)[t] - y_i[t]). \quad (34)$$

减去 $y_i[t]$ 是因为非因果项求和到 $t-1$ 而不是 t 。

d) *Step 4*: *S-TLLR* 的资格迹。: *S-TLLR* 把 $y_i[t]$ 替换为次级激活函数 $\Psi(u_i[t])$:

$$e_{ij}[t] = \alpha_{\text{pre}} \Psi(u_i[t]) \text{tr}(x_j)[t] + \alpha_{\text{post}} x_j[t] (\text{tr}(\Psi(u_i))[t] - \Psi(u_i[t])). \quad (35)$$

这是一个瞬时资格迹（没有 β 项），只依赖当前和历史的 x_j 、 $\Psi(u_i)$ 。

e) *Step 5*: 学习信号。:

$$\delta_i^{(l)}[t] = \begin{cases} \frac{\partial \mathcal{L}(y^L[t], y^*)}{\partial y_i^{(l)}[t]}, & t \geq T_l, \\ 0, & t < T_l. \end{cases} \quad (36)$$

$\delta_i^{(l)}[t]$ 是误差反传得到的 learning signal; T_l 是 learning signal 的起始时间步，通常设成最后几步。

f) *Step 6*: 权重更新。:

$$w_{ij} := w_{ij} + \rho \sum_{t=T_l}^T \delta_i[t] e_{ij}[t]. \quad (37)$$

与 **BPTT** 的区别: *S-TLLR* 的 eligibility 故意包含 non-causal 项 ($\alpha_{\text{post}} \neq 0$), 这在 **BPTT** 中不存在。这就是它可能改善任务性能的来源, 也是 **H3** 假设的动机。

F. TESS: 时空全局部

a) *Step 1*: 因果迹（与 *S-TLLR* 的因果项同构）。:

$$q^{(l)}[t] = \lambda_{\text{pre}} q^{(l)}[t-1] + o^{(l-1)}[t], \quad (38)$$

$$e_{\text{pre}}^{(l)}[t] = \alpha_{\text{pre}} \Psi(u^{(l)}[t]) \otimes q^{(l)}[t]. \quad (39)$$

$\otimes$ 是外积（得到矩阵）， $\Psi(u^{(l)}[t])$ 是次级激活。

b) *Step 2*: 非因果迹。:

$$h^{(l)}[t] = \lambda_{\text{post}} h^{(l)}[t-1] + \Psi(u^{(l)}[t-1]), \quad (40)$$

$$e_{\text{post}}^{(l)}[t] = \alpha_{\text{post}} h^{(l)}[t] \otimes o^{(l-1)}[t]. \quad (41)$$

c) *Step 3*: 本地学习信号 (*LSG*)。: **TESS** 的关键创新是把 learning signal 也本地化:

$$m^{(l)}[t] = B^{(l)\top} (f(B^{(l)} o^{(l)}[t]) - y^*). \quad (42)$$

推导思路: 把本层输出 $o^{(l)}[t]$ 投影到任务空间（用固定二值矩阵 $B^{(l)}$ ），应用 softmax (f)，与标签 y^* 比较，再投影回来。 $B^{(l)}$ 的列是方波函数，各列准正交，用来同步层内神经元的活动。

d) *Step 4*: 权重更新。:

$$\Delta W^{(l)}[t] = (m^{(l)}[t] \odot \alpha_{\text{pre}} \Psi(u^{(l)}[t])) \otimes q^{(l)}[t] + (m^{(l)}[t] \odot \alpha_{\text{post}} h^{(l)}[t]) \otimes o^{(l-1)}[t]. \quad (43)$$

e) *Step 5*: 与 *S-TLLR* 的关系。: *S-TLLR* 的 $\delta_i[t]$ 由 BP/DFA 提供（空间上不局部）; **TESS** 的 $m^{(l)}[t]$ 完全在层内生成（空间也局部）。**TESS** 因此是 temporal + spatial 都局部，而 *S-TLLR* 只是 temporal 局部。

G. 统一视角下的定位

算法	学习信号 L_t	资格迹 e_t
BPTT	未来感知 dE/dz_t	完整时间反向图
OTTT	瞬时 $\partial \ell_t / \partial z_t$	固定衰减迹 $\sum_{\tau \leq t} \lambda^{t-\tau} s_\tau$
NDOT	瞬时 $\partial \ell_t / \partial z_t$	动态比率迹 $\sum_{k < t} P_{k,t} \odot s_k$
e-prop (exact)	未来感知 dE/dz_t	局部资格迹 ξ_{ji}^t
e-prop (online)	近似 $\hat{L}_j^t$	局部资格迹 ξ_{ji}^t
S-TLLR	最后几步 $\partial \ell_t / \partial z_t$	STDP 迹 (因果 + 非因果)
TESS	本地生成 $m^{(l)}[t]$	STDP 迹 (因果 + 非因果)

IV. PAPER 1 的受控设计

A. 为什么固定 e_t , 只改变 L_t

五个算法同时在改 L_t 和 e_t , 所以无法回答“到底是哪个因素导致梯度偏差”。Paper 1 固定 e_t 为 e-prop 局部资格迹, 只把 L_j^t 取四种形式, 形成干净的 2×2 :

	Global objective E_G	Local objective $E_L^{(l)}$
Future-aware	FG	FL
Future-blind	BG	BL

B. 四个 learning signal

Global future-aware (对照 BPTT):

$$L_{G,j}^{F,l,t} := \frac{dE_G}{dz_j^{l,t}}, \quad E_G = \sum_{t=1}^T \ell_t. \quad (44)$$

未来感知: 所有时间步的 loss 一起反传。

Global future-blind (对照 OTTT/NDOT):

$$L_{G,j}^{B,l,t} := \frac{\partial \ell_t}{\partial z_j^{l,t}}. \quad (45)$$

只对当前时刻的 ℓ_t 求偏导。空间上的 BP 仍保留, 只是时间上不看未来。

Local future-aware:

$$L_{L,j}^{F,l,t} := \frac{dE_L^{(l)}}{dz_j^{l,t}}, \quad E_L^{(l)} = -\frac{1}{T} \sum_{t=1}^T \sum_c y_c \log p_{l,c}^t, \quad p_l^t = \text{softmax}(M_l o_l^t). \quad (46)$$

M_l 是固定随机分类器, $M_{l,ij} \sim \mathcal{N}(0, 1/d_l)$, 训练中不更新。这是 Mostafa-style random local objective。

Local future-blind:

$$L_{L,j}^{B,l,t} := \frac{\partial \ell_L^{(l)}[t]}{\partial z_j^{l,t}}, \quad \ell_L^{(l)}[t] = - \sum_c y_c \log p_{l,c}^t. \quad (47)$$

强调：对当前时刻的 $\ell_L^{(l)}[t]$ 求偏导，不是对整段 $E_L^{(l)}$ 。

C. 四个 estimator 的组装

对 $X \in \{FG, BG, FL, BL\}$:

$$g_X^{(l)} = \sum_{j,t} L_{\bullet,j}^{\bullet,l,t} e_{ji}^{l,t}, \quad g_X = \text{concat}_{l=1}^L g_X^{(l)}. \quad (48)$$

层间约定:

- FG / BG: 所有层使用 global learning signal;
- FL / BL: hidden layers ($l < L$) 使用 local learning signal, output layer ($l = L$) 使用 global learning signal。

这样四个 estimator 的参数维度、flattening 顺序完全一致，可以逐元素比较。

D. 三个研究问题与主指标

RQ1 (未来信息):

$$FG \leftrightarrow BG, \quad \Delta_F = g_{BG} - g_{FG}, \quad D_F = \frac{\|\Delta_F\|}{\|g_{FG}\| + \epsilon}. \quad (49)$$

RQ2 (目标替换):

$$FG \leftrightarrow FL, \quad \Delta_L = g_{FL} - g_{FG}, \quad D_L = \frac{\|\Delta_L\|}{\|g_{FG}\| + \epsilon}. \quad (50)$$

RQ3 (非加性交互):

$$\Delta_{FL} = g_{BL} - g_{BG} - g_{FL} + g_{FG}, \quad D_{FL} = \frac{\|\Delta_{FL}\|}{\|g_{FG}\| + \epsilon}. \quad (51)$$

优化层面有符号交互:

$$I_D^{\text{dir}} = D_{\text{dir},BL} - D_{\text{dir},BG} - D_{\text{dir},FL} + D_{\text{dir},FG}, \quad (52)$$

$$D_{\text{dir}}(g) = E_G(W) - E_G\left(W - \eta \frac{g}{\|g\| + \epsilon}\right). \quad (53)$$

$I_D^{\text{dir}} > 0$ 表示 synergistic, < 0 表示 antagonistic。

辅助指标:

$$\cos(g, g_{FG}), \quad c_{\parallel}(g) = \frac{g^{\top} g_{FG}}{\|g_{FG}\|^2}, \quad R_{\perp}(g) = \frac{\|g - c_{\parallel}(g)g_{FG}\|}{\|g_{FG}\|}. \quad (54)$$

$c_{\parallel}$ 是 g 在 g_{FG} 方向上的投影系数, $R_{\perp}$ 是垂直分量相对大小。

V. 固定约定（一次写死）

- 时间索引: $u_t = \lambda(u_{t-1} - V_{th}s_{t-1}) + W_{ff}x_t + W_{rec}s_{t-1} + b$, $s_t = H(u_t - V_{th})$ 。
- hidden state: $h_t \equiv u_t$ 。
- reset: Paper 1 用 DR ($A_t^{DR} = \lambda I + W_{rec}D_{\Psi,t-1}$); Paper 2 用 RA ($A_t^{RA} = \lambda I - \lambda V_{th}D_{\Psi,t-1} + W_{rec}D_{\Psi,t-1}$)。
- recurrent: Paper 1 固定 $\text{diag}(W_{rec}) = 0$, 即禁止 autapse。
- surrogate: Paper 1 用 fast sigmoid; $\Psi'(x) = 1/(1 + \beta|x|)^2$, $\beta = 4$ 。
- loss: tiny gate 用 MSE; 主实验用 cross-entropy。
- random local classifier: $M_{l,ij} \sim \mathcal{N}(0, 1/d_l)$, 训练中不更新。
- local objective detach boundary: $\nabla_{\Theta_k} E_L^{(l)} = 0$, $k \neq l$ 。

VI. 四个 GATE

在进入任何因子实验前, 必须按顺序通过:

$$\text{Gate A: } A_t^{\text{manual,SG}} \approx A_t^{\text{AD,SG}}, \quad \text{Gate B: } B_t^{\text{manual}} \approx B_t^{\text{AD}}, \quad (55)$$

$$\text{Gate C: } g_{\text{BPTT}}^{\text{manual}} \approx g_{\text{BPTT}}^{\text{AD}}, \quad \text{Gate D: } \boxed{g_{FG} \approx g_{\text{BPTT}}}. \quad (56)$$

Gate D 不过的处理: 这是实现/定义错误, 不是可接受的近似。逐一排查 eligibility 推导、reset convention、时间索引、surrogate、autograd hook、parameter flattening。所有 Gate 通过前不做任何因子实验。

VII. 研究阶段与思路

以下按研究思路组织, 而不是逐日任务清单。每个阶段给出研究目标、核心问题、判断标准。

A. 阶段一: Oracle 建立与 factorization 验证

研究目标: 确认 BPTT-SG oracle 可信, 且 e-prop 局部资格迹的分解在本文约定下精确成立。

核心问题:

- 手写 A_t^{DR} 与 autograd 给出的 surrogate computational Jacobian 是否一致?
- B_t 对三种参数 (W_{ff} 、 W_{rec} 、 b) 的分量是否与 autograd 一致?
- 手写 adjoint $\lambda_t = \partial \ell_t / \partial h_t + A_{t+1}^\top \lambda_{t+1}$ 与 autograd 的 BPTT 梯度是否一致?
- $g_{FG} = \sum_{j,t} (dE/dz_j^t) e_{ji}^t$ 是否与 g_{BPTT} 一致?

判断标准: double precision 下相对误差 $< 10^{-6}$ (前三 Gate) 与 $< 10^{-5}$ (Gate D)。

思路: tiny 网络 ($n = 2$, $T = 3$, $B = 1$) + MSE loss 起手, 逐渐增大规模。每一步单独验证, 不合并。Gate D 通过后进入阶段二。

B. 阶段二：单层时间分析 ($FG \leftrightarrow BG$)

研究目标：测量移除未来信息对梯度的独立效应。

核心问题：

- D_F 随 temporal horizon (T, λ, k) 如何变化?
- g_{BG} 相对 g_{FG} 的角度偏移 θ_{BG} 、平行分量 $c_{\parallel}$ 、垂直分量 $R_{\perp}$ 呈现什么结构?
- $D_{\text{dir}}(g_{BG})$ 相对 $D_{\text{dir}}(g_{FG})$ 是否有明显退化?

判断标准：至少在一个 (T, λ, k) 区域出现稳定且可重复的 D_F 上升趋势；否则转向阶段三。

思路：从极端点 $(64, 0.99)$ 、 $(32, 0.95)$ 、 $(16, 0.9)$ 起手，然后均匀扫描。核心 synthetic task: Delayed Copy (测纯记忆)、Delayed XOR (测非线性依赖)。必须同时报告 fidelity ($\cos$ 、 $c_{\parallel}$ 、 $R_{\perp}$) 和 optimization utility (D_{dir})。

C. 阶段三：两层目标替换分析 ($FG \leftrightarrow FL$)

研究目标：测量目标替换 (global $\rightarrow$ local) 的独立效应。

核心问题：

- D_L 随网络深度、随机分类器质量如何变化?
- $q_l^{\text{local}} = \text{Acc}(\text{softmax}(r_l), y)$ 与 $Q_l = \cos(\nabla_{\Theta_l} E_L, \nabla_{\Theta_l} E_G)$ 能否预测 D_L ?
- local readout quality 是否作为 $q_l^{\text{local}} \rightarrow Q_l \rightarrow D_{\text{opt}}$ 的中介变量?

判断标准： Q_l 与 D_L 呈现稳定相关性，且 D_L 在 $L = 2, 3$ 上可测量。

思路：Paper 1 只使用 Mostafa-style random local objective (不引入 hybrid loss 作为主分析)。网络深度扫描 $L \in \{1, 2, 3\}$ 。

D. 阶段四：完整 factorial 与 interaction

研究目标：回答 RQ3——两个因素的联合效应是否超出各自独立效应之和。

核心问题：

- D_{FL} 是否显著非零?
- I_D^{dir} 的符号 (synergistic 或 antagonistic)?
- D_{FL} 是否跨越 T, λ, L, k, q_l 稳定存在?

判断标准： $N = 10$ seeds 下, $\text{LCB}_{95\%}(D_{FL}) > \delta_{\text{practical}}$ 。

思路：所有四个 estimator 必须共用同一个 eligibility trace。主分析用 paired permutation / bootstrap; minimum-effect test 关注 practical relevance 而非仅统计显著性。Confirmatory Gate 后，如果 interaction 稳定存在，进入条件性机制设计；否则转为 locality trade-off analysis。

E. 阶段五：外部算法对照

研究目标：验证 OTTT / NDOT / S-TLLR 是否呈现相同的 locality-error structure。

核心问题：

- OTTT 的 D_F 是否与 BG 在同一量级?
- NDOT 的动态比率是否在某些 regime 下比固定衰减更接近 oracle?

- S-TLLR 的 non-causal 项是否对任务性能有可测量贡献（对应 H3）？

判断标准：至少一个外部算法的 fidelity map 与本研究的 D_F 、 D_L 结构 qualitatively 一致。

思路：Paper 1 不承诺全部实现三个算法。W6 结果决定对照范围。TESS / TP 作为 external validation，放 Paper 2 或 related work。

F. 阶段六：结果冻结与论文

研究目标：整理 Paper 1 的核心结果。

核心产出： $D_F(k)$ 、temporal map、 D_{FL} 分布、 I_D^{dir} 符号分布、fidelity-utility 散点图。

思路：Paper 1 定位为诊断型论文。若 interaction 稳定且机制清晰，则加入最小机制设计，成为诊断+解决方案型。

VIII. 后续工作

Paper 2 (Temporal representation)：研究时间敏感度的压缩路径

$$A_t^{\text{full}} \rightarrow A_t^{\text{diag}} \rightarrow A_t^{\text{OTTT/NDOT}}, \quad P_t/E_t \rightarrow \text{pp-prop.} \quad (57)$$

使用 A_t^{RA} 。具体设计等 Paper 1 结果出来后再定。

Paper 3 (Hardware-aware adaptive locality)：根据 Paper 1/2 的 failure mode 设计最小硬件适配机制。

新算法引入原则：

Only design a new mechanism if a reproducible, optimization-relevant failure mode is identified.

(58)

failure mode 可以是 D_F 、 D_L 、 D_{FL} 任意一个，只要它稳定、可重复、真正影响 optimization utility。

参考文献

- [1] R. J. Williams and D. Zipser, “A learning algorithm for continually running fully recurrent neural networks,” *Neural computation*, vol. 1, no. 2, pp. 270–280, 1989.
- [2] G. Bellec, F. Scherr, A. Subramoney, E. Hajek, D. Salaj, R. Legenstein, and W. Maass, “A solution to the learning dilemma for recurrent networks of spiking neurons,” *Nature Communications*, vol. 11, no. 1, p. 3625, Jul. 2020. [Online]. Available: <https://doi.org/10.1038/s41467-020-17236-y>
- [3] M. Xiao, Q. Meng, Z. Zhang, D. He, and Z. Lin, “Online Training Through Time for Spiking Neural Networks,” in *Advances in Neural Information Processing Systems*, S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, and A. Oh, Eds., vol. 35. Curran Associates, Inc., 2022, pp. 20717–20730. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2022/file/82846e19e6d42ebfd4ace4361def29ae-Paper-Conference.pdf
- [4] H. Jiang, G. D. Masi, H. Xiong, and B. Gu, “NDOT: Neuronal Dynamics-based Online Training for Spiking Neural...” [Online]. Available: <https://openreview.net/forum?id=eIF0QoBSFV>
- [5] M. P. E. Apolinario and K. Roy, “S-TLLR: STDP-inspired Temporal Local Learning Rule for Spiking Neural Networks,” Oct. 2024, arXiv:2306.15220 [cs]. [Online]. Available: <http://arxiv.org/abs/2306.15220>
- [6] M. P. E. Apolinario, K. Roy, and C. Frenkel, “TESS: A Scalable Temporally and Spatially Local Learning Rule for Spiking Neural Networks,” in *2025 International Joint Conference on Neural Networks (IJCNN)*, Jun. 2025, pp. 1–9, iSSN: 2161-4407. [Online]. Available: <https://ieeexplore.ieee.org/abstract/document/11227652>