

脉冲神经网络在线学习：算法评述、关键科学问题与研究推进方案

Tao

摘要

脉冲神经网络（Spiking Neural Network, SNN）凭借其事件驱动、稀疏脉冲通信和生物可解释性，被认为是实现低功耗边缘智能的重要候选模型。然而，传统的训练算法，尤其是基于时间的反向传播（BPTT），因需展开整个时间计算图并存储所有时刻的状态，内存和计算开销随时间步数线性增长，难以在资源受限设备上实现在线学习。为突破这一瓶颈，研究者提出了多种在线学习算法，包括OTTT、NDOT、S-TLLR和TESS，分别从时序依赖近似、动态核重参数化、STDP启发式资格迹以及本地学习信号生成等角度，实现了与时间步数无关的常数存储复杂度，并在不同程度上降低了计算复杂度。

然而，这些算法仍面临若干根本性挑战：在线梯度究竟丢失了哪些信息、如何补偿梯度误差、如何设计更优的资格迹与学习信号、如何在生物合理性与高性能间取得平衡、如何在存储与计算复杂度间达到帕累托最优、如何有效应对长期时间依赖、如何与神经形态硬件协同设计、以及如何无缝融合持续学习能力。本文首先系统梳理这四种算法的核心思想、数学形式与复杂度特性，然后从上述八个维度提炼关键研究问题，结合已有算法的技术特点，提出详细的推进方案，旨在为SNN在线学习的后续研究提供系统性的路线图与理论指导。

文章汇总

RTRL: A learning algorithm for continually running fully recurrent neural networks [1];

E-prop: A solution to the learning dilemma for recurrent networks of spiking neurons [2];

OTTT: Online Training Through Time for Spiking Neural Networks [3];

NDOT: NDOT: Neuronal Dynamics-based Online Training for Spiking Neural Networks [4];

S-TLLR: S-TLLR: STDP-inspired Temporal Local Learning Rule for Spiking Neural Networks [5];

TESS: TESS: A Scalable Temporally and Spatially Local Learning Rule for Spiking Neural Networks [6]

I. 引言

A. SNN在线学习的背景与意义

脉冲神经网络（Spiking Neural Networks, SNNs）被誉为第三代神经网络，其神经元通过离散脉冲（spikes）进行通信，在神经形态硬件上具有极高的能效。然而，SNN的监督训练长期受困于脉冲发放函数不可微的问题。基于代理梯度的BPTT（Backpropagation Through Time）虽然通过时间展开实现了有效的梯度传播，但其存储和计算成本均与时间步数 T 成正比：

$$\text{Mem}_{\text{BPTT}} = O(TLn), \quad \text{MAC}_{\text{BPTT}} = O(TLn^2),$$

其中 L 为层数, n 为每层神经元数。这种对 T 的线性依赖使得BPTT无法满足在线学习和边缘部署的需求。

为突破这一瓶颈, 近年的研究聚焦于设计“时间本地”或“时空本地”的学习规则。这些算法的核心目标可以概括为: 在不保存完整时间历史的情况下, 尽可能准确地近似BPTT的时空梯度, 并使权重更新更加适合实时学习和硬件实现。

B. 四种代表性在线学习算法概述

a) (1) *OTTT (Online Training Through Time)*: OTTT的核心思想是丢弃BPTT时间连乘中的重置路径, 即令:

$$\frac{\partial u[i+1]}{\partial s[i]} \frac{\partial s[i]}{\partial u[i]} \approx 0,$$

仅保留泄漏路径 λ 。其梯度公式简化为:

$$\nabla_{\mathbf{w}^l} L = \sum_{t=1}^T \mathbf{g}_{\mathbf{u}^{l+1}}[t] \left(\sum_{\tau \leq t} \lambda^{t-\tau} \mathbf{s}^l[\tau] \right)^\top,$$

其中踪迹 $\hat{\mathbf{a}}^l[t] = \sum_{\tau \leq t} \lambda^{t-\tau} \mathbf{s}^l[\tau]$ 可通过递推 $\hat{\mathbf{a}}^l[t] = \lambda \hat{\mathbf{a}}^l[t-1] + \mathbf{s}^l[t]$ 前向计算。存储复杂度 $O(Ln)$, 时间复杂度 $O(Ln^2)$ 。

b) (2) *NDOT (Neuronal Dynamics-based Online Training)*: NDOT认为OTTT中固定的 λ 无法精确刻画神经元动态, 因此从连续LIF微分方程推导出动态时序核:

$$\mathbf{e}^l[t] = \frac{\mathbf{u}^l[t] - V_{th} \mathbf{s}^l[t]}{\mathbf{u}^l[t-1] - V_{th} \mathbf{s}^l[t-1]},$$

并用 $\mathbf{e}$ 替代固定 λ 构造前向递推:

$$\hat{\mathbf{a}}^l[t] = \mathbf{e}^l[t-1] \odot \hat{\mathbf{a}}^l[t-1] + \mathbf{s}^l[t].$$

存储复杂度仍为 $O(Ln)$ (额外存储分母项), 时间复杂度仍为 $O(Ln^2)$ 。

c) (3) *S-TLLR (STDP-inspired Temporal Local Learning Rule)*: S-TLLR受STDP启发, 定义广义资格迹:

$$e_{ij}[t] = \alpha_{pre} \Psi(u_i[t]) \sum_{t'=0}^t \lambda_{pre}^{t-t'} x_j[t'] + \alpha_{post} x_j[t] \sum_{t'=0}^{t-1} \lambda_{post}^{t-t'} \Psi(u_i[t']),$$

其中红色项为因果项, 蓝色项为非因果项。通过引入踪迹变量 $\text{tr}(x_j)$ 和 $\text{tr}(\Psi(u_i))$, 可前向计算。学习信号 δ_i 由BP或DFA生成, 因此S-TLLR仅时间本地, 空间上仍依赖全局误差传播。存储复杂度 $O(Ln)$, 时间复杂度 $O(Ln^2)$ 。

d) (4) *TESS (Temporally and Spatially Local Learning Rule)*: TESS在S-TLLR的基础上, 将抽象踪迹 tr 实例化为显式张量 $\mathbf{q}$ (前突触踪迹) 和 $\mathbf{h}$ (后突触踪迹), 并引入本地学习信号生成 (LSG):

$$\mathbf{v}_m^{(l)}[t] = \mathbf{B}^{(l)\top} (f(\mathbf{B}^{(l)} \mathbf{o}^{(l)}[t]) - \mathbf{y}^*),$$

其中 $\mathbf{B}^{(l)}$ 为固定随机矩阵 (维度 $C \times n$, C 为类别数)。该信号完全在本层生成, 无需跨层传播。存储复杂度仍为 $O(Ln)$, 但时间复杂度降至 $O(LCn)$, 因为LSG将空间误差传播从 $O(n^2)$ 降为 $O(Cn)$ 。

C. 本文的结构安排

尽管上述算法取得了显著进展，但从理论到实际部署仍存在多个尚未解决的核心问题。本文剩余部分的结构如下：第2节从梯度信息分解的角度分析在线学习究竟丢失了哪些信息，并提出梯度误差补偿的统一框架。第3节讨论生物合理性与高性能的平衡问题，重点关注 α_{post} 的自适应与 $\mathbf{B}$ 矩阵的优化。第4节研究存储-计算帕累托平衡，分析复杂度下界与轻量化策略。第5节探讨资格迹的新定义方式与长期依赖应对。第6节研究学习信号的设计原则与自动生成机制。第7节讨论硬件-算法协同设计。第8节研究在线学习与持续学习的融合。第9节提出统一的在线学习理论框架。第10节总结全文并为后续研究提供方向性指导。

II. 关键问题一：在线梯度究竟丢失了哪些信息？

A. 问题背景

目前几乎所有在线学习算法都会宣称自身是在对BPTT进行某种近似，然而绝大多数工作仅仅关注如何构造新的梯度表达式，却很少回答一个更加本质的问题：在线学习究竟丢失了哪些信息？

BPTT能够获得完整梯度，是因为它能够保存整个时间序列上的神经元状态，并利用未来时刻产生的误差信号对历史状态进行统一修正。因此，一个完整的梯度实际上包含了多个不同来源的信息：未来误差（Future Error）、未来状态依赖（Future State Dependency）、时间信用分配（Temporal Credit Assignment）、跨层误差传播（Spatial Dependency）以及网络整体优化目标（Global Objective）等多个组成部分。

B. 信息丢失的来源分析

在BPTT中，第 l 层第 t 时刻的梯度可以严格写为以下形式：

$$\frac{\partial L}{\partial \mathbf{W}^l} = \sum_{t=1}^T \frac{\partial L}{\partial \mathbf{s}^{l+1}[t]} \frac{\partial \mathbf{s}^{l+1}[t]}{\partial \mathbf{u}^{l+1}[t]} \left(\frac{\partial \mathbf{u}^{l+1}[t]}{\partial \mathbf{W}^l} + \sum_{\tau < t} \prod_{i=t-1}^{\tau} \left(\frac{\partial \mathbf{u}^{l+1}[i+1]}{\partial \mathbf{u}^{l+1}[i]} + \frac{\partial \mathbf{u}^{l+1}[i+1]}{\partial \mathbf{s}^{l+1}[i]} \frac{\partial \mathbf{s}^{l+1}[i]}{\partial \mathbf{u}^{l+1}[i]} \right) \frac{\partial \mathbf{u}^{l+1}[\tau]}{\partial \mathbf{W}^l} \right) \quad (1)$$

该公式揭示了完整梯度所包含的多个关键信息来源：

- 1) **当前时刻直接贡献**: $\frac{\partial \mathbf{u}^{l+1}[t]}{\partial \mathbf{W}^l}$ ，表示当前输入对权重的直接影响，即当前时刻的输入脉冲。
- 2) **时间依赖链**: $\prod_{i=t-1}^{\tau}$ (绿色 + 青色 × 红色)，其中绿色项表示膜电位的泄漏传播，青色项表示脉冲对膜电位的重置影响，红色项表示脉冲发放对膜电位的导数（需用代理梯度）。
- 3) **历史起点信息**: $\frac{\partial \mathbf{u}^{l+1}[\tau]}{\partial \mathbf{W}^l}$ ，表示历史时刻 τ 的膜电位对权重的直接偏导，即历史时刻的输入脉冲。
- 4) **未来误差**: $\frac{\partial L}{\partial \mathbf{s}^{l+1}[t]}$ ，表示来自输出层或高层反向传播的误差信号，它包含了整个未来序列的信息。

大多数在线学习算法都会主动舍弃其中的一部分信息。例如，OTTT通过Detach机制忽略重置路径（青色×红色），因此丢失了重置耦合信息；E-prop利用Eligibility Trace替代完整时间展开，因此舍弃了完整未来误差传播；NDOT则进一步利用神经元动力学模型近似未来梯度；而TESS则通过时间窗口截断减少历史依赖。

C. 信息分解框架与推进方案

建议建立一个统一的信息分析框架（Information Decomposition Framework），将真实梯度拆分为多个组成部分，并分析不同算法究竟保留了哪些信息、舍弃了哪些信息。可以按照以下方式分解：

$$g_{\text{BPTT}} = g_{\text{current}} + g_{\text{leak}} + g_{\text{reset}} + g_{\text{future}}$$

其中：

- $g_{\text{current}} = \frac{\partial u[t]}{\partial W}$ ：当前时刻直接贡献
- $g_{\text{leak}} = \sum_{\tau < t} \lambda^{t-\tau} \frac{\partial u[\tau]}{\partial W}$ ：泄漏传播贡献
- $g_{\text{reset}} = \sum_{\tau < t} \prod(-\lambda V_{th} \sigma') \frac{\partial u[\tau]}{\partial W}$ ：重置耦合贡献
- $g_{\text{future}} = \frac{\partial L}{\partial s[t']}$ ：未来误差贡献

进一步地，可以构建一种Information Loss Taxonomy，对现有所有在线学习算法按照信息损失类型进行统一分类：

算法	保留当前信息	保留泄漏	保留重置	保留未来误差
BPTT	✓	✓	✓	✓
OTTT	✓	✓	×	✓
NDOT	✓	动态替代	动态替代	✓
S-TLLR	✓	tr	tr	✓（BP/DFA）
TESS	✓	q	h	本地LSG

该方向的核心研究问题包括：

- 1) 不同类型的信息丢失分别对最终性能造成怎样的影响？
- 2) 在给定资源约束下，哪些信息是“必须保留”的，哪些是可以舍弃的？
- 3) 能否设计一种“信息重要性度量”，动态决定在资源紧张时应优先保留哪些信息？

III. 关键问题二：如何补偿在线梯度与真实梯度之间的误差？

A. 统一误差建模

几乎所有在线学习方法最终都可以写成如下统一形式：

$$g_{\text{online}} = g_{\text{true}} + \epsilon,$$

其中 g_{true} 表示BPTT产生的真实梯度，而 ϵ 表示由于在线近似所带来的梯度误差。不同算法产生误差的来源并不相同。具体而言：

- OTTT中的误差主要来源于Detach带来的梯度截断，即丢失了重置路径信息。
- E-prop中的误差主要来源于Learning Signal对真实误差信号的替代。
- NDOT中的误差来源于神经元动力学模型的近似，即用 $e[t]$ 替代 $\epsilon[t]$ 。
- S-TLLR中的误差来源于资格迹对真实时间依赖的近似以及学习信号的近似。
- TESS中的误差来源于时间截断和空间本地信号替代全局误差。

在NDOT中，时间依赖项从BPTT的离散 $\epsilon[t]$ 被替换为连续动力学导出的 $e[t]$ ，两者之间的误差为：

$$\Delta^l[t] = \epsilon^l[t] - e^l[t],$$

其中 $\epsilon^l[t] = \lambda - \lambda V_{th} \sigma'(u[t])$ ，而 $e^l[t] = \frac{u[t] - V_{th} s[t]}{u[t-1] - V_{th} s[t-1]}$ 。

B. 梯度误差的统计特性分析

可以分析梯度误差的统计特性。假设真实梯度服从分布 $g_{\text{true}} \sim \mathcal{N}(\mu_g, \Sigma_g)$ ，在线梯度误差 ϵ 可能表现出以下特性：

$$\mathbb{E}[\epsilon] = \mu_\epsilon, \quad \text{Cov}(\epsilon) = \Sigma_\epsilon, \quad \mathbb{E}[\|g_{\text{online}} - g_{\text{true}}\|^2] = \text{Tr}(\Sigma_\epsilon) + \|\mu_\epsilon\|^2.$$

理想情况下，我们希望 $\mathbb{E}[\epsilon] = 0$ 且 $\|\epsilon\|$ 尽可能小。

C. 推进方案

建议从以下几个方向推进梯度误差补偿研究：

a) (1) 残差梯度网络：可以设计一个小型可训练网络 $h_\phi(\cdot)$ ，将在线梯度映射到更接近真实梯度的方向：

$$\hat{g}_{\text{online}} = g_{\text{online}} + h_\phi(g_{\text{online}}, \text{context}),$$

其中 **context** 包括当前膜电位、脉冲、时间步等信息。该网络可以离线预训练或在线自适应更新。

b) (2) 元学习补偿：使用元学习框架，在不同的任务或时间序列上学习一个“梯度修正策略”，使其能够快速适应不同网络结构和数据分布。

$$\phi^* = \arg \min_{\phi} \mathbb{E}_{\text{task}} [\mathcal{L}_{\text{val}}(W - \eta(g_{\text{online}} + h_\phi(g_{\text{online}})))].$$

c) (3) 在线误差估计：直接估计当前梯度的误差方差，并将其纳入优化步骤：

$$\Delta W = -\eta \cdot \frac{g_{\text{online}}}{\text{Var}(g_{\text{online}}) + \sigma^2}.$$

这种方法可以参考Adam等自适应优化器中方差估计的思想，但需要适用于在线场景。

d) (4) 理论与实践结合的验证体系：为了系统评估梯度误差补偿效果，建议构建以下三个层次的验证体系：

- 1) **梯度级评估**：在小规模网络上，计算在线梯度与BPTT真实梯度的余弦相似度、相对误差和方向偏差，直接量化梯度质量。
- 2) **训练级评估**：在中等规模任务上，比较不同补偿方法对收敛速度、最终精度和训练稳定性的影响。
- 3) **推广级评估**：在多种不同类型的数据集上验证补偿方法的通用性和鲁棒性，分析补偿策略是否对特定任务过拟合。

该方向不仅具有较强的理论价值，也有望突破当前在线学习精度普遍低于BPTT的瓶颈。

IV. 关键问题三：如何设计同时具备“生物合理性”与“高性能”的本地学习规则？

A. 问题背景

生物神经系统依赖局部突触可塑性（如STDP、资格迹）进行学习，无需全局误差反向传播。然而，纯生物启发的方法在复杂任务上性能远不及梯度方法。当前在线学习算法在“生物合理性”与“任务性能”之间存在明显断层。

S-TLLR中非因果项系数 α_{post} 的最优取值（-1、0、+1）在不同任务上表现迥异：

数据集	$\alpha_{post} = 0$	$\alpha_{post} = +1$	$\alpha_{post} = -1$
DVS Gesture	94.61%	94.01%	95.07%
DVS CIFAR10	72.93%	73.42%	73.93%
SHD	77.09%	78.23%	74.69%

- 空间主导任务（DVS CIFAR10、DVS Gesture）： $\alpha_{post} = -1$ 最优（因果性占主导）。
- 时间主导任务（SHD）： $\alpha_{post} = +1$ 最优（同步性占主导）。

B. 核心研究问题

- 1) 能否建立统一框架，将OTTT/NDOT与S-TLLR/TESS纳入同一数学形式？
- 2) α_{post} 的最优取值是否与任务的时间结构（事件密度、脉冲稀疏度）存在确定性关联？
- 3) 能否优化 $\mathbf{B}$ 矩阵以提升TESS的性能，同时保持本地性？
- 4) 代理梯度 σ' 能否被设计为更具生物合理性的形式？

C. 推进方案

a) (1) 统一框架构建：从三因子规则 $\Delta w = \sum_t \delta_i[t] e_{ij}[t]$ 出发，将各算法的 δ 和 e 显式写出：

算法	资格迹 $e_{ij}[t]$	学习信号 $\delta_i[t]$
OTTT	$\sum_{\tau \leq t} \lambda^{t-\tau} s^l[\tau]$	$\mathbf{g}_u$
NDOT	$\sum_{\tau \leq t} \mathbf{e}[\tau] \odot s^l[\tau]$	$\mathbf{g}_u$
S-TLLR	$\alpha_{pre} \Psi(u_i) \text{tr}(x_j) + \alpha_{post} x_j \text{tr}(\Psi(u_i))$	$\frac{\partial L}{\partial y_i}$
TESS	$\mathbf{q}^{(l)}[t], \mathbf{h}^{(l)}[t]$	$\mathbf{B}^\top (f(\mathbf{Bo}) - y^*)$

通过变量代换，可以证明在特定条件下S-TLLR可退化为OTTT，TESS的LSG可视为S-TLLR中DFA的推广。

b) (2) α_{post} 的自适应机制：设计可学习的参数 $\alpha_{post}^{(l)}$ ，通过梯度下降调整，或设计基于任务统计量的启发式方法：

$$\alpha_{post} = g(r, \rho, \sigma_s),$$

其中 r 为平均发放率， ρ 为脉冲时序相关性， σ_s 为脉冲稀疏度。

c) (3) $\mathbf{B}$ 矩阵的优化：

- 使用无监督预训练（如PCA）提取主成分作为 $\mathbf{B}$ 初始值。
- 使用准正交确定性序列（如Hadamard矩阵）替代随机矩阵。
- 设计可学习的低秩矩阵 $\mathbf{B} = \mathbf{UV}^\top$ 。

d) (4) 更具生物合理性的代理梯度设计: 传统代理梯度 $\sigma'(x)$ 可被设计为类STDP的时间依赖形式:

$$\sigma'(u[t], u[t-1], s[t-1]) = f(u[t] - V_{th}, \Delta t, s[t-1]),$$

使得代理梯度不仅依赖当前膜电位, 还依赖脉冲发放历史。这将使学习规则更接近真实的生物突触可塑性。

V. 关键问题四: 如何实现“存储复杂度最优”与“计算精度最优”的帕累托平衡?

A. 复杂度现状分析

现有在线学习算法的复杂度对比如下:

算法	存储复杂度	时间复杂度	关键操作
OTTT	$O(Ln)$	$O(Ln^2)$	外积 $\mathbf{g} \cdot \hat{\mathbf{a}}^\top + \text{BP}$
NDOT	$O(Ln)$	$O(Ln^2)$	外积 + BP (动态核逐元素计算)
S-TLLR	$O(Ln)$	$O(Ln^2)$	外积 + BP/DFA (n^2)
TESS	$O(Ln)$	$O(LCn)$	外积 + LSG (Cn)

TESS通过LSG将空间误差传播从 $O(n^2)$ 降至 $O(Cn)$, 但权重更新的外积 $O(n^2)$ 仍然是“物理极限”。

B. 推进方案

a) (1) 复杂度下界的信息论分析: 从信息论角度论证: 全连接层 n^2 个突触更新至少需要 $O(n^2)$ 次操作。理论上最优为 $O(n^2 + Cn)$, 当 $C \ll n$ 时即 $O(n^2)$ 。若采用稀疏连接或结构化权重(卷积), 可进一步降低。

b) (2) 极致轻量算法探索:

- 符号梯度: $\Delta W = -\eta \cdot \text{sign}(g_{\text{online}})$
- 稀疏更新: 每步仅随机选择部分突触更新
- 量化梯度: 使用低精度(如8位)表示梯度
- 二值化LSG: 将 $\mathbf{v}_m$ 二值化, 外积简化为符号外积

c) (3) 任务自适应复杂度调节: 设计“复杂度旋钮”, 允许在完整梯度、LSG、二值化等模式间切换:

$$\text{Mode} = \arg \min_m (\alpha \cdot \text{Error}_m + \beta \cdot \text{Cost}_m).$$

VI. 关键问题五: ELIGIBILITY TRACE是否存在新的定义方式?

A. 传统定义的局限

目前, 大多数Eligibility Trace都采用统一形式:

$$e_t = \frac{\partial s_t}{\partial W},$$

即利用神经元状态对权重的偏导数描述历史影响。这种定义方式存在三个主要局限:

- 1) 存储与计算代价：每个突触需要独立的 e_{ij} ，导致 $O(n^2)$ 的存储和计算成本（虽然通过踪迹分解可降至 $O(n)$ ，但表达能力受限）。
- 2) 单一时间尺度：传统资格迹仅支持单一的指数衰减时间尺度，难以捕捉多尺度时序依赖。
- 3) 局限于神经元级表示：资格迹仅追踪单个神经元的脉冲历史，无法捕获更抽象的时序模式（如神经群体同步、时空脉冲模式）。

B. 推进方案

a) (1) 多尺度踪迹设计：设计多个不同衰减率的踪迹 $(\lambda_1, \lambda_2, \dots, \lambda_K)$ ，分别对应短、中、长时间尺度：

$$\hat{a}^{(k)}[t] = \lambda_k \hat{a}^{(k)}[t-1] + s[t], \quad k = 1, \dots, K$$

最终资格迹为多尺度踪迹的加权组合：

$$\hat{a}[t] = \sum_{k=1}^K w_k \hat{a}^{(k)}[t], \quad w_k \text{ 可通过学习获得.}$$

b) (2) 层级化资格迹：

- 神经元级：传统 e_{ij} ，追踪单个突触历史。
- 层级别： $\mathbf{E}^l[t] = \sum_{\tau \leq t} \lambda^{t-\tau} \mathbf{s}^l[\tau] \otimes \mathbf{s}^{l-1}[\tau]$ ，追踪层间活动模式。
- 网络级： $\mathbf{E}^{\text{net}}[t] = \sum_{\tau \leq t} \lambda^{t-\tau} \mathbf{s}^{\text{all}}[\tau]$ ，追踪整体网络状态。

c) (3) 注意力式踪迹：借鉴Transformer，用可学习的查询-键-值机制动态选择历史关键时刻：

$$\text{Attention}(t, \tau) = \text{softmax} \left(\frac{\mathbf{q}(t)^\top \mathbf{k}(\tau)}{\sqrt{d}} \right),$$

$$\hat{a}[t] = \sum_{\tau \leq t} \text{Attention}(t, \tau) \cdot s[\tau].$$

d) (4) 基于信息理论的踪迹设计：从信息论角度设计最优踪迹，最大化历史信息保留同时最小化存储代价：

$$\text{maximize } I(\hat{a}[t]; \{s[\tau]\}_{\tau \leq t}), \quad \text{s.t. } \dim(\hat{a}) \leq K.$$

VII. 关键问题六：LEARNING SIGNAL应该如何设计？

A. 问题背景

E-prop提出之后，Learning Signal逐渐成为在线学习研究的重要组成部分。目前，大多数Learning Signal主要来源于：

- 全局误差（Global Error）—— 来自输出层的反向传播
- 局部分类器（Local Classifier）—— 每层独立分类
- 随机投影（Random Projection）—— DFA/DRTP风格
- 教师信号（Teacher Signal）—— 蒸馏/知识迁移
- Synthetic Gradient—— 用网络预测梯度

然而，目前尚不存在一种统一的方法能够说明什么样的Learning Signal才是最优的。理想的Learning Signal应当同时满足：

- 1) 信息丰富，能够有效引导权重更新
- 2) 通信开销低，适合硬件实现
- 3) 能够在线生成，不依赖未来信息
- 4) 训练稳定性好，收敛快
- 5) 适合神经形态硬件实现

B. 推进方案

a) (1) 动态误差调制：引入注意力机制动态调节误差信号：

$$\delta_i^{(l)}[t] = \alpha_i^{(l)}[t] \cdot \frac{\partial L}{\partial y_i^{(l)}[t]},$$

其中 $\alpha_i^{(l)}[t]$ 可由该神经元当前活动或置信度决定。

b) (2) 预测性学习信号：利用预测网络生成未来误差估计：

$$\delta_{\text{pred}}[t] = \mathcal{P}(u[t], s[t], \theta_{\text{pred}}),$$

使权重更新不仅考虑当前误差，还考虑未来可能的修正方向。

c) (3) 自监督学习信号：利用自监督学习构建局部训练目标，使每层获得独立的监督信号，无需全局标签信息。

d) (4) 教师-学生蒸馏信号：使用教师-学生网络框架产生更稳定的局部监督信息，教师网络可以是预训练的BPTT模型或EMA模型。

VIII. 关键问题七：如何实现在线学习与神经形态硬件的协同设计？

A. 问题背景

目前，大多数在线学习算法主要关注数学模型，而硬件实现通常作为后续工作独立开展。然而，对于神经形态芯片而言，算法设计与硬件资源之间存在高度耦合关系。仅仅优化算法而忽略硬件限制，很难真正实现高效片上学习。

B. 推进方案

a) (1) 硬件-算法联合仿真平台：构建模拟神经形态芯片硬件约束的仿真框架，支持自定义位宽、存储容量、计算精度等参数。识别各算法对硬件最敏感的部分。

b) (2) 脉冲驱动算法重设计：将算法操作映射为硬件友好操作：

- 踪迹更新： λ 取 2^{-k} ，乘法变为移位。
- 权重更新：二值化或稀疏化，乘法简化为逻辑运算。
- LSG投影：固定随机连接（硬件布线），无需存储矩阵。

c) (3) 硬件成本模型：建立完整的硬件成本模型：

$$C_{\text{total}} = C_{\text{mem}} + C_{\text{comm}} + C_{\text{mul}} + C_{\text{update}}.$$

d) (4) 稀疏与量化资格迹：设计稀疏资格迹（只保留重要突触）、量化资格迹（低精度存储）、共享资格迹（多个突触共享状态）等机制，进一步减少片上存储需求。

IX. 关键问题八：在线学习如何与“持续学习”无缝融合？

A. 问题背景

在线学习通常假设数据来自同一分布，而持续学习要求模型在面对新任务时不遗忘旧任务知识。现有在线算法均未考虑任务切换，面临灾难性遗忘风险。关键问题包括：如何将巩固机制集成到踪迹更新中？能否设计“睡眠-觉醒”框架？

B. 推进方案

a) (1) 持续学习基准测试：在Split CIFAR-100、Permuted MNIST上评估四种算法的遗忘率，与BPTT+EWC对比。

b) (2) 巩固踪迹机制：为每个突触维护重要性权重 Ω_{ij} （通过梯度平方移动平均在线估计）：

$$\Delta w_{ij} = \rho \sum_t \delta_i[t] e_{ij}[t] \cdot (1 - \eta \Omega_{ij}).$$

c) (3) 睡眠-觉醒两阶段框架：

- 觉醒阶段：使用TESS快速在线学习。
- 睡眠阶段：设备空闲时，通过重放典型样本巩固记忆，学习率降低，同时启用巩固项。

X. 关键问题九：是否能够建立统一的在线学习理论框架？

A. 统一框架的形式化表达

目前，RTRL、E-prop、OTTT、NDOT、TESS以及S-TLLR等算法形式各异，看似属于不同的发展路线。然而，从梯度计算角度来看，这些算法本质上都可以理解为真实梯度的不同近似形式。

一个具有长期价值的研究方向是建立统一的在线学习理论框架，将各种算法统一表示为：

$$\Delta W = \text{Learning Signal} \times \text{Eligibility},$$

或进一步表示为：

$$\Delta W = \text{Approximation}(\nabla_{\text{BPTT}}).$$

在这一统一框架下，不同算法之间的区别将不再体现在公式形式，而体现在不同的信息近似策略：

近似维度	描述
时间近似（Temporal）	如何压缩/近似时间维度
空间近似（Spatial）	如何处理层间信息传播
误差近似（Error）	如何近似真实梯度误差
存储近似（Memory）	如何减少状态存储
通信近似（Communication）	如何减少层间通信
硬件近似（Hardware）	如何适配硬件约束

基于上述思想,可以进一步建立Online Learning Approximation Space,对现有所有在线学习算法进行统一分类,并分析各种近似策略之间的联系与差异。

B. 推进方案

a) (1) 统一数学形式: 将所有算法写为统一形式:

$$\Delta W^l[t] = \eta \cdot \mathcal{E}^l[t] \cdot \mathcal{L}_{\text{local}}^l[t],$$

其中 $\mathcal{E}^l[t]$ 表示突触或神经元局部可获得的时间轨迹, $\mathcal{L}_{\text{local}}^l[t]$ 表示局部学习信号。

b) (2) 近似策略的分类与分析: 建立近似策略的分类学 (Taxonomy), 按照上述六个维度对现有算法进行分类, 并分析各维度之间的耦合关系。

c) (3) 理论边界分析: 从信息论和优化理论角度, 分析不同近似策略的理论边界。具体而言, 可以研究:

- 1) 时间近似的代价: 当忽略重置路径时, 梯度误差的上界是什么? 这可以建立OTTT类方法的理论保证。
- 2) 空间近似的代价: 当用本地信号替代全局误差时, 最优性损失有多大? 这可以为TESS类方法提供理论支撑。
- 3) 信息论下界: 在给定的存储和计算约束下, 在线梯度与BPTT梯度的最小可能误差是多少? 这可以为所有在线算法设立理论基准。

d) (4) 统一框架下的算法设计: 基于统一框架和理论分析, 指导设计新的在线学习算法, 在给定近似策略组合下达到最优性能。

XI. 未来研究路线总结

综合以上九个关键问题的分析, 可以归纳出一条完整的未来研究路线图:

A. 近期研究重点 (1-2年)

- 1) 梯度信息分解与误差分析: 系统分析各类在线算法在时间依赖、空间传播和未来误差三个维度上的信息丢失模式, 建立完整的Information Loss Taxonomy。
- 2) NDOT动力学依赖的理论边界: 分析NDOT中 $e[t]$ 与BPTT中 $\epsilon[t]$ 的理论误差, 明确其适用条件和失效场景。
- 3) 多尺度踪迹的实现与验证: 设计并实现多尺度踪迹机制, 在长时间依赖任务上验证其有效性。

B. 中期研究目标 (2-4年)

- 1) 梯度误差补偿机制: 设计可学习的残差梯度网络或元学习补偿策略, 在线逼近真实梯度。
- 2) 统一框架的建立: 构建完整的Online Learning Approximation Space, 将各类算法统一分类和比较。
- 3) 硬件-算法协同设计: 在FPGA或神经形态芯片上实现TESS及后续改进算法, 建立真实的硬件-算法联合优化流程。
- 4) 持续学习集成: 将巩固踪迹与睡眠-觉醒框架在真实硬件上验证, 实现芯片上的持续学习能力。

C. 长期研究方向（4年以上）

- 1) **脑启发在线学习的理论完备性**：借鉴神经科学中的脉冲时间依赖可塑性、神经调节、睡眠巩固等机制，设计更接近真实生物系统的在线学习算法，并建立严格的数学理论。
- 2) **多任务通用在线学习系统**：设计支持多任务、多模态输入的通用在线学习架构，实现真正意义上的“边缘智能”。
- 3) **大规模在线SNN系统**：将在线SNN扩展到数十亿突触的规模，解决大规模系统中的通信、同步、容错等分布式学习问题。

D. 对研究者的方向性建议

基于上述分析，对不同研究阶段的学者提供以下方向性指导：

a) 对低年级研究生的建议：低年级研究生应优先掌握基础理论，夯实数学和算法基础。建议：

- 1) 系统学习BPTT的完整推导和在线算法的三种基础类型（RTRL、E-prop、OTTT）。
- 2) 在一个中等规模数据集上实现NDOT或S-TLLR，深入理解算法细节。
- 3) 完成一个系统性实验：比较固定 λ （OTTT）与动态 $e[t]$ （NDOT）在不同时间步长下的性能差异，明确各自优势区间。

b) 对博士研究生的建议：博士研究生应在已有算法基础上探索新的改进方向。建议从以下切入点开始：

- 1) **时间依赖改进**：设计多尺度踪迹或多时间尺度NDOT，从根本上解决单一踪迹表达力不足的问题。
- 2) **空间传播改进**：探索NDOT+local loss的混合架构，在保持在线性的同时减少对全局反向传播的依赖。
- 3) **生物合理性**：研究 α_{post} 的自适应机制，让网络自主决定因果/非因果比重。
- 4) **硬件部署**：与神经形态芯片团队合作，将算法部署到真实硬件上，发现理论复杂度之外的工程问题。

c) 对高级研究人员的建议：高级研究人员应着眼于理论突破和系统级创新：

- 1) **统一理论框架**：建立包含时间近似、空间近似、误差近似、存储近似、通信近似和硬件近似的统一优化理论。
- 2) **理论边界研究**：从信息论和优化理论角度，严格推导在线梯度与BPTT梯度的最小可能误差。
- 3) **多任务持续学习系统**：设计完整的在线持续学习系统，在机器人、自动驾驶等真实场景中验证。
- 4) **脑启发理论的数学化**：将神经科学中更复杂的可塑性规则（如神经调节、三因子可塑性的多种变体）数学化并融入在线学习框架。

总体来看，一个理想的在线SNN学习算法应当同时满足：

精确的时间信用分配 + 空间局部性 + 硬件友好性 + 持续学习能力

这条研究路线不仅能够统一当前已有的大多数在线学习算法，同时也能够为未来新的SNN在线学习理论、算法以及硬件设计提供系统性的理论基础和发展方向。

XII. 结论

本文围绕脉冲神经网络在线学习的核心挑战，系统回顾了OTTT、NDOT、S-TLLR和TESS四种算法的技术特点与复杂度特性，并在此基础上提炼出九个关键研究问题：在线梯度信息丢失分析、梯度误差补偿、生物合理性与高性能平衡、存储-计算帕累托优化、资格迹重新定义、学习信号设计、硬件协同设计、持续学习融合，以及统一理论框架的建立。针对每个问题，我们提出了具体可行的推进方案，涵盖理论分析、算法设计、实验基准与硬件实现等多个层面。

我们相信，沿着上述研究方向深入探索，将有望推动SNN在线学习从实验室走向真实边缘应用，为低功耗智能系统提供坚实的理论与技术支撑。

参考文献

- [1] R. J. Williams and D. Zipser, "A learning algorithm for continually running fully recurrent neural networks," *Neural computation*, vol. 1, no. 2, pp. 270–280, 1989.
- [2] G. Bellec, F. Scherr, A. Subramoney, E. Hajek, D. Salaj, R. Legenstein, and W. Maass, "A solution to the learning dilemma for recurrent networks of spiking neurons," *Nature Communications*, vol. 11, no. 1, p. 3625, Jul. 2020. [Online]. Available: <https://doi.org/10.1038/s41467-020-17236-y>
- [3] M. Xiao, Q. Meng, Z. Zhang, D. He, and Z. Lin, "Online Training Through Time for Spiking Neural Networks," in *Advances in Neural Information Processing Systems*, S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, and A. Oh, Eds., vol. 35. Curran Associates, Inc., 2022, pp. 20 717–20 730. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2022/file/82846e19e6d42ebfd4ace4361def29ae-Paper-Conference.pdf
- [4] H. Jiang, G. D. Masi, H. Xiong, and B. Gu, "NDOT: Neuronal Dynamics-based Online Training for Spiking Neural..." [Online]. Available: <https://openreview.net/forum?id=eIF0QoBSFV>
- [5] M. P. E. Apolinario and K. Roy, "S-TLLR: STDP-inspired Temporal Local Learning Rule for Spiking Neural Networks," Oct. 2024, arXiv:2306.15220 [cs]. [Online]. Available: <http://arxiv.org/abs/2306.15220>
- [6] M. P. E. Apolinario, K. Roy, and C. Frenkel, "TESS: A Scalable Temporally and Spatially Local Learning Rule for Spiking Neural Networks," in *2025 International Joint Conference on Neural Networks (IJCNN)*, Jun. 2025, pp. 1–9, iSSN: 2161-4407. [Online]. Available: <https://ieeexplore.ieee.org/abstract/document/11227652>