

SNN 在线学习与本地学习的未来发展方向 与本人研究方向探索

Tao

摘要

本文基于对 BPTT、OTTT、NDOT、S-TLLR、TESS、E-prop、RTRL 等 SNN 训练算法的系统调研，梳理当前研究的主要技术路线（从离线 BPTT 到在线 OTTT/NDOT，再到本地 S-TLLR/TESS），分析各路线中的信息丢失环节与近似假设，提出未来可能的研究方向及本人聚焦的研究思路。

RTRL: A learning algorithm for continually running fully recurrent neural networks [?];

E-prop: A solution to the learning dilemma for recurrent networks of spiking neurons [?];

OTTT: Online Training Through Time for Spiking Neural Networks [1];

NDOT: NDOT: Neuronal Dynamics-based Online Training for Spiking Neural Networks [2];

S-TLLR: S-TLLR: STDP-inspired Temporal Local Learning Rule for Spiking Neural Networks [3];

TESS: TESS: A Scalable Temporally and Spatially Local Learning Rule for Spiking Neural Networks [4]

I. 引言：当前研究格局

SNN 训练算法的演化路径可概括为：

$$\text{BPTT/STBP} \rightarrow \text{Online (OTTT/NDOT/E-prop)} \rightarrow \text{Local (S-TLLR/TESS)} \quad (1)$$

这一演化的核心驱动力是对以下三个目标的权衡：

- 1) **梯度精确性**：越接近完整 BPTT，梯度估计越准确；
- 2) **内存与计算效率**：O(1) 内存、在线更新、低计算复杂度；
- 3) **生物合理性与硬件适配**：局部规则、无全局反传、适合神经形态芯片。

当前各方法在这三个维度上的定位大致如下：

II. 核心问题分析：信息丢失的环节

A. 离散化导致的信息丢失

SNN 的脉冲生成函数为 Heaviside 阶跃函数：

$$s[t] = H(u[t] - V_{th}) \quad (2)$$

其导数几乎处处为 0，导致梯度无法直接传播。当前所有方法均以某种方式处理此问题：

表 I: 各算法在三个维度上的定位

方法	梯度精确性	计算效率	生物合理性
BPTT/STBP	最高（精确）	低（ $O(T)$, 离线）	低
OTTT	中（近似）	高（ $O(1)$, 在线）	中
NDOT	较高（物理）	高（ $O(1)$, 在线）	中
S-TLLR	中（三因子）	中（ $O(n)$, 在线）	高
TESS	中（全本地）	最高（ $O(C)$, 在线）	很高
E-prop	中（资格迹）	中（在线）	高
RTRL	较高（精确）	低（ $O(n^3)$ ）	中

- **代理梯度（Surrogate Gradient）**: BPTT/STBP、OTTT、NDOT 在反向传播中用光滑函数导数替代 H' ，本质上是引入一个近似，丢失了精确的二值信息。
- **次级激活函数 Ψ** : S-TLLR 和 TESS 使用 $\Psi(u)$ 来衡量“距发放的接近程度”，避免了对阶跃函数求导，但 Ψ 本身的设计（形状、宽度）是一个超参数，同样引入了信息偏差。
- **E-prop 的资格迹**: 利用突触前后活动的痕迹来构造学习信号，回避了直接对 spike 求导，但资格迹的衰减常数 β 决定了信息保留的时间尺度，过长或过短都会导致信息丢失或噪声积累。

B. 时间截断导致的信息丢失

- **BPTT**: 保留完整时间序列，无截断丢失，但 $O(T)$ 内存不可接受。
- **OTTT**: 通过丢弃重置路径（ $\frac{\partial u[i+1]}{\partial s[i]} \frac{\partial s[i]}{\partial u[i]} \approx 0$ ），将时序核简化为固定 $\lambda^{t-\tau}$ 。这等同于假设“spike 只通过泄漏影响未来，发放本身不影响未来的膜电位动态”——这显然是一个物理上不精确的近似。
- **NDOT**: 用动态比值 $e[t] = \frac{u[t]-V_{th}s[t]}{u[t-1]-V_{th}s[t-1]}$ 替代固定 λ ，比 OTTT 保留了更多神经元状态信息，但仍然是一种单步线性近似，未完全恢复 BPTT 中的重置耦合路径。

C. 空间信用分配中的信息丢失

- **BPTT/OTTT/NDOT**: 完整保留空间反向传播，通过 $\frac{\partial L}{\partial s^{l+1}}$ 逐层传递误差，空间信息损失最小。
- **S-TLLR**: 学习信号 δ 仍来自 BP 或 DFA（Direct Feedback Alignment），DFA 使用随机固定矩阵替代精确的层间 Jacobian，引入随机投影误差。
- **TESS**: 通过 LSG（Local Signal Generation）完全切断层间依赖， $\mathbf{v}_m^{(l)} = \mathbf{B}^{(l)\top}(f(\mathbf{B}^{(l)}\mathbf{o}^{(l)}) - \mathbf{y}^*)$ ，其中 $\mathbf{B}$ 为固定随机方波矩阵。虽然 $\mathbf{B}$ 准正交，但随机投影不可避免地丢失了精确的梯度方向信息。理论上有：

$$\mathbb{E}[\mathbf{B}^\top \mathbf{B} \mathbf{x}] = \mathbf{x} + \epsilon(\mathbf{B}, \mathbf{x}) \quad (3)$$

其中 ϵ 是投影误差项。

D. 资格迹设计中的信息丢失

三因子规则的一般形式：

$$\Delta w_{ij} = \sum_t \delta_i[t] \cdot e_{ij}[t] \quad (4)$$

资格迹 $e_{ij}[t]$ 的设计决定了“哪些历史信息被保留”：

- **标准资格迹**： $e_{ij}[t] = \beta e_{ij}[t-1] + f(y_i[t])g(x_j[t])$ ， β 控制衰减速度。固定 β 无法自适应不同时间尺度的依赖关系。
- **S-TLLR 的因果/非因果资格迹**：显式区分 α_{pre} （因果）和 α_{post} （非因果）两项，比标准资格迹更丰富，但 α_{post} 取值的符号（+1 奖励、-1 惩罚、0 忽略）是一个离散选择，丢失了连续的信度信息。

III. 未来可能的研究方向

A. 方向一：信息丢失的可恢复性理论研究

核心问题：在各算法的近似环节中，丢失的信息究竟是可逆的“压缩”还是不可逆的“损坏”？
具体可研究的内容：

- 对 OT/NDOT/S-TLLR/TESS 分别定义信息丢失的度量（如互信息 $I(\nabla_{BPTT} L; \nabla_{approx} L)$ 、梯度余弦相似度），系统量化各近似环节的信息损失量。
- 证明或证伪：在什么条件下，近似梯度 $\nabla_{approx} L$ 的方向足以保证收敛？
- 借鉴压缩感知/信息论框架，分析“哪些信息可以通过额外的辅助变量恢复，哪些不可逆”。

B. 方向二：自适应时序核设计

OTTT 和 NDOT 的核心差异在于时序核是固定 λ 还是动态 $e[t]$ 。这暗示了一个更一般的问题：
是否可以在 $O(1)$ 内存约束下，设计更精确的时序核来近似 BPTT 的完整连乘项？

$$\prod_{i=k}^{t-1} (\lambda + (-\lambda V_{th}) \cdot \sigma') \approx ? \quad (5)$$

可能的技术路线：

- 引入可学习的时序核参数 $\lambda_\theta(u[t], s[t])$ ，用一个微型网络预测当前时间步的衰减系数。
- 用 Kalman 滤波或状态空间模型的思路，将膜电位动态建模为带噪声的线性系统， $u[t+1] = A_t u[t] + B_t s[t] + w_t$ ，通过在线滤波估计“最优”衰减系数 A_t 。
- 用神经 ODE 框架， $u'(t) = f(u(t), t; \theta)$ ，将离散的时序核推广为连续时间模型，在 $O(1)$ 内存下获得更丰富的时序表示。

C. 方向三：本地学习信号的增强与校正

TESS 的 LSG 用固定随机矩阵 B 生成本地学习信号，实现了空间本地化，但引入了投影误差。

可以在不恢复全局 BP 的前提下，减少 LSG 的投影误差吗？

可能的技术路线：

- **自适应 B 矩阵**：在训练过程中逐步更新 B （如通过 Hebbian 规则或局部 Hebbian 学习），使其列向量逐步与数据分布对齐，减少投影误差。
- **辅助重建信号**：在各层引入一个轻量解码器，将 LSG 信号 $\mathbf{v}_m^{(l)}$ 映射回标签空间，与全局标签比较产生本地校正信号，实现“准本地”误差修正。

- **共识机制：**多个本地信号的“投票”或“共识”可用作额外的正则化，减少单层的投影误差在整个网络中的累积效应。

D. 方向四：混合学习策略

不需要在全网统一使用同一种学习规则。可以针对不同层设计不同的学习策略：

- 浅层（靠近输入）使用全本地规则（TESS-style），减少计算开销；深层（靠近输出）使用更精确的在线规则（NDOT-style），保证关键语义层的信息完整性。
- 对关键时间步（如 spike 发放密集的时刻）启用更精确的时序回溯，对其余时间步使用快速近似——类似于 adaptive computation time 的思想。
- 结合 ANN-SNN 转换的思路，在 SNN 训练中周期性地用 ANN 教师网络的梯度信号进行校准。

E. 方向五：多时间尺度学习

当前的资格迹和时序核大多使用单一时间常数 λ 或 β 。但生物神经网络中存在多种时间尺度的可塑性（从毫秒级的 STDP 到分钟级的 homeostatic plasticity）。

- 设计多尺度资格迹： $e_{ij}^{(\tau)}[t]$ 对应不同时间常数 $\tau_1, \tau_2, \dots, \tau_k$ ，在不同时间尺度上捕获时序依赖。
- 引入门控机制自动选择/融合不同尺度的资格迹。
- 与神经形态硬件的多时间常数突触电路设计对齐。

IV. 本人研究方向探索

基于以上分析，本人拟聚焦以下研究方向：

A. 核心问题：在线/本地学习中的信息恢复

问题陈述：在 $O(1)$ 内存和在线更新的约束下，各算法的近似环节（代理梯度、丢弃重置路径、固定衰减、随机投影）会导致梯度估计与真实 BPTT 梯度之间存在偏差。本研究的核心问题是——在保持 $O(1)$ 内存和在线更新的前提下，能否通过引入额外的辅助状态变量或轻量校准机制，将近似梯度中丢失的信息部分恢复，从而在不显著增加计算成本的前提下提升训练精度？

B. 具体研究思路

1) 思路 A：NDOT 时序核的扩展——带记忆的多步近似：NDOT 的 $e[t] = \frac{u[t] - V_{th}s[t]}{u[t-1] - V_{th}s[t-1]}$ 是对单步比值的利用，形成的是望远镜乘积的化简。但 BPTT 中真正的时序核包含了重置路径的贡献（青色×红色项）。

idea：在 $O(1)$ 内存下维护一个额外的“重置轨迹”辅助变量（大小为 n 的向量），记录最近的 spike 事件的累积影响，用于修正 $e[t]$ 的估计。数学上：

$$\tilde{e}[t] = e[t] + \alpha \cdot \underbrace{\text{ResetCorrection}(s[t-k:t])}_{\text{基于最近 spike 历史的校正}} \quad (6)$$

2) 思路 B: TESS 中 LSG 的 Hebbian 自适应投影: TESS 的 LSG 使用固定 $\mathbf{B}$ 矩阵, 投影误差 ϵ 在训练过程中无法改善。考虑引入轻量的 Hebbian 自适应:

$$\Delta \mathbf{B}^{(l)} = \eta \cdot \mathbf{v}_m^{(l)}[t] \otimes \mathbf{o}^{(l)}[t] \quad (7)$$

即在生成学习信号的同时, 用学习信号自身的结构来微调投影矩阵, 使 $\mathbf{B}$ 逐步与当前层的数据流形对齐。这一更新本身是局部的 (仅依赖层内信息), 不破坏 TESS 的空间本地性。

3) 思路 C: 信息丢失的度量与自适应补偿: 对每个近似环节, 在线计算近似梯度与“假想的精确梯度”之间的对齐度量:

$$\text{Align}[t] = \cos(\nabla_{\text{approx}} L[t], \nabla_{\text{exact}} L[t]) \quad (8)$$

当 $\text{Align}[t]$ 低于阈值时, 触发补偿机制 (如增大代理梯度的宽度、减小资格迹的衰减率、或临时启用更精确的计算路径)。这种“按需补偿”的策略在平均意义上保持 $O(1)$ 内存, 但在关键时刻提供更准确的梯度。

C. 预期贡献

- 1) 系统性地分析并量化各 SNN 在线/本地学习算法中信息丢失的来源、环节与程度。
- 2) 提出一种或多种轻量级的信息恢复机制 (如在 NDOT 基础上扩展重置校正、或在 TESS 基础上引入自适应投影), 在不超出 $O(1)$ 内存约束的前提下提升梯度估计精度。
- 3) 在标准 benchmark (CIFAR-10/100、DVS-Gesture、SHD 等) 上验证所提方法的有效性。
- 4) 为目标应用场景 (边缘设备、神经形态硬件) 提供理论指导与算法支撑。

V. 总结

本文梳理了 SNN 训练算法从 BPTT 到在线学习再到本地学习的演化路径, 分析了各算法中的信息丢失环节 (离散化、时间截断、空间投影近似、资格迹设计), 提出了五个未来可能的研究方向 (可恢复性理论、自适应时序核、LSG 增强、混合策略、多时间尺度), 并在此基础上明确了本人拟聚焦的研究问题——在 $O(1)$ 内存和在线约束下的信息恢复, 给出了三条具体的探索思路。

参考文献

- [1] M. Xiao, Q. Meng, Z. Zhang, D. He, and Z. Lin, “Online Training Through Time for Spiking Neural Networks,” in *Advances in Neural Information Processing Systems*, S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, and A. Oh, Eds., vol. 35. Curran Associates, Inc., 2022, pp. 20717–20730. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2022/file/82846e19e6d42ebfd4ace4361def29ae-Paper-Conference.pdf
- [2] H. Jiang, G. D. Masi, H. Xiong, and B. Gu, “NDOT: Neuronal Dynamics-based Online Training for Spiking Neural...” [Online]. Available: <https://openreview.net/forum?id=eIF0QoBSFV>
- [3] M. P. E. Apolinario and K. Roy, “S-TLLR: STDP-inspired Temporal Local Learning Rule for Spiking Neural Networks,” Oct. 2024, arXiv:2306.15220 [cs]. [Online]. Available: <http://arxiv.org/abs/2306.15220>
- [4] M. P. E. Apolinario, K. Roy, and C. Frenkel, “TESS: A Scalable Temporally and Spatially Local Learning Rule for Spiking Neural Networks,” in *2025 International Joint Conference on Neural Networks (IJCNN)*, Jun. 2025, pp. 1–9, iSSN: 2161-4407. [Online]. Available: <https://ieeexplore.ieee.org/abstract/document/11227652>