

脉冲神经网络在线学习的关键问题与推进方案

1 SNN在线学习的发展方向与未来研究问题

近年来，脉冲神经网络（Spiking Neural Networks, SNN）的在线学习（Online Learning）逐渐成为神经形态计算领域的重要研究方向。与传统深度神经网络主要依赖反向传播算法（Backpropagation Through Time, BPTT）进行离线训练不同，SNN更加希望能够模拟生物神经系统持续学习（Continual Learning）的能力，即在数据到达的同时立即完成参数更新，而无需等待整个时间序列结束。因此，如何设计一种兼具在线性（Online）、高精度（Accuracy）、低存储（Low Memory）、低计算（Low Computation）以及良好硬件可部署性（Hardware-friendly）的学习算法，已经成为当前SNN研究的重要目标。

目前，围绕这一目标已经出现了RTRL、Eligibility Trace、E-prop、OTTT、NDOT、TESS、S-TLLR等一系列在线学习算法。这些方法虽然在形式上各不相同，但本质上都在回答同一个科学问题，即如何在不执行完整BPTT的情况下尽可能恢复真实梯度，从而实现在线学习。因此，与其将这些算法视为彼此独立的方法，不如将整个领域重新归纳为若干个尚未解决的关键科学问题。未来SNN在线学习的发展，也将主要围绕这些问题展开。

1.1 关键问题一：在线学习究竟丢失了哪些梯度信息？

目前几乎所有在线学习算法都会宣称自身是在对BPTT进行某种近似（Approximation），然而绝大多数工作仅仅关注如何构造新的梯度表达式，却很少回答一个更加本质的问题：在线学习究竟丢失了哪些信息？

BPTT能够获得完整梯度，是因为它能够保存整个时间序列上的神经元状态，并利用未来时刻产生的误差信号对历史状态进行统一修正。因此，一个完整的梯度实际上包含了多个不同来源的信息，包括未来误差（Future Error）、未来状态依赖（Future State Dependency）、时间信用分配（Temporal Credit Assignment）、跨层误差传播（Spatial Dependency）以及网络整体优化目标（Global Objective）等多个组成部分。

然而，大多数在线学习算法都会主动舍弃其中的一部分信息。例如，OTTT主要通过Detach机制忽略未来状态依赖；E-prop利用Eligibility Trace替代完整时间展开，因此舍弃了完整未来误差传播；NDOT则进一步利用神经元动力学模型近似未来梯度；而TESS则通过时间窗口截断减少历史依赖。这些方法虽然能够显著降低计算复杂度，却不可避免地引入梯度误差。

因此，一个值得深入研究的问题是建立一套统一的信息分析框架（Information Decomposition Framework），将真实梯度拆分为多个组成部分，并分析不同算法究竟保留了哪些信息、舍弃了哪些信息，以及这些信息缺失分别对最终性能造成怎样的影响。进一步地，可以构建一

种Information Loss Taxonomy，对现有所有在线学习算法按照信息损失类型进行统一分类，为未来算法设计提供理论依据。

1.2 关键问题二：如何补偿在线梯度与真实梯度之间的误差？

在线学习算法的本质目标并不是重新定义梯度，而是在有限计算资源下尽可能逼近真实梯度。因此，几乎所有在线学习方法最终都可以写成如下统一形式：

$$g_{\text{online}} = g_{\text{true}} + \epsilon,$$

其中， g_{true} 表示BPTT产生的真实梯度，而 ϵ 表示由于在线近似所带来的梯度误差。

不同算法产生误差的来源并不相同。例如，OTTT中的误差主要来源于Detach带来的梯度截断；E-prop中的误差主要来源于Learning Signal对真实误差信号的替代；NDOT则来源于神经元动力学模型的近似；而TESS主要来源于时间截断所引起的信息缺失。

未来研究的重要方向，不再是不断设计新的在线梯度表达式，而是直接研究误差项 ϵ 本身。可以尝试建立梯度误差建模方法（Gradient Error Modeling），分析误差的统计特性，并进一步设计梯度补偿网络（Gradient Compensation Network）、残差梯度修正（Residual Gradient Correction）、元学习补偿（Meta Gradient Compensation）等机制，使在线梯度逐渐逼近真实梯度。这一方向不仅具有较强的理论价值，也有望突破当前在线学习精度普遍低于BPTT的瓶颈。

1.3 关键问题三：Eligibility Trace是否存在新的定义方式？

Eligibility Trace作为目前在线学习最核心的理论基础之一，其本质作用是在局部保存神经元历史信息，以替代BPTT对整个时间序列的存储。目前，大多数Eligibility Trace都采用统一形式：

$$e_t = \frac{\partial s_t}{\partial W},$$

即利用神经元状态对权重的偏导数描述历史影响。

然而，这种定义方式实际上只是众多可能形式中的一种。未来研究可以进一步思考：Eligibility Trace是否一定只能定义在单个神经元层面？是否可以扩展到更高层次的信息表示？

例如，可以研究Layer-level Eligibility，即以整个网络层作为信息保存单位；研究Feature-level Eligibility，以神经特征作为追踪对象；研究Memory-level Eligibility，将历史信息压缩到低维状态空间；甚至研究Frequency-level Eligibility或Spike Cluster Eligibility，以事件簇或频率信息替代传统资格迹。这些新的定义方式有可能进一步降低存储需求，同时提高在线学习效率。

因此，重新定义Eligibility Trace，将其由传统神经元级表示推广到更加抽象、更适合硬件实现的信息表示形式，将是未来的重要研究方向之一。

1.4 关键问题四：Learning Signal应该如何设计？

E-prop提出之后，Learning Signal逐渐成为在线学习研究的重要组成部分。目前，大多数Learning Signal主要来源于全局误差（Global Error）、局部分类器（Local Classifier）、随机投影（Random

Projection)、教师信号 (Teacher Signal) 以及Synthetic Gradient等不同来源。

然而, 目前尚不存在一种统一的方法能够说明什么样的Learning Signal才是最优的。理想的Learning Signal应当同时满足信息丰富、通信开销低、能够在线生成、具有较好的训练稳定性, 并且适合神经形态硬件实现等多个要求。

未来可以进一步研究Learning Signal的自动生成机制。例如, 引入注意力机制 (Attention) 动态调节误差信号; 利用预测网络 (Predictor) 生成未来误差估计; 利用自监督学习 (Self-supervised Learning) 构建局部训练目标; 或者利用教师-学生网络 (Teacher-Student Framework) 产生更加稳定的局部监督信息。Learning Signal未来的发展方向, 很可能从固定信号逐渐演变为动态、自适应甚至可学习的误差生成机制。

1.5 关键问题五: 如何实现在线学习与神经形态硬件的协同设计?

目前, 大多数在线学习算法主要关注数学模型, 而硬件实现通常作为后续工作独立开展。然而, 对于神经形态芯片而言, 算法设计与硬件资源之间存在高度耦合关系。

例如, Eligibility Trace虽然能够降低时间展开带来的存储需求, 但仍需要保存大量中间状态; 局部学习虽然减少了误差传播距离, 却可能增加局部分类器带来的额外计算; Learning Signal虽然能够提高训练精度, 却可能带来较大的通信开销。因此, 仅仅优化算法而忽略硬件限制, 很难真正实现高效片上学习。

未来更加重要的发展方向是算法-体系结构-电路的协同优化 (Algorithm-Architecture Co-design)。例如, 可以设计稀疏资格迹 (Sparse Eligibility Trace)、量化资格迹 (Quantized Eligibility Trace)、共享资格迹 (Shared Trace)、压缩资格迹 (Compressed Trace) 等机制, 进一步减少片上存储需求。同时, 可以根据FPGA、ASIC以及神经形态芯片的资源特点, 共同设计学习规则、存储结构以及计算流程, 使在线学习真正适用于低功耗硬件部署。

1.6 关键问题六: 是否能够建立统一的在线学习理论框架?

目前, RTRL、E-prop、OTTT、NDOT、TESS以及S-TLLR等算法形式各异, 看似属于不同的发展路线。然而, 从梯度计算角度来看, 这些算法本质上都可以理解为真实梯度的不同近似形式。

因此, 一个具有长期价值的研究方向是建立统一的在线学习理论框架, 将各种算法统一表示为

$$\Delta W = \text{Learning Signal} \times \text{Eligibility},$$

或者进一步表示为

$$\Delta W = \text{Approximation}(\nabla_{\text{BP-TT}}).$$

在这一统一框架下, 不同算法之间的区别将不再体现在公式形式, 而体现在不同的信息近似策略, 包括时间近似 (Temporal Approximation)、空间近似 (Spatial Approximation)、误差近似 (Error Approximation)、存储近似 (Memory Approximation)、通信近似 (Communication Approximation) 以及硬件近似 (Hardware Approximation) 等多个维度。

基于上述思想，可以进一步建立Online Learning Approximation Space，对现有所有在线学习算法进行统一分类，并分析各种近似策略之间的联系与差异。这不仅能够帮助研究者更加清晰地理解现有算法的发展脉络，也能够为未来设计新的在线学习算法提供统一理论指导。

1.7 未来研究路线总结

综合以上分析可以发现，目前SNN在线学习的发展已经逐渐由单纯提出新算法，转向更加系统的理论与协同优化研究。未来更加值得关注的方向，不再是不断设计新的梯度更新公式，而是从信息论、优化理论以及硬件实现等多个角度重新理解在线学习的本质。

未来较为完整的一条研究路线可以概括为：首先建立BPTT梯度的信息分解理论，明确在线学习过程中不同算法所丢失的信息类型；随后建立统一的梯度误差建模方法，对在线梯度与真实梯度之间的偏差进行理论分析；进一步设计梯度补偿机制以及更加高效的Learning Signal和Eligibility Trace表示方式，提高在线学习精度；最后结合神经形态硬件平台开展算法—体系结构协同优化，实现真正适用于片上学习（On-chip Learning）的高效在线学习系统。

这一研究路线不仅能够统一当前已有的大多数在线学习算法，同时也能够为未来新的SNN在线学习理论、算法以及硬件设计提供系统性的理论基础和发展方向。

2 研究背景

脉冲神经网络（Spiking Neural Networks, SNNs）由于其事件驱动、稀疏激活和低功耗计算特性，被认为是面向神经形态硬件和边缘智能的重要模型。然而，SNN的训练仍然面临较大挑战。一方面，脉冲发放函数通常由Heaviside 阈值函数表示，具有不可导特性；另一方面，膜电位在时间维度上递归演化，使得当前输出不仅依赖当前输入，还依赖历史状态。因此，SNN训练同时涉及空间维度的误差传播和时间维度的 credit assignment。

传统的 BPTT with surrogate gradient 方法可以较好地训练 SNN。其基本思想是将 SNN 沿时间展开，并在反向传播中使用 surrogate gradient 近似脉冲函数导数。然而，该方法需要保存所有时间步的膜电位、脉冲输出和计算图，因此训练内存随时间步数线性增长，难以满足在线学习和神经形态硬件的实时更新需求。

近年来，E-prop、OTTT、NDOT、S-TLLR 和 TESS 等方法试图减少 BPTT 的时间展开开销，使训练过程更加在线化和局部化。这些方法的核心目标可以概括为：在不保存完整时间历史的情况下，尽可能准确地近似 BPTT 的时空梯度，并使权重更新更加适合实时学习和硬件实现。围绕这一目标，仍然存在多个值得深入探索的问题。

3 关键问题一：时间依赖建模是否足够准确

SNN 在线学习的核心问题之一是如何准确表示时间维度上的依赖关系。在完整 BPTT 中，膜电位从 t 到 $t+1$ 的时间依赖可以写为：

$$\epsilon^l[t] = \frac{\partial u^l[t+1]}{\partial u^l[t]} + \frac{\partial u^l[t+1]}{\partial s^l[t]} \frac{\partial s^l[t]}{\partial u^l[t]}. \quad (1)$$

其中第一项表示膜电位自身的递归传播，例如泄露或衰减；第二项表示由脉冲发放引起的反馈路径，即 $u^l[t] \rightarrow s^l[t] \rightarrow u^l[t+1]$ 。这一项是 SNN 区别于普通 RNN 的关键，因为 spike 既是非连续的输出，又参与后续膜电位更新。

OTTT 为了实现在线训练，通常将 spike feedback 项近似忽略，即：

$$\frac{\partial u^l[t+1]}{\partial s^l[t]} \frac{\partial s^l[t]}{\partial u^l[t]} \approx 0, \quad (2)$$

于是时间依赖退化为固定泄露因子：

$$\epsilon^l[t] \approx \lambda. \quad (3)$$

NDOT 则进一步提出使用神经元动力学中的连续时间依赖来近似这一过程：

$$\epsilon^l[t] = \frac{u^l[t] - V_{th}s^l[t]}{u^l[t-1] - V_{th}s^l[t-1]}. \quad (4)$$

因此，一个重要研究问题是： $\epsilon^l[t]$ 在什么条件下能够更好地近似 BPTT 中的 $\epsilon^l[t]$ ？这一问题可以通过理论和实验两条路线推进。

理论上，可以定义近似误差：

$$\Delta^l[t] = \epsilon^l[t] - e^l[t], \quad (5)$$

并分析该误差与膜电位分布、发放率、阈值距离、泄露因子 λ 、surrogate gradient 形状以及时间步数之间的关系。尤其需要关注膜电位接近阈值时的情况，因为此时 spike feedback 项对梯度的影响可能显著增大。

实验上，可以比较 BPTT、OTTT 和 NDOT 对时间依赖的不同处理方式：

$$\begin{aligned} \text{BPTT: } & \epsilon^l[t], \\ \text{OTTT: } & \lambda, \\ \text{NDOT: } & \epsilon^l[t]. \end{aligned} \quad (6)$$

具体评价指标可以包括梯度余弦相似度、梯度误差、训练收敛速度、最终分类精度和训练稳定性。该方向的预期贡献是明确说明：NDOT 的动力学依赖项在什么条件下优于 OTTT 的固定泄露近似，以及在哪些场景下仍然可能失效。

4 关键问题二：空间梯度是否仍然过于全局

许多在线训练方法主要解决的是时间维度的反传问题，但空间维度仍然依赖全局误差反向传播。例如，在 NDOT 中，梯度被分解为：

$$\nabla_{W^l} L = \sum_{t=1}^T g_u^l[t] \left(\hat{a}^{l-1}[t] \right)^\top, \quad (7)$$

其中 $\hat{a}^{l-1}[t]$ 表示时间维度上的历史轨迹或 temporal gradient，而 $g_u^l[t]$ 表示空间维度上的梯度。虽然时间项可以通过前向递推得到，但 $g_u^l[t]$ 仍然通常需要从输出层反向传播得到。因此，现有在线方法往往只是 temporal online，而不是完全 local learning。

该问题可以表述为：能否进一步减少甚至去除 spatial backpropagation，使 SNN 在线学习同时具备时间局部性和空间局部性？这一方向可以从三种方案推进。

第一种方案是引入 local loss。对于每一层 l ，可以增加一个局部分类头或局部预测模块，并定义局部损失：

$$L^l[t] = \ell(h^l[t], y), \quad (8)$$

其中 $h^l[t]$ 是由该层神经元状态或 spike 生成的局部输出。此时空间梯度可以由局部损失直接计算：

$$g_u^l[t] = \frac{\partial L^l[t]}{\partial u^l[t]}. \quad (9)$$

第二种方案是 feedback alignment，用固定随机矩阵 B^l 替代真实反向传播权重：

$$g_u^l[t] \approx B^l \frac{\partial L[t]}{\partial s^N[t]}. \quad (10)$$

这样可以减少对精确全局反传路径的依赖。

第三种方案是 learned local error。可以训练一个小型局部误差预测模块：

$$\hat{g}_u^l[t] = \phi^l(u^l[t], s^l[t]), \quad (11)$$

使其尽可能预测真实的空间梯度 $g_u^l[t]$ 。该模块只依赖当前层局部活动，因此更接近硬件友好的局部学习。

实验上，可以比较原始 NDOT、NDOT + local loss、NDOT + feedback alignment 和 NDOT + learned local error。评价指标除了 accuracy，还应包括反向通信开销、局部性程度、硬件可实现性和训练稳定性。该方向的潜在贡献是将在线学习从 temporal online 推进到 temporal online + spatial local，从而自然连接到 TESS 等 fully local learning 方向。

5 关键问题三：instantaneous loss 是否限制在线学习性能

在线学习通常使用每个时间步的即时损失：

$$L[t] = \ell(s^N[t], y), \quad (12)$$

而传统 SNN 分类任务往往基于整个时间窗口的平均发放率：

$$L_{\text{offline}} = \ell\left(\frac{1}{T} \sum_{t=1}^T s^N[t], y\right). \quad (13)$$

这就带来一个问题：instantaneous loss 是否破坏了时间窗口内的整体决策信息？如果每个时间步都独立要求输出正确，模型可能无法充分利用跨时间累积的信息，尤其是在早期时间步输出尚不稳定时，强行施加监督信号可能引入噪声梯度。

一个可行方案是构造带历史记忆的 online loss。首先可以定义指数滑动平均输出：

$$\bar{s}^N[t] = \beta \bar{s}^N[t-1] + (1 - \beta) s^N[t], \quad (14)$$

并以其作为当前时间步的分类依据：

$$L[t] = \ell(\bar{s}^N[t], y). \quad (15)$$

这种方法仍然满足在线计算，但比单步 spike 输出保留了更多历史信息。

另一种方案是 confidence-aware loss。可以根据当前时间步预测置信度调整损失权重：

$$L[t] = \alpha_t \ell(s^N[t], y), \quad (16)$$

其中 α_t 可以由输出熵、最大类别概率或 margin 决定。当模型在早期时间步不确定时，降低其损失权重；当输出逐渐稳定时，再增强监督信号。

还可以借鉴 FTRL 风格的正则化思想，引入历史最优权重或历史输出作为约束：

$$\hat{L}[t] = L[t] + \rho \|W - \hat{W}\|^2. \quad (17)$$

其中 $\hat{W}$ 可以来自小时间步预训练模型或历史阶段的累积最优模型。该方向的关键实验是比较 offline loss、instantaneous loss、temporal averaged loss、confidence-aware loss 和 FTRL-style loss，分析不同 loss 设计对在线训练性能和收敛稳定性的影响。

6 关键问题四：surrogate gradient 是否应该动态调整

SNN 的训练依赖 surrogate gradient：

$$\frac{\partial s}{\partial u} \approx \sigma'(u - V_{th}). \quad (18)$$

传统方法通常使用固定 surrogate function，例如 sigmoid surrogate、rectangular surrogate 或 fast sigmoid surrogate。然而，在线学习中的梯度在每个时间步实时产生，固定 surrogate 可能不是最优选择。如果 surrogate 过于尖锐，梯度只在阈值附近有效，可能导致训练不稳定；如果 surrogate 过于平滑，则会带来较大梯度偏差。

因此，可以研究 adaptive surrogate gradient。设 surrogate 的形状由参数 α_t 控制：

$$\frac{\partial s}{\partial u} \approx \sigma'_{\alpha_t}(u - V_{th}), \quad (19)$$

其中 α_t 可以根据膜电位分布、发放率和训练阶段动态调整：

$$\alpha_t = f(\text{Var}(u[t]), r[t], t). \quad (20)$$

这里 $\text{Var}(u[t])$ 表示膜电位方差， $r[t]$ 表示当前 firing rate。直觉上，当膜电位分布远离阈值时，可以使用较宽的 surrogate 来扩大有效梯度区域；当膜电位集中在阈值附近时，可以使用较窄的 surrogate 来提高梯度精度。

实验可以比较 fixed surrogate、time-adaptive surrogate、layer-adaptive surrogate 和 firing-rate-adaptive surrogate。该方向的预期目标是在保持在线训练低内存优势的同时，提高小时间步训练下的稳定性和精度。

7 关键问题五：单一 eligibility trace 是否足以处理长时间依赖

多数在线学习方法使用单一时间轨迹来压缩历史信息。例如 NDOT 中：

$$\hat{a}[t] = e[t-1] \odot \hat{a}[t-1] + s[t]. \quad (21)$$

该形式本质上是一阶递推，它能够以常数内存保留历史信息，但可能不足以表达复杂任务中的多时间尺度依赖。例如语音、动作识别和 delayed-response 任务往往需要同时保留短期和长期信息。

一个自然方向是设计 multi-timescale eligibility trace。可以定义多个不同时间尺度的 trace：

$$\hat{a}_m[t] = e_m[t-1] \odot \hat{a}_m[t-1] + s[t], \quad m = 1, \dots, M. \quad (22)$$

最终 trace 由不同时间尺度加权组合：

$$\hat{a}[t] = \sum_{m=1}^M \alpha_m \hat{a}_m[t]. \quad (23)$$

其中 $e_m[t]$ 可以对应不同的泄露因子、不同的动力学估计方式，或不同长度的历史窗口。该方案可以被看作对单一 NDOT trace 的扩展，使模型能够同时捕获短时脉冲模式和长期时序结构。

实验任务应选择对长时间依赖敏感的数据集，例如 SHD、SSC、DVS Gesture、DVS-CIFAR10 或 synthetic delayed-response task。评价指标包括长序列分类精度、trace 数量对性能的影响、计算开销和内存开销。该方向有机会形成 Multi-scale NDOT 或 Multi-timescale Online SNN Learning 方法。

8 关键问题六：在线学习中的权重更新时机如何设计

在线学习并不一定意味着每个时间步都必须立即更新权重。以 NDOT 为例，可以存在实时更新和累积更新两种策略：一种是在每个时间步计算梯度后立即更新权重，另一种是在多个时间步上累积梯度后再更新。二者各有优缺点。实时更新更符合在线学习和神经形态硬件要求，但可能带来梯度噪声和训练不稳定；累积更新更接近 mini-batch 或 offline 训练，稳定性较好，但在线性较弱。

因此，可以研究窗口式更新策略：

$$W[t+1] = W[t] - \eta \sum_{\tau=t-K+1}^t \nabla_W L[\tau]. \quad (24)$$

其中 K 是更新窗口大小。当 $K = 1$ 时，对应完全在线更新；当 $K = T$ 时，对应整个时间窗口累积更新；当 $1 < K < T$ 时，则是在在线性和稳定性之间折中。

实验可以设置 $K \in \{1, 2, 4, T\}$ ，并比较不同更新窗口下的最终精度、收敛速度、梯度方差、实时延迟和硬件写入频率。该研究可以形成一个 practical guideline，即什么任务适合 real-time update，什么任务适合 accumulated update，以及如何选择最优更新周期。

9 关键问题七：在线学习是否真的硬件友好

许多在线学习方法声称 memory efficient 或 hardware friendly，但算法层面的在线性并不等价于硬件上的高效实现。实际部署时还需要考虑 trace 存储、element-wise multiplication、surrogate gradient 计算、空间误差反传通信、权重更新频率以及片上存储容量。

因此，需要建立更完整的硬件成本模型：

$$C_{\text{total}} = C_{\text{mem}} + C_{\text{comm}} + C_{\text{mul}} + C_{\text{update}}. \quad (25)$$

其中 C_{mem} 表示状态和 trace 存储成本， C_{comm} 表示层间和误差信号通信成本， C_{mul} 表示乘法或近似乘法成本， C_{update} 表示权重写入和更新成本。

可以在同一模型规模和任务上比较 BPTT、E-prop、OTTT、NDOT、S-TLLR 和 TESS。评价不应只包括 accuracy，还应包括能耗、延迟、存储占用、通信量和是否支持片上更新。该方向的潜在贡献是提出更真实的 online hardware efficiency 指标，避免只从算法复杂度层面判断方法是否适合硬件部署。

10 关键问题八：在线学习能否与完全本地学习统一

当前 SNN 在线学习方法大多仍处于从 BPTT 到局部学习的过渡阶段。OTTT 和 NDOT 主要关注时间维度的在线化，但仍需要一定形式的空间误差信号；E-prop 使用 eligibility trace 与 learning signal 的分解形式，但 learning signal 仍可能是全局或半全局的；S-TLLR 和 TESS 则进一步强调 temporal locality 和 spatial locality。

因此，一个更大的研究问题是：能否构造统一框架，将在线学习、eligibility trace、temporal local learning 和 spatial local learning 统一起来？一个可能的统一形式是：

$$\Delta W^l[t] = \eta \cdot \mathcal{E}^l[t] \cdot \mathcal{L}_{\text{local}}^l[t], \quad (26)$$

其中 $\mathcal{E}^l[t]$ 表示突触或神经元局部可获得的时间轨迹， $\mathcal{L}_{\text{local}}^l[t]$ 表示局部学习信号。该形式可以覆盖 E-prop、NDOT-style trace、STDP-inspired rule 和 TESS-style spatial local signal。

推进方案可以分为三步。第一步，将不同方法统一写成 trace 与 learning signal 的乘积形式。第二步，比较不同 trace 对 temporal credit assignment 的表达能力。第三步，将空间误差信号替换为局部可计算信号，从而逐步减少对全局反传的依赖。

该方向适合作为综述或理论框架研究，也可以进一步发展为新的 fully online and fully local SNN learning algorithm。

11 总结

SNN 在线学习的核心挑战可以概括为：如何在不保存完整时间计算图的情况下，准确、稳定并且局部地近似 BPTT 梯度。围绕这一目标，未来可以从多个层面展开研究，包括时间依赖建模、空间局部误差、在线损失函数、自适应 surrogate gradient、多时间尺度 trace、权重更新策略、硬件成本建模以及在线学习与本地学习的统一框架。

如果从当前 OTTT、NDOT、S-TLLR 和 TESS 的研究脉络出发，最值得优先推进的方向有三个。第一是分析 $e[t]$ 与 $\epsilon[t]$ 的近似误差，明确在线时间依赖建模的理论边界。第二是将 NDOT 这类 temporal online 方法与 spatial local learning 结合，减少对全局反向传播的依赖。第三是设计 multi-timescale eligibility trace，以提升在线 SNN 对长时间依赖任务的建模能力。

总体来看，SNN 在线学习未来的关键目标可以写为：

$$\boxed{\text{Accurate Temporal Credit Assignment} + \text{Spatial Locality} + \text{Hardware Efficiency}} \quad (27)$$

也就是说，一个理想的在线 SNN 学习算法应当同时具备较高的梯度近似精度、较强的局部性、较低的存储和通信开销，以及在神经形态硬件上实时更新的能力。