

脉冲神经网络在线学习的关键问题与推进方案

1 研究背景

脉冲神经网络 (Spiking Neural Networks, SNNs) 由于其事件驱动、稀疏激活和低功耗计算特性, 被认为是面向神经形态硬件和边缘智能的重要模型。然而, SNN 的训练仍然面临较大挑战。一方面, 脉冲发放函数通常由 Heaviside 阈值函数表示, 具有不可导特性; 另一方面, 膜电位在时间维度上递归演化, 使得当前输出不仅依赖当前输入, 还依赖历史状态。因此, SNN 训练同时涉及空间维度的误差传播和时间维度的 credit assignment。

传统的 BPTT with surrogate gradient 方法可以较好地训练 SNN。其基本思想是将 SNN 沿时间展开, 并在反向传播中使用 surrogate gradient 近似脉冲函数导数。然而, 该方法需要保存所有时间步的膜电位、脉冲输出和计算图, 因此训练内存随时间步数线性增长, 难以满足在线学习和神经形态硬件的实时更新需求。

近年来, E-prop、OTTT、NDOT、S-TLLR 和 TESS 等方法试图减少 BPTT 的时间展开开销, 使训练过程更加在线化和局部化。这些方法的核心目标可以概括为: 在不保存完整时间历史的情况下, 尽可能准确地近似 BPTT 的时空梯度, 并使权重更新更加适合实时学习和硬件实现。围绕这一目标, 仍然存在多个值得深入探索的问题。

2 关键问题一: 时间依赖建模是否足够准确

SNN 在线学习的核心问题之一是如何准确表示时间维度上的依赖关系。在完整 BPTT 中, 膜电位从 t 到 $t+1$ 的时间依赖可以写为:

$$\epsilon^l[t] = \frac{\partial u^l[t+1]}{\partial u^l[t]} + \frac{\partial u^l[t+1]}{\partial s^l[t]} \frac{\partial s^l[t]}{\partial u^l[t]}. \quad (1)$$

其中第一项表示膜电位自身的递归传播, 例如泄露或衰减; 第二项表示由脉冲发放引起的反馈路径, 即 $u^l[t] \rightarrow s^l[t] \rightarrow u^l[t+1]$ 。这一项是 SNN 区别于普通 RNN 的关键, 因为 spike 既是非连续的输出, 又参与后续膜电位更新。

OTTT 为了实现在线训练, 通常将 spike feedback 项近似忽略, 即:

$$\frac{\partial u^l[t+1]}{\partial s^l[t]} \frac{\partial s^l[t]}{\partial u^l[t]} \approx 0, \quad (2)$$

于是时间依赖退化为固定泄露因子:

$$\epsilon^l[t] \approx \lambda. \quad (3)$$

NDOT 则进一步提出使用神经元动力学中的连续时间依赖来近似这一过程：

$$e^l[t] = \frac{u^l[t] - V_{th}s^l[t]}{u^l[t-1] - V_{th}s^l[t-1]}. \quad (4)$$

因此，一个重要研究问题是： $e^l[t]$ 在什么条件下能够更好地近似 BPTT 中的 $\epsilon^l[t]$ ？这一问题可以通过理论和实验两条路线推进。

理论上，可以定义近似误差：

$$\Delta^l[t] = \epsilon^l[t] - e^l[t], \quad (5)$$

并分析该误差与膜电位分布、发放率、阈值距离、泄露因子 λ 、surrogate gradient 形状以及时间步数之间的关系。尤其需要关注膜电位接近阈值时的情况，因为此时 spike feedback 项对梯度的影响可能显著增大。

实验上，可以比较 BPTT、OTTT 和 NDOT 对时间依赖的不同处理方式：

$$\begin{aligned} \text{BPTT: } & \epsilon^l[t], \\ \text{OTTT: } & \lambda, \\ \text{NDOT: } & e^l[t]. \end{aligned} \quad (6)$$

具体评价指标可以包括梯度余弦相似度、梯度误差、训练收敛速度、最终分类精度和训练稳定性。该方向的预期贡献是明确说明：NDOT 的动力学依赖项在什么条件下优于 OTTT 的固定泄露近似，以及在哪些场景下仍然可能失效。

3 关键问题二：空间梯度是否仍然过于全局

许多在线训练方法主要解决的是时间维度的反传问题，但空间维度仍然依赖全局误差反向传播。例如，在 NDOT 中，梯度被分解为：

$$\nabla_{W^l} L = \sum_{t=1}^T g_u^l[t] \left(\hat{a}^{l-1}[t] \right)^\top, \quad (7)$$

其中 $\hat{a}^{l-1}[t]$ 表示时间维度上的历史轨迹或 temporal gradient，而 $g_u^l[t]$ 表示空间维度上的梯度。虽然时间项可以通过前向递推得到，但 $g_u^l[t]$ 仍然通常需要从输出层反向传播得到。因此，现有在线方法往往只是 temporal online，而不是完全 local learning。

该问题可以表述为：能否进一步减少甚至去除 spatial backpropagation，使 SNN 在线学习同时具备时间局部性和空间局部性？这一方向可以从三种方案推进。

第一种方案是引入 local loss。对于每一层 l ，可以增加一个局部分类头或局部预测模块，并定义局部损失：

$$L^l[t] = \ell(h^l[t], y), \quad (8)$$

其中 $h^l[t]$ 是由该层神经元状态或 spike 生成的局部输出。此时空间梯度可以由局部损失直接计算：

$$g_u^l[t] = \frac{\partial L^l[t]}{\partial u^l[t]}. \quad (9)$$

第二种方案是 feedback alignment, 用固定随机矩阵 B^l 替代真实反向传播权重:

$$g_u^l[t] \approx B^l \frac{\partial L[t]}{\partial s^N[t]}. \quad (10)$$

这样可以减少对精确全局反传路径的依赖。

第三种方案是 learned local error. 可以训练一个小型局部误差预测模块:

$$\hat{g}_u^l[t] = \phi^l(u^l[t], s^l[t]), \quad (11)$$

使其尽可能预测真实的空间梯度 $g_u^l[t]$ 。该模块只依赖当前层局部活动, 因此更接近硬件友好的局部学习。

实验上, 可以比较原始 NDOT、NDOT + local loss、NDOT + feedback alignment 和 NDOT + learned local error。评价指标除了 accuracy, 还应包括反向通信开销、局部性程度、硬件可实现性和训练稳定性。该方向的潜在贡献是将在线学习从 temporal online 推进到 temporal online + spatial local, 从而自然连接到 TESS 等 fully local learning 方向。

4 关键问题三: instantaneous loss 是否限制在线学习性能

在线学习通常使用每个时间步的即时损失:

$$L[t] = \ell(s^N[t], y), \quad (12)$$

而传统 SNN 分类任务往往基于整个时间窗口的平均发放率:

$$L_{\text{offline}} = \ell\left(\frac{1}{T} \sum_{t=1}^T s^N[t], y\right). \quad (13)$$

这就带来一个问题: instantaneous loss 是否破坏了时间窗口内的整体决策信息? 如果每个时间步都独立要求输出正确, 模型可能无法充分利用跨时间累积的信息, 尤其是在早期时间步输出尚不稳定时, 强行施加监督信号可能引入噪声梯度。

一个可行方案是构造带历史记忆的 online loss。首先可以定义指数滑动平均输出:

$$\bar{s}^N[t] = \beta \bar{s}^N[t-1] + (1 - \beta) s^N[t], \quad (14)$$

并以其作为当前时间步的分类依据:

$$L[t] = \ell(\bar{s}^N[t], y). \quad (15)$$

这种方法仍然满足在线计算, 但比单步 spike 输出保留了更多历史信息。

另一种方案是 confidence-aware loss。可以根据当前时间步预测置信度调整损失权重:

$$L[t] = \alpha_t \ell(s^N[t], y), \quad (16)$$

其中 α_t 可以由输出熵、最大类别概率或 margin 决定。当模型在早期时间步不确定时，降低其损失权重；当输出逐渐稳定时，再增强监督信号。

还可以借鉴 FTRL 风格的正则化思想，引入历史最优权重或历史输出作为约束：

$$\hat{L}[t] = L[t] + \rho \|W - \hat{W}\|^2. \quad (17)$$

其中 $\hat{W}$ 可以来自小时间步预训练模型或历史阶段的累积最优模型。该方向的关键实验是比较 offline loss、instantaneous loss、temporal averaged loss、confidence-aware loss 和 FTRL-style loss，分析不同 loss 设计对在线训练性能和收敛稳定性的影响。

5 关键问题四：surrogate gradient 是否应该动态调整

SNN 的训练依赖 surrogate gradient：

$$\frac{\partial s}{\partial u} \approx \sigma'(u - V_{th}). \quad (18)$$

传统方法通常使用固定 surrogate function，例如 sigmoid surrogate、rectangular surrogate 或 fast sigmoid surrogate。然而，在线学习中的梯度在每个时间步实时产生，固定 surrogate 可能不是最优选择。如果 surrogate 过于尖锐，梯度只在阈值附近有效，可能导致训练不稳定；如果 surrogate 过于平滑，则会带来较大梯度偏差。

因此，可以研究 adaptive surrogate gradient。设 surrogate 的形状由参数 α_t 控制：

$$\frac{\partial s}{\partial u} \approx \sigma'_{\alpha_t}(u - V_{th}), \quad (19)$$

其中 α_t 可以根据膜电位分布、发放率和训练阶段动态调整：

$$\alpha_t = f(\text{Var}(u[t]), r[t], t). \quad (20)$$

这里 $\text{Var}(u[t])$ 表示膜电位方差， $r[t]$ 表示当前 firing rate。直觉上，当膜电位分布远离阈值时，可以使用较宽的 surrogate 来扩大有效梯度区域；当膜电位集中在阈值附近时，可以使用较窄的 surrogate 来提高梯度精度。

实验可以比较 fixed surrogate、time-adaptive surrogate、layer-adaptive surrogate 和 firing-rate-adaptive surrogate。该方向的预期目标是在保持在线训练低内存优势的同时，提高小时间步训练下的稳定性和精度。

6 关键问题五：单一 eligibility trace 是否足以处理长时间依赖

多数在线学习方法使用单一时间轨迹来压缩历史信息。例如 NDOT 中：

$$\hat{a}[t] = e[t - 1] \odot \hat{a}[t - 1] + s[t]. \quad (21)$$

该形式本质上是一阶递推，它能够以常数内存保留历史信息，但可能不足以表达复杂任务中的多时间尺度依赖。例如语音、动作识别和 delayed-response 任务往往需要同时保留短期和长期信息。

一个自然方向是设计 multi-timescale eligibility trace。可以定义多个不同时间尺度的 trace：

$$\hat{a}_m[t] = e_m[t-1] \odot \hat{a}_m[t-1] + s[t], \quad m = 1, \dots, M. \quad (22)$$

最终 trace 由不同时间尺度加权组合：

$$\hat{a}[t] = \sum_{m=1}^M \alpha_m \hat{a}_m[t]. \quad (23)$$

其中 $e_m[t]$ 可以对应不同的泄露因子、不同的动力学估计方式，或不同长度的历史窗口。该方案可以被看作对单一 NDOT trace 的扩展，使模型能够同时捕获短时脉冲模式和长期时序结构。

实验任务应选择对长时间依赖敏感的数据集，例如 SHD、SSC、DVS Gesture、DVS-CIFAR10 或 synthetic delayed-response task。评价指标包括长序列分类精度、trace 数量对性能的影响、计算开销和内存开销。该方向有机会形成 Multi-scale NDOT 或 Multi-timescale Online SNN Learning 方法。

7 关键问题六：在线学习中的权重更新时机如何设计

在线学习并不一定意味着每个时间步都必须立即更新权重。以 NDOT 为例，可以存在实时更新和累积更新两种策略：一种是在每个时间步计算梯度后立即更新权重，另一种是在多个时间步上累积梯度后再更新。二者各有优缺点。实时更新更符合在线学习和神经形态硬件要求，但可能带来梯度噪声和训练不稳定；累积更新更接近 mini-batch 或 offline 训练，稳定性较好，但在线性较弱。

因此，可以研究窗口式更新策略：

$$W[t+1] = W[t] - \eta \sum_{\tau=t-K+1}^t \nabla_W L[\tau]. \quad (24)$$

其中 K 是更新窗口大小。当 $K = 1$ 时，对应完全在线更新；当 $K = T$ 时，对应整个时间窗口累积更新；当 $1 < K < T$ 时，则是在在线性和稳定性之间折中。

实验可以设置 $K \in \{1, 2, 4, T\}$ ，并比较不同更新窗口下的最终精度、收敛速度、梯度方差、实时延迟和硬件写入频率。该研究可以形成一个 practical guideline，即什么任务适合 real-time update，什么任务适合 accumulated update，以及如何选择最优更新周期。

8 关键问题七：在线学习是否真的硬件友好

许多在线学习方法声称 memory efficient 或 hardware friendly，但算法层面的在线性并不等价于硬件上的高效实现。实际部署时还需要考虑 trace 存储、element-wise multiplication、surrogate gradient 计算、空间误差反传通信、权重更新频率以及片上存储容量。

因此，需要建立更完整的硬件成本模型：

$$C_{\text{total}} = C_{\text{mem}} + C_{\text{comm}} + C_{\text{mul}} + C_{\text{update}}. \quad (25)$$

其中 C_{mem} 表示状态和 trace 存储成本, C_{comm} 表示层间和误差信号通信成本, C_{mul} 表示乘法或近似乘法成本, C_{update} 表示权重写入和更新成本。

可以在同一模型规模和任务上比较 BPTT、E-prop、OTTT、NDOT、S-TLLR 和 TESS。评价不应只包括 accuracy, 还应包括能耗、延迟、存储占用、通信量和是否支持片上更新。该方向的潜在贡献是提出更真实的 online hardware efficiency 指标, 避免只从算法复杂度层面判断方法是否适合硬件部署。

9 关键问题八：在线学习能否与完全本地学习统一

当前 SNN 在线学习方法大多仍处于从 BPTT 到局部学习的过渡阶段。OTTT 和 NDOT 主要关注时间维度的在线化, 但仍需要一定形式的空间误差信号; E-prop 使用 eligibility trace 与 learning signal 的分解形式, 但 learning signal 仍可能是全局或半全局的; S-TLLR 和 TESS 则进一步强调 temporal locality 和 spatial locality。

因此, 一个更大的研究问题是: 能否构造统一框架, 将在线学习、eligibility trace、temporal local learning 和 spatial local learning 统一起来? 一个可能的统一形式是:

$$\Delta W^l[t] = \eta \cdot \mathcal{E}^l[t] \cdot \mathcal{L}_{\text{local}}^l[t], \quad (26)$$

其中 $\mathcal{E}^l[t]$ 表示突触或神经元局部可获得的时间轨迹, $\mathcal{L}_{\text{local}}^l[t]$ 表示局部学习信号。该形式可以覆盖 E-prop、NDOT-style trace、STDP-inspired rule 和 TESS-style spatial local signal。

推进方案可以分为三步。第一步, 将不同方法统一写成 trace 与 learning signal 的乘积形式。第二步, 比较不同 trace 对 temporal credit assignment 的表达能力。第三步, 将空间误差信号替换为局部可计算信号, 从而逐步减少对全局反传的依赖。

该方向适合作为综述或理论框架研究, 也可以进一步发展为新的 fully online and fully local SNN learning algorithm。

10 总结

SNN 在线学习的核心挑战可以概括为: 如何在不保存完整时间计算图的情况下, 准确、稳定并且局部地近似 BPTT 梯度。围绕这一目标, 未来可以从多个层面展开研究, 包括时间依赖建模、空间局部误差、在线损失函数、自适应 surrogate gradient、多时间尺度 trace、权重更新策略、硬件成本建模以及在线学习与本地学习的统一框架。

如果从当前 OTTT、NDOT、S-TLLR 和 TESS 的研究脉络出发, 最值得优先推进的方向有三个。第一是分析 $e[t]$ 与 $\epsilon[t]$ 的近似误差, 明确在线时间依赖建模的理论边界。第二是将 NDOT 这类 temporal online 方法与 spatial local learning 结合, 减少对全局反向传播的依赖。第三是设计 multi-timescale eligibility trace, 以提升在线 SNN 对长时间依赖任务的建模能力。

总体来看, SNN 在线学习未来的关键目标可以写为:

$$\boxed{\text{Accurate Temporal Credit Assignment} + \text{Spatial Locality} + \text{Hardware Efficiency}} \quad (27)$$

也就是说，一个理想的在线 SNN 学习算法应当同时具备较高的梯度近似精度、较强的局部性、较低的存储和通信开销，以及在神经形态硬件上实时更新的能力。