

脉冲神经网络在线学习：关键科学问题与研究推进方案

摘要

脉冲神经网络（SNN）凭借其事件驱动、稀疏脉冲通信和生物可解释性，被认为是实现低功耗边缘智能的候选模型。然而，传统的训练算法——尤其是基于时间的反向传播（BPTT）——因需要展开整个时间计算图并存储所有时刻的状态，内存和计算开销随时间步数线性增长，难以在资源受限设备上实现在线学习。近年来，研究者提出了多种在线学习算法，如OTTT、NDOT、S-TLLR和TESS，分别从时序依赖近似、动态核重参数化、STDP启发式资格迹以及本地学习信号生成等角度，实现了与时间步数无关的常数存储复杂度，并在不同程度上降低了计算复杂度。

然而，这些算法仍面临若干根本性挑战：如何在生物合理性与高性能之间取得平衡、如何在存储与计算复杂度之间达到帕累托最优、如何有效应对长期时间依赖、如何与神经形态硬件协同设计，以及如何无缝融合持续学习能力。本文围绕这五个核心问题，结合已有算法的技术特点，提出详细的推进方案，旨在为SNN在线学习的后续研究提供系统性的路线图。

1 引言

脉冲神经网络（Spiking Neural Networks, SNNs）被誉为第三代神经网络，其神经元通过离散脉冲（spikes）进行通信，在神经形态硬件上具有极高的能效。然而，SNN的监督训练长期受困于脉冲发放函数不可微的问题。基于代理梯度的BPTT（Backpropagation Through Time）虽然通过时间展开实现了有效的梯度传播，但其存储和计算成本均与时间步数 T 成正比，无法满足在线学习和边缘部署的需求。

为突破这一瓶颈，近年的研究聚焦于设计“时间本地”或“时空本地”的学习规则。OTTT（Online Training Through Time）通过丢弃时序依赖中的重置路径，将时间传播退化为固定指数衰减，实现 $O(Ln)$ 存储。NDOT（Neuronal Dynamics-based Online Training）进一步用连续动力学推导的动态比值替代固定衰减系数，提升了时序建模精度。S-TLLR（STDP-inspired Temporal Local Learning Rule）引入广义STDP形式的资格迹，融合因果与非因果信息，并依靠反向传播（BP）或直接反馈对齐（DFA）产生学习信号。TESS（Temporally and Spatially Local Learning Rule）则在S-TLLR的基础上，通过本地学习信号生成（LSG）彻底切断了层间误差传播，将时间复杂度从 $O(Ln^2)$ 降至 $O(LCn)$ 。

尽管这些算法取得了显著进展，但从理论到实际部署仍存在多个尚未解决的关键问题。本文从算法设计、复杂度理论、长期依赖建模、硬件协同设计、持续学习融合等维度，提炼出五个核心科学问题，并逐一给出详尽的推进方案，以期为该领域的后续研究提供参考。

2 问题一：如何设计同时具备“生物合理性”与“高性能”的本地学习规则？

2.1 问题背景与现状

生物神经系统依赖局部突触可塑性（如STDP、资格迹）进行学习，无需全局误差反向传播。然而，纯生物启发的方法（如无监督STDP）在复杂任务上性能远不及梯度方法。当前在线学习算法在“生物合理性”与“任务性能”之间存在明显断层：

- 以OTTT、NDOT为代表的算法，本质上是BPTT的近似，虽性能优越，但其学习规则（尤其是代理梯度的使用）缺乏明确的生物学对应。
- 以S-TLLR、TESS为代表的算法，引入了STDP形式的因果/非因果项，更具生物可解释性，但其学习信号的生成仍依赖BP（S-TLLR）或固定随机投影（TESS），与真实的生物机制尚有距离。

此外，S-TLLR中非因果项系数 α_{post} 的最优取值（-1、0、+1）在不同任务上表现迥异，其背后的任务依赖性尚未被系统理解。TESS中固定随机矩阵 $\mathbf{B}$ 的设计虽然硬件友好，但与BPTT相比仍有约1.4%的性能差距（以CIFAR10-DVS为例），如何在不牺牲本地性的前提下缩小这一差距，是一个亟待解决的问题。

2.2 核心研究问题

1. **Q1.1:** 能否建立一个统一的数学框架，将“梯度近似型”（OTTT/NDOT）和“STDP启发型”（S-TLLR/TESS）算法纳入同一形式，并揭示它们之间的等价或互补关系？
2. **Q1.2:** S-TLLR/TESS中的非因果项系数 α_{post} 的最优取值是否与任务的时间结构（如事件密度、脉冲稀疏度）存在确定性关联？能否设计自适应机制，让网络动态调整 α_{post} ？
3. **Q1.3:** TESS中LSG所用的固定随机矩阵 $\mathbf{B}$ 能否被优化（如使用可学习的低秩矩阵、数据驱动的投影或任务相关的正交基），在保持本地性的前提下进一步逼近BPTT的性能？

2.3 推进方案

（1）统一框架构建 从三因子学习规则的一般形式 $\Delta w_{ij} = \sum_t \delta_i[t] e_{ij}[t]$ 出发，分别写出各类算法的 δ 与 e 的显式表达式。分析OTTT/NDOT中的空间梯度 $\mathbf{g}_u$ 与S-TLLR/TESS中的本地学习信号 $\mathbf{v}_m$ 之间的数学关联，以及踪迹 $\hat{\mathbf{a}}$ 、 tr 、 $\mathbf{q}$ 、 $\mathbf{h}$ 之间的转换关系。通过变量代换，证明在特定条件下（如忽略非因果项、令 λ 与 γ 相等），S-TLLR可退化为OTTT；而TESS的LSG可视为对S-TLLR中DFA的一种推广。该统一框架将为后续算法设计提供理论指导。

（2） α_{post} 的自适应机制 设计可学习的参数 $\alpha_{post}^{(l)}$ （可逐层或逐任务自适应），将其与网络输出误差相关联，让网络在训练过程中自主决定因果/非因果项的权重。例如，可将 α_{post} 视为一个可训练标量，通过梯度下降（利用代理梯度）调整，或通过元学习（如MAML）在不同任务上快速适应。同时，设计实验，系统测量不同任务的事件密度、平均发放率、时间相关性等指标，建立 α_{post} 最优值与这些指标之间的经验映射关系。

(3) **B 矩阵的优化** 保留LSG的本地性，但将固定的随机 **B** 替换为任务相关的投影矩阵。考虑以下方案：

- 使用无监督预训练（如PCA）从数据中提取主成分，作为 **B** 的初始值，并在本地学习过程中保持固定，从而在不引入额外反向传播的前提下获得更具判别性的投影。
- 设计可学习的低秩矩阵 $\mathbf{B} = \mathbf{U}\mathbf{V}^\top$ ，其中 **U** 和 **V** 在层内通过本地更新规则调整，但保持层间独立。
- 借鉴神经科学中的“随机突触后投影”理论，使用具有准正交性的确定性序列（如Hadamard矩阵或方波函数）替代随机矩阵，以提升投影的稳定性与表征能力。

3 问题二：如何实现“存储复杂度最优”与“计算精度最优”的帕累托平衡？

3.1 问题背景与现状

如前文所述，现有在线学习算法均实现了 $O(Ln)$ 的存储复杂度，与时间步数 T 完全解耦。然而，时间复杂度差异显著：

算法	存储复杂度	时间复杂度	关键操作
OTTT	$O(Ln)$	$O(Ln^2)$	外积 $\mathbf{g} \cdot \hat{\mathbf{a}}^\top + \text{BP}$
NDOT	$O(Ln)$	$O(Ln^2)$	外积 + BP（动态核仅需逐元素计算）
S-TLLR	$O(Ln)$	$O(Ln^2)$	外积 + BP/DFA (n^2)
TESS	$O(Ln)$	$O(LCn)$	外积 + LSG (Cn)

除TESS外，其余算法的时间复杂度均为 $O(Ln^2)$ ，因为权重更新本身需要计算 $n \times n$ 的外积（这是突触数量决定的“物理极限”）。但TESS通过LSG将空间误差传播从 $O(n^2)$ 降至 $O(Cn)$ ，从而整体上大幅降低了计算量。然而，这一改进是否已触及复杂度下界？是否存在理论上更优的方案？另外，对于不同的任务类型（静态图像 vs. 动态事件流），最优的复杂度-精度折中点可能不同，这需要系统性研究。

3.2 核心研究问题

1. **Q2.1:** 在SNN在线学习中，是否存在一个理论上的“复杂度下界”——即任何算法都必须至少达到的存储和计算复杂度？特别地， $n \times n$ 的外积是否不可避免？
2. **Q2.2:** 能否设计一种算法，在保持 $O(Ln)$ 存储的同时，将时间复杂度也降至 $O(Ln)$ （即与 n^2 完全解耦）？
3. **Q2.3:** 不同任务类型（静态图像分类、动态手势识别、连续语音流）对复杂度-精度权衡的最优点是否不同？能否设计自适应复杂度调节机制？

3.3 推进方案

(1) **复杂度下界的信息论分析** 从信息论视角出发，分析突触权重更新所需的最小计算量。考虑一个具有 n 个输入和 n 个输出的全连接层，其权重矩阵有 n^2 个独立参数。在线学习每个时间步都需要更新这些参数，因此任何算法都至少需要 $O(n^2)$ 次操作来更新所有突触——除非引入结构化

稀疏（如卷积的局部连接）。因此， $O(n^2)$ 可视为“更新所有突触”的固有成本。但我们可以区分“突触更新”和“误差传播”两部分：误差传播可以借助本地信号（如LSG）降为 $O(Cn)$ ，但突触更新本身仍为 $O(n^2)$ 。因此，理论上最优的时间复杂度应为 $O(n^2 + Cn)$ ，当 $C \ll n$ 时即 $O(n^2)$ 。TESS已将误差传播降至 $O(Cn)$ ，但突触更新部分仍是瓶颈。若采用稀疏连接或结构化权重（如卷积），则可进一步降低。

（2）“极致轻量”算法探索 借鉴“符号梯度下降”（sign-based gradient descent）或“伪零阶优化”（pseudo-zero-order optimization）的思想，在更新权重时仅使用权重的符号或等级信息，而非完整浮点数梯度。例如，在TESS框架下，可将LSG产生的学习信号 $\mathbf{v}_m$ 二值化（仅保留正负号），从而将外积计算简化为符号外积，大幅降低计算精度需求，同时可能保持相近性能。此外，可探索“稀疏更新”策略：每时间步仅随机选择一部分突触进行更新，利用随机近似理论保证收敛性。

（3）任务自适应的复杂度调节 设计一个“复杂度旋钮”——即一个超参数或可配置策略，允许用户根据任务需求（延迟限制、能耗预算、精度要求）动态切换算法内部的计算模式。例如：

- 在时间充裕时，使用OTTT/NDOT的完整梯度更新；
- 在资源紧张时，切换至TESS的LSG模式；
- 在极端受限时，启用二值化或稀疏更新模式。

通过在线性能监控，实时调整模式，实现帕累托最优。

4 问题三：如何有效应对“时空信用分配”的长期依赖问题？

4.1 问题背景与现状

在线学习算法依赖踪迹（eligibility trace）机制来解决时间信用分配问题。踪迹本质上是一个指数衰减的低通滤波器，其记忆长度由衰减系数 λ 控制（如OTTT中的 $\lambda^{t-\tau}$ ）。然而，这种固定指数衰减的“有效记忆范围”约为 $1/(1-\lambda)$ ，当时间步数 T 远超此范围时，历史信息将指数级消失，导致长期依赖无法被有效捕捉。此问题在S-TLLR和TESS中同样存在，尽管它们通过非因果项部分缓解了时序建模的局限性，但根源未变。

4.2 核心研究问题

1. **Q3.1:** 现有踪迹机制能否扩展以捕捉更长的时间依赖？是否存在“多时间尺度”踪迹的自然实现？
2. **Q3.2:** 在极端长时依赖任务（如语音序列、导航决策）中，在线学习算法是否必然逊色于BPTT？差距有多大？
3. **Q3.3:** 能否借鉴Transformer的注意力机制，设计一种“注意力踪迹”，让网络动态决定关注哪些历史时刻？

4.3 推进方案

(1) **多尺度踪迹设计** 设计多个不同衰减率的踪迹 ($\lambda_1, \lambda_2, \dots, \lambda_K$), 分别对应短、中、长时间尺度。每个时刻, 网络维护一组踪迹:

$$\hat{a}^{(k)}[t] = \lambda_k \hat{a}^{(k)}[t-1] + s[t], \quad k = 1, \dots, K$$

最终的资格迹为这些多尺度踪迹的加权组合, 权重可以通过学习获得 (例如, 通过一个小的可学习网络或注意力机制)。这样, 网络既保留了短时的精确信息, 又能积累长时的统计信息, 从而应对不同时间尺度的依赖。

(2) **注意力式踪迹** 借鉴Transformer中的自注意力机制, 设计“踪迹注意力”模块。在每个时间步, 计算当前时刻与过去若干个关键时刻的相关性分数, 然后加权融合历史信息。具体而言, 可维护一个固定长度的“记忆缓冲区” (例如最近 M 个时刻的脉冲), 并利用可学习的查询、键、值向量计算注意力权重, 从而动态决定哪些历史时刻对当前更新最重要。虽然这会引入额外的计算开销, 但可显著改善长期依赖建模能力。

(3) **长时依赖基准实验** 设计一组具有不同时间依赖长度的任务 (如合成序列任务、语音命令识别、机器人导航), 在这些任务上系统评估OTTT、NDOT、S-TLLR、TESS以及BPTT的性能。测量各算法在不同时间步长下的精度衰减曲线, 明确当前在线学习算法的“长时依赖极限”。实验应包括对 λ 超参数的大规模扫描, 以揭示衰减系数与任务时间结构之间的匹配规律。

5 问题四：如何实现“片上学习”的硬件-算法协同设计？

5.1 问题背景与现状

SNN在线学习的终极应用场景是神经形态芯片上的片上学习 (on-chip learning)。然而, 当前算法设计大多基于通用处理器 (GPU) 的抽象计算模型, 忽略了神经形态硬件的物理约束: 低精度定点数运算、有限的片上存储 (SRAM)、稀疏脉冲驱动的事件型计算。算法与硬件之间的这种“语义鸿沟”导致即便算法复杂度在理论上很低, 实际部署时仍可能面临巨大的效率和精度损失。

5.2 核心研究问题

1. **Q4.1:** 在硬件约束 (如8位定点数、无乘法器、存储受限) 下, OTTT/NDOT/S-TLLR/TESS中哪一个最容易实现? 哪一个精度损失最小?
2. **Q4.2:** 能否设计一种“硬件原生”的在线学习算法——其基本操作与神经形态硬件的原生指令集完全对齐 (如脉冲累积、移位操作、表查找)?
3. **Q4.3:** 如何将TESS中的随机矩阵 $\mathbf{B}$ 在芯片上高效实现, 而不消耗大量存储资源?

5.3 推进方案

(1) **硬件-算法联合仿真平台** 构建一个模拟神经形态芯片硬件约束的仿真框架 (如基于PyTorch的量化仿真工具), 支持自定义位宽、存储容量、计算精度等参数。在该平台上实现OTTT、NDOT、S-TLLR、TESS, 运行统一基准测试, 量化不同硬件约束下的精度损失和资源占用。通过该平台, 可以识别各算法对硬件最敏感的部分 (如S-TLLR的BP信号传播中的矩阵乘法对精度要求高; TESS的LSG则相对鲁棒)。

(2) “脉冲驱动” 算法重设计 重新审视算法中的每一步操作，将其映射为“脉冲驱动”的硬件友好操作：

- 踪迹更新 $\hat{a}[t] = \lambda \hat{a}[t-1] + s[t]$ ：在硬件上可通过移位加法和累加实现（ λ 可取 2^{-k} ，则乘法变为移位）。
- 权重更新 $\Delta W = \mathbf{v}_m \otimes \mathbf{q}$ ：可分解为外积，但若采用二值化或稀疏化，可将乘法简化为逻辑运算。
- 学习信号生成（LSG）： $\mathbf{Bo}$ 可通过固定随机连接（硬件布线）实现，无需存储完整矩阵。

重点优化S-TLLR中的BP传播，因其涉及浮点矩阵乘法，可考虑用DFA替代BP以降低硬件开销。

(3) **B 矩阵的硬件化存储** 利用神经形态芯片中已有的随机连接资源（如Loihi中的突触随机投影功能），将 $\mathbf{B}$ 矩阵实现为芯片上的固定随机连接，而非存储在内存中。这样， $\mathbf{B}$ 的存储成本降为 $O(1)$ ，同时投影操作可通过事件驱动的脉冲传播自然完成。若芯片不支持随机连接，则可采用伪随机数发生器在运行时即时生成投影系数，从而避免存储开销。

6 问题五：在线学习如何与“持续学习”无缝融合？

6.1 问题背景与现状

在线学习通常假设数据来自同一分布（即任务不变），而**持续学习（Continual Learning）**要求模型在面对新任务时，不遗忘旧任务的知识。SNN的在线学习能力天然适合持续学习场景，因为数据是流式到达的。然而，现有在线学习算法几乎都未考虑任务边界，也无防止灾难性遗忘的机制。当任务发生切换时，权重会被新任务的数据迅速覆盖，导致旧任务性能急剧下降。

6.2 核心研究问题

1. **Q5.1:** OTTT/NDOT/S-TLLR/TESS在面对任务切换时，遗忘率如何？哪种算法对连续任务更鲁棒？
2. **Q5.2:** 能否将现有的持续学习策略（如弹性权重巩固EWC、突触巩固）无缝集成到在线学习的踪迹更新过程中，而无需额外的反向传播？
3. **Q5.3:** 能否设计一个“睡眠-觉醒”两阶段框架：觉醒时快速在线学习新知识，睡眠时通过重放或生成式模型巩固记忆，同时不额外消耗大量资源？

6.3 推进方案

(1) **持续学习基准测试** 选择标准持续学习基准数据集（如Split CIFAR-100、Permuted MNIST），在这些数据集上评估四种在线学习算法的遗忘率（即新任务学习后旧任务精度的下降幅度）。同时对比BPTT结合传统持续学习策略（如EWC、LwF）的性能，以建立性能标杆。重点分析各算法在“任务增量”和“类增量”两种场景下的表现差异。

(2) “巩固踪迹” 机制 在现有踪迹更新中引入“巩固项”。借鉴EWC的思想，为每个突触维护一个重要性权重 Ω_{ij} ，该权重衡量该突触对已学任务的贡献度。在更新资格迹时，加入惩罚项，使得重要性高的突触在后续学习中变化更慢。具体地，可将更新公式修改为：

$$\Delta w_{ij} = \rho \sum_t \delta_i[t] e_{ij}[t] \cdot (1 - \eta \cdot \Omega_{ij})$$

其中 η 为巩固强度系数， Ω_{ij} 可通过任务结束后计算Fisher信息矩阵的迹来估计，或在每次更新中通过梯度平方的移动平均在线估计。这样，在不引入额外反向传播的情况下，实现了对关键突触的保护。

(3) “睡眠-觉醒” 两阶段框架 设计两阶段学习策略：

- **觉醒阶段：**使用TESS（因其实时性好）对当前数据流进行快速本地学习，实时更新权重。
- **睡眠阶段：**在设备空闲时（如夜间或低负载时段），启动“巩固过程”。这一过程可通过重放存储的少量典型样本（或由生成模型合成的伪样本）来重新激活旧任务，并使用相同的TESS规则进行少量额外训练，但此时学习率降低，同时开启巩固项（如上述 Ω_{ij} 的作用）。此外，可探索使用生成式模型（如GNN）在睡眠阶段生成重放样本，以避免存储大量历史数据。

该框架将在线学习的“快速性”与持续学习的“稳定性”有机分离，有望在不显著增加在线计算开销的前提下，大幅提升对旧任务的保留能力。

7 结论

本文围绕脉冲神经网络在线学习的核心挑战，提炼了五个关键科学问题：生物合理性与高性能的平衡、复杂度-精度的帕累托优化、长期时间依赖建模、硬件-算法协同设计、以及在线学习与持续学习的融合。针对每个问题，我们分析了现有算法（OTTT、NDOT、S-TLLR、TESS）的技术特点与不足，并提出了详细的推进方案。这些方案既包含理论基础（如统一框架、信息论下界），也包含工程实践（如硬件仿真、自适应机制），构成了一套系统性的研究路线图。

未来的研究可以沿着上述方向深入：一方面，从理论上探索在线学习算法的能力边界；另一方面，在实际边缘设备和神经形态芯片上验证算法的有效性。我们相信，随着这些问题的逐步解决，SNN在线学习将真正从学术研究走向实用部署，为低功耗智能系统提供有力的算法支撑。