

脉冲神经网络（SNN）训练中的信息丢失与恢复： 中文汇总与研究思路

Tao

摘要

本文基于仓库中 ‘Algorithm/’ 目录下的 8 份 PDF 文献，采用 Python 程序将其转化为纯文本，并在 Work_Copilot/snn_info_summary_cn.tex 中完成中文汇总。本文包括：(1) 现有 SNN 算法的主要机制与信息丢失环节；(2) 常用“模糊边界/近似”技术的作用机理；(3) 可量化指标与恢复机制；(4) 基于当前证据的研究思路与后续计划。

I. 高层概要（概括性结论）

- SNN 训练中信息丢失主要来自离散化（阈值/重置）、时间截断（窗口化/衰减）、局部化近似（资格迹或随机反馈）、以及替代梯度导致的梯度偏差。
- 常用缓解手段包括替代梯度（surrogate）、资格迹（三因子规则）、随机/固定反馈近似、以及 ANN→SNN 的软化映射；这些方法通常以牺牲精确度为代价换取可训练性与在线/低内存实现。
- 信息丢失可以用互信息、重建误差、Spike-timing 距离、Fisher 信息近似等多维指标量化；区分“压缩”与“不可逆丢失”需要基于最优解码器的可恢复性测试。
- 恢复策略可发生在训练内（资格迹、动态阈值、潜变量推断）、训练后（强解码器、时间重采样、生成式重建）或利用约束反向估计（把截断梯度视为 Fisher 近似用于校正）。

II. 方法族与仓库覆盖

- 1) BPTT（完整反向传播通过时间）：基线，能精确分配时间信用，但需 $O(T)$ 内存且存在梯度消失/爆炸问题。
- 2) 三因子/资格迹类（S-TLLR、TESS）：局部在线规则，使用资格迹 $e_{ij}[t]$ 与学习信号 $\delta_i[t]$ 的乘积更新权重，适合在线学习和低内存场景。
- 3) 事件驱动/在线近似类（OTTT、NDOT）：本仓库包含这两类方法的论文，侧重前向时间学习与常数训练记忆 [1], [2].
- 4) 替代梯度家族（surrogate gradient）：通过平滑不可导阶跃激活恢复梯度信息流；NDOT/OTTT 文本中均提及该技术 [2].
- 5) ANN→SNN 转换：率或延迟编码替代连续激活，通常丢失单脉冲时序细节，为对比基线提供分析视角。

III. 导致信息丢失的具体环节（分类与机理）

A. 时间维度

- 时间量化与采样间隔：采样步长 dt 决定可表示的频带，粗采样会丢失高频时间信息。
- 资格迹的衰减：以指数衰减形式近似长期依赖，导致远期事件对当前学习信号的影响被模糊化。
- 截断 BPTT 或在线近似：当仅利用有限历史或即时损失时，超出窗口的时间贡献被舍弃。

B. 空间/表示维度

- 局部更新：三因子规则和本地学习规则仅利用局部可用信号，无法完整表达跨层全局梯度结构。
- 量化/稀疏化：为节省带宽和能耗，对膜电位、权重或脉冲进行量化，会丢失连续幅值信息。

C. 梯度与优化维度

- 替代梯度的失真：用连续代理函数近似阶跃函数导数时，会改变梯度幅值和二阶特性，但保留方向信息的主体。
- 近似反馈：如随机反馈或反馈对齐用近似梯度方向替代精确反向传播，会引入方向噪声。

D. 离散非线性截断

- 硬阈值和完全重置使膜电位信息在放电后不可逆丢失，这类似于对连续信号的非可逆量化。

IV. “模糊边界/近似”技术与信息恢复机理

leftmargin=*

1) 替代梯度（surrogate gradient）

- 机理：用可导函数替代 Heaviside 的导数，使误差能够传播回脉冲生成模块。
- 信息影响：恢复梯度方向信息，减少不可导引起的零梯度问题；但幅值和高阶信息仍可能失真。

2) 资格迹与三因子规则

- 机理：利用递推变量记录前后脉冲相关性，并用学习信号调制，保留历史时序统计。
- 信息影响：在有限记忆下保留时序相关，但对远期或高频信息存在衰减。

3) 本地学习/反馈近似

- 机理：以固定随机矩阵或局部学习信号替代层间反向传播，降低空间复杂度。
- 信息影响：保留误差信号的粗粒度流动，可训练性增强，但精确梯度空间结构部分丢失。

4) ANN→SNN 软化映射

- 机理：通过平均率或时间延迟将连续激活映射到脉冲，以平滑离散化误差。
- 信息影响：保留整体信息量，但丢失单脉冲级别时间细节。

V. 可量化指标建议

- 互信息 $I(X; S)$: 输入与脉冲序列之间的信息上限，反映可恢复性。
- Fisher 信息与其近似: 衡量参数变化对输出的敏感度，可用于评估梯度近似带来的信息损失。
- 重建误差 (MSE/SNR): 训练解码器从 spikes 恢复原始信号，直接衡量实际可恢复信息。
- Spike-timing 距离: 如 Victor–Purpura、van Rossum，用于时序抖动的量化。
- 活动统计: 发放率、脉冲覆盖度、熵、有效秩，衡量表征空间的富集程度。
- 任务性能: 分类/回归精度作为间接信息保留指标。

VI. 信息恢复机制（训练内/训练后/约束反向）

A. 训练阶段内恢复

- 资格迹和三因子规则 (S-TLLR、TESS): 在线记录时序相关，作为梯度近似的记忆载体。
- 动态阈值与软重置: 降低硬阈值的不可逆效应，保留膜电位残余信息。
- 潜在变量推断: 将膜电位视为隐变量，通过后验推断补偿观测脉冲带来的信息损失。
- 增强 surrogate 设计: 用更精细的近似函数保持更多梯度细节。

B. 训练阶段后恢复

- 强解码器/群体解码: 用并行神经元的冗余信息恢复细节。
- 时间重采样和插值: 基于先验在离散脉冲间补偿高频成分。
- 生成式恢复: 用生成模型或扩散模型从脉冲恢复连续信号。
- 多脉冲/多位宽扩展: 通过增加脉冲载体提高信息容量。

C. 约束反向恢复

- 将截断梯度或替代梯度视为 Fisher 信息的粗估，用于优化器的自适应预条件或不确定性估计。
- 变分框架: 直接在观测与隐变量间推断，重建被丢弃的连续状态。

VII. ALGORITHM 论文汇总与证据

A. 转换结果

已将 Algorithm/ 下 8 个 PDF 文献转换为文本，保存在 Algorithm/converted_texts/ 下，便于逐页检索与内容摘录。

B. *NDOT*

- 论文名: ‘NDOT: Neuronal Dynamics-based Online Training for Spiking Neural Networks’，并包含一个 bilinear 版本 [1].
- 关键点: 全梯度分解为时间梯度和空间梯度，使用神经元动力学连续信息实现前向时间训练；强调在线性和常数内存开销。
- 术语: 包含 surrogate gradient、online training、temporal gradient、spatial gradient；未直接使用“信息丢失”。

C. OTTT

- 论文名：‘Online Training Through Time for Spiking Neural Networks’ [2].
- 关键点：通过跟踪 presynaptic activity 及瞬时损失，实现前向时间学习；证明 OTTT 与 spike representation 梯度具有类似下降方向，并提出三因子 Hebbian 更新形式。
- 术语：强调 online learning、surrogate gradient、equivalent mapping、three-factor Hebbian；未直接使用“信息丢失”。

D. S-TLLR

- 论文名：‘S-TLLR: STDP-inspired Temporal Local Learning Rule for Spiking Neural Networks’ [3].
- 关键点：STDP 灵感的时间局部三因子学习规则，兼顾因果与非因果时序关系，内存复杂度与时间步数无关。
- 术语：强调 local learning、eligibility traces、temporal locality；当前文本未直接提及“信息丢失”。

E. TESS

- 论文名：‘TESS: A Scalable Temporally and Spatially Local Learning Rule for Spiking Neural Networks’ [4].
- 关键点：实现时间局部与空间局部，使用本地信号和同步学习信号，避免跨层误差反向传播；内存复杂度与时间步数无关。
- 术语：强调 temporally local、spatially local、eligibility traces、local learning signal；未直接使用“信息丢失”。

F. 当前证据与缺失

- 当前转换文本中可直接确认的主要内容：online training、surrogate gradient、eligibility trace、local learning、constant memory、three-factor update 等。
- 但从文本检索结果来看，论文中尚未直接明确出现“information loss”或“信息丢失”的术语。
- 因此，本报告的“信息丢失与恢复”分析需进一步结合具体段落或作者原话进行补充验证。

VIII. 研究思路与后续计划

A. 候选算法族

- 替代梯度类型：BPTT+SG 基线与其在线改进（NDOT、OTTT）。
- 事件驱动在线局部类型：S-TLLR、TESS，关注资格迹和本地学习信号的时间/空间信息保留。
- ANN→SNN 类型：用于对比离散化与时间信息丢失。

B. 建议实验设计

- 任务：输入噪声控制的信号重建、事件流分类、CIFAR10-DVS、IBM DVS Gesture。
- 变量：时间步长、噪声强度、eligibility decay、surrogate 形状、在线/离线训练、网络冗余度。
- 指标：重建 MSE/SNR、互信息估计、Spike-timing 距离、脉冲活动覆盖度、分类精度。
- 区分压缩与丢失：若强解码器能恢复信号则更接近压缩；若不可恢复且互信息下降则判定为信息丢失。

C. 可能的新方向

- 变分推理：把膜电位建模为隐变量，利用后验恢复丢弃的连续内容。
- 扩散/生成式模型：从脉冲序列恢复高频时间信息。
- 记忆重放与历史事件回放：补偿在线近似带来的长期依赖缺失。

结论

本次工作已完成：

- 在 Algorithm/ 下建立 Python 工作区，生成 convert_pdfs.py。
- 将 8 份 PDF 转换为文本，保存在 Algorithm/converted_texts/。
- 在本 LaTeX 文档中按 ‘NDOT’、‘OTTT’、‘S-TLLR’、‘TESS’ 进行中文汇总，并注明当前证据与缺失。

后续建议：请继续提供具体摘要或关键段落，将根据这些原文进一步补充“信息丢失”、“恢复机制”和“定量指标”的精确引用。

参考文献

- [1] H. Jiang, G. D. Masi, H. Xiong, and B. Gu, “NDOT: Neuronal dynamics-based online training for spiking neural networks,” in *Forty-first International Conference on Machine Learning*, 2024. [Online]. Available: <https://openreview.net/forum?id=eIF0QoBSFV>
- [2] M. Xiao, Q. Meng, Z. Zhang, D. He, and Z. Lin, “Online training through time for spiking neural networks,” *Advances in neural information processing systems*, vol. 35, pp. 20 717–20 730, 2022.
- [3] M. P. E. Apolinario and K. Roy, “S-tllr: Stdp-inspired temporal local learning rule for spiking neural networks,” *arXiv preprint arXiv:2306.15220*, 2023.
- [4] M. P. Apolinario, K. Roy, and C. Frenkel, “Tess: A scalable temporally and spatially local learning rule for spiking neural networks,” in *2025 International Joint Conference on Neural Networks (IJCNN)*. IEEE, 2025, pp. 1–9.