

SNN中的时间步及其训练机制

Tao

I. SNN中的时间步及其训练机制

对于传统人工神经网络（ANN）而言，训练过程主要围绕样本、批次（Batch）和训练轮数（Epoch）展开。当训练集中的所有样本被完整遍历一次时，称为一个Epoch。如果一个模型训练了100个Epoch，则表示整个数据集被重复学习了100次。在这种情况下，神经元的计算仅发生在单次前向传播和反向传播过程中，并不存在显式的时间维度。

与ANN不同，脉冲神经网络（Spiking Neural Network, SNN）引入了时间维度。对于同一输入样本，网络并不会立即得到最终输出，而是需要在多个离散时间步（Time Step）上进行动态演化。假设时间步长度为 T ，则网络需要经历 $t = 1, 2, \dots, T$ 个时刻的状态更新后，才能形成最终输出。因此，Epoch和Time Step描述的是两个完全不同的概念。Epoch表示整个数据集被重复训练的次数，而Time Step表示单个样本在网络内部持续演化的时间长度，两者相互独立，可以分别进行设置。

在SNN中，每一个时间步都会更新神经元的内部状态。以最常见的LIF（Leaky Integrate-and-Fire）神经元为例，其膜电位更新过程可以表示为

$$V[t+1] = \lambda V[t] + I[t] - V_{th}S[t], \quad (1)$$

其中 $V[t]$ 表示时刻 t 的膜电位， $I[t]$ 表示输入电流， $S[t]$ 表示神经元是否发放脉冲， V_{th} 表示发放阈值， λ 表示漏电系数。随着时间推进，神经元不断接收输入脉冲并积累膜电位。当膜电位超过阈值时，神经元产生输出脉冲并进行复位。因此，在每个时间步中都会发生神经元状态的变化，包括膜电位更新、脉冲产生以及其他可能存在的辅助状态变量更新。

需要特别区分的是，神经元状态更新并不等同于网络权重更新。许多初学者容易误认为每经过一个时间步就会更新一次权重，但实际上这取决于具体采用的训练算法。在目前最主流的BPTT（Backpropagation Through Time）和STBP（Spatio-Temporal Backpropagation）训练框架中，时间步内只进行神经元状态更新，而网络权重在整个时间序列结束后才统一更新。具体而言，对于一个长度为 T 的样本序列，网络首先完成从 $t = 1$ 到 $t = T$ 的全部状态演化，并保存每个时间步产生的膜电位和脉冲信息。随后计算损失函数，再通过时间展开后的计算图进行反向传播，最终得到参数梯度并更新权重。因此，在BPTT框架下，权重在整个时间序列期间保持不变，而只有神经元状态随着时间不断变化。

这种训练方式带来了一个重要问题，即必须保存所有时间步的中间状态信息。例如，需要存储

$$V[1], V[2], \dots, V[T] \quad (2)$$

以及

$$S[1], S[2], \dots, S[T] \quad (3)$$

等变量，以便后续计算梯度。因此，当时间步数量增加时，所需存储的中间状态也会同步增加，显存开销近似与时间步长度成线性关系，即

$$\text{Memory} = O(T). \quad (4)$$

这也是为什么近年来许多高性能SNN工作都在努力减少所需时间步数，希望仅通过4至6个时间步就获得接近传统ANN的分类精度，从而降低训练和推理成本。

与BPTT不同，在线学习（Online Learning）方法试图在时间维度上即时完成学习。例如e-prop、OTTT、TESS等方法都希望避免完整的时间展开过程。当网络运行到某个时间步时，不仅更新神经元状态，同时根据当前误差信息立即修正权重参数。因此，在这类方法中，权重和神经元状态都可能随着时间不断变化。其核心思想是在保证学习性能的前提下，减少对历史状态的存储需求，从而更符合生物神经系统的工作机制，也更适合神经形态芯片上的片上学习实现。

综上所述，SNN中的时间步并不是类似Epoch那样的训练次数，而是描述神经元动态演化过程的时间维度。在每个时间步中，神经元状态都会发生变化；而权重是否更新，则取决于具体采用的学习算法。对于BPTT和STBP而言，时间步内只更新神经元状态，在整个时间序列结束后统一更新权重；而对于e-prop、OTTT等在线学习方法，则可以在时间步内同步完成状态更新和权重更新。正是由于时间维度的引入，SNN训练不仅需要考虑空间上的网络结构，还需要考虑时间上的动态依赖关系，这也是其与传统ANN最本质的区别之一。

II. 输入编码方式对时间步的影响

在SNN中，输入编码方式会直接影响所需时间步长度。由于SNN通常以脉冲序列而非连续实值作为信息传递形式，因此同一个静态输入样本需要先被转换为时间维度上的脉冲活动。不同编码方式对时间步数量的依赖程度不同。

最常见的是频率编码（Rate Coding）。在频率编码中，输入强度通常被表示为一定时间窗口内的脉冲发放频率。例如，像素值越大，对应神经元在 T 个时间步内产生脉冲的概率或频率越高。由于频率估计需要在一段时间内统计脉冲数量，因此该方法通常依赖较长的时间步。当 T 较小时，脉冲数量过少，输入信息表达不充分，可能导致分类精度下降。

另一类方法是延迟编码（Latency Coding）。在延迟编码中，输入强度不再主要通过脉冲数量表示，而是通过首次脉冲出现的时间表示。通常输入越强，神经元越早发放脉冲；输入越弱，神经元越晚发放脉冲，甚至不发放脉冲。相比频率编码，延迟编码能够用较少的脉冲表达输入信息，因此在理论上更适合低时间步SNN。然而，延迟编码对时间顺序较为敏感，若时间窗口过短，可能无法充分区分不同输入强度。

近年来，许多低时间步SNN工作更倾向于采用直接编码（Direct Coding）或混合编码方式。直接编码通常不再将输入显式转换为随机脉冲序列，而是将连续输入电流直接送入第一层脉冲神经元，由神经元自身的膜电位动态完成信息转换。这种方式减少了输入阶段的信息损失，也避免了频率编码对长时间窗口的依赖，因此更适合 $T = 2, 4, 6$ 等低时间步场景。

因此，输入编码方式与时间步长度之间存在紧密关系。频率编码通常需要较大的 T 来稳定表达输入强度；延迟编码可以减少脉冲数量，但对时间精度要求较高；直接编码则更适合低时间步训练，能够在较短时间内保留更多原始输入信息。在实际设计SNN模型时，时间步长度的选择不能脱离输入编码方式单独考虑。

III. 低时间步SNN的优化方法

低时间步SNN的核心目标是在较短的时间窗口内获得足够强的特征表达能力，从而降低训练显存、计算量和推理延迟。由于时间步减少后，神经元可积累的信息变少，脉冲活动也更加稀疏，因此模型往往更难训练。为了解决这一问题，研究者通常从神经元模型、网络结构、训练方法和知识迁移等方面进行优化。

首先，可以改进神经元模型，使其在少量时间步内具有更强的信息表达能力。传统LIF神经元主要依赖膜电位随时间逐步积累输入，当 T 较小时，膜电位可能尚未充分积累便结束推理过程，导致输出脉冲不足。因此，一些方法会引入可学习的膜时间常数、可学习阈值或自适应复位机制，使神经元能够根据任务自动调整动态特性。这样可以提高神经元在短时间窗口内的响应能力。

其次，可以通过改进训练策略缓解低时间步下的梯度传播困难。SNN中的脉冲发放函数不可导，通常需要使用替代梯度（Surrogate Gradient）进行近似训练。在低时间步场景下，脉冲数量更少，梯度信号更稀疏，因此合适的替代梯度函数、阈值初始化和膜电位归一化策略非常重要。通过稳定膜电位分布，可以减少神经元过度沉默或过度发放的问题，使网络更容易收敛。

第三，可以利用ANN到SNN的知识迁移方法提高低时间步性能。传统ANN具有成熟的训练方法和较高的精度，因此可以先训练一个高性能ANN模型，再将其结构或参数迁移到SNN中。常见方法包括权重转换、特征蒸馏和输出蒸馏等。通过让SNN学习ANN的中间特征或最终预测分布，可以弥补低时间步下信息积累不足的问题，使SNN在较少时间步内获得接近ANN的分类能力。

此外，网络结构设计也会影响低时间步SNN的表现。例如，引入残差连接、归一化层、注意力机制或更适合脉冲特征传播的模块，可以改善深层SNN中的信息流动问题。残差结构能够缓解深层网络训练困难，使脉冲特征在层间更稳定地传播；注意力机制则可以增强关键时间步或关键通道的特征响应，从而提高短时间窗口内的信息利用效率。

综上，低时间步SNN优化的关键在于提高单位时间步内的信息表达效率。通过采用直接编码、改进神经元动态、优化替代梯度训练、引入知识蒸馏以及设计更稳定的网络结构，SNN可以在较少时间步下保持较高精度。这对于降低推理延迟、减少能耗以及推动SNN在边缘设备和神经形态硬件上的应用具有重要意义。